

局部最小值与鞍点

李宏毅《机器学习》2025 · 类神经网络训练不起来怎么办
(一)



基于李宏毅老师课程整理

2026 年 6 月 4 日

视频信息

频道: 李宏毅深度学习课堂 (Bilibili 搬运)

时长: 约 34 分钟

链接: <https://www.bilibili.com/video/BV1TAtwzTE1S?p=4>

目录

1 引言：当 gradient 很小，训练就停了	3
1.1 Critical Point：梯度为零的点	3
1.2 为什么一定要区分 local minima 与 saddle point	3
2 如何判断 critical point 的类型	4
2.1 Taylor Series Approximation（泰勒级数近似）	5
2.2 在 critical point：只剩 Hessian 项	6
2.3 用 $\mathbf{v}^T H \mathbf{v}$ 判定三种情形	6
2.4 捷径：直接看 Hessian 的特征值	7
3 一个具体例子：史上最废的 network	7
3.1 模型与资料	7
3.2 求梯度 $\mathbf{g}$ ，定位 critical point	8
3.3 求 Hessian H ，算特征值	8
4 不要怕 saddle point：Hessian 指出逃生方向	8
4.1 逃离原理：沿负特征值的特征向量走	9
4.2 回到例子：沿 $\mathbf{u} = [1, 1]^T$ 逃离	10
5 Saddle Point 还是 Local Minima 更常见？	10
5.1 高维直觉：魔法师 Diorena 的故事	11
5.2 error surface 同理：维度越高，路越多	12
5.3 Empirical Study：local minima 确实罕见	13
6 总结与延伸	14
6.1 诊断流程复盘	14
6.2 核心要点提炼	15
6.3 下一讲预告	15

1 引言：当 gradient 很小，训练就停了

承接上一节的攻略：当训练资料上的 loss 很大、又排除了 Model Bias 之后，问题就出在 **Optimization 失败**——gradient descent 没能找到那组好参数。这一节专门讨论：**optimization 为什么会失败，以及失败时该怎么办。**

本节的定位

这一节只关心 optimization 本身，与 overfitting 没有太大关联。我们讨论的是：随着参数不断 update，training loss 不再下降、却仍不令人满意（甚至一开始就 train 不起来），这时到底发生了什么、又能怎么补救。

1.1 Critical Point：梯度为零的点

一个常见的猜想是：训练之所以停下来，是因为参数走到了一个**对 loss 的微分为零**的地方。梯度一旦为零，gradient descent 就再也无法更新参数，training 随之停滞，loss 自然不再下降。

讲到“梯度为零”，大多数人脑海里最先浮现的就是 **local minima**（局部最小值）。坊间常有一种说法：“做 deep learning 会卡在 local minima，所以 gradient descent 不 work、deep learning 不行。”

千万别张口就说“卡在 local minima”

如果你要写 deep learning 相关的论文，**千万不要轻易断言“卡在 local minima”**，否则会显得非常没有水准。原因很简单：**不是只有 local minima 的梯度才为零**。鞍点（saddle point）的梯度同样是零。

因此，对于这些梯度为零的点，应统称为 **Critical Point（临界点）**。你可以说“loss 降不下去也许是卡在了某个 critical point”，但**不能武断地说是卡在 local minima**。

什么是 Saddle Point（鞍点）

Saddle point 是指：梯度为零，但**既不是 local minima、也不是 local maxima**的点。在下图右侧的例子里，红点沿某个方向看是“谷底”（左右方向更高），沿另一个方向看却是“山顶”（前后方向更低），形状像一个**马鞍**，故称鞍点。

1.2 为什么一定要区分 local minima 与 saddle point

区分这两者非常关键，因为它们的“处境”完全不同：

Optimization Fails because




图 1: Optimization 失败时, gradient 接近零, 参数卡在 critical point。critical point 有两种: **local minima** (左, 四周都高, “No way to go”, 无路可走) 与 **saddle point** (右, 旁边仍有更低处, 可以 “escape” 逃离)。当务之急是判断 “Which one?”

- 卡在 **local minima**: 四周的 loss 都比当前位置高, 你已身处附近的最低点, 真的无路可走。
- 卡在 **saddle point**: 旁边还有让 loss 更低的方向, 只要能逃离鞍点, 就有机会继续把 loss 降下去。

所以, 当训练停在一个 critical point 时, 它究竟是 **local minima** 还是 **saddle point**, 是一个非常值得探讨的问题——答案直接决定了我们还有没有救。

2 如何判断 critical point 的类型

要判断一个 critical point 是哪种类型, 就需要知道 loss function 在该点附近的“地貌”。network 极其复杂, 我们无法写出整个 loss function 的完整形状, 但在给定参数 θ' 的邻域内, 可以用泰勒级数把它近似出来。

2.1 Taylor Series Approximation (泰勒级数近似)

手书体文字 Lala

Taylor Series Approximation

$L(\theta)$ around $\theta = \theta'$ can be approximated below

$$L(\theta) \approx L(\theta') + \boxed{(\theta - \theta')^T \mathbf{g}} + \boxed{\frac{1}{2} (\theta - \theta')^T \mathbf{H} (\theta - \theta')}$$

Gradient $\mathbf{g}$ is a vector

$$\mathbf{g} = \nabla L(\theta') \quad g_i = \frac{\partial L(\theta')}{\partial \theta_i}$$

Hessian $\mathbf{H}$ is a matrix

$$H_{ij} = \frac{\partial^2}{\partial \theta_i \partial \theta_j} L(\theta')$$




图 2: $L(\theta)$ 在 $\theta = \theta'$ 附近的泰勒近似: 常数项 $L(\theta')$ 、一次项 (绿框, 含 Gradient $\mathbf{g}$)、二次项 (红框, 含 Hessian $\mathbf{H}$)。 $\mathbf{g}$ 是向量 (一次微分), $\mathbf{H}$ 是矩阵 (二次微分)。

在 θ' 附近, loss function 可近似为:

$$L(\theta) \approx L(\theta') + (\theta - \theta')^T \mathbf{g} + \frac{1}{2} (\theta - \theta')^T \mathbf{H} (\theta - \theta')$$

三项的含义:

- 第一项 $L(\theta')$: 当 θ 与 θ' 很近时, $L(\theta)$ 应与 $L(\theta')$ 接近。
- 第二项 (Gradient 项): $\mathbf{g} = \nabla L(\theta')$ 是梯度向量 (一次微分), 其第 i 个分量为

$$g_i = \frac{\partial L(\theta')}{\partial \theta_i}$$

它弥补 θ' 与 θ 之间的一阶差距。

- 第三项 (Hessian 项): $\mathbf{H}$ 是 Hessian 矩阵 (二次微分), 其第 i 行第 j 列的元素为

$$H_{ij} = \frac{\partial^2}{\partial \theta_i \partial \theta_j} L(\theta')$$

它在一次项之外, 进一步补足与真实 $L(\theta)$ 的二阶差距。

2.2 在 critical point: 只剩 Hessian 项

critical point 处梯度为零, 地貌由 Hessian 决定

在 critical point, $\mathbf{g} = \mathbf{0}$ (零向量), 泰勒展开的绿色一次项整项消失, 只剩下:

$$L(\boldsymbol{\theta}) \approx L(\boldsymbol{\theta}') + \frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\theta}')^T H (\boldsymbol{\theta} - \boldsymbol{\theta}')$$

于是, $\boldsymbol{\theta}'$ 附近的地貌完全由 Hessian 项决定。判断它是 local minima、local maxima 还是 saddle point, 就看这一项的正负。

为了书写方便, 记 $\mathbf{v} = \boldsymbol{\theta} - \boldsymbol{\theta}'$, 则需要考察的就是 $\mathbf{v}^T H \mathbf{v}$ 的符号。

2.3 用 $\mathbf{v}^T H \mathbf{v}$ 判定三种情形

At critical point:

Hessian $L(\boldsymbol{\theta}) \approx L(\boldsymbol{\theta}') + \frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\theta}')^T H (\boldsymbol{\theta} - \boldsymbol{\theta}')$

For all $\mathbf{v}$

$$\mathbf{v}^T H \mathbf{v} > 0 \implies \text{Around } \boldsymbol{\theta}': L(\boldsymbol{\theta}) > L(\boldsymbol{\theta}') \implies \text{Local minima}$$

For all $\mathbf{v}$

$$\mathbf{v}^T H \mathbf{v} < 0 \implies \text{Around } \boldsymbol{\theta}': L(\boldsymbol{\theta}) < L(\boldsymbol{\theta}') \implies \text{Local maxima}$$

$$\text{Sometimes } \mathbf{v}^T H \mathbf{v} > 0, \text{ sometimes } \mathbf{v}^T H \mathbf{v} < 0 \implies \text{Saddle point}$$

图 3: 在 critical point, 根据 $\mathbf{v}^T H \mathbf{v}$ 对所有 $\mathbf{v}$ 的符号判定类型: 恒正 $\Rightarrow$ Local minima; 恒负 $\Rightarrow$ Local maxima; 时正时负 $\Rightarrow$ Saddle point。

- 对所有 $\mathbf{v}$, $\mathbf{v}^T H \mathbf{v} > 0$: 则附近恒有 $L(\boldsymbol{\theta}) > L(\boldsymbol{\theta}')$, $\boldsymbol{\theta}'$ 是最低点 $\Rightarrow$ Local minima。
- 对所有 $\mathbf{v}$, $\mathbf{v}^T H \mathbf{v} < 0$: 则附近恒有 $L(\boldsymbol{\theta}) < L(\boldsymbol{\theta}')$, $\boldsymbol{\theta}'$ 是最高点 $\Rightarrow$ Local maxima。
- 有时 > 0 、有时 < 0 : 附近有些方向更高、有些方向更低 $\Rightarrow$ Saddle point。

2.4 捷径：直接看 Hessian 的特征值

逐一尝试“所有的 v ”显然不现实。线性代数给出了更简便的结论——只需看 Hessian 矩阵 H 的特征值 (eigenvalue):

特征值判定法 (无需遍历 v)

- 所有特征值都为正 $\Rightarrow H$ 是 positive definite (正定) $\Rightarrow$ 对所有 v 有 $v^T H v > 0 \Rightarrow$ **Local minima**
- 所有特征值都为负 $\Rightarrow H$ 是 negative definite (负定) $\Rightarrow$ **Local maxima**
- 特征值有正有负 $\Rightarrow$ **Saddle point**

一句话：算出 Hessian，看它的特征值符号，类型立刻揭晓。

3 一个具体例子：史上最废的 network

为了把上面的流程走一遍，老师举了一个“史上最废”的例子。

3.1 模型与资料




图 4: 史上最废的 network: $x \rightarrow w_1 \rightarrow w_2 \rightarrow y$, 无 bias、无 activation, 故 $y = w_1 w_2 x$ 。仅一笔训练资料 $x = 1, \hat{y} = 1$, 损失 $L = (1 - w_1 w_2)^2$ 。右上为穷举所有 (w_1, w_2) 画出的 error surface (呈鞍形)。

- **模型**：输入 x ，经过两个神经元（仅各乘一个权重、无激活函数），输出 $y = w_1 w_2 x$ 。整个网络只有 w_1 、 w_2 两个参数。
- **资料**：只有一笔， $x = 1$ 时 $\hat{y} = 1$ 。
- **损失**： $L = (\hat{y} - w_1 w_2 x)^2 = (1 - w_1 w_2)^2$ 。

由于只有两个参数，可以穷举所有 (w_1, w_2) 算出 loss，直接画出 error surface：四个角落 loss 高，中间有一条“山沟”。图上原点 $(0, 0)$ 是一个 critical point，沿对角线方向还排布着一排 critical point。

3.2 求梯度 g ，定位 critical point

对 $L = (1 - w_1 w_2)^2$ 求偏导：

$$\frac{\partial L}{\partial w_1} = 2(1 - w_1 w_2)(-w_2), \quad \frac{\partial L}{\partial w_2} = 2(1 - w_1 w_2)(-w_1)$$

令两者同时为零，原点 $w_1 = 0, w_2 = 0$ 即为一个 critical point。但它到底是哪种类型？光看梯度无法判断，**必须看 Hessian**。

3.3 求 Hessian H ，算特征值

四个二阶偏导为：

$$\begin{aligned} \frac{\partial^2 L}{\partial w_1^2} &= 2(-w_2)(-w_2), & \frac{\partial^2 L}{\partial w_1 \partial w_2} &= -2 + 4w_1 w_2, \\ \frac{\partial^2 L}{\partial w_2 \partial w_1} &= -2 + 4w_1 w_2, & \frac{\partial^2 L}{\partial w_2^2} &= 2(-w_1)(-w_1). \end{aligned}$$

将原点 $w_1 = w_2 = 0$ 代入，得到 Hessian 及其特征值：

$$H = \begin{bmatrix} 0 & -2 \\ -2 & 0 \end{bmatrix}, \quad \lambda_1 = 2, \quad \lambda_2 = -2$$

特征值有正有负，所以原点是一个 **saddle point**（与穷举 error surface 的观察一致）。

4 不要怕 saddle point：Hessian 指出逃生方向

如果卡住的地方是 saddle point，其实**不必惊慌**——因为 Hessian 不仅能判断类型，**还能告诉我们参数该往哪个方向 update**。

4.1 逃离原理：沿负特征值的特征向量走

Don't afraid of saddle point?

$$\text{At critical point: } L(\boldsymbol{\theta}) \approx L(\boldsymbol{\theta}') + \frac{1}{2} (\boldsymbol{\theta} - \boldsymbol{\theta}')^T \mathbf{H} (\boldsymbol{\theta} - \boldsymbol{\theta}')$$

Sometimes $\mathbf{v}^T \mathbf{H} \mathbf{v} > 0$, sometimes $\mathbf{v}^T \mathbf{H} \mathbf{v} < 0 \Rightarrow$ Saddle point

$\mathbf{H}$ may tell us parameter update direction!

$$\begin{array}{l} \mathbf{u} \text{ is an eigen vector of } \mathbf{H} \\ \lambda \text{ is the eigen value of } \mathbf{u} \\ \lambda < 0 \end{array} \Rightarrow \mathbf{u}^T \mathbf{H} \mathbf{u} = \mathbf{u}^T (\lambda \mathbf{u}) = \lambda \|\mathbf{u}\|^2 < 0$$

$$L(\boldsymbol{\theta}) \approx L(\boldsymbol{\theta}') + \frac{1}{2} (\boldsymbol{\theta} - \boldsymbol{\theta}')^T \mathbf{H} (\boldsymbol{\theta} - \boldsymbol{\theta}')$$

图 5: $\mathbf{H}$ 可以指出更新方向。设 $\mathbf{u}$ 是 $\mathbf{H}$ 的特征向量、 λ 是其特征值，则 $\mathbf{u}^T \mathbf{H} \mathbf{u} = \mathbf{u}^T (\lambda \mathbf{u}) = \lambda \|\mathbf{u}\|^2$ 。若取 $\lambda < 0$ ，此项即为负，沿 $\boldsymbol{\theta} - \boldsymbol{\theta}' = \mathbf{u}$ 方向走即可降低 loss。

设 $\mathbf{u}$ 是 $\mathbf{H}$ 的一个特征向量， λ 是它对应的特征值。若把 $\mathbf{v} = \boldsymbol{\theta} - \boldsymbol{\theta}'$ 取为 $\mathbf{u}$ ，则利用 $\mathbf{H}\mathbf{u} = \lambda\mathbf{u}$ ：

$$\mathbf{u}^T \mathbf{H} \mathbf{u} = \mathbf{u}^T (\lambda \mathbf{u}) = \lambda \|\mathbf{u}\|^2$$


找到负特征值，就找到了下山的路

由于 $\|\mathbf{u}\|^2 > 0$ ，只要特征值 $\lambda < 0$ ，就有 $\mathbf{u}^T \mathbf{H} \mathbf{u} = \lambda \|\mathbf{u}\|^2 < 0$ 。代回 critical point 处的近似式：

$$L(\boldsymbol{\theta}) \approx L(\boldsymbol{\theta}') + \frac{1}{2} \mathbf{u}^T \mathbf{H} \mathbf{u} < L(\boldsymbol{\theta}')$$

也就是说，令 $\boldsymbol{\theta} = \boldsymbol{\theta}' + \mathbf{u}$ 、沿着负特征值对应的特征向量方向更新参数，就能让 loss 下降，从而逃离 saddle point。

4.2 回到例子：沿 $u = [1, 1]^T$ 逃离



$$\lambda_2 = -2 \quad \text{Has eigenvector } \mathbf{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Update the parameter along the direction of $\mathbf{u}$

You can escape the saddle point and decrease the loss.

(this method is seldom used in practice)

图 6: 例子的完整结论: 原点 $H = \begin{bmatrix} 0 & -2 \\ -2 & 0 \end{bmatrix}$, $\lambda_1 = 2, \lambda_2 = -2 \Rightarrow$ saddle point。负特征值 $\lambda_2 = -2$ 对应特征向量 $\mathbf{u} = [1, 1]^T$; 沿 $\mathbf{u}$ 方向更新即可逃离鞍点、降低 loss。注: 此法实务中很少使用。

在上一节的例子里, 原点处负特征值 $\lambda_2 = -2$ 对应的一个特征向量是 $\mathbf{u} = [1, 1]^T$ 。于是只要从原点沿 $(1, 1)$ 方向更新参数, 就能走到一个 loss 更低的点, 成功逃离鞍点。

这个方法实务上几乎不用

虽然理论上漂亮, 但实务中几乎没有人真的去算 Hessian 来逃离 saddle point。原因是: Hessian 要做二次微分, 计算这个矩阵的运算量极大, 更别说还要求它的特征值与特征向量。后续课程会介绍运算量小得多的逃离方法 (如 batch 与 momentum)。这里把它拿出来讲, 只是想说明: 卡在 saddle point 并不可怕, 最坏情况下你也总有一条已知的路可走。

5 Saddle Point 还是 Local Minima 更常见?

既然 saddle point 没那么可怕, 那么一个自然的问题是: 实际训练中, 我们更常遇到的是 saddle point 还是 local minima? 如果多半是 saddle point, 那就太好了。

5.1 高维直觉：魔法师 Diorena 的故事

中文标题：魔法师 Diorena 的故事

来源《三体III·死神永生》

Saddle Point v.s. Local Minima

- The Magician Diorena (魔法师狄奥伦娜)

From 3 dimensional space, it is sealed.

It is not in higher dimensions.



Source of image: <https://read01.com/mz2DBPE.html#YECz22gzblU>

图 7: 魔法师 Diorena (迪奥伦娜, 出自《三体 III · 死神永生》): 石棺从三维空间看是密封的 (“it is sealed”), 但在更高维度里并非封闭 (“not in higher dimensions”), 存在可以进出的路径。

故事的寓意：低维的“封闭”在高维未必封闭

传说魔法师 Diorena 能从一只密封石棺中取出圣杯。在三维空间看，石棺四壁封闭、无路可入；但若能进入四维空间，石棺其实是“开着”的，存在可以进去的通路。
(历史上君士坦丁堡陷落于 1453 年；课堂讲述的魔法师情节出自科幻小说《三体》，仅作类比之用。)

5.2 error surface 同理：维度越高，路越多

手书数学自习课堂 bilibili

Source of image: <https://arxiv.org/abs/1712.09913>

Saddle Point v.s. Local Minima





图 8: Saddle point vs. local minima 的维度直觉：在低维（左）看似“无路可走”的 local minima，放到**更高维度**（右，真实 network 的 error surface）也许只是一个 saddle point——存在尚未被“看见”的下降方向。

把这个直觉搬到 error surface 上：在低维空间里看起来四周都高、像是 local minima 的点，放到更高的维度去看，旁边可能就有路可以走，其实只是个 saddle point。

参数动辄百万千万，维度极高

训练 network 时，参数往往百万、千万乃至上亿。有多少参数，error surface 就有多少维度。维度如此之高，意味着可走的方向（路）非常多。既然路这么多，真正“四面八方都堵死”的 local minima，反而可能很罕见。

5.3 Empirical Study: local minima 确实罕见



Source: https://docs.google.com/presentation/d/1siUFXARYRpNiMeSRwgFbt7mZVjkMPhR5od09w0Z8xaU/edit#slide=id.g31470fd33a_0_33

图 9: 实证研究: 每个点是一个训练到 critical point 的 network。纵轴为卡住时的 training loss, 横轴为 **Minimum Ratio** (正特征值数目 / 全部特征值数目)。Minimum Ratio 越靠近 1 越像 local minima, 但实测最大也只好到约 0.5–0.6。

Minimum Ratio 怎么读

$$\text{Minimum Ratio} = \frac{\text{正特征值的数目}}{\text{特征值的总数目}}$$

- 若所有特征值都为正 (ratio = 1), 该 critical point 才是真正的 local minima。
- 实验中, 无论训练多少个 network, Minimum Ratio **最大也不过** 0.5 ~ 0.6——意味着即便在最“像” local minima 的情况下, 仍有**近一半特征值是负的**。

结论: 负特征值的存在, 代表在那些维度上**仍有让 loss 下降的路**。所以从经验上看, 真正的 local minima 并不常见; 多数时候你发现梯度很小、参数停止更新, 其实是卡在了 saddle point。

6 总结与延伸

中在机器学习课程 babili

Small Gradient ...




图 10: Small Gradient 的三种典型成因: 在 **plateau** (平原) 上 $\partial L / \partial w \approx 0$, 更新极慢; 卡在 **saddle point** 或 **local minima** 时 $\partial L / \partial w = 0$, 更新停滞。本节回答了“是哪一种”与“saddle point 怎么逃”。

6.1 诊断流程复盘

遇到梯度很小、训练停滞时的处理流程

1. 确认是 **critical point** (梯度接近零), 而非简单的学习率问题。
2. 算出该点的 **Hessian** H , 求其特征值。
3. 看特征值符号: 全正 $\Rightarrow$ local minima; 全负 $\Rightarrow$ local maxima; 有正有负 $\Rightarrow$ saddle point。
4. 若是 **saddle point**: 取负特征值对应的特征向量 u , 沿 $\theta' + u$ 方向更新即可逃离、降低 loss。
5. 实务上因 Hessian 运算量太大, 几乎不直接这么做——但好消息是: 经验表明卡住时多半是 **saddle point** 而非 **local minima**, 本就有路可走。

本节关键概念清单

概念	英文	说明
临界点	Critical Point	梯度为零的点（统称）
局部最小值	Local Minima	四周都更高，无路可走
局部最大值	Local Maxima	四周都更低
鞍点	Saddle Point	梯度为零，但有方向更高、有方向更低
泰勒近似	Taylor Approximation	用 g 、 H 近似邻域内的 L
梯度	Gradient g	一次微分向量， $g_i = \partial L / \partial \theta_i$
海森矩阵	Hessian H	二次微分矩阵， $H_{ij} = \partial^2 L / \partial \theta_i \partial \theta_j$
特征值	Eigenvalue λ	判定 critical point 类型的依据
特征向量	Eigenvector u	负特征值对应的 u 即逃离方向
正定	Positive Definite	特征值全正 $\Rightarrow$ local minima
最小值比例	Minimum Ratio	正特征值数 / 总特征值数

6.2 核心要点提炼

- **别只想到 local minima**：梯度为零的点统称 critical point，saddle point 同样会让训练停滞。
- **Hessian 是判别工具**：critical point 处一次项消失，地貌由 Hessian 决定；看其特征值即可定类型。
- **saddle point 可逃**：沿负特征值的特征向量方向更新即可下山——尽管实务上有更省的办法。
- **高维世界里 local minima 罕见**：参数维度极高，下降的“路”很多；实证的 Minimum Ratio 从未接近 1，说明卡住时多为 saddle point。

6.3 下一讲预告

- 既然直接算 Hessian 太贵，**有哪些运算量小、又能帮助逃离 critical point / 加速训练的方法？**
- 下一节将介绍 **Batch（批次）与 Momentum（动量）**：小批次带来的噪声本身就有助于跳出 saddle point 甚至 local minima，而 momentum 则借“惯性”冲过平坦与小坑。
- 之后还会讲到**自动调整学习率、损失函数的选择**等“类神经网络训练不起来怎么办”系列的其余技巧。

本节完 · 下一节：类神经网络训练不起来怎么办（二）——Batch 与 Momentum

课程视频：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=4>
