

为什么用了 Validation Set 仍会过拟合？

李宏毅《机器学习》2025 · Model Selection 也会 Overfit



基于李宏毅老师课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 9 分钟

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=10>

目录

1	问题: Validation Set 不是免死金牌	3
2	标准流程: 先训练每个模型, 再用 Validation 选择	3
3	关键转念: Validation 选择本身也是 Training	5
4	沿用 P08 的上界: 坏 Validation Set 的机率	6
5	什么时候 Validation 也会 Overfit ?	7
6	本讲综合	8

1 问题：Validation Set 不是免死金牌

这段短讲回答一个常见疑问：已经切了 validation set，没有直接用 training loss 选模型，为什么上传 leaderboard 或遇到 testing set 时还是 overfitting？



I used a validation set, but
my model still overfitted?



<https://youtu.be/WeHM2xpYQpw>



图 1: 本讲问题：我用了 validation set，但模型仍然 overfitted? 画面依据：约 00:00–00:40。

许多人初学 validation 时，会把它理解成一种绝对防护：只要没有拿 testing set 调参数，只要用 validation set 选模型，就不会 overfit。课堂的重点是修正这个理解：**validation set 能降低风险，但它本身也可能被过度使用。**

直觉上，training set 会被模型拟合；validation set 则被我们拿来选模型。若我们只在少数几个模型之间选择，validation set 通常很可靠；但若我们在大量模型、超参数、架构、训练技巧之间反复试，validation set 也会成为被优化的对象。

一句话

用 validation set 选模型，本质上是在 validation set 上做 model selection。Model selection 也是一种优化；只要优化，就有 overfitting 的可能。

2 标准流程：先训练每个模型，再用 Validation 选择

假设有三个模型家族：

$$\mathcal{H}_1, \mathcal{H}_2, \mathcal{H}_3.$$

每个模型先在 training set 上训练，得到各自的最佳函数：

$$h_1^* = \arg \min_{h \in \mathcal{H}_1} L(h, \mathcal{D}_{train}), \quad h_2^* = \arg \min_{h \in \mathcal{H}_2} L(h, \mathcal{D}_{train}), \quad h_3^* = \arg \min_{h \in \mathcal{H}_3} L(h, \mathcal{D}_{train}).$$

接下来不直接看它们在 $\mathcal{D}_{train}$ 上的 loss，而是在 validation set 上评估：

$$L(h_1^*, \mathcal{D}_{val}), \quad L(h_2^*, \mathcal{D}_{val}), \quad L(h_3^*, \mathcal{D}_{val}).$$

若第三个最小，例如

$$L(h_1^*, \mathcal{D}_{val}) = 0.9, \quad L(h_2^*, \mathcal{D}_{val}) = 0.7, \quad L(h_3^*, \mathcal{D}_{val}) = 0.5,$$

就选择 h_3^* ，再把它送到 testing set 或真实环境中。

手谈机器学习课堂 bilibili

Validation Set




图 2: Validation 的标准流程：每个模型先用 $\mathcal{D}_{train}$ 训练，再用 $\mathcal{D}_{val}$ 比较 h_i^* 的 loss；最低者送往 testing set。画面依据：约 01:35–02:25。

这里的 $\mathcal{D}_{test}$ 被视为 $\mathcal{D}_{all}$ 的近似：我们真正关心的是所有未来资料上的表现，但 $\mathcal{D}_{all}$ 不可得，所以用 testing set 估计。

Validation 和 Testing 的角色差异

Validation set 可以参与模型选择，例如调 learning rate、层数、regularization、early stopping。Testing set 则应该尽量只用于最终评估。如果你看了 testing result 后又回头改模型，testing set 就被卷入选择过程，评估会变得乐观。

3 关键转念：Validation 选择本身也是 Training

把前面得到的三个已训练函数收集成一个新的候选集合：

$$\mathcal{H}_{val} = \{h_1^*, h_2^*, h_3^*\}.$$

用 validation set 选模型，其实就是解下面这个问题：

$$h^* = \arg \min_{h \in \mathcal{H}_{val}} L(h, \mathcal{D}_{val}).$$




图 3: 把 validation 选择写成 argmin: $\mathcal{H}_{val} = \{h_1^*, h_2^*, h_3^*\}$, 再从中选出 $\mathcal{D}_{val}$ 上 loss 最小的 h^* 。画面依据: 约 02:55-03:35。

这与一般训练的形式完全一样：一般训练是在某个候选函数集合 $\mathcal{H}$ 里，找一个让 $\mathcal{D}_{train}$ 上 loss 最小的函数；validation 选择是在 $\mathcal{H}_{val}$ 里，找一个让 $\mathcal{D}_{val}$ 上 loss 最小的函数。




图 4: 用 validation set 选模型, 可被视为在 $\mathcal{D}_{val}$ 上对 $\mathcal{H}_{val}$ 做带引号的 “training”。画面依据: 约 03:45–05:20。

当然, 这里的 training 不是用 gradient descent 更新神经网络参数, 而是在少数候选模型中挑一个。但数学结构一样: 都是根据一组有限资料, 选择在这组资料上表现最好的候选函数。

为什么这个转念重要?

一旦把 validation 选择看成 training, 就可以把 P08 的泛化理论直接搬过来: 如果候选集合太大, 或 validation set 太小, 就可能抽到一组对 $\mathcal{H}_{val}$ 来说 “不够代表真实分布” 的 validation set, 于是 validation loss 和真实 loss 出现落差。

4 沿用 P08 的上界: 坏 Validation Set 的机率

P08 推导过: 对候选集合 $\mathcal{H}$ 与训练样本数 N , 坏训练集机率有上界

$$P(\mathcal{D}_{train} \text{ is bad}) \leq |\mathcal{H}| \cdot 2 \exp(-2N\epsilon^2).$$

现在把同样逻辑套到 validation 选择上。若 validation set 大小为 N_{val} , 候选集合为 $\mathcal{H}_{val}$, 则

$$P(\mathcal{D}_{val} \text{ is bad}) \leq |\mathcal{H}_{val}| \cdot 2 \exp(-2N_{val}\epsilon^2).$$

Using validation set to select model =
considered as “training by $\mathcal{D}_{val}$ ”

Your model is $\mathcal{H}_{val} = \{h_1^*, h_2^*, h_3^*\}$

$$P(\mathcal{D}_{train} \text{ is bad}) \leq |\mathcal{H}| \cdot 2\exp(-2N\varepsilon^2)$$

图 5: 把 P08 的坏样本上界套到 validation: $\mathcal{D}_{val}$ 是否可靠, 取决于 validation 样本数 N_{val} 与候选集合大小 $|\mathcal{H}_{val}|$ 。画面依据: 约 05:35–07:20。

这个式子直接解释了为什么 validation set 通常有用: 如果我们只在少数几个模型之间选择, $|\mathcal{H}_{val}|$ 很小; 只要 $\mathcal{D}_{val}$ 有一定大小, 坏 validation set 的机率就不高。

但它也解释了为什么 validation set 不是万能: 如果你反复尝试大量架构和超参数, $\mathcal{H}_{val}$ 会变大。 $|\mathcal{H}_{val}|$ 一大, 坏 validation set 的机率上界也变大, validation loss 就可能被 overfit。

反复试模型会扩大 $\mathcal{H}_{val}$

每试一次模型、每改一次超参数、每看一次 validation result 后再调整设计, 都在扩大实际被 validation set 选择过的候选集合。即使代码里没有显式写出 $\mathcal{H}_{val}$, 实验过程本身已经在构造它。

5 什么时候 Validation 也会 Overfit ?

课堂举了一个极端例子: 如果你要调十层网络, 每层 neuron 数从 1 到 1000 都试一遍, 那么候选架构数可能达到

$$1000^{10}.$$

再用同一个 validation set 从这些模型里挑一个, $\mathcal{H}_{val}$ 就非常大。此时你很可能选到一个在 validation set 上偶然表现好的模型, 而它在 testing set 上不一定好。

Using validation set to select model =
considered as “training by $\mathcal{D}_{val}$ ”

Your model is $\mathcal{H}_{val} = \{h_1^*, h_2^*, h_3^*\}$

$$P(\mathcal{D}_{train} \text{ is bad}) \leq |\mathcal{H}| \cdot 2\exp(-2N\varepsilon^2)$$

$$P(\mathcal{D}_{val} \text{ is bad}) \leq |\mathcal{H}_{val}| \cdot 2\exp(-2N_{val}\varepsilon^2)$$



It is small. Hopefully

If your $|\mathcal{H}_{val}|$ is large, you still have high $P(\mathcal{D}_{val} \text{ is bad})$.

图 6: 若 $|\mathcal{H}_{val}|$ 很大, 即使用 validation set 选模型, 也仍有较高机率让 $\mathcal{D}_{val}$ 被 overfit。画面依据: 约 07:30–08:50。

这并不是说不要用 validation set。正确结论是:

- validation set 应该用于模型选择, 但不要无限制反复试;
- 若要大规模调参, validation set 需要足够大, 或使用交叉验证、nested validation、独立 holdout 等更严格评估方式;
- 最终 testing set 应尽量保持干净, 只在最后报告一次。

实践中的判断

如果 validation performance 越调越好, 但 public leaderboard 或最终 test performance 没有同步改善, 就要怀疑自己正在 overfit validation。此时应减少搜索空间、增加验证资料、重新切分资料, 或保留一个完全没参与模型选择的最终测试集。

6 本讲综合

P10 的核心很短, 但非常实用:

validation set 不是不参与训练; 它参与的是模型选择层面的训练。

训练集用于选择模型内部参数; validation set 用于选择模型、超参数或实验方案。只要某个资料集被拿来选模型, 它就可能被 overfit。过拟合不是只发生在 gradient descent 里, 也会发生在人的实验循环里。

最终结论

Validation 能防止你直接 overfit training set，但不能防止你 overfit validation set 本身。是否会发生，取决于 $\mathcal{D}_{val}$ 的大小与你实际比较过的候选模型数 $|\mathcal{H}_{val}|$ 。候选越多、验证集越小，validation overfitting 风险越高。