

生成式对抗网络 GAN (一)

基本概念：Generator、Discriminator 与交替训练



基于李宏毅老师《机器学习》课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅机器学习深度学习课程 (Bilibili)

时长：约 39 分钟

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=18>

目录

1 从确定性网络到分布型 Generator	3
1.1 把随机变量送进网络	3
1.2 为什么输出分布很重要	4
1.3 本章小结	5
2 GAN 的问题设定	5
2.1 Unconditional Generation	6
2.2 简单分布为什么够用	7
2.3 本章小结	7
3 Discriminator 与对抗直觉	8
3.1 对抗关系	8
3.2 本章小结	10
4 GAN 的交替训练算法	10
4.1 第一步：固定 Generator，训练 Discriminator	11
4.2 第二步：固定 Discriminator，训练 Generator	12
4.3 反复交替	13
4.4 本章小结	14
5 训练结果与生成能力	14
5.1 StyleGAN 与 Progressive GAN	15
5.2 从第一代 GAN 到 BigGAN	17
5.3 本章小结	19
6 总结与延伸	19
6.1 概念总表	20
6.2 这节课最重要的直觉	20
6.3 延伸	20

1 从确定性网络到分布型 Generator

过去讲的 supervised learning 多半把神经网络看成一个确定性函数：

$$y = f_{\theta}(x).$$

同一个输入 x 进来，网络输出一个固定的 y 。这适合分类、回归、语音帧标注等任务，因为训练资料通常告诉你「这一个输入对应这一个答案」。


生成任务不一定如此。很多时候，同一个输入可以有很多合理输出。例如给定一段游戏画面的过去几帧，下一帧可能往左走、往右走、停下来，甚至出现多种视觉变化；给定「画一个红眼睛角色」这样的描述，不同人会画出不同角色，这些答案都可以是合理的。若仍强迫网络输出一个单一平均答案，模型常会产生模糊、混合、没有个性的结果。

1.1 把随机变量送进网络

解决思路是给网络额外输入一个随机变量 z 。令 z 从简单分布中采样，例如标准正态分布或均匀分布：

$$z \sim p_z(z), \quad y = G_{\theta}(x, z).$$

这样同一个 x 搭配不同的 z ，可以得到不同输出。网络不再只表示一个点，而是在表示一个由 z 推出来的输出分布。



2

图 1: Generator 接收普通输入 x 与简单分布中采样出的 z ，再把它们变换成复杂输出分布中的样本 y 。²

²视频画面时间区间：约 02:48–03:42；字幕附近说明每次从简单分布 sample 到不同的 z ，同一个 x 的输出 y 就不一样，网络输出变成复杂 distribution。

这里的关键不是正态分布本身有多神奇，而是它足够简单、容易采样。真正复杂的部分交给 generator：它学习一个映射，把简单分布中的点推到复杂资料分布上。用概率语言说，generator 学的是一个 push-forward distribution：

$$z \sim p_z, \quad G_\theta(z) \sim p_g.$$


训练的目标是让 p_g 接近真实资料分布 p_{data} 。

1.2 为什么输出分布很重要

视频预测是一个典型例子。若模型只用传统 supervised learning，把可能的未来都平均起来，就可能得到模糊画面。多个未来都合理时，平均未来往往不是一个真实未来。

Source: https://github.com/dyelax/Adversarial_Video_Generation

Why distribution?



4

图 2: 在 video prediction 中，给定过去帧以后，下一帧可能有多种合理走向；若训练成单一输出，容易得到模糊或混合的预测。⁴

这种问题不是模型不够大就能彻底解决，因为目标本身是多模态的。若一个输入对应多个可能输出，单一均方误差会鼓励平均值；而平均值常常落在真实分布之外。生成模型要做的不是输出平均答案，而是学会从所有合理答案中采样。


⁴视频画面时间区间：约 05:35–06:25；字幕附近说明用普通 supervised learning 预测下一帧可能会模糊，甚至出现角色分裂或消失。

Why distribution?

(The same input has different outputs.)

- Especially for the tasks needs “creativity”

Drawing



6

图 3: 需要创造性的任务常有「同一输入，多种正确输出」的结构；generator 应学会产生一个分布，而不是只给一个平均答案。⁶

为什么需要随机变量

随机变量 z 让网络拥有「选择不同合理输出」的自由度。没有 z ，同一输入只能对应一个输出；有了 z ，模型可以把一个简单、可采样的分布扭曲成复杂资料分布。

1.3 本章小结

Generator 的核心不是单纯「产生图片」，而是学习一个从简单随机分布到复杂资料分布的映射。生成任务常有多种正确答案，因此模型必须能输出分布；否则就容易产生模糊的平均结果。

2 GAN 的问题设定

GAN 是 Generative Adversarial Network 的缩写。2014 年 Ian Goodfellow 等人提出 GAN 后，围绕 GAN 的变型非常多，课程中也展示了 GAN zoo: GAN、ACGAN、BGAN、CGAN、DCGAN、EBGAN、fGAN、GoGAN 等名称层出不穷。

⁶视频画面时间区间：约 09:02–09:56；字幕附近说明同样输入有多种可能输出，画红眼睛角色时每个人想象的答案可能不同。

GAN
ACGAN
BGAN
CGAN
DCGAN
EBGAN
fGAN
GoGAN
⋮

- SeUDA - Semantic-Aware Generative Adversarial Nets for Unsupervised Domain Adaptation Segmentation
- SG-GAN - Semantic-aware Grad-GAN for Virtual-to-Real Urban Scene Adaption (github)
- SG-GAN - Sparsely Grouped Multi-task Generative Adversarial Networks for Facial Attribute
- SGAN - Texture Synthesis with Spatial Generative Adversarial Networks
- SGAN - Stacked Generative Adversarial Networks (github)
- SGAN - Steganographic Generative Adversarial Networks
- SGAN - SGAN: An Alternative Training of Generative Adversarial Networks
- SGAN - CT Image Enhancement Using Stacked Generative Adversarial Networks and T1 Segmentation Improvement
- sGAN - Generative Adversarial Training for MRA Image Synthesis Using Multi-Contrast
- SiftingGAN - SiftingGAN: Generating and Sifting Labeled Samples to Improve the Remote Sensing Classification Baseline in vitro
- SiGAN - SiGAN: Siamese Generative Adversarial Network for Identity-Preserving Face Image Synthesis
- SimGAN - Learning from Simulated and Unsupervised Images through Adversarial Training
- SisGAN - Semantic Image Synthesis via Adversarial Learning

Mihaela Rosca, Balaji Lakshminarayanan, David Warde-Farley, Shakir Mohamed, "Variational Approaches for Auto-Encoding Generative Adversarial Networks", arXiv, 2017

²We use the Greek α prefix for α -GAN, α -AEGAN and most other Latin prefixes seem to have been taken <https://deephunt.in/the-gan-zoo-79597dc8c347>.

9

图 4: GAN 之后出现了大量变型, 名称从 A 到 Z 几乎都被用过; 本讲先聚焦最基本的 GAN 训练概念。⁸

这节课不急着讨论所有变型, 而是用「生成动画人物头像」作为例子, 讲清楚最基本的 generator、discriminator 与对抗训练。

2.1 Unconditional Generation

Unconditional generation 指的是: 不输入类别、文字描述或其他条件, 只从随机向量 z 产生样本。例如从正态分布采样一个低维向量, 经由 generator 输出一张高维图片:


$$z \sim \mathcal{N}(0, I), \quad x_{\text{fake}} = G_{\theta}(z).$$

这里 z 的维度可能只有几十或几百, 而输出图片的维度等于像素数乘以通道数, 远高于 z 。

⁸视频画面时间区间: 约 13:04–13:52; 字幕附近说明 GAN 相关论文和名称非常多, 并转入本讲使用的动画人脸 unconditional generation 例子。

Anime Face Generation

• Unconditional generation



10

图 5: 动画头像生成例子中, generator 把低维随机向量 z 映射为高维图片向量, 希望不同 z 都能产生看起来像动画人物脸的图片。¹⁰

这和普通分类器很不一样。分类器的目标是把输入压成标签; generator 的目标是从低维隐空间展开到高维资料空间。它不是记忆训练图片, 而是学习资料分布的结构: 眼睛、头发、脸型、颜色、姿态等因素如何组合成可信样本。

2.2 简单分布为什么够用

课程中特别提醒: z 不一定非要正态分布, 也可以是其他容易采样的分布。选择正态分布的主要原因是方便。因为 generator 有足够表达能力, 它可以把简单分布变成复杂分布。换句话说, 复杂性不在 p_z , 而在 G_θ 。

隐变量不是标签

z 通常不是人工标注的语义标签。它只是生成过程的随机源。训练成功后, z 空间中的某些方向可能会对应发色、姿态、表情等语义变化, 但这些语义不是一开始硬编码进去的, 而是模型在拟合资料分布时学出来的。

2.3 本章小结

GAN 的基本设定是让 generator 从简单随机分布产生假样本。以动画头像为例, 模型从低维 z 出发, 输出高维图片。训练目标不是为每个 z 指定标准答案, 而是让整体生成分布接近真实图片分

¹⁰ 视频画面时间区间: 约 15:32-16:21; 字幕附近说明 sample 不同 z 会得到不同 y , 但希望无论采到什么 z , 输出都像动画人物头像。


布。

3 Discriminator 与对抗直觉

Generator 负责产生假样本，但训练时还需要一个 judge，也就是 discriminator。Discriminator 本身也是一个神经网络：

$$D_{\phi}(x) \in \mathbb{R}.$$

它输入一张图片，输出一个分数。分数越高，表示它认为图片越像真实资料；分数越低，表示越像 generator 造出来的假图片。



11

图 6: Discriminator 输入图片并输出 scalar score；课程例子中分数越大代表越像真实动画头像，分数越小代表越像假图。¹²

3.1 对抗关系

GAN 的名字里有 adversarial，因为 generator 和 discriminator 不是各自独立训练，而是互相推动。Discriminator 越强，越能指出 generator 产生图片的破绽；generator 被迫改进，以骗过 discriminator；generator 变强以后，又会迫使 discriminator 学会更细的判断标准。

¹²视频画面时间区间：约 16:45–17:42；字幕附近说明 discriminator 输入一张图片，输出一个数值，数值越大代表越像真实二次元头像。

Basic Idea of GAN




图 7: 课程用演化式类比说明 GAN: 一方学会伪装, 另一方学会识别, 双方互相推动, 判断标准越来越细。¹⁴

这个过程像一个动态课程。早期 discriminator 只需发现很粗糙的假图特征, 例如没有头发、没有嘴巴、颜色不自然; generator 修掉这些问题后, discriminator 才会学习更细的判断, 例如眼睛是否对称、脸部轮廓是否自然、纹理是否合理。

¹⁴视频画面时间区间: 约 19:19–20:12; 字幕附近用伪装与识别的演化故事引出 GAN 中 generator 与 discriminator 的对应关系。

Basic Idea of GAN




图 8: Generator 和 discriminator 交替进步: 更严格的 discriminator 会逼迫下一代 generator 产生更真实、更完整的图片。¹⁶

GAN 难训练的根源

GAN 不是固定目标函数上的普通单人优化。训练过程中, generator 的目标会随 discriminator 改变, discriminator 的训练资料又包含 generator 当前产生的样本。因此训练动态更像双人博弈, 稳定性比普通 supervised learning 更微妙。

3.2 本章小结

Discriminator 是 GAN 中的评审网络, 用来判断图片真伪。Generator 的目标不是直接匹配某一张训练图, 而是产生能骗过 discriminator 的样本。两者交替进步, 形成 adversarial training。

4 GAN 的交替训练算法

课程把 GAN 训练拆成两个步骤。初始化时, generator G 和 discriminator D 都是随机参数。每一次训练迭代中, 先固定 G 更新 D , 再固定 D 更新 G 。

¹⁶视频画面时间区间: 约 21:48-22:42; 字幕附近说明 generator 为了骗过越来越严苛的 discriminator, 会逐渐补上嘴巴、头发等细节。

4.1 第一步：固定 Generator，训练 Discriminator


一开始 generator 参数随机，输入随机向量后会输出杂讯般的假图片。此时可以从真实资料库 sample 一批真实图片，再让 G 产生一批假图片。对 discriminator 来说，这就变成一个普通二分类或回归问题：真实图片标为 1，假图片标为 0。

Algorithm

- Initialize generator and discriminator
- In each training iteration:



Step 1: Fix generator G , and update discriminator D



15

图 9: Step 1 开始时固定 generator，从随机向量产生一批 fake objects；这些假样本会和真实资料一起交给 discriminator 学习。¹⁸


¹⁸视频画面时间区间：约 24:18–25:11；字幕附近说明先固定 generator，只训练 discriminator；随机初始化的 generator 会产生不像真实头像的图片。

Algorithm

- Initialize generator and discriminator  

- In each training iteration:

Step 1: Fix generator G, and update discriminator D



Discriminator learns to assign high scores to real objects and low scores to generated objects.

15

图 10: 训练 discriminator 时, 真实图片被标为高分, generator 产生的图片被标为低分; 此时 G 固定, 只更新 D。²⁰

若用概率形式写, discriminator 常见目标是最大化

$$\mathcal{L}_D = \mathbb{E}_{x \sim p_{\text{data}}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z))).$$

第一项鼓励真实图片分数高, 第二项鼓励假图片分数低。课程此处强调的是训练流程, 因此不需要一开始被公式困住; 先把它看作「训练一个真伪分类器」就够了。

4.2 第二步: 固定 Discriminator, 训练 Generator

第二步反过来: 固定 discriminator, 更新 generator。Generator 的目标是让 $D(G(z))$ 尽可能高, 也就是让 discriminator 以为假图是真的。

²⁰ 视频画面时间区间: 约 25:48-26:44; 字幕附近说明真实人物图片可标为 1, generator 产生图片标为 0, 让 discriminator 学会区分 real image 与 generated image。

Algorithm

- Initialize generator and discriminator


G

D

- In each training iteration:

Step 2: Fix discriminator D, and update generator G

Generator learns to “fool” the discriminator



16

图 11: Step 2 固定 discriminator, 把 generator 与 discriminator 接成一个大网络; 只更新 generator, 让它产生能得到高分的图片。²²

这里有一个重要实现细节。虽然 discriminator 固定, 它仍参与前向传播和反向传播。梯度会穿过 discriminator 传回 generator, 用来告诉 generator 哪些像素或特征方向能提高 D 的分数; 但 discriminator 自己的参数不更新。

Generator 的目标函数常见写法有两种。原始 minimax 形式是最小化

$$\mathbb{E}_{z \sim p_z} \log(1 - D(G(z))),$$

实践中也常用 non-saturating 形式最大化

$$\mathbb{E}_{z \sim p_z} \log D(G(z)).$$

两者都表达同一个方向: 让生成图片更像真实图片。

4.3 反复交替

训练不是只做一次, 而是反复执行: 训练一阵子 D , 再训练一阵子 G , 再用更新后的 G 产生新假图, 继续训练 D 。

²²视频画面时间区间: 约 28:03–29:01; 字幕附近说明把 generator 与 discriminator 接起来看成一个大 network, 并固定 discriminator, 只调整 generator。

Algorithm

- Initialize generator and discriminator **G** **D**
- In each training iteration:




图 12: GAN 的完整训练循环: Learning D 时固定 G , Learning G 时固定 D ; 两者交替更新, 互相推动。²⁴

训练流程的最小记忆版

训练 D : 真实图给高分, 假图给低分, G 不动。训练 G : 让假图通过固定的 D 得高分, D 不动。反复交替, 直到生成分布越来越接近真实分布。

4.4 本章小结

GAN 的训练可以理解为交替优化。Discriminator 学会区分真实与生成样本; generator 学会骗过当前 discriminator。公式上这是一个双人博弈, 流程上就是「固定一方、训练另一方」的循环。

5 训练结果与生成能力

训练早期的 generator 输出很粗糙, 常只出现一些模糊块状结构。随着更新次数增加, 模型逐渐学到人脸结构: 先出现眼睛, 再出现嘴巴、头发、脸部轮廓, 最后颜色和纹理越来越像真实动画头像。

²⁴视频画面时间区间: 约 30:49–31:40; 字幕附近总结两个步骤: 固定 generator 训练 discriminator, 再固定 discriminator 训练 generator, 反复执行。

Anime Face Generation



22

图 13: 动画头像 GAN 的训练过程: 更新次数增加后, 生成图从模糊块状逐渐变成有眼睛、嘴巴、头发和脸部结构的头像。²⁶

这个例子说明 GAN 学到的不是逐张复制, 而是资料分布中反复出现的结构。若训练资料都是动画头像, 模型会逐渐发现「头像通常有两只眼睛」「眼睛有高光」「脸部有轮廓」「头发和背景有颜色组合」等统计规律。

5.1 StyleGAN 与 Progressive GAN

课程展示了 StyleGAN 生成的动画人物, 以及 Progressive GAN 生成的真实人脸。它们说明 GAN 可以把简单随机向量映射成非常高质量的图片。

²⁶ 视频画面时间区间: 约 32:47-33:40; 字幕附近说明模型先学到眼睛, 再出现嘴巴, 更新到 1 万、2 万、5 万次后形状越来越完整。





图 14: StyleGAN 可生成高质量动画人物, Progressive GAN 可生成逼真的人脸; 这些例子展示了 GAN 在图像生成上的强大能力。²⁸

GAN 的一个有趣能力是 latent interpolation。因为输入是连续向量, 若在两个 z 之间做线性插值, 输出图片也常会平滑变化。这意味着 generator 学到的映射不是离散记忆, 而是在隐空间中形成了某种连续结构。

²⁸ 视频画面时间区间: 约 34:17–35:13; 字幕附近说明 StyleGAN 生成动画人物, Progressive GAN 可以产生高清真实人脸。




28

图 15: 对输入向量做 interpolation 时, generator 输出的人脸会连续变化; 这显示 latent space 中存在可平滑移动的语义方向。³⁰

5.2 从第一代 GAN 到 BigGAN

2014 年第一篇 GAN 论文中的结果, 在今天看来质量并不惊人, 但当时已经证明「对抗训练确实能产生图片」。几年后, BigGAN 等模型可以产生复杂、高分辨率、接近真实的图片, 但仍可能有细节破绽, 例如结构不对称、物体局部异常、概念混合等。

³⁰ 视频画面时间区间: 约 36:01–36:52; 字幕附近说明把两个输入向量做内插, 会看到两张图片之间连续变化。



The first GAN

<https://arxiv.org/abs/1406.2661> (Ian J. Goodfellow)

29

图 16: 最早 GAN 论文中的生成样本质量有限, 但它证明了 adversarial training 可以让模型学会生成图像。³²

³²视频画面时间区间: 约 37:31–38:16; 字幕附近提到 GAN 由 Ian Goodfellow 等人在 2014 年提出, 并展示当时的第一批生成结果。



图 17: BigGAN 能产生更复杂、更高质量的图像，但仔细看仍可能出现结构破绽或幻想式组合。³³

不要把 GAN 理解成「万能画图机」

GAN 强在学习资料分布并采样，但训练可能不稳定，也可能产生模式崩溃、细节破绽或语义混合。高质量结果来自模型结构、训练技巧、资料规模和计算资源的共同作用。

5.3 本章小结

GAN 的训练效果会随 generator 和 discriminator 的交替更新逐渐改善。高质量 GAN 不只是把噪声变图片，而是让隐空间中的连续向量对应到资料分布中的合理样本。第一代 GAN 证明了概念，后续 StyleGAN、Progressive GAN、BigGAN 等方法把生成质量大幅推进。

6 总结与延伸

本讲给出 GAN 的基本概念。Generator 学习把简单随机分布映射为复杂资料分布；discriminator 学习判断样本是真实还是生成；训练时两者交替更新，形成 adversarial learning。

³³ 视频画面时间区间：约 38:04–38:55；字幕附近说明 BigGAN 可产生高质量图像，但有时仍会出现不对称、局部异常或混合概念。

6.1 概念总表

概念	作用	需要注意的点
随机向量 z	提供生成过程的随机性，使同一条条件下可产生多种结果。	分布通常选简单可采样的形式，语义结构由 generator 学出来。
Generator	把 z 或条件输入映射到样本空间，产生 fake sample。	目标不是复制训练样本，而是让生成分布接近真实分布。
Discriminator	输入样本并输出真伪分数。	它既是评审，也是 generator 的训练信号来源。
训练 D	固定 G ，用真实图和假图训练真伪分类器。	假图来自当前 generator，因此训练资料会随 G 改变。
训练 G	固定 D ，让 $G(z)$ 得到更高真图分数。	梯度穿过 D 回到 G ，但 D 的参数不更新。

表 1: GAN 第一讲中的核心概念。

6.2 这节课最重要的直觉

第一，生成模型要处理的是分布，而不是单一答案。随机变量 z 不是可有可无的噪声，而是让模型表达多种合理输出的来源。

第二，GAN 的训练信号来自 discriminator。Generator 没有被直接告诉「这张图应该长什么样」，它只知道怎样让当前 discriminator 更相信自己产生的图是真的。

第三，GAN 是动态系统。若 discriminator 太弱，generator 学不到有用信号；若 discriminator 太强，generator 也可能拿不到有效梯度。后续关于 GAN 理论和训练技巧的讨论，都会围绕这个动态平衡展开。

和下一讲的衔接

本讲主要讲操作流程：什么是 generator、什么是 discriminator、如何交替训练。下一讲会进一步讨论 GAN 背后的理论问题：这个对抗游戏到底在优化什么，什么时候生成分布会接近真实分布。

6.3 延伸

GAN 的思想后来影响了许多生成式模型和表示学习方法。即使今天 diffusion model 和 autoregressive model 在很多生成任务上更常见，GAN 的核心问题仍值得学习：如何比较两个分布，如何从不可微的人类感受中构造可训练信号，如何让一个模型通过另一个模型给出的反馈学习。

本讲可以用一句话压缩：Generator 负责提出样本，discriminator 负责挑毛病；挑毛病越精准，提出样本的一方就被迫变得越好。