

生成式对抗网络 GAN (二)

理论介绍：JS Divergence、Wasserstein Distance 与 WGAN



基于李宏毅老师《机器学习》课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅机器学习深度学习课程 (Bilibili)

时长：约 47 分钟

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=19>


目录

1 GAN 真正想优化什么	3
1.1 Generator 诱导出一个分布	3
1.2 困难在于分布本身不可见	5
1.3 本章小结	5
2 Discriminator 如何估计 Divergence	6
2.1 把 Discriminator 看成二分类器	6
2.2 原始 GAN 的 Minimax 结构	8
2.3 本章小结	9
3 为什么 JS Divergence 不适合	9
3.1 高维资料常在低维流形上	10
3.2 非重叠时 JS 值恒定	10
3.3 分类器准确率也失去意义	12
3.4 本章小结	13
4 Wasserstein Distance	13
4.1 土方距离直觉	14
4.2 为什么它比 JS 更适合	15
4.3 本章小结	16
5 WGAN: 用 Critic 估计 Wasserstein Distance	16
5.1 为什么需要 Lipschitz 约束	17
5.2 Generator 如何更新	18
5.3 本章小结	18
6 如何让 Critic 足够平滑	19
6.1 Weight Clipping	19
6.2 Gradient Penalty 与 Spectral Normalization	19
6.3 本章小结	20
7 总结与延伸	21
7.1 核心公式回顾	21
7.2 理解路径	21
7.3 延伸	21

1 GAN 真正想优化什么

上一讲给出了 GAN 的训练流程：固定 generator 训练 discriminator，再固定 discriminator 训练 generator。本讲要回答更根本的问题：这种互动到底在优化什么？为什么两个网络互相欺骗，最后 generator 就能产生像真实资料的样本？

普通 supervised learning 通常先定义 loss function，再用 gradient descent 调参数。GAN 也是如此，只是它的 loss 不是单一输入对应单一标签，而是两个分布之间的距离。



32

图 1: GAN 的目标是让 generator 诱导出的分布 P_G 尽可能接近真实资料分布 P_{data} 。¹


1.1 Generator 诱导出一个分布

Generator 从简单分布中采样 z ，经过神经网络得到样本：

$$z \sim P_z, \quad x = G_\theta(z).$$

当 z 在 P_z 中变化， $G_\theta(z)$ 就在样本空间中形成一个分布，记为 P_G 。真实资料也有自己的分布，记为 P_{data} 。

¹视频画面时间区间：约 00:19–01:06；字幕附近说明本讲要弄清楚训练目标是什么，以及 generation 问题中要 minimize 或 maximize 什么。



32

图 2: 简单分布经过 generator 之后会被扭曲成新的分布 P_G ; 训练希望 P_G 与真实资料分布 P_{data} 越接近越好。³

因此，生成模型的目标可以抽象写成

$$G^* = \arg \min_G \text{Div}(P_G, P_{\text{data}}),$$

其中 Div 是某种衡量分布差异的距离或 divergence。

³视频画面时间区间：约 02:04–02:53；字幕附近说明 normal distribution 中的点经过 generator 后位置改变，形成新的 distribution，并希望它接近真实资料分布。




图 3: 若能计算 P_G 与 P_{data} 的 divergence, 就可以把 GAN 看成寻找使 divergence 最小的 generator。
5

1.2 困难在于分布本身不可见

问题是, 我们通常不知道 P_G 和 P_{data} 的完整解析式。真实资料分布只以 dataset 的形式存在; 生成分布也只能通过采样 z 后得到一批假样本。GAN 的巧妙之处就在这里: 即使不知道两个分布的公式, 只要能从它们采样, 就可以通过 discriminator 估计某种分布差异。

GAN 理论的一句话版本

GAN 把「比较两个分布」变成「训练一个分类器区分两个分布的样本」。如果分类器很容易区分, 两个分布差异大; 如果分类器难以区分, 两个分布更接近。

1.3 本章小结

GAN 的目标不是让某个输出等于某张训练图, 而是让生成分布 P_G 接近真实分布 P_{data} 。理论问题因此变成: 在只能采样、不能写出分布公式的情况下, 如何估计并最小化两个分布之间的差异。

⁵视频画面时间区间: 约 04:19–05:06; 字幕附近说明 generation 问题中的 loss function 就是 P_G 与 P_{data} 的 divergence, 目标是找 G 使它最小。

2 Discriminator 如何估计 Divergence


虽然不知道两个分布的公式，但我们能从它们采样。从资料库抽出的样本来自 P_{data} ；从随机向量经过 generator 得到的样本来自 P_G 。

哔哩哔哩 Bilibili

Sampling is good enough

$$G^* = \arg \min_G \text{Div}(P_G, P_{\text{data}})$$

Although we do not know the distributions of P_G and P_{data} , we can sample from them.



33

图 4: GAN 只需要能够从 P_{data} 和 P_G 采样: 真实资料来自 database, 生成资料来自 z 经过 generator。

7

2.1 把 Discriminator 看成二分类器

给定一个 generator, discriminator 的训练资料可以这样构造: 真实样本标为 class 1, 生成样本标为 class 2。于是 discriminator 变成一个 binary classifier。若用 $D(x)$ 表示样本来自真实资料的概率, 原始 GAN 中 discriminator 的目标是最大化

$$V(D, G) = \mathbb{E}_{x \sim P_{\text{data}}} [\log D(x)] + \mathbb{E}_{x \sim P_G} [\log(1 - D(x))].$$


等价地, 也可以写成 $z \sim P_z$:

$$\mathbb{E}_{z \sim P_z} [\log(1 - D(G(z)))].$$

⁷ 视频画面时间区间: 约 06:49–07:33; 字幕附近说明我们可以从 normal distribution sample 向量给 generator, 也可以从真实资料库 sample, 因此可在只能采样的前提下估计 divergence。

Discriminator $G^* = \arg \min_G \text{Div}(P_G, P_{data})$

★ : data sampled from P_{data} ★ : data sampled from P_G



Training: $D^* = \arg \max_D V(D, G)$

Objective Function for D

$$V(G, D) = E_{y \sim P_{data}} [\log D(y)] + E_{y \sim P_G} [\log(1 - D(y))]$$

$$D^* = \arg \max_D V(D, G)$$

negative cross entropy

=

Training classifier:
minimize cross entropy

图 5: Discriminator 的 objective 等价于训练 binary classifier: 真实样本为 class 1, 生成样本为 class 2, 最大化负 cross entropy。⁹

如果两个分布差异小, 真实样本和生成样本混在一起, 分类器很难分, 最佳 $V(D, G)$ 的值不会太大。若两个分布差异大, 分类器容易把它们分开, 最佳 objective 值就会变大。

⁹视频画面时间区间: 约 10:35-11:23; 字幕附近说明最大化该 objective 等同于最小化 cross entropy, 也就是训练一个二分类器。

Discriminator $G^* = \arg \min_G \text{Div}(P_G, P_{data})$

★ : data sampled from P_{data}

★ : data sampled from P_G

Training:

$$D^* = \arg \max_D V(D, G)$$



small divergence

train



hard to discriminate

$$\text{Small } \max_D V(D, G)$$

35

图 6: 当两组样本混在一起时, discriminator 难以区分, 最大 objective 值较小; 当两组样本很分离时, 最大 objective 值较大。¹¹

2.2 原始 GAN 的 Minimax 结构

在给定 G 时, 最强 discriminator 会达到

$$\max_D V(D, G).$$

这个最大值和 P_G 、 P_{data} 之间的 Jensen-Shannon divergence 有关。经典推导会得到

$$\max_D V(D, G) = -\log 4 + 2 \text{JS}(P_{data} \| P_G).$$

因此让 generator 最小化这个最大值, 就等价于让 P_G 靠近 P_{data} :

$$G^* = \arg \min_G \max_D V(D, G).$$

¹¹ 视频画面时间区间: 约 13:19–14:07; 字幕附近说明小 divergence 对应较小的 objective maximum, 大 divergence 对应容易分类和较大的 maximum。

$$G^* = \arg \min_G \max_D V(G, D)$$

$$D^* = \arg \max_D V(D, G)$$

The maximum objective value is related to JS divergence.

36

图 7: 原始 GAN 的互动可以写成 min-max 问题: 固定 G 时找最大化 $V(D, G)$ 的 D , 再找使该最大值最小的 G 。¹³

为什么 Discriminator 能提供训练信号

对固定 generator 来说, 最优 discriminator 的能力反映了两个分布的差异。Generator 更新时, 就是在尝试让 discriminator 越来越难分辨真实样本和生成样本。

2.3 本章小结

Discriminator 把分布比较转化为二分类任务。原始 GAN 中, 最优 discriminator 的 objective 与 JS divergence 有关, 因此 GAN 的 min-max 训练可以被理解为间接最小化生成分布和真实分布之间的 JS divergence。

3 为什么 JS Divergence 不适合

既然原始 GAN 和 JS divergence 有关, 为什么 GAN 仍然难训练? 本讲的关键解释是: 在高维真实资料中, P_G 和 P_{data} 往往几乎不重叠, 而 JS divergence 在非重叠分布上无法提供有用的距离信息。

¹³视频画面时间区间: 约 15:19–16:06; 字幕附近解释红框里的 $\max_D V(D, G)$ 是另一个 optimization problem, 而 generator 要让这个最大值最小。

JS divergence is not suitable

- In most cases, P_G and P_{data} are not overlapped.
- 1. The nature of data
- 2. Sampling

40

图 8: 课程指出 JS divergence 不适合的主要原因: 多数情况下 P_G 与 P_{data} 不重叠, 原因来自资料本身的低维结构和采样限制。¹⁵

3.1 高维资料常在低维流形上

真实图片虽然处在极高维像素空间中, 但自然图片只占其中极小一部分。随机像素几乎不可能是一张合理图片; 合理图片形成的集合更像嵌在高维空间中的低维流形。Generator 产生的图片也落在另一个低维流形上。两个低维流形在高维空间中随机相交的机会很小, 因此 P_G 和 P_{data} 常常没有重叠。

另一个原因是采样。即使真实分布和生成分布理论上有些重叠, 我们实际训练只看有限样本。有限样本在高维空间中非常稀疏, discriminator 很容易画出分界线把真实样本和生成样本完全分开。

3.2 非重叠时 JS 值恒定

JS divergence 有一个关键性质: 如果两个分布完全不重叠, JS divergence 就是常数 $\log 2$ 。这意味着两个生成分布只要都没和真实分布重叠, 不管一个离真实分布近、另一个离得远, JS divergence 都可能给出同样的值。

¹⁵ 视频画面时间区间: 约 18:17–18:56; 字幕附近说明原始 GAN 最小化 JS divergence, 但 P_G 和 P_{data} 的重叠部分往往非常少。

What is the problem of JS divergence?

JS divergence is always $\log 2$ if two distributions do not overlap.




41.

图 9: 只要两个分布没有重叠, JS divergence 就会是 $\log 2$, 无法区分「远一点」和「近一点」。¹⁶

¹⁶ 视频画面时间区间: 约 21:20–22:07; 字幕附近说明两个没有重叠的分布, JS divergence 算出来永远都是 $\log 2$ 。

What is the problem of JS divergence?

JS divergence is always $\log 2$ if two distributions do not overlap.



41.

图 10: 不同 generator 可能明显有好坏之分, 但若它们与真实分布都不重叠, JS divergence 会认为它们一样糟。¹⁸

这会直接破坏训练。若 loss 对许多 generator 都给出同样数值, gradient 就无法告诉 generator 应该往哪里移动。模型不是没有方向, 就是训练信号极不稳定。


3.3 分类器准确率也失去意义

从实际操作看, 若真实样本和生成样本总能被 binary classifier 完全分开, discriminator 的正确率每次都是 100%。这时你无法从 discriminator 的 loss 或 accuracy 看出 generator 有没有进步, 只能靠肉眼观察样本质量。

¹⁸ 视频画面时间区间: 约 22:47–23:24; 字幕附近说明中间的 generator 明明比左边更接近真实分布, 但从 JS divergence 看不出差别。

What is the problem of JS divergence?

JS divergence is always $\log 2$ if two distributions do not overlap.



Intuition: If two distributions do not overlap, binary classifier achieves 100% accuracy.

The accuracy (or loss) means nothing during GAN training.

41.

图 11: 当两个分布不重叠时, binary classifier 可以轻松达到 100% accuracy; 此时分类器 loss 对 GAN 训练不再提供有效进度信息。²⁰

JS divergence 的核心问题

JS divergence 在分布不重叠时饱和为常数。对 GAN 来说, 这表示「离真实分布很远」和「已经靠近但还没重叠」可能得到一样的训练信号。

3.4 本章小结

原始 GAN 理论上对应 JS divergence, 但高维资料分布常不重叠, 有限采样又会加剧不重叠。JS divergence 在不重叠时恒为 $\log 2$, 不能反映 generator 是否更接近真实分布, 因此训练信号容易失效。


4 Wasserstein Distance

为了解决 JS divergence 的饱和问题, 人们考虑使用其他衡量分布差异的方式。本讲重点介绍 Wasserstein distance, 也叫 Earth Mover distance。

²⁰ 视频画面时间区间: 约 25:35–26:23; 字幕附近说明若 classifier 每次正确率都是 100%, 就无法知道 generator 有没有越来越好。

4.1 土方距离直觉

把一个分布想象成一堆土，把另一个分布想象成目标地形。Wasserstein distance 衡量的是：平均要把土移动多远，才能把第一个分布变成第二个分布。




Source of image: <https://vincentherrmann.github.io/blog/wasserstein/> 43

图 12: Wasserstein distance 可理解为 earth mover distance: 把分布 P 重新搬运成分布 Q , 平均移动距离就是分布差异。²²

对于复杂分布，搬运方案不止一种。一个地方的质量可以搬到多个目标位置，多个来源也可以汇到同一目标。Wasserstein distance 不是随便选一个搬运方案，而是在所有可行 moving plans 中，选择平均搬运距离最小的那个。

²²视频画面时间区间：约 27:49–28:37；字幕附近说明 Wasserstein distance 又叫 earth mover distance，并用推土机搬运分布形状作类比。

Wasserstein distance



There are many possible “moving plans”.

Using the “moving plan” with the smallest average distance to define the Wasserstein distance.

Source of image: <https://vincentherrmann.github.io/blog/wasserstein/>

43

图 13: 同一对分布之间可能有许多 moving plans; Wasserstein distance 使用平均移动距离最小的方案。²⁴

数学上可写为

$$W(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \mathbb{E}_{(x, y) \sim \gamma} [\|x - y\|],$$


其中 $\Pi(P, Q)$ 表示所有边缘分布分别为 P 和 Q 的 joint distributions, 也就是所有合法搬运方案。

4.2 为什么它比 JS 更适合

Wasserstein distance 即使在两个分布不重叠时, 也能反映距离远近。若生成分布逐渐向真实分布移动, Wasserstein distance 会逐渐变小; JS divergence 则可能一直是 $\log 2$ 。

²⁴视频画面时间区间: 约 29:17–30:07; 字幕附近说明要穷举所有把 P 变成 Q 的 moving plan, 并选平均距离最短的方案。

What is the problem of JS divergence?



https://www.pnas.org/content/104/suppl_1/8567.figures-only

45

图 14: 即使分布不重叠, Wasserstein distance 仍能区分 generator 是否更接近真实分布, 从而提供连续的训练信号。²⁶

这正是 WGAN 想解决的问题: GAN 训练需要的不只是一个理论上的 divergence, 更需要一个能在训练早期提供有意义 gradient 的目标。

4.3 本章小结

Wasserstein distance 把分布差异看成搬运成本。它的优势是: 即使两个分布没有重叠, 也能根据距离远近给出不同数值。因此它比 JS divergence 更适合描述 GAN 训练中生成分布逐渐靠近真实分布的过程。

5 WGAN: 用 Critic 估计 Wasserstein Distance

直接计算 Wasserstein distance 需要解 optimal transport 问题, 成本不低。WGAN 使用 Kantorovich-Rubinstein duality, 把 Wasserstein distance 写成另一个优化问题:

$$W(P_{data}, P_G) = \max_{\|D\|_L \leq 1} [\mathbb{E}_{x \sim P_{data}} D(x) - \mathbb{E}_{x \sim P_G} D(x)].$$

这里的 D 不再是输出概率的 classifier, 而是 critic。它给真实样本高分、给生成样本低分, 两者期望差用来估计 Wasserstein distance。

²⁶ 视频画面时间区间: 约 31:04–31:27; 字幕附近说明若换成 Wasserstein distance, 就能看出 generator 由左向右越来越好。

WGAN

Evaluate Wasserstein distance between P_{data} and P_G

$$\max_{D \in 1\text{-Lipschitz}} \{E_{x \sim P_{data}}[D(x)] - E_{x \sim P_G}[D(x)]\}$$

46

图 15: WGAN 用一个受约束的 critic D 来估计 P_{data} 与 P_G 的 Wasserstein distance。²⁷

5.1 为什么需要 Lipschitz 约束

公式里的 $\|D\|_L \leq 1$ 是关键。若没有限制 D , critic 可以把真实样本分数推到无限大, 把生成样本分数推到无限小, objective 会发散。这样得到的最大值没有意义, 也不会是 Wasserstein distance。

²⁷视频画面时间区间: 约 34:35–35:22; 字幕附近直接给出 WGAN 的 optimization 形式, 并说明该值就是 P_{data} 与 P_G 的 Wasserstein distance。

WGAN

Evaluate Wasserstein distance between P_{data} and P_G

$$\max_{D \in \text{1-Lipschitz}} \{E_{x \sim P_{data}}[D(x)] - E_{x \sim P_G}[D(x)]\}$$

D has to be smooth enough.

Without the constraint, the training of D will not converge.




图 16: 若没有 Lipschitz 约束, critic 可把真实样本分数推到正无穷、生成样本分数推到负无穷, 训练不会收敛。²⁹

1-Lipschitz 的直觉是: D 不能变化得太剧烈。若两个样本在输入空间中很近, D 的输出不能差太多。这样 critic 的分数差才会反映空间距离, 而不是任意放大。

WGAN 中的 D 不是分类器

原始 GAN 的 discriminator 输出真假概率; WGAN 的 critic 输出实数分数。它不需要 sigmoid, 也不直接训练二分类 cross entropy。它的任务是估计两个分布的 Wasserstein 距离。

5.2 Generator 如何更新

WGAN 训练 critic 时, 最大化真实样本分数和生成样本分数的差:

$$\mathbb{E}_{x \sim P_{data}} D(x) - \mathbb{E}_{z \sim P_z} D(G(z)).$$

训练 generator 时, 固定 critic, 让生成样本获得更高分数, 也就是最小化 critic 估计出的分布差异。

5.3 本章小结

WGAN 用受 Lipschitz 约束的 critic 估计 Wasserstein distance。相比原始 GAN 的分类器, critic 提供更连续的距离信息; 但 Lipschitz 约束是必要条件, 否则优化目标会发散。


²⁹ 视频画面时间区间: 约 36:49–37:35; 字幕附近说明若不限制 D , real image 可被给无限大正值, generated image 给无限大负值, 因此必须加限制。

6 如何让 Critic 足够平滑

WGAN 的理论要求 critic 是 1-Lipschitz。实际训练时，如何强制神经网络满足这个限制，是一个重要工程问题。

6.1 Weight Clipping

原始 WGAN 使用 weight clipping：每次参数更新后，把 critic 的权重裁剪到区间 $[-c, c]$ 内。若某个权重大于 c ，设为 c ；小于 $-c$ ，设为 $-c$ 。


$$\max_{D \in 1\text{-Lipschitz}} \{E_{x \sim P_{data}}[D(x)] - E_{x \sim P_G}[D(x)]\}$$

- Original WGAN $\rightarrow$ Weight

Force the parameters w between c and $-c$

After parameter update, if $w > c$, $w = c$; if $w < -c$, $w = -c$

<https://arxiv.org/abs/1704.00028>

<https://arxiv.org/abs/1802.05957>

图 17: 原始 WGAN 用 weight clipping 粗略限制 critic；后续 improved WGAN 提出 gradient penalty，让梯度接近 1。³¹

Weight clipping 简单，但缺点明显。参数范围受限不等于函数一定满足 1-Lipschitz；过小的 c 会限制模型容量，过大的 c 又难以有效约束。因此它可以作为最初尝试，但不是理想解法。

6.2 Gradient Penalty 与 Spectral Normalization

Improved WGAN 提出 gradient penalty，直接约束 critic 对输入的梯度范数：

$$\lambda \mathbb{E}_{\hat{x}} (\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2.$$


常见做法是在真实样本和生成样本之间插值出 $\hat{x}$ ，要求这些点上的 gradient norm 接近 1。这样比单纯裁剪参数更贴近 Lipschitz 条件。

³¹ 视频画面时间区间：约 39:19–40:07；字幕附近说明原始 WGAN 把参数限制在 $[-c, c]$ ，但这只是粗糙处理，后来有 gradient penalty。

另一种方法是 spectral normalization。它通过控制每层权重矩阵的 spectral norm，让网络整体的 Lipschitz 常数受到控制。课程提到，若要训练较好的 GAN，这类方法往往很有用。

$$\max_{D \in 1-Lipschitz} \{E_{x \sim P_{data}}[D(x)] - E_{x \sim P_G}[D(x)]\}$$

- Original WGAN → Weight
 - Force the parameters w between c and $-c$
 - After parameter update, if $w > c$, $w = c$; if $w < -c$, $w = -c$
- Improved WGAN → Gradient Penalty



<https://arxiv.org/abs/1704.00028>
- Spectral Normalization → Keep gradient norm smaller than 1 everywhere

•
<https://arxiv.org/abs/1802.05957>

图 18: 改进方法包括 gradient penalty 和 spectral normalization: 前者让梯度接近 1, 后者控制各层权重的谱范数以限制函数斜率。³³

理论与实作之间的缝隙

理论上 critic 应该在每次 generator 更新前充分优化，但实践中通常只更新几步 critic，再更新 generator。WGAN 的公式提供方向，真实训练仍需要在计算量、稳定性和约束强度之间调参。

6.3 本章小结

WGAN 的关键是让 critic 近似满足 Lipschitz 条件。Weight clipping 简单但粗糙；gradient penalty 更直接约束梯度；spectral normalization 通过控制权重矩阵谱范数限制函数变化。这些技巧决定了 WGAN 理论能否在实际训练中发挥作用。

³³视频画面时间区间: 约 40:50–41:27; 字幕附近提到 improved WGAN、spectral normalization, 并说明训练高质量 GAN 可能需要这些技巧。

7 总结与延伸

本讲从理论上解释了 GAN 的训练。原始 GAN 的 discriminator 可以被看成估计 JS divergence 的二分类器；但在高维资料中，真实分布和生成分布常常不重叠，JS divergence 会饱和，导致训练信号失效。Wasserstein distance 即使在非重叠时也能反映距离，因此 WGAN 用 critic 估计 Wasserstein distance，给 generator 更有意义的优化方向。

7.1 核心公式回顾

对象	公式	含义
生成分布目标	$G^* = \arg \min_G \text{Div}(P_G, P_{\text{data}})$	让生成分布接近真实分布。
原始 GAN	$\min_G \max_D V(D, G)$	最优 D 的值与 JS divergence 有关。
JS 问题	非重叠时 $\text{JS} = \log 2$	无法区分近与远。
Wasserstein	$W(P, Q) = \inf_{\gamma} \mathbb{E} \ x - y\ $	最小平均搬运距离。
WGAN dual	$\max_{\ D\ _L \leq 1} \mathbb{E}_{P_{\text{data}}} D - \mathbb{E}_{P_G} D$	用受约束 critic 估计 Wasserstein distance。

表 1: 本讲公式主线。

7.2 理解路径

第一，不要把 GAN 只记成「两个网络互相骗」。更准确地说，discriminator/critic 是分布差异的估计器，generator 根据这个估计器提供的信号更新。

第二，原始 GAN 难训练不是偶然。高维资料分布不重叠时，JS divergence 不能提供渐进信号；这解释了为什么过去训练 GAN 常要靠大量经验和人工观察。

第三，WGAN 的贡献不是简单换一个 loss，而是换了分布距离，并通过 Lipschitz critic 让这个距离可以被神经网络估计。后续的 weight clipping、gradient penalty、spectral normalization 都是在解决「如何让 critic 满足约束」这个问题。

带走的判断

原始 GAN 用分类器判断真假，WGAN 用 critic 衡量距离。前者在分布不重叠时容易饱和，后者在不重叠时仍能给出远近信息。理解这一点，就理解了 WGAN 为什么会成为 GAN 训练稳定化的重要里程碑。

7.3 延伸

继续学习 GAN 理论时，可以沿三条线深入：一是不同 divergence 和 probability metric 的性质，例如 KL、reverse KL、JS、Total Variation、Wasserstein；二是 Lipschitz 约束的实现，例如 gradient penalty、spectral normalization、orthogonal regularization；三是训练动态和收敛问题，也就是 min-max optimization 本身为什么难。

本讲的主线可以浓缩为一句话：GAN 的困难不只是生成器不够强，而是训练信号本身可能不可靠；WGAN 通过更合适的分布距离，让「越来越接近真实资料」这件事在 loss 上也看得见。