

生成式对抗网络 GAN (三)

生成器效能评估与条件式生成



基于李宏毅老师《机器学习》课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 49 分钟

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=20>

目录

1 为什么 GAN 仍然难以训练	4
1.1 两方互动不是普通监督学习	4
1.2 训练技巧有用，但不是银弹	5
1.3 本章小结	5
2 GAN 用于序列生成的特殊困难	5
2.1 把 decoder 看成 generator	5
2.2 为什么不能简单类比 CNN 的 max pooling	7
2.3 强化学习式处理：能做，但更难	8
2.4 本章小结	8
3 更多生成模型与 latent optimization	9
3.1 为什么课程仍以 GAN 为主	9
3.2 能否用 supervised learning 训练 generator	9
3.3 本章小结	10
4 Generator 的质量评估	11
4.1 人类评估的问题	11
4.2 用分类器置信度估计图像质量	11
4.3 Mode collapse: 高质量但低多样性	12
4.4 Mode dropping: 更隐蔽的覆盖不足	13
4.5 Diversity 与 Inception Score	14
4.6 本章小结	15
5 FID 与评估指标的陷阱	15
5.1 从图片到 feature vector	16
5.2 FID 的优点与限制	17
5.3 大规模比较: Are GANs Created Equal?	18
5.4 Memory GAN: 低 FID 的反例	18
5.5 本章小结	19
6 Conditional Generation: 让生成结果可控	20
6.1 Text-to-image 的基本设定	20
6.2 为什么 discriminator 也必须看条件	21
6.3 负样本不只是假图，还包括错配图	22
6.4 本章小结	23

7 Image Translation 与更多条件生成应用	23
7.1 Image-to-image translation 与 pix2pix	24
7.2 Sound-to-image: 声音作为条件	25
7.3 Talking head generation	26
7.4 从 paired data 到 unpaired data	27
7.5 本章小结	27
8 总结与延伸	27

1 为什么 GAN 仍然难以训练

上一讲从理论上解释了原始 GAN、WGAN、gradient penalty 与 spectral normalization 等稳定化手段。本讲开头先强调一个现实判断：即使有了这些方法，GAN 也仍然以难训练闻名。难点不只是某个 loss 不好调，而是 generator 与 discriminator 之间存在高度耦合的共同演化关系。

Discriminator 的任务是区分真实图片与生成图片；generator 的任务是产生足以欺骗 discriminator 的假图片。两者的能力必须接近，训练过程才会持续提供有效信号。如果 discriminator 太弱，generator 不需要真正进步就能得到高分；如果 discriminator 太强，generator 看到的梯度可能贫乏或不稳定；如果其中一方在某一步没有继续改善，另一方也会失去可学习的目标。




图 1: GAN 的训练依赖 generator 与 discriminator 互相匹配、互相推动；任何一方停止进步，另一方也容易跟着停滞。²

1.1 两方互动不是普通监督学习

普通监督学习常常可以用一个固定资料集、固定标签和固定 loss 来描述。虽然也会遇到学习率、初始化、正则化等问题，但模型面对的目标至少相对稳定。GAN 则不同：discriminator 的决策边界会随着 generator 改变；generator 的训练信号又来自当前版本的 discriminator。换言之，训练目标本身是动态的。

这带来几个实践后果：

- **超参数敏感。**不是只调一次网络就结束，generator 与 discriminator 的学习率、更新频率、batch

²视频画面时间区间：约 01:18–03:45；字幕说明 discriminator 若不能分辨真伪，generator 失去改善目标，而 generator 若不能产生更真实图片，discriminator 也无法继续进步。

size、正则化强度都可能影响互动节奏。

- **短期 loss 不一定等于生成质量。** Discriminator loss 或 generator loss 的下降可能只是对方变弱或进入某种局部策略，并不保证样本更好。
- **失败会连锁传播。** 其中一方的训练失败会改变另一方看到的环境，进而让整体过程偏离目标。

GAN 难训的本质

GAN 的困难不只是“network 很深”或“loss 很难优化”。更核心的是：它要同时维持两个模型的竞争平衡。一个模型的训练品质会立刻改变另一个模型的训练信号，因此训练 GAN 更像是在控制一个互动系统，而不是单独最小化一个静态函数。

1.2 训练技巧有用，但不是银弹

课程提到，网络上可以找到大量 GAN training tips。它们当然可能有用，例如使用 spectral normalization、调整 discriminator 更新次数、使用较大的 batch、做 label smoothing 或 data augmentation 等。但这些技巧的效果往往依赖资料、架构和目标，不一定可以机械套用。对学习者来说，更重要的是理解为什么这些技巧可能有帮助：它们通常都在试图维持梯度、限制 discriminator 过强、改善两方更新节奏，或避免生成分布坍塌。

1.3 本章小结

GAN 的训练不是 generator 单方面变好，也不是 discriminator 单方面变强，而是两者必须保持适当张力。课程用“棋逢敌手”来形容这个关系：一方太弱、太强或突然停滞，都会让另一方失去有效学习信号。这也解释了为什么后面讨论评估指标时，不能只看一两个训练曲线，而必须回到生成样本的质量、多样性和泛化能力。

2 GAN 用于序列生成的特殊困难

图像生成中，generator 输出连续像素值，discriminator 的分数可以沿着网络反向传播回 generator。序列生成表面上也可以套用 GAN：用 decoder 当 generator 产生文字，再用 discriminator 判断文本是真实语料还是生成语料。然而在真正训练时，离散 token 会让反向传播变得困难。

2.1 把 decoder 看成 generator

在语言生成任务中，decoder 每一步输出一个 token 的机率分布，再通过 sampling、argmax 或 beam search 等方式得到实际 token。GAN 的高层流程仍然类似：discriminator 读入一段文字并给分；decoder/generator 调整参数，希望生成的文字被 discriminator 判断为真实文字。

GAN for Sequence Generation




图 2: 序列生成中的 GAN: decoder 产生 token 序列, discriminator 对整段序列给分, generator 希望提高这个分数。⁴

如果只看这个流程, 序列 GAN 和图像 GAN 的差异似乎不大。但关键问题出现在“从机率分布到离散 token”的步骤。Generator 参数发生微小变化时, 输出分布可能也只发生微小变化; 只要最大机率的 token 没变, discriminator 看到的离散序列就完全没变, 输出分数也不会变。于是 generator 的小变化无法反映到目标函数上, 梯度就难以定义或几乎没有信号。

⁴视频画面时间区间: 约 04:48–05:41; 字幕说明 decoder 扮演 generator, discriminator 判断文字是真实语料还是机器产生。




图 3: 离散 token 选择使序列 GAN 难以直接微分: 分布有小变化, 但 argmax 后 token 不变, discriminator 的输入和输出也不变。⁶

2.2 为什么不能简单类比 CNN 的 max pooling

课程中留下了一个思考问题: CNN 里也有 max pooling, 为什么仍可以训练? 关键在于 max pooling 虽然不可处处微分, 但在多数位置可以把梯度传给当前最大值所在的输入单元; 它仍在连续张量内部传递数值。序列生成的 token 选择则更像从连续机率分布跳到离散符号, 符号一旦确定, 后续 discriminator 看到的是类别编号或嵌入后的离散选择。这个离散选择把“参数的小变化”截断了。

更准确地说, 问题不只是“max”这个操作本身, 而是生成文本通常涉及从分布中取样或选取符号。取样动作的输出不是连续可微的像素, 而是某个 token 的身份。除非使用 Gumbel-Softmax、straight-through estimator、policy gradient 或其他估计方法, 否则很难把 discriminator 的分数稳定传回 token 选择之前的 decoder 参数。

序列 GAN 的常见误解

不能把“有 max 所以不能训练”理解得太粗糙。真正的障碍是离散符号选择使 generator 的连续参数变化无法平滑地反映到 discriminator 输入上。连续图像像素的小变化会被 discriminator 看见; 离散 token 的小概率变化经常在取样后被抹掉。

⁶视频画面时间区间: 约 07:04–07:56; 字幕说明 decoder 参数微调后最大 token 可能不变, 导致 discriminator 分数不变, 无法直接做 gradient descent。

2.3 强化学习式处理：能做，但更难

一种常见做法是把序列生成当作 reinforcement learning 问题：generator 是 policy，每一步选 token 是 action，discriminator 最后的分数是 reward。这样不需要直接对 token 选择微分，而是用 policy gradient 等方法估计“选择某个 token 对最终 reward 的影响”。

课程的评价很直接：reinforcement learning 本来就难训，GAN 也难训，两者相加会非常困难。这也是为什么语言 GAN 很长一段时间通常需要预训练。先用最大似然或其他监督方式让 decoder 有基本语言能力，再用 adversarial objective 微调，会比从随机初始化开始可靠得多。



GAN for Sequence Generation

- Usually, the generator are fine-tuned from a model learned by other approaches.
- However, with enough hyperparameter-tuning and tips, ScrachGAN can train from scratch.

Training language
GANs from Scratch
<https://arxiv.org/abs/1905.09922>




图 4: ScrachGAN 标榜可以从随机初始化训练 language GAN，但课程强调其成功依赖大量超参数搜索和技巧。⁸


2.4 本章小结

GAN 应用于序列生成时，最大的额外困难来自离散 token。图像 GAN 可以把 discriminator 的梯度传回连续像素输出；文本 GAN 在 sampling 或 argmax 后，generator 参数的小变化可能不会改变实际 token，从而让梯度消失或难以估计。强化学习方法可以绕过不可微操作，但会引入更高方差和更困难的训练问题。因此，序列 GAN 往往需要预训练、技巧和大量调参。

⁸视频画面时间区间：约 09:19–10:20；字幕提到 ScrachGAN 可从 scratch 训练 language GAN，但关键在于大量调参和多种 training tips。

3 更多生成模型与 latent optimization

课程在 GAN 之后短暂提到其他生成模型，例如 VAE 与 flow-based model。这里的重点不是展开这些模型，而是说明：生成模型并不只有 GAN 一条路线；选择 GAN 是因为它在高质量图像生成上曾长期表现突出，但这不意味着其他模型更容易训练或不重要。



54

图 5: 除了 GAN，课程也指出 VAE 与 flow-based model 是重要的生成模型分支，可作为进一步学习方向。¹⁰

3.1 为什么课程仍以 GAN 为主

从课程定位看，讲 GAN 的原因有两层。第一，GAN 是许多图像生成系统的关键思想，理解 generator/discriminator 互动对于后续学习 diffusion、adversarial training 和表示学习也有帮助。第二，GAN 在图像品质上曾经具有很强的代表性。课程提到，VAE 或 flow-based model 也可以生成图像，但若目标是非常锐利、逼真的图像，传统上 GAN 的表现往往更突出。

这并不表示 VAE 或 flow-based model 比 GAN 简单。它们有较明确的 likelihood 或变换结构，但实践中也需要平衡多个 loss 项、架构限制和数值稳定性。“看起来目标函数比较明确”不等于“训练一定容易”。

3.2 能否用 supervised learning 训练 generator

课程提出一个自然疑问：既然 generator 是把随机向量 z 变成图片，能不能直接给每张训练图片随机配一个 latent vector，然后用 supervised learning 训练一个网络，让它从该 vector 重建对应图片？

¹⁰ 视频画面时间区间：约 11:33–12:25；字幕说明若想深入研究生成模型，可以继续学习 VAE 与 flow-based model。

形式上，这可以写成

$$\min_{\theta, \{z_i\}} \sum_{i=1}^N \ell(G_{\theta}(z_i), x_i),$$

其中 x_i 是第 i 张训练图片， z_i 是分配给它的 latent code， G_{θ} 是生成网络， ℓ 可以是像素重建误差或感知误差。

如果 z_i 完全随机且固定，模型很可能训练不好：latent 空间没有结构，相邻 latent 不一定对应相近图片，网络要学习的是一堆任意配对。较合理的方向是同时优化 latent code 与 generator，或设计特殊方法安排 latent 空间，这类思想对应 Generative Latent Optimization (GLO) 等工作。




图 6: Latent optimization 的思路：为训练图片安排或优化 latent vector，再训练网络从 latent vector 生成对应图片。¹²

latent space 需要结构

一个好的生成模型不只是记住“某个向量对应某张图”。它还希望 latent 空间具有可插值、可采样、可泛化的结构：相近的 z 生成相近语义，随机采样的 z 大概率落在合理区域。若 latent code 与图像只是任意配对，模型可能只是在背表，而不是学到可用的生成分布。

3.3 本章小结

GAN 是生成模型的重要路线，但不是唯一路线。VAE、flow-based model 和 latent optimization 都从不同角度处理“如何从简单分布产生复杂资料”的问题。课程在这里提醒我们：生成模型的核心不是某个固定架构，而是如何建立一个可采样、可泛化、可评价的分布映射。

¹² 视频画面时间区间：约 13:36–15:17；字幕讨论能否用 supervised learning 训练 generator，并指出需要特殊方法安排 latent vectors，例如 GLO 与 Gradient Origin Networks。

4 Generator 的质量评估

训练出 generator 之后，下一步问题是：如何判断它好不好？这比分类任务困难得多。分类可以看 accuracy，回归可以看误差；生成任务没有唯一标准答案。一张生成图是否“好”，既涉及视觉质量，也涉及多样性、语义覆盖、是否抄袭训练资料，以及是否符合条件。

4.1 人类评估的问题

最直觉的做法是找人看生成图片。早期生成模型论文常常在最后展示几张图片，用视觉效果说服读者。但这有明显问题：

- **昂贵**。大规模人工评分需要成本。
- **不稳定**。不同评审者标准不同，同一评审者在不同时间也可能偏好变化。
- **不公平**。作者可能挑选最好看的样本，读者看到的是 cherry-picked 结果。
- **难比较**。不同论文展示的图片数量、数据集、训练预算不同，仅靠肉眼很难做严谨比较。


因此需要自动化指标。课程先从“用现成图像分类器判断单张图质量”讲起。

4.2 用分类器置信度估计图像质量

假设有一个已经训练好的图像分类器，例如 Inception Net 或 VGG。把 generator 产生的图片 y 输入分类器，得到类别分布 $P(c|y)$ 。如果这个分布很集中，说明分类器很确定这张图像属于某个类别，图像可能比较清楚、像真实物体；如果分布很平坦，说明分类器困惑，图像可能模糊、混乱或不像任何真实类别。

Quality of Image

- Human evaluation is expensive (and sometimes unfair/unstable).
- How to evaluate the quality of the generated images automatically?



58

图 7: 用现成图像分类器评估单张生成图质量: 类别分布越集中, 通常表示分类器越确信图中对象, 视觉质量可能越高。¹⁴

这个想法可以捕捉“单张图是否清楚”, 但它并不能判断 generator 是否覆盖了真实分布的多样性。一个 generator 如果只会产生一类非常清楚的图片, 分类器也会给出高置信度; 但这样的 generator 并不理想。

4.3 Mode collapse: 高质量但低多样性

Mode collapse 指 generator 反复产生少数几种样本。单看一张样本可能不错, 但生成一批样本后会发现来来去去都是相似结果。课程用二次元头像例子说明: 训练到后期, 某一张脸越来越多, 最后几乎所有输出都变成同一张脸, 只是在发色等局部属性上变化。

¹⁴视频画面时间区间: 约 17:35–19:07; 字幕说明将生成图片输入图像分类系统, 若输出分布集中, 代表分类器较确信图像内容, 可能表示质量较高。

Diversity - Mode Collapse



图 8: Mode collapse: 生成分布集中在真实分布的一小块区域, 单张样本可能看起来不错, 但整体多样性严重不足。¹⁶

直觉上, mode collapse 可以理解为 generator 找到了 discriminator 的某个盲点。只要某类样本能稳定骗过 discriminator, generator 就可能反复利用这条策略, 而不是覆盖整个真实分布。课程还提到, 即使是强大的模型和大量调参, 也未必能完全避免 collapse; 有些实践只能通过保存 checkpoint, 在 collapse 发生前停止训练。

高置信度不代表好 generator


如果 generator 只产生一张非常清楚的图片, 分类器可能每次都非常确信, 质量指标看起来不错。但生成模型真正追求的是分布匹配: 既要单张样本像真图, 也要整体样本覆盖真实资料的变化范围。

4.4 Mode dropping: 更隐蔽的覆盖不足

Mode dropping 比 mode collapse 更难发现。Collapse 往往肉眼可见: 输出一批图, 发现都差不多。Mode dropping 则可能生成一批看起来多样的样本, 但只覆盖了真实资料的一部分。例如生成的人脸有男女、左右朝向等变化, 看似丰富; 下一轮或更仔细观察后才发现肤色、年龄、姿态或其他属性范围明显不足。

¹⁶ 视频画面时间区间: 约 19:19-20:32; 字幕说明 generator 可能只会产生少数几张图, 二次元头像训练中会出现同一张脸越来越多的现象。

Diversity - Mode Dropping



60

图 9: Mode dropping: 生成资料看起来有变化, 但只覆盖真实资料分布的一部分, 遗漏某些重要属性或族群。¹⁸

从评估角度看, mode dropping 提醒我们: 只看生成样本内部的多样性还不够, 还要比较它与真实数据分布的覆盖关系。一个生成器可以在一个子分布内变化丰富, 却完全忽略另一个真实子分布。

4.5 Diversity 与 Inception Score

为了量化多样性, 可以让 generator 产生许多图片 $y^1, \dots, y^N$, 分别送入分类器得到 $P(c|y^n)$, 再对这些分布取平均:

$$P(c) = \frac{1}{N} \sum_{n=1}^N P(c|y^n).$$

这里 $P(c|y^n)$ 是第 n 张生成图片的类别分布, $P(c)$ 是整批生成图片的平均类别分布, N 是生成图片数量。

如果平均后的 $P(c)$ 很平坦, 说明生成图片覆盖了很多类别, 多样性可能较高; 如果 $P(c)$ 很集中, 说明大多数图片都被分类器判为同一类别, 多样性可能较低。Inception Score 将单张图片的高置信度和整体类别分布的高多样性结合起来, 常见写法是

$$IS = \exp \left(\mathbb{E}_{y \sim P_G} \text{KL}(P(c|y) \| P(c)) \right).$$

其中 P_G 是 generator 诱导的生成分布, KL 衡量单张图片类别分布与整体平均类别分布之间的差异。好的情况是: 单张图片的 $P(c|y)$ 集中, 表示质量高; 整批图片的 $P(c)$ 分散, 表示多样性大, 因

¹⁸ 视频画面时间区间: 约 22:19–23:56; 字幕用人脸生成例子说明 mode dropping 可能隐藏在看似合理的多样性之下, 例如肤色覆盖不足。

此 KL 值较大, IS 较高。




图 10: 用分类器输出估计多样性: 单张图要有集中分布, 整批图的平均分布要尽量均匀; Inception Score 试图综合这两点。²⁰

但课程也指出, Inception Score 不一定适合所有任务。若作业目标是生成二次元头像, 把它们丢进 ImageNet 训练的 Inception Net, 输出类别可能并不能反映发色、眼睛、脸型等真正关心的变化。指标依赖分类器, 而分类器的类别体系可能与生成任务的语义不匹配。

4.6 本章小结

Generator 评估至少要同时考虑质量与多样性。分类器置信度可以估计单张图是否清楚, 但会被 mode collapse 欺骗; 平均类别分布可以估计多样性, 但依赖分类器类别是否适合任务。Inception Score 把两者合并, 却仍有任务适配问题。生成模型评估的核心难题在于: 我们想评价的是一个分布, 而不是某几张好看的样本。

5 FID 与评估指标的陷阱

课程接着介绍作业中会使用的 Fréchet Inception Distance (FID)。FID 是今天生成模型论文中很常见的指标之一。它不直接看分类器最后输出的类别, 而是取分类器中间层特征, 将真实图片与生成图片映射到同一 feature space 后比较两组特征分布。

²⁰ 视频画面时间区间: 约 24:33-26:48; 字幕说明平均分类分布越均匀代表多样性越大, 并提到 Inception Score 结合 quality 与 diversity。

5.1 从图片到 feature vector

把一张图片送入 Inception Network，不取 softmax 后的类别，而取进入 softmax 前的 hidden representation。这个向量通常有上千维，可以看成对图片内容的高层语义表示。即使两张图片最后都被分类为“人脸”，它们在这个 feature vector 上仍可能因为发色、姿态、细节不同而分开。



<https://arxiv.org/pdf/1706.08500.pdf>

Fréchet Inception Distance (FID)




图 11: FID 不使用最后分类类别，而是使用 Inception Network 的中间层特征向量表示图片。²¹

对真实图片集合得到一组特征向量，对生成图片集合也得到一组特征向量。FID 将这两组高维特征分别近似为高斯分布：

$$f(x_{\text{real}}) \sim \mathcal{N}(\mu_r, \Sigma_r), \quad f(x_{\text{gen}}) \sim \mathcal{N}(\mu_g, \Sigma_g).$$

其中 $f(\cdot)$ 是特征抽取网络， μ_r, Σ_r 是真实图片特征的均值与协方差， μ_g, Σ_g 是生成图片特征的均值与协方差。

FID 的常见公式为

$$\text{FID} = \|\mu_r - \mu_g\|_2^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2}).$$

公式中的第一项比较两组特征中心是否接近，第二项比较两组特征协方差形状是否接近。FID 是距离，越小表示生成特征分布越接近真实特征分布。

²¹ 视频画面时间区间：约 27:17–28:09；字幕说明将生成图片送入 Inception Network，取进入 softmax 之前的 hidden layer 输出作为图片表示。

Fréchet Inception Distance (FID)




图 12: FID 将真实图像与生成图像的特征分别拟合为高斯分布，并计算两者的 Fréchet distance；数值越小通常越好。²³

5.2 FID 的优点与限制

FID 相比 Inception Score 有一个重要优点：它直接比较真实资料与生成资料，而不是只看生成资料自己的分类结果。这样可以更好地捕捉分布偏移。若生成图片虽然清楚但与真实图片的整体 feature distribution 不一致，FID 会变大。

但 FID 也有明显假设和限制：

- **高斯假设。** FID 假设 feature vectors 可以用高斯分布近似。真实特征分布未必高斯，这只是实用近似。
- **样本量需求。** 均值和协方差估计需要大量样本。样本太少时，FID 波动会很大。
- **特征抽取器依赖。** FID 依赖 Inception 或其他网络的表示。如果特征抽取器与任务不匹配，指标也会偏。
- **不能检测所有失败。** FID 低不代表 generator 一定真正学到了生成机制。

课程提到作业不会只看 FID，还会结合动画人脸侦测数量等任务特定指标。这个设计体现了一个原则：生成模型评估常常需要多个互补指标，单一指标容易被钻空子。

²³视频画面时间区间：约 28:42–30:58；字幕说明红点是真实图片特征、蓝点是生成图片特征，FID 计算两组高斯之间的距离，且需要大量 samples 才较稳定。

5.3 大规模比较: Are GANs Created Equal?

课程引用 “Are GANs Created Equal? A Large-Scale Study” 说明不同 GAN objective 的比较。该研究在多个数据集上测试不同 GAN 方法, 并用不同 random seed 得到分布式结果。图中每个方法不是一个点, 而是一段分布, 表示不同随机种子和训练设置会带来显著差异。




图 13: 不同 GAN 方法在多组数据集上的 FID 分布比较; 课程提醒不能从图中简单得出 “所有 GAN 都一样” 的结论。²⁵


这里有两个值得注意的结论。第一, GAN 方法在不同 random seed 下差异很大, 训练稳定性本身就是重要指标。第二, 课程提醒不能把研究标题理解为 “所有 GAN 研究都没有意义”。如果实验固定了网络架构, 只搜索 random seed 和 learning rate, 那么结果可能无法反映某种 GAN objective 在其他架构下的优势。例如 WGAN 早期强调对网络架构更鲁棒, 这类性质未必能从单一架构比较中完全看出来。

5.4 Memory GAN: 低 FID 的反例

评估指标最危险的地方是: 模型可能优化了指标, 却没有完成我们真正想要的任务。课程用 memory GAN 说明这一点。如果 generator 只是把训练资料背下来, 甚至直接输出与训练集一样的图片, 那么生成分布与真实训练分布会非常接近, FID 可能很小。但这显然不是我们想要的 generator, 因为训练资料本来就在手上, 直接从训练集 sample 就可以得到同样结果。

²⁵ 视频画面时间区间: 约 31:05–33:58; 字幕讨论该研究比较多种 GAN objective、random seed 与 learning rate, 并提醒网络架构固定会影响结论解释。

We don't want memory GAN.



65

图 14: Memory GAN 的评估陷阱: 若生成图片直接复制或简单翻转训练资料, FID 可能很小, 但模型没有真正学会产生新的样本。²⁷

进一步地, 课程还提出“左右翻转”的情况: 如果 generator 学到把所有训练图片水平翻转, 肉眼看起来合理, FID 也可能不错, 简单的逐图相似度检查却不一定发现它只是做了固定变换。这说明生成模型评估不仅要看距离, 还要看新颖性、覆盖性、语义合理性和任务目标。

评估指标的正确使用方式

指标不是目标本身, 而是目标的代理。FID、Inception Score、人脸检测数量都只能观察生成质量的一部分。真正可靠的评估往往需要: 自动指标、人工检查、训练集相似度分析、条件匹配检查、下游任务验证等多种证据一起使用。

5.5 本章小结

FID 通过比较真实图片与生成图片在 feature space 中的高斯分布, 提供了比单纯分类置信度更有力的分布级评估。但它仍依赖高斯近似、样本数量和特征抽取器, 也无法保证模型没有记忆训练集。生成模型评估本身就是研究问题; 低指标值只能说明模型在某个代理指标上表现好, 不能自动等价于真正优秀的 generator。

²⁷ 视频画面时间区间: 约 34:34–36:09; 字幕指出若生成资料与真实资料相同或只是左右翻转, FID 与相似度检查都可能无法完整揭示问题。

6 Conditional Generation: 让生成结果可控

到目前为止, generator 的输入主要是随机向量 z 。这能产生多样样本, 却不方便控制输出。Conditional generation 要解决的是: 给定条件 x , 例如文字描述、类别标签、草图、声音或另一张图片, 让 generator 根据条件与随机向量一起生成目标 y 。

6.1 Text-to-image 的基本设定

以文字生图为例, 条件 x 可以是 “red eyes”、“red hair, green eyes” 等文字描述, 随机向量 z 控制同一条件下的变化。模型希望学到:

$$y = G(x, z).$$

其中 x 是条件, z 是随机噪声, y 是生成图片。固定 x 、改变 z , 应该得到不同但都符合条件的图片; 固定 z 、改变 x , 输出语义应该跟着条件改变。




图 15: Text-to-image 条件生成: 文字条件控制属性, 随机向量 z 控制同一属性下的具体样貌变化。
29

文字如何输入 generator 并没有唯一标准。传统做法可能用 RNN 编码文字, 再把向量传入 generator; 今天也可以使用 transformer encoder, 将文字编码成向量或 token features。课程强调的是概念: 只要 generator 能读入条件并利用条件, 具体编码方式可以随模型设计变化。

²⁹ 视频画面时间区间: 约 37:06–39:05; 字幕说明输入红眼睛、红发绿眼等条件时, 模型应产生符合条件但彼此不同的角色。



Conditional GAN



图 16: Conditional generator 的形式化表示：由条件 c 和随机向量 z 共同决定输出 $y = G(c, z)$ 。³⁰

6.2 为什么 discriminator 也必须看条件

如果 discriminator 只看图片 y ，它只能判断图片是否真实，不能判断图片是否符合条件。这样 generator 可能学会无视 x ：不管输入什么文字，都产生一张清晰好看的图片，只要能骗过 discriminator 就行。这显然不是 conditional generation 的目标。

因此 conditional GAN 中 discriminator 也要读入条件，形式上可以写为 $D(x, y)$ 。它输出的分数不只是“图片像不像真实图片”，还包括“图片与条件是否匹配”。只有当图片真实且符合条件时，discriminator 才应该给高分。

³⁰视频画面时间区间：约 39:05–39:18；字幕说明 conditional GAN 中 generator 有两个输入：从 normal distribution sample 的 z 与文字条件 x 。

Conditional GAN




图 17: Conditional discriminator 同时读入条件 x 与图片 y , 判断图片是否真实以及是否与条件匹配。³²

一个基本的 conditional GAN objective 可以写成:

$$\min_G \max_D \mathbb{E}_{(x,y) \sim P_{\text{data}}} [\log D(x, y)] + \mathbb{E}_{x \sim P_{\text{data}}, z \sim P_z} [\log(1 - D(x, G(x, z)))].$$

这里第一项让真实配对 (x, y) 得到高分, 第二项让生成配对 $(x, G(x, z))$ 得到低分, 而 generator 试图让第二项中的生成图片骗过 discriminator。

6.3 负样本不只是假图, 还包括错配图

课程特别强调, 实作上只用“真实配对为正、生成图片为负”往往不够。Discriminator 还需要看到另一类负样本: 图片本身是真实图片, 但文字条件与图片不匹配。例如图片是黄头发角色, 却配上“red eyes”或其他不对应描述。这样 discriminator 才会真正学习条件匹配, 而不是只学习图片真假。

³²视频画面时间区间: 约 40:19–41:10; 字幕说明只看图片的 discriminator 会让 generator 忽略文字条件, 因此 discriminator 必须同时看 x 与 y 。

Diagram illustrating the GAN architecture:

Generator (G): Takes input x (Red eyes) and a latent variable z (Normal distribution) as inputs. It outputs an Image $y = G(c, z)$.

Discriminator (D): Takes inputs y (Image) and x (Text) as inputs. It outputs a scalar, which is interpreted as "y is realistic or not + x and y are matched or not".

True text-image pairs:

- (red eyes,) 1
- (red eyes,) 0

条件生成的核心约束

Conditional GAN 的目标不是“生成一张好图”，而是“生成一张既好又符合条件的图”。因此 discriminator 必须评估两个维度：视觉真实性与条件一致性。错配负样本是让 discriminator 学会第二个维度的关键。

Conditional generation 让 generator 从无条件采样变成可控生成。Generator 接收条件 x 与随机变量 z , discriminator 也必须同时接收 x 与 y , 否则 generator 会无视条件。训练时除了真实配对和生成负样本, 还需要真实图片与错误条件组成的错配负样本, 才能逼迫模型学习条件语义。

Conditional generation 不只用于文字生图，也可以用于图像到图像、声音到图像、甚至静态头像到动态说话头的生成。共同点是：输入条件提供约束，随机性或模型内部表示提供变化空间。

³⁴ 视频画面时间区间：约 41:50-42:50；字幕说明除了 positive examples 与生成图片负样本，还应加入文字和真实图片乱配的负样本。

7.1 Image-to-image translation 与 pix2pix

在 image-to-image translation 中, 条件 x 本身是一张图片, 输出 y 是另一种风格或模态的图片。例如建筑平面图到外观图、黑白图到彩色图、素描到真实照片、白天到夜晚、有雾到无雾等。Pix2pix 是这类 supervised image translation 的经典例子。

若只用 supervised learning, 例如最小化像素级 L_1 或 L_2 误差, 输出常常模糊。原因是同一个输入可能对应多个合理输出, 像素误差会鼓励模型预测这些可能性的平均值, 而平均值在图像上往往就是模糊结果。




图 19: Image translation 可以用 supervised learning 做, 但单独使用像素损失时输出容易模糊, 因为多个合理答案被平均。³⁶

GAN 的 discriminator 可以补上“看起来像真实图片”的约束。对于 pix2pix, discriminator 同时看输入条件图和输出图, 判断这对图片是否真实匹配。这样 generator 不只要接近标准答案, 还要产生视觉上锐利、真实的细节。

³⁶视频画面时间区间: 约 43:50–44:40; 字幕说明 image-to-image 可以用监督学习, 但文献中单纯监督学习常得到模糊输出。

Conditional GAN




图 20: Pix2pix 中的 discriminator 同时检查条件图片与生成图片；GAN loss 提升真实感，但通常还要结合监督损失避免过度想象。³⁸

课程指出，单独用 GAN 也有问题：generator 可能“想象力过度丰富”，生成输入中没有的结构。例如建筑图左上角没有东西，输出却在屋顶上加了类似烟囱或窗户的物体。实践中常把 adversarial loss 与 supervised loss 结合：

$$\mathcal{L}_G = \mathcal{L}_{\text{adv}} + \lambda \mathcal{L}_{\text{sup}}.$$

其中 $\mathcal{L}_{\text{adv}}$ 鼓励图片真实， $\mathcal{L}_{\text{sup}}$ 鼓励输出接近 paired ground truth， λ 控制两者权重。前者减少模糊，后者限制乱加内容。

7.2 Sound-to-image: 声音作为条件

声音也可以作为条件。视频天然提供音画配对资料：每一帧画面附近都有对应音频片段。收集大量视频后，可以训练 conditional GAN 根据声音想象画面，例如听到水声生成溪流或瀑布，听到快艇声生成水面快艇。

³⁸ 视频画面时间区间：约 45:19–46:10；字幕说明 GAN 输出更真实，但可能生成输入没有的细节，因此文献中常结合 GAN 与 supervised learning。

Conditional GAN

The images are generated by Chia-Hung Wan and Shun-Po Chuang.

https://wjohn1483.github.io/audio_to_scene/index.html




图 21: Sound-to-image 条件生成：声音强度变化可对应生成画面中的水花、速度感等视觉变化，但结果也可能不稳定。⁴⁰

这个例子说明条件生成不要求条件一定是标签或文字。只要存在可学习的配对关系，条件可以是文本、类别、图片、草图、语音、音乐、动作、深度图等。但条件越弱、配对噪声越大，模型越容易生成模糊或不可靠结果。

7.3 Talking head generation


课程最后展示了 talking head generation：给定一张静态肖像，让人物产生说话或表情变化。这里条件可以包括原始头像、驱动视频、关键点、语音或动作表示。它仍属于 conditional generation：输出不是任意视频，而是受输入身份和动作条件约束的视频。

⁴⁰ 视频画面时间区间：约 46:26–49:04；字幕说明可从视频中收集声音与画面配对资料，训练模型根据声音生成场景；课程也提醒有些结果是 cherry-picked，很多生成仍不知所云。



Conditional GAN

Talking Head Generation



<https://arxiv.org/abs/1905.08233>

图 22: Talking head generation: 以静态肖像或身份图像为条件, 生成具有动作或表情变化的图像序列。⁴²

7.4 从 paired data 到 unpaired data

本讲主要讨论 paired conditional generation, 也就是训练资料中有条件与目标的成对样本: 文字配图片、草图配照片、声音配画面。视频末尾转向下一主题 “Learning from Unpaired Data”。这预告了一个更困难的问题: 如果没有成对资料, 只有两个资料域各自的样本, 能否学习从一个域转换到另一个域? 这正是后续 CycleGAN 等方法要解决的方向。

7.5 本章小结

条件生成的应用范围很广。Image translation 说明 GAN 可以补足监督学习的模糊问题, 但也需要监督损失约束细节; sound-to-image 说明条件可以来自跨模态信号, 但配对噪声会影响可靠性; talking head generation 则展示了条件生成在动态内容上的潜力。共同原则是: 条件负责控制语义, 随机性负责提供变化, discriminator 负责同时检查真实感与条件一致性。

8 总结与延伸

本讲从 GAN 的训练困难出发, 转向生成器评估与 conditional generation。它补上了前两讲中较少讨论的一点: 即使我们知道 GAN 的理论目标, 也会面对两个现实问题。第一, 训练出来的 generator 到底好不好? 第二, 如何让 generator 不只是随机生成, 而是按条件生成?

⁴² 视频画面时间区间: 约 49:04–49:35; 字幕以蒙娜丽莎说话为例, 说明 conditional GAN 可用于会动的肖像生成。

核心脉络可以压缩成四句话：

1. GAN 难训，因为 generator 与 discriminator 必须保持动态平衡；任何一方停滞都会影响另一方。
2. 序列 GAN 更难，因为离散 token 选择切断了普通反向传播，常需要强化学习式估计或预训练。
3. 生成模型评估是分布级问题，不能只看单张样本；quality、diversity、FID、新颖性和条件匹配都需要考虑。
4. Conditional GAN 的关键是让 discriminator 同时看条件与输出，并加入错配负样本，避免 generator 无视条件。

对实践者来说，本讲最重要的提醒是：指标要服务于目标，而不能取代目标。FID 小、Inception Score 高、分类器信心强，都只是在某个角度上支持“生成结果较好”的证据。若模型只是记忆训练集、遗漏重要模式、无视条件，指标仍可能被欺骗。

进一步思考

后续学习生成模型时，可以把本讲作为评估清单：样本是否清楚？分布是否多样？是否覆盖真实资料的重要模式？是否只是记忆训练集？若有条件，输出是否真的遵守条件？这些问题不只适用于 GAN，也适用于 VAE、flow、diffusion 和现代多模态生成模型。

下一讲从“paired data”走向“unpaired data”。当我们没有一一对应的输入输出样本时，模型必须依靠循环一致性、分布匹配或其他结构假设来学习跨域转换。这会把 conditional generation 的问题推进到更接近真实应用的场景：资料往往不完美，监督往往不完整，而模型仍要从有限信号中学出可控转换。