

自监督式学习（一）

芝麻街命名谱系、BERT 与大模型时代



基于李宏毅老师《机器学习》课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 7 分钟

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=22>

目录

1 进入自监督式学习	3
1.1 什么叫自监督	3
1.2 为什么这件事重要	4
1.3 本章小结	4
2 芝麻街模型命名谱系	4
2.1 ELMo 与 BERT	4
2.2 ERNIE 与 BigBird	5
2.3 名字之外真正要关注什么	6
2.4 本章小结	6
3 BERT 为什么被说成巨大模型	7
3.1 参数量代表什么	7
3.2 BERT 的历史位置	8
3.3 本章小结	8
4 模型规模快速增长	8
4.1 从亿级到十亿级	9
4.2 GPT-3 与 Switch Transformer	9
4.3 规模化背后的风险	10
4.4 本章小结	10
5 BERT 系列与 GPT 系列	11
5.1 预先理解两条路线	11
5.2 为什么这两条线都会重要	11
5.3 本章小结	12
6 总结与延伸	12

1 进入自监督式学习

GAN 系列结束后，课程转入下一个主题：self-supervised learning，自监督式学习。这个短片段主要是导论，正式的训练目标和模型机制会在后续课程展开。本讲的作用是先建立背景：为什么自然语言处理中的自监督模型有一串奇妙的名字，为什么 BERT 被视为一个很大的模型，以及为什么后续模型会一路变得更大。



图 1: 课程进入 self-supervised learning 单元，并用芝麻街人物引出一系列 NLP 自监督模型名称。²

1.1 什么叫自监督

虽然本讲还没有正式定义训练方法，但可以先给出概念框架。自监督学习的核心是：不依赖人工标注标签，而是从资料本身构造监督信号。例如在语言模型中，可以遮住一句话中的某些词，让模型根据上下文预测它们；也可以让模型根据前文预测下一个词。标签不是人工写出来的，而是原始文本中本来就存在的部分。

这个思想介于 supervised learning 与 unsupervised learning 之间：

- 它不需要人工为每个样本标注类别或答案，因此不像传统监督学习那样依赖昂贵标签。
- 它又不是完全没有目标，而是从数据内部设计预测任务，因此训练时仍有明确 loss。
- 它尤其适合文字、语音、图像等可以大量收集但难以精细标注的数据。

²视频画面时间区间：约 00:02–00:44；字幕说明接下来主题是 self-supervised learning，并引出芝麻街命名传统。

自监督学习的一句话

自监督学习不是没有监督，而是把监督信号藏在资料本身里。模型通过预测被遮住、被打乱、未来出现或跨模态对应的内容，学到可迁移的表示。

1.2 为什么这件事重要

深度学习系统常常受限于标签。图像分类需要人工标图，语音辨识需要转写，翻译需要平行语料。可是互联网文本、图片、影片和音频的原始资料量巨大。自监督学习的价值在于，它把这些未标注资料变成可训练资源，让模型先通过大规模预训练学到通用表示，再用少量标注资料做下游任务。

这也是后续 BERT、GPT 等模型会成为关键基础模型的原因：它们不是只为某个小任务训练，而是在大量文本上学习语言结构，然后迁移到问答、分类、生成、检索、翻译等任务。

1.3 本章小结

本讲开场还没有进入公式和训练细节，而是先解释自监督学习单元的背景。自监督学习的基本精神是从资料本身产生训练目标，降低人工标注依赖。它之所以重要，是因为它让大规模无标注资料成为模型能力的主要来源。

2 芝麻街模型命名谱系

课程用芝麻街人物串起一批 NLP 自监督模型名称。这个段落表面上是趣味介绍，实际上也给出了模型发展的一条时间线：ELMo 较早，BERT 成为代表，随后出现 ERNIE、BigBird 等变体。

2.1 ELMo 与 BERT

ELMo 的全称是 Embeddings from Language Models，是早期重要的 contextual word embedding 模型。它的重点在于：词的表示不再是固定向量，而是会随上下文变化。例如“bank”在河岸与银行语境中应有不同表示。

BERT 的全称是 Bidirectional Encoder Representations from Transformers，是后续更具代表性的自监督模型。BERT 使用 Transformer encoder，并通过双向上下文学习 token 表示。课程此处只是介绍名字，后续会再讲它到底如何训练。




图 2: ELMo 与 BERT 都借用了芝麻街人物名称；课程用名字梗引出 NLP 自监督模型的发展脉络。

4

2.2 ERNIE 与 BigBird

BERT 之后出现了多个 ERNIE。课程调侃这些名称有时像是为了凑出芝麻街人物名而设计全称，例如 Enhanced Representation through Knowledge Integration。BigBird 则更直接，名称来自处理长序列的 Transformer 变体，课程指出它甚至已经不太努力凑缩写。

⁴视频画面时间区间：约 00:55–01:31；字幕说明 ELMo 是较早的 self-supervised model，BERT 是更广为人知的模型。




图 3: BERT 之后出现 ERNIE 与 BigBird 等模型; BigBird 代表面向长序列处理的 Transformer 方向。⁶

2.3 名字之外真正要关注什么

这些名字容易让人记住，但学习时更应该关注模型背后的问题：

- **输入表示。**模型如何把 token、位置和上下文编码成向量？
- **训练目标。**模型预测被遮住的词、下一词，还是句子关系？
- **上下文方向。**模型使用双向上下文，还是只看左侧历史？
- **可处理长度。**模型能处理多长的序列，注意力复杂度如何扩展？
- **迁移方式。**预训练后的表示如何用于下游任务？

后续课程会集中回答这些问题。本讲的名字谱系只是入口：它提示我们，BERT 不是孤立模型，而是一条自监督预训练路线中的节点。

2.4 本章小结

ELMo、BERT、ERNIE、BigBird 的命名很有趣，但更重要的是它们代表了 NLP 预训练模型的发展：从上下文化词向量，到 Transformer encoder 表示，再到知识整合与长序列处理。理解这些模型，需要把名字背后的训练目标、结构和迁移方式拆开来看。

⁶视频画面时间区间：约 01:23–02:30；字幕介绍 ERNIE、BigBird，并说明 self-supervised learning model 中有许多芝麻街命名。

3 BERT 为什么被说成巨大模型

课程接着用《进击的巨人》的比喻说明 BERT 的规模。BERT 有 340M 参数。单看这个数字可能没有直觉，于是课程把它与作业四中的 Transformer baseline 对比：作业模型约 0.1M 参数，BERT 约是它的三千倍。



图 4: BERT 有约 340M 参数，课程用超大体型比喻帮助建立规模直觉。⁷

3.1 参数量代表什么

参数量不是模型能力的唯一来源，但它反映模型容量。更多参数通常意味着模型可以存储更复杂的模式、学习更丰富的特征组合，并在大规模资料上形成更强表示。但参数多也会带来成本：

- 训练需要更多算力、显存和时间。
- 推理更慢，部署成本更高。
- 若资料或正则化不足，可能过拟合或学习到偏差。
- 模型行为更难解释和调试。

因此，“大”不是自动等于“好”。大模型真正有效，通常依赖三件事同时成立：足够大的资料、合适的训练目标、以及能支撑训练的计算资源。

⁷ 视频画面时间区间：约 02:47–03:18；字幕说明 BERT 有 340M 参数，是作业四 0.1M Transformer baseline 的约三千倍。

3.2 BERT 的历史位置

在 2018 年左右，BERT 的规模和效果都非常醒目。它推动了 NLP 从“为每个任务单独设计模型”转向“先大规模预训练，再针对任务微调”的范式。BERT 之后，许多模型继续沿着更大数据、更大参数、更通用预训练目标的方向发展。

从 feature engineering 到 pretraining

早期 NLP 常常为不同任务设计特征和模型；BERT 之后，通用预训练表示成为基础。模型先在大量无标注文本上学语言，再通过 fine-tuning 或 prompting 适配具体任务。这种范式后来扩展成更广义的 foundation model 思路。

3.3 本章小结

BERT 的 340M 参数在当时已经相当巨大，远大于课程作业中的模型。课程用形象比喻建立规模感，但真正值得记住的是：BERT 的重要性不只是参数多，而是它把大规模自监督预训练变成 NLP 任务的核心范式。

4 模型规模快速增长

课程随后指出，BERT 虽然大，但很快就不是最大的。自监督语言模型进入了模型规模迅速膨胀的阶段：ELMo、BERT、GPT-2、Megatron、T5、Turing NLG、GPT-3、Switch Transformer 等模型相继出现，参数量从千万级、亿级走向千亿级、万亿级。




图 5: 课程用身高比喻模型参数量：ELMo、BERT、GPT-2、T5、GPT-3 等模型规模不断增长。⁸

4.1 从亿级到十亿级

课程列出的几个数字可以形成直观表格：

模型	课程中提到的参数量
ELMo	约 94M
BERT	约 340M
GPT-2	约 1.5B
Megatron	约 8B
T5	约 11B
Turing NLG	约 17B
GPT-3	约 175B
Switch Transformer	约 1.6T



图 6: GPT-2、Megatron、T5 等模型进一步扩大参数量，十亿级参数开始成为常见比较尺度。⁹

4.2 GPT-3 与 Switch Transformer

为了让 GPT-3 的 175B 参数更有直觉，课程把 BERT 比作一公尺高的人，再把 GPT-3 比作台北 101。随后又提到 Switch Transformer 约 1.6T 参数，比 GPT-3 又大约十倍。这里的重点不是记住每个数字，而是意识到：自监督预训练与模型规模增长紧密绑定，现代 NLP 的进展很大程度上来自“更大模型 + 更多资料 + 更强算力”的组合。

⁸视频画面时间区间：约 04:22–05:03；字幕说明 ELMo 约 94M，BERT 约 340M，GPT-2 约 1.5B 参数。

⁹视频画面时间区间：约 04:55–05:33；字幕依次说明 GPT-2、Megatron、T5、Turing NLG 与 GPT-3 的参数规模。




图 7: 从 BERT 到 GPT-3, 再到 Switch Transformer, 参数量从亿级、千亿级迈向万亿级。¹⁰

4.3 规模化背后的风险

规模化带来强大能力, 也带来新的问题。课程此处只是用幽默方式引入规模, 但学习时应同时记住几个现实限制:

- **资料偏差会被放大。**大模型从大规模资料学习, 资料中的偏见、错误和噪声也可能被吸收。
- **成本集中。**训练超大模型需要高昂算力, 使研究和部署门槛提高。
- **评估更困难。**大模型能力广泛, 单一 benchmark 难以覆盖其行为。
- **可解释性下降。**参数量越大, 越难追踪具体知识和推理过程来自哪里。

不要把参数量当成唯一指标

参数量是理解大模型时代的重要坐标, 但不是唯一坐标。训练数据、架构、目标函数、优化稳定性、推理方式和任务对齐都会影响最终能力。更大的模型若没有合适训练与评估, 也可能只是更昂贵。

4.4 本章小结

自监督模型的发展很快进入规模化阶段。从 ELMo 到 BERT, 再到 GPT-3 与 Switch Transformer, 参数量增长了数个数量级。规模化是现代语言模型成功的重要因素, 但它必须与数据、训练目标和计算资源一起理解。

¹⁰ 视频画面时间区间: 约 05:40–06:34; 字幕用台北 101 比喻 GPT-3, 并提到 Switch Transformer 约 1.6T 参数。

5 BERT 系列与 GPT 系列

本讲最后给出后续课程大纲：接下来会讲两个系列，BERT series 与 GPT series。它们都是自监督语言模型，但关注点不同。课程此处尚未展开细节，可以先建立一个预备理解。



图 8: 后续课程将围绕 BERT series 与 GPT series 展开，分别介绍这些 self-supervised learning models 在做什么。¹²

5.1 预先理解两条路线

在正式进入后续课程前，可以先用一张概念表区分它们：

路线	典型结构	常见用途直觉
BERT series	Transformer encoder	学上下文表示，适合理解、分类、抽取等任务
GPT series	Transformer decoder	学下一个 token 预测，适合生成、续写、对话等任务

这个表只是导读。真正的差异要看训练目标：BERT 如何利用双向上下文，GPT 如何自回归生成，以及两者如何转移到下游任务。

5.2 为什么这两条线都会重要

BERT 与 GPT 代表自监督学习的两个核心方向。BERT 强调理解式表示：把一句话编码成含上下文信息的向量，供下游任务使用。GPT 强调生成式建模：根据历史 token 预测未来 token，逐

¹²视频画面时间区间：约 06:43–07:05；字幕说明接下来会介绍 BERT 与 GPT 两类 self-supervised learning model。

步产生文本。一个更像“读懂文本”的基础编码器，一个更像“继续写下去”的生成器。

现代模型的发展已经让这两条线互相影响，但在学习基础时，把 BERT/GPT 分清楚仍然很有帮助：它们对应不同的 attention mask、训练目标和任务适配方式。

5.3 本章小结

本讲作为自监督学习单元开场，先建立名称、规模和路线图。后续要真正理解 BERT 与 GPT，需要进入它们的训练目标、架构细节和下游迁移方式。本讲的任务是让我们知道：这些模型为什么叫这些名字，为什么会变得巨大，以及接下来要分别学习哪两类模型。

6 总结与延伸

这段短讲义真正传达的是一个时代转折：机器学习从依赖人工标注的小模型，逐渐转向利用海量未标注资料训练的大型自监督模型。ELMo、BERT、ERNIE、BigBird、GPT-2、GPT-3、Switch Transformer 这些名字背后，是同一条主线：让模型从资料本身学习语言结构，再迁移到各种任务。

本讲可以压缩成三点：

1. 自监督学习从资料本身构造监督信号，不等于没有目标。
2. BERT 等模型让大规模预训练成为 NLP 的核心范式。
3. 模型规模迅速膨胀，从亿级参数走向千亿级、万亿级参数，也带来成本、偏差和评估问题。

后续学习时，建议把注意力放在两个问题上。第一，模型到底被要求预测什么？这决定它学到什么表示。第二，预训练后的模型如何用于下游任务？这决定自监督学习如何真正转化为应用能力。名字和规模只是入口，训练目标和迁移机制才是理解 BERT/GPT 的关键。