

自监督式学习（二）

BERT 简介：从遮蔽填空到下游任务微调



基于李宏毅老师《机器学习》2025 课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂（Bilibili）

时长：约 50 分 40 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=23>

目录

1 自监督学习与 BERT 的问题设定	4
1.1 从监督学习到自监督学习	4
1.2 LeCun 对 self-supervised learning 的说法	5
1.3 本章小结	6
2 BERT 的两个预训练目标	6
2.1 Masked Language Modeling: 遮住一部分再猜回来	6
2.2 MASK 与随机替换	7
2.3 Next Sentence Prediction: 判断两句是否相邻	9
2.4 NSP 的后续修正: RoBERTa 与 ALBERT	11
2.5 本章小结	12
3 从预训练到微调	12
3.1 预训练提供通用表示, 微调负责具体任务	13
3.2 用 GLUE 评估通用语言理解能力	13
3.3 BERT family 与性能演进	14
3.4 本章小结	15
4 BERT 的四种下游用法	15
4.1 Case 1: 输入一个序列, 输出一个类别	16
4.2 Case 2: 输入一个序列, 输出等长序列	17
4.3 Case 3: 输入两个序列, 输出一个类别	18
4.4 Case 4: 抽取式问答	19
4.5 本章小结	22
5 训练成本与 BERT 胚胎学	22
5.1 训练 BERT 的困难	23
5.2 BERT Embryology: 模型什么时候学会什么	23
5.3 本章小结	24
6 BERT 之后: seq2seq 自监督模型	24
6.1 预训练 seq2seq: 弄坏输入, 再要求还原	25
6.2 MASS 与 BART: 多种 corruption 策略	26
6.3 T5: 把任务统一成 text-to-text	26
6.4 本章小结	27

1 自监督学习与 BERT 的问题设定

本讲从上一讲的自监督学习导入，正式进入 BERT。课程的重点不是把 BERT 当作一个神秘的大模型名称，而是把它拆成一个可理解的训练流程：先从没有人工标签的大量文本中构造训练目标，让模型学会利用上下文；再把这个预训练好的模型迁移到分类、标注、双句判断、问答等下游任务。

如果只记一句话：BERT 是一个先通过自监督任务学语言表示，再通过少量标注数据微调用于具体任务的 Transformer encoder。

1.1 从监督学习到自监督学习

监督学习中，训练样本通常以 (x, y) 形式出现：输入 x 交给模型，模型输出 $\hat{y}$ ，再用人工给定的标签 y 计算损失。问题是，人工标签很贵。文本、语音、图片、影片可以大量收集，但要让它们逐条标成情感类别、词性标签、问答答案或语义关系，成本很高。

自监督学习把思路反过来：不先问“人类给了什么标签”，而是问“数据本身能不能产生一个可预测的目标”。例如把一句话的某些词遮住，让模型根据上下文猜原词；或者给两句话，让模型判断它们是否相邻。标签不是人另外写的，而是从原始数据中自动挖出来的。

Self-supervised Learning




图 1: 监督学习使用外部标签；自监督学习从输入本身构造预测目标，因此可以利用大量未标注资料。²

²视频画面时间区间：约 00:01:56–00:02:23；字幕说明 self-supervised learning 可以看作一种从资料本身产生训练目标的方法。

自监督不是没有监督

自监督学习仍然有明确的训练目标和损失函数。它和传统监督学习的差异,不在于有没有 loss,而在于监督信号来自哪里:传统监督学习依赖人工标签,自监督学习从原始资料中自动构造伪标签或预测目标。

1.2 LeCun 对 self-supervised learning 的说法

课程引用 Yann LeCun 的说法: self-supervised learning 之所以不是简单叫 unsupervised learning, 是因为它仍然构造了一个预测任务。系统从输入的某些部分预测另一些部分, 因此它既不像分类任务那样依赖人工标签, 也不像传统聚类那样只寻找数据结构。

Self-supervised Learning

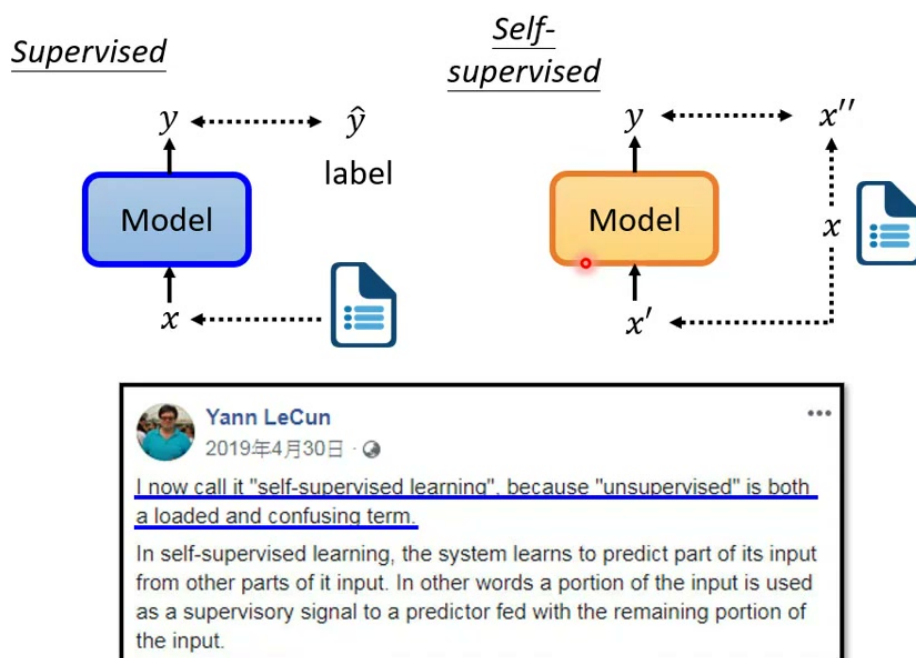


图 2: LeCun 强调 self-supervised learning 通过 “从输入的一部分预测另一部分” 来产生训练目标。

4

用自然语言作为例子, 输入可以是一句话、一个段落或两句话的组合。模型可以被要求回答:

- 这句话中被遮住的字或词是什么?
- 两句话是否原本相邻?
- 被弄乱或删除一部分的句子, 原本应该长什么样?

这些任务本身未必是最终应用。我们真正需要的是模型在完成这些任务时, 被迫学习词义、句法、上下文、长距离依赖和语义关系。BERT 的关键价值就在这里: 预训练任务像练基本功, 下游

⁴视频画面时间区间: 约 00:03:12-00:03:35; 字幕说明 unsupervised learning 是较大的 family, 而 self-supervised learning 更明确指向这种预测式训练。

任务像正式比赛。

1.3 本章小结

本章建立 BERT 的大前提：未标注数据可以通过自监督目标转化为训练资料。BERT 不直接从人工标注任务开始，而是先在大规模文本上学习可迁移的表示。后续章节要回答两个问题：BERT 预训练时到底做什么题，以及预训练完成后如何变成各种下游任务模型。

2 BERT 的两个预训练目标

BERT 的经典预训练包含两个目标：Masked Language Modeling (MLM) 和 Next Sentence Prediction (NSP)。前者是遮蔽填空，后者是判断两句话是否相邻。课程也补充说明，后续研究发现 NSP 未必有帮助，RoBERTa 移除了它，而 ALBERT 使用了更有用的 Sentence Order Prediction (SOP)。

2.1 Masked Language Modeling：遮住一部分再猜回来

MLM 的基本流程是：给 BERT 一段文字，随机选一些 token 做处理，再要求 BERT 在对应位置预测原本的 token。课程用中文句子举例：输入包含“台、湾、大、学”等字，其中某个字可能被遮住，BERT 要根据周围上下文猜出正确答案。

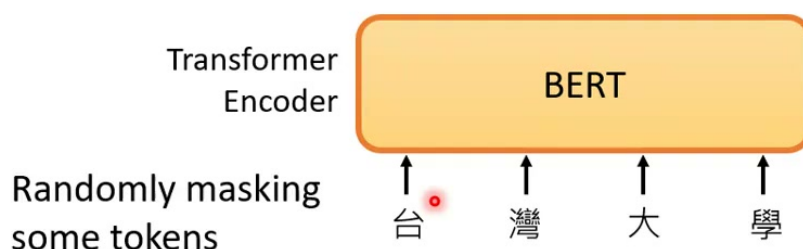


图 3: BERT 以 Transformer encoder 为主体，输入序列后，对被选中的位置学习恢复原始 token。⁶

⁶视频画面时间区间：约 00:05:11–00:05:29；字幕说明 BERT 的想法最早用于文字，但同类自监督思想也可迁移到语音或影像。

设原始序列为 $x = (x_1, \dots, x_n)$ ，被选中要预测的位置集合为 M ，经过遮蔽或替换后的输入为 $\tilde{x}$ 。MLM 的损失可以写为

$$\mathcal{L}_{\text{MLM}} = - \sum_{i \in M} \log p_{\theta}(x_i | \tilde{x})$$

符号说明：

- M ：被抽中作为预测目标的位置集合。
- $\tilde{x}$ ：经过 mask、随机替换或保持原样后的输入序列。
- $p_{\theta}(x_i | \tilde{x})$ ：模型在位置 i 预测原始 token x_i 的机率。
- θ ：BERT 的参数，包括 Transformer encoder 和输出分类层。

为什么不是把所有 token 都拿来预测

如果每个位置都要求预测自己，模型可能学到近乎复制输入的捷径。MLM 只抽一部分位置作为目标，让模型必须利用上下文推断缺失信息。这样训练出来的表示更容易捕捉语义和句法，而不是只记住当前位置的字形。

2.2 MASK 与随机替换

课程强调，被选中的 token 不一定总是变成特殊符号 [MASK]。训练时有两类典型处理：一类是把原 token 替换成 [MASK]，另一类是替换成随机 token。这样做的原因是，真实下游任务里通常不会出现 [MASK] 这个特殊符号。如果训练时只让模型看 [MASK]，预训练和微调之间会有落差。

Masking Input

<https://arxiv.org/abs/1810.04805>




图 4: 被选中的位置可以替换为特殊的 [MASK]，也可以随机换成另一个 token；两种方式都是为了构造恢复原词的训练目标。⁸

可以把 MLM 想成一个大规模分类问题：如果词表大小是 V ，那么每个被预测位置都要在 V 个类别中选出原始 token。课程用“湾”这个字举例：BERT 在被遮蔽位置输出一个向量，经过线性层和 softmax 后，产生对所有中文字或 token 的机率分布；训练目标是让正确字的机率最高。

⁸视频画面时间区间：约 00:06:55–00:07:09；字幕说明训练时有两种做法：一种加 mask，一种随机换成某个字，实际采用哪种也是随机决定。




图 5: MLM 在被选中位置接线性层与 softmax，把恢复原 token 转化为词表上的分类问题，并以交叉熵训练。¹⁰

MLM 学到的是上下文，不是单纯背答案

被遮蔽位置的答案来自原句，因此看起来像“把答案藏起来再猜”。但只要语料足够大、上下文足够多样，模型不能靠记忆单一句子解决问题，而必须学习词与词之间的搭配、语法结构和语义线索。

2.3 Next Sentence Prediction: 判断两句是否相邻

BERT 的第二个经典目标是 NSP。输入由两个句子组成，中间放入 [SEP]，最前面放入 [CLS]。BERT 读取整个序列后，取 [CLS] 对应的输出向量，接一个线性分类器，判断这两个句子是否在原始语料中相邻。

¹⁰视频画面时间区间：约 00:08:59–00:09:28；字幕说明模型输出要接近 ground truth token 的 one-hot vector，本质上是在做类别数等于词表大小的分类问题。

Next Sentence Prediction




图 6: NSP 的输入格式: 最前面加入 [CLS], 两句话之间加入 [SEP], 让 BERT 知道这是一个双句输入。¹²

¹²视频画面时间区间: 约 00:10:41–00:11:04; 字幕说明从语料中取两个句子, 并在中间加入特殊分隔符, 在最前面加入 [CLS]。

Next Sentence Prediction

- This approach is not helpful.




图 7: NSP 用 [CLS] 位置的表示接线性分类器，输出 Yes/No，判断两句是否相接。¹³

若 $h_{[\text{CLS}]}$ 表示 [CLS] 的输出向量，NSP 可以写成

$$p = \sigma(w^\top h_{[\text{CLS}]} + b), \quad \mathcal{L}_{\text{NSP}} = -[y \log p + (1 - y) \log(1 - p)]$$

符号说明：

- $h_{[\text{CLS}]}$: BERT 对整个双句输入压缩出的分类用表示。
- p : 模型判断“两句相邻”的机率。
- y : 真实标签，1 表示相邻，0 表示不相邻。
- w, b : NSP 分类头的参数。

2.4 NSP 的后续修正：RoBERTa 与 ALBERT

课程指出，后来的研究认为 NSP 并不一定有帮助。RoBERTa 通过更充分的训练和资料处理，移除了 NSP；ALBERT 则采用 SOP，也就是 Sentence Order Prediction。SOP 不只是问两句是否相邻，而是给一对相邻句子，随机交换顺序，让模型判断它们是否顺序正确。

¹³ 视频画面时间区间：约 00:11:56–00:12:20；字幕说明 Yes/No 指的是两个句子是不是相接，模型看到相接句子应输出 Yes，否则输出 No。

Next Sentence Prediction




图 8: NSP 后来被质疑效果有限; RoBERTa 移除 NSP, ALBERT 使用 SOP 来判断相邻句子的顺序是否正确。¹⁵

NSP 与 SOP 的差异

NSP 可能被模型用主题差异解决: 两句来自同一篇文章就可能比较像, 来自不同文章就可能比较不像。SOP 更聚焦于篇章顺序, 因为正负样本都来自相邻句, 只是顺序可能被调换。它迫使模型学习句子之间的前后逻辑, 而不只是主题是否一致。

2.5 本章小结

BERT 的预训练以 MLM 为核心: 随机处理部分 token, 让模型恢复原本内容。NSP 则试图让模型学习句子关系, 但后续研究发现它不是不可或缺, RoBERTa 和 ALBERT 给出了不同修正。理解这两个任务的重点, 不是记住它们的名字, 而是看见自监督学习如何把无标签文本变成有 loss 的训练资料。

3 从预训练到微调

BERT 预训练完成后, 只会做它被训练过的自监督题目: 遮蔽填空、或在原始版本中做 NSP。它并不会天然懂得情感分类、词性标注或问答。要让 BERT 执行具体任务, 需要把它接到任务头上, 并用少量标注资料微调。

¹⁵ 视频画面时间区间: 约 00:14:12-00:14:30; 字幕说明 SOP 被用于 ALBERT, 而 ALBERT 名称也延续了芝麻街命名趣味。

3.1 预训练提供通用表示，微调负责具体任务

课程用一个非常清楚的图说明流程：大量未标注文字先经过 self-supervised learning 训练出 BERT；接着同一个 BERT 被复制到不同下游任务中，各自接上不同输出头，再用少量标注资料 fine-tune。




图 9: BERT 先通过 MLM/NSP 等目标预训练，再被微调到不同下游任务；各任务共享预训练表示，但有各自的输出头。¹⁷

这个流程有两个重要含义。


1. 预训练阶段吃的是大量无标签资料，目标是学语言表示，而不是直接解决某个应用。
2. 微调阶段吃的是少量有标签资料，目标是把通用表示转成任务需要的输出。

课程把 BERT 比喻成胚胎干细胞：还没有分化时，它不等于任何具体器官；但它具有分化成多种功能的潜能。预训练 BERT 也是如此，它不是现成的情感分析器或问答系统，但它包含可被塑造这些系统的表示能力。

3.2 用 GLUE 评估通用语言理解能力

要评价一个自监督模型，不能只看它在单一任务上的表现。GLUE (General Language Understanding Evaluation) 就是一组自然语言理解任务集合，包括语法可接受性、情感分析、句子对相似度、问答式推理、自然语言推论等。

¹⁷ 视频画面时间区间：约 00:15:59-00:16:27；字幕说明 BERT 学会做填空题后，可被拿去做各种下游任务，但仍需要一些标注资料。



- Corpus of Linguistic Acceptability (CoLA)
- Stanford Sentiment Treebank (SST-2)
- Microsoft Research Paraphrase Corpus (MRPC)
- Quora Question Pairs (QQP)
- Semantic Textual Similarity Benchmark (STS-B)
- Multi-Genre Natural Language Inference (MNLI)
- Question-answering NLI (QNLI)
- Recognizing Textual Entailment (RTE)
- Winograd NLI (WNLI)

GLUE also has Chinese version (<https://www.cluebenchmarks.com/>)

图 10: GLUE 把多个语言理解任务放在一起评估，避免只用单一任务判断模型是否真的学到通用表示。¹⁹

GLUE 的意义在于，它把“模型是否懂语言”拆成多种可测的行为。一个模型如果只在情感分类上表现好，可能只是学到情绪词；如果在句子相似度、自然语言推论、问答式判断等任务上也表现好，才更有理由相信它学到较一般的语言表示。


3.3 BERT family 与性能演进

课程展示 BERT 及其后续模型在 GLUE 上的变化。随着模型架构、预训练资料、训练策略和规模不断改进，许多任务从明显落后人类逐步接近甚至超过人类基准。

¹⁹ 视频画面时间区间：约 00:18:23–00:18:37；字幕说明评估 self-supervised model 通常会测试多个任务，因为 BERT 要分化到各种下游任务。

BERT and its Family

• GLUE scores



Source of image: <https://arxiv.org/abs/1905.00537>

图 11: BERT family 在 GLUE 上不断推进, 说明预训练表示、模型规模与训练策略会显著影响下游任务表现。²¹

不要把 benchmark 分数误读成“真正理解”

GLUE 分数提升说明模型在这些任务格式上表现更好, 但不等于模型具有和人一样的理解方式。课程也提醒, 这些结果是在特定资料集和评估方式上的结果; 真实语义理解、稳健性、泛化与可解释性仍需要额外检验。

3.4 本章小结

BERT 的使用方式是“先预训练, 再微调”。预训练阶段提供可迁移表示, 微调阶段把表示对接到具体任务。GLUE 这样的多任务 benchmark 用来检查模型是否具有较通用的语言理解能力, 但 benchmark 只是测量工具, 不应被误认为完整智能。

4 BERT 的四种下游用法

课程把 BERT 的下游应用整理成四个 case。这个分类非常实用, 因为它告诉我们: 面对一个 NLP 任务时, 关键不是重新发明模型, 而是判断输入输出形式, 然后选择合适的任务头。

²¹ 视频画面时间区间: 约 00:20:42–00:21:05; 字幕说明较强模型在某些 GLUE 任务上逐渐追上甚至超过人类平均表现。

4.1 Case 1: 输入一个序列，输出一个类别

第一类任务是 sequence classification。输入是一段文字，输出是一个类别，例如情感分析：句子 “this is good” 要被分类为 positive。做法是把 [CLS] 放在序列开头，让 BERT 编码整个句子，再取 [CLS] 的输出向量接线性分类器。




图 12: Case 1 使用 [CLS] 表示做整句分类；BERT 参数由预训练初始化，分类头再由下游标注资料学习。²³

数学上可写为

$$\hat{y} = \text{softmax}(Wh_{[\text{CLS}]} + b)$$

符号说明：


- $h_{[\text{CLS}]}$: BERT 对整段输入产生的分类向量。
- W, b : 下游任务的线性分类头。
- $\hat{y}$: 对类别的预测分布，例如 positive/negative。

这里真正需要从头学习的，主要是任务头和 BERT 参数的微调方向。预训练参数给模型一个比随机初始化更好的起点，因此少量标注数据也可能得到不错结果。

²³视频画面时间区间：约 00:24:28–00:24:58；字幕说明下游分类模型不是随机初始化 BERT，而是用预训练好的 BERT 参数作为初始化。

Pre-train v.s. Random Initialization

(fine-tune) (scratch)



Source of image: <https://arxiv.org/abs/1908.05620>

图 13: 预训练初始化通常比从随机初始化开始更快、更稳; 图中 fine-tune 曲线明显优于 scratch 曲线。²⁵

微调不是只训练最后一层

在典型 fine-tuning 中, 分类头当然要学习, 但 BERT 本体参数也会跟着更新。预训练提供的是起点, 不是冻结不动的知识库。若资料很少或任务很特殊, 也可以选择冻结部分层, 但这已经是另一个训练策略问题。

4.2 Case 2: 输入一个序列, 输出等长序列

第二类任务是 sequence labeling。输入是一个序列, 输出也是一个等长序列, 常见例子包括词性标注、命名实体识别、逐字分类等。每个 token 的 BERT 输出向量都接一个分类器, 各自预测该位置的标签。

²⁵ 视频画面时间区间: 约 00:24:53-00:25:07; 字幕说明会用会做填空题的 BERT 初始化, 直觉上会比随机初始化更好, 并引入文献曲线作为例子。

How to use BERT – Case 2




图 14: Case 2 对每个 token 的输出分别接线性分类器, 得到与输入长度相同的标签序列, 例如 POS tagging。²⁷

若 h_i 是第 i 个 token 的 BERT 输出, 则

$$\hat{y}_i = \text{softmax}(Wh_i + b), \quad i = 1, \dots, n$$

符号说明:

- h_i : 第 i 个 token 的上下文表示。
- $\hat{y}_i$: 第 i 个位置的标签预测, 例如名词、动词、限定词。
- n : 输入序列长度。

Case 2 和 Case 1 的区别在输出粒度。Case 1 要整句一个答案, 因此用 [CLS]; Case 2 要每个 token 一个答案, 因此保留每个位置的输出。

4.3 Case 3: 输入两个序列, 输出一个类别

第三类任务是 sentence pair classification。输入两个句子, 输出一个类别, 例如自然语言推论 (NLI): 判断 premise 与 hypothesis 是 entailment、contradiction 还是 neutral。做法与 NSP 类似: 把两个句子用 [SEP] 分开, 整体送入 BERT, 再取 [CLS] 输出做分类。

²⁷ 视频画面时间区间: 约 00:29:35–00:30:18; 字幕说明每个词汇要判断属于哪一类, 本质仍是分类问题, 但 BERT encoder 由预训练参数初始化。

How to use BERT – Case 3




图 15: Case 3 把两个句子合并为一个双句输入, 用 $[CLS]$ 的输出判断二者关系, 例如 NLI 中的矛盾、蕴含或中立。²⁹

这一类任务特别体现 BERT 的双向上下文能力。两个句子不是分别编码后才比较, 而是合并输入, 让 self-attention 可以在两句话之间直接交互。这样模型在编码 premise 中某个词时, 可以同时看 hypothesis 中相关词, 反之亦然。

4.4 Case 4: 抽取式问答

第四类任务是 extraction-based question answering。给模型一个问题和一篇文章, 答案一定是文章中的一个连续片段。模型不用生成新文字, 只要输出两个整数: 答案起点 s 和终点 e 。


²⁹ 视频画面时间区间: 约 00:33:06–00:33:49; 字幕说明 BERT 读入两句话后, 只取 $[CLS]$ 部分接线性层, 判断两句应输出什么类别。

How to use BERT – Case 4

- Extraction-based Question Answering (QA)

Document: $D = \{d_1, d_2, \dots, d_N\}$

Query: $Q = \{q_1, q_2, \dots, q_M\}$



Answer: $A = \{d_s, \dots, d_e\}$

In meteorology, precipitation is any product of the condensation of atmospheric water vapor that falls under **gravity**. The main forms of precipitation include drizzle, rain, sleet, snow, **graupel** and hail... Precipitation forms as smaller droplets coalesce via collision with other rain drops or ice crystals **within a cloud**. Short, intense periods of rain in scattered locations are called "showers".

What causes precipitation to fall?
gravity

What is another main form of precipitation besides drizzle, rain, snow, sleet and hail?
graupel

Where do water droplets collide with ice crystals to form precipitation?
within a cloud

图 16: 抽取式 QA 的答案被定义为文章中的连续 span; 模型输出起点与终点, 而不是从零开始生成答案。³¹

BERT 的输入格式仍然是把问题和文章串接起来:

[CLS] question [SEP] document [SEP]

模型读取整个序列后, 对文章中的每个 token 预测 “是否为答案起点” 和 “是否为答案终点”。

³¹ 视频画面时间区间: 约 00:35:12–00:35:32; 字幕说明 QA 可以被设定为输出两个整数 (s, e), 答案就是文章中从 s 到 e 的片段。

How to use BERT – Case 4




图 17: QA 微调时, BERT 同时读取 question 与 document, 并利用 [SEP] 区分二者。³²

常见做法是学习两个向量 u_s, u_e , 分别对应起点和终点。对文章中第 i 个 token 的表示 h_i , 计算

$$P_s(i) = \frac{\exp(h_i^\top u_s)}{\sum_j \exp(h_j^\top u_s)}, \quad P_e(i) = \frac{\exp(h_i^\top u_e)}{\sum_j \exp(h_j^\top u_e)}$$

符号说明:

- h_i : 第 i 个文章 token 的 BERT 表示。
- u_s : 判断“答案起点”的可学习向量。
- u_e : 判断“答案终点”的可学习向量。
- $P_s(i), P_e(i)$: 第 i 个位置分别作为起点、终点的机率。

³²视频画面时间区间: 约 00:36:55–00:37:16; 字幕说明 BERT 要同时看问题和文章, 中间用特殊符号分隔。

How to use BERT – Case 4




图 18: 抽取式 QA 用两个分布选择答案 span 的起点与终点；图中最高分位置给出答案区间 d_2, d_3 。

抽取式 QA 的隐藏假设

这种方法假设答案一定能在文章中找到一个连续片段。如果问题需要综合多段信息、答案不在文章中、或需要生成解释，单纯预测 (s, e) 就不够。它适合 SQuAD 式设定，但不是所有问答任务的通用解法。

4.5 本章小结

BERT 的下游使用可以按输入输出形式整理：整句分类取 [CLS]；逐 token 标注取每个位置；双句分类把两句合并后取 [CLS]；抽取式 QA 预测文章中的起点和终点。四种 case 的共同点是：BERT 本体来自预训练，任务差异主要体现在输入组织方式与输出头设计。

5 训练成本与 BERT 胚胎学

课程在讲完如何使用 BERT 后，转向两个更高层的问题：第一，训练 BERT 很难；第二，BERT 在预训练过程中到底什么时候学会哪些语言能力。

³⁴ 视频画面时间区间：约 00:39:26–00:39:44；字幕说明模型要预测正确答案出现的起始位置和结束位置，答案必须在文章中。

5.1 训练 BERT 的困难

BERT 的资料规模很大。课程提到，原始 BERT 训练资料超过 30 亿词，相当于数千本《哈利波特》的量级。资料本身可以从网络上爬取，但真正困难的是训练：大量参数、多轮更新、昂贵硬件和长时间计算。

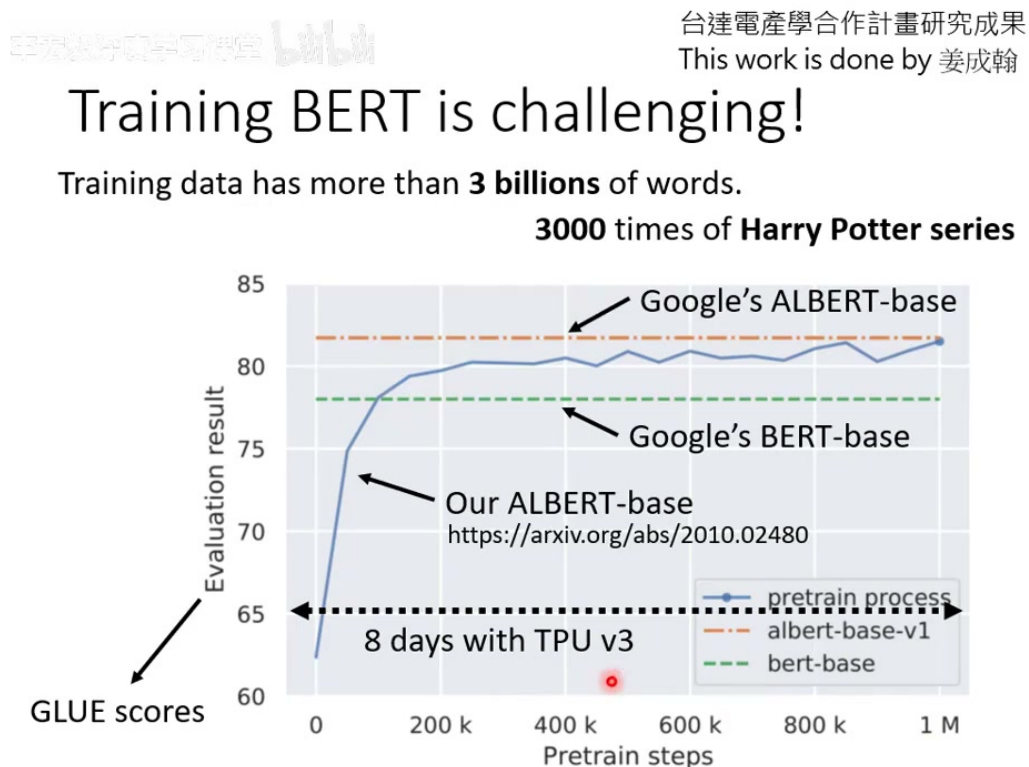


图 19: 训练 BERT 的成本很高：预训练步数可达百万级，硬件与时间成本显著，后续模型也不断尝试提高训练效率。³⁶

这也解释了为什么 BERT 之后会出现大量改进模型。它们不只是为了把 benchmark 分数提高一点，也常常为了让训练更有效率、参数更少、资料利用更充分，或让同样成本换来更好的下游表现。

预训练成本改变了研究与应用分工

当预训练成本很高时，多数应用团队不会从零训练 BERT，而是下载公开预训练模型，再用自己的少量标注资料微调。于是 NLP 工作流从“为每个任务训练一个模型”，转向“共享基础模型，再做任务适配”。

5.2 BERT Embryology：模型什么时候学会什么

课程最后提到一个有趣问题：BERT 在训练过程中，到底先学会词性、句法还是语义？它什么时候开始会填简单名词，什么时候能处理代名词，什么时候学会更复杂的语义关系？这类问题被课程称为 BERT Embryology，也就是观察 BERT 的“发育过程”。

³⁶ 视频画面时间区间：约 00:44:26-00:44:44；字幕说明资料量很大但爬取不一定最难，困难在训练过程，百万次更新可能需要 TPU 跑数天。

BERT Embryology (胚胎學)

<https://arxiv.org/abs/2010.02480>



When does BERT know POS tagging,
syntactic parsing, semantics?

The answer is counterintuitive!

图 20: BERT Embryology 关注模型在预训练过程中能力如何逐步出现：词性、句法、语义等能力并不一定同步成熟。³⁸

这个问题很重要，因为它不再只问“最后分数多少”，而是问“能力是怎么长出来的”。如果某些能力很早出现，说明它们可能是训练目标的直接副产品；如果某些能力很晚才出现，可能需要更长训练、更大模型或更复杂上下文。这样的分析有助于理解预训练过程，也能帮助设计更有效的训练策略。

5.3 本章小结

BERT 的成功不是免费的。大规模预训练需要大量资料和算力，因此实际应用通常依赖公开预训练模型，再做下游微调。BERT Embryology 则提醒我们，模型能力不是瞬间出现的，而是在训练过程中逐步形成；理解这个过程，可能比只看最终 benchmark 更接近模型机制本身。

6 BERT 之后：seq2seq 自监督模型

课程结尾从 BERT 自然延伸到 seq2seq 预训练。BERT 是 encoder-only 架构，适合理解与抽取式任务；如果要做翻译、摘要、生成式问答等输入输出长度不同的任务，就会需要 encoder-decoder 或 text-to-text 架构。

³⁸ 视频画面时间区间：约 00:46:26–00:46:46；字幕说明可以观察 BERT 在什么时候学会填不同类型的词，以及填空能力如何增进。

6.1 预训练 seq2seq：弄坏输入，再要求还原

seq2seq 自监督预训练的基本想法是：先把输入句子弄坏，再让 encoder 读损坏后的输入，由 decoder 还原原句。这里的“弄坏”可以是删除、遮蔽、打乱、替换片段等。



Pre-training a seq2seq model




图 21: seq2seq 预训练把输入破坏后交给 encoder，再让 decoder 重建原始输入，从而学习可生成的语言表示。⁴⁰

可将目标写为

$$\mathcal{L}_{\text{denoise}} = -\log p_{\theta}(x \mid c(x))$$

符号说明：

- x ：原始序列。
- $c(x)$ ：经过 corruption function 破坏后的序列。
- $p_{\theta}(x \mid c(x))$ ：模型根据损坏输入重建原始序列的机率。

这种目标和 BERT 的 MLM 有同源关系：都是从资料中拿掉或扰动一部分信息，再训练模型恢复。但 seq2seq 版本输出的是完整序列，更适合生成式任务。

⁴⁰视频画面时间区间：约 00:47:20–00:47:58；字幕说明 encoder 看到被弄坏的结果，decoder 要输出还原前的句子。

6.2 MASS 与 BART: 多种 corruption 策略

课程提到 MASS 与 BART。MASS 主要强调遮蔽片段并恢复；BART 则把多种破坏方式组合起来，例如删除 token、句子排列、旋转、text infilling 等。课程开玩笑说 BART 名字不再是芝麻街，而是换成另一个角色；但技术重点是：不同破坏策略会迫使模型学习不同粒度的恢复能力。




图 22: MASS/BART 通过删除、重排、旋转、片段填补等方式构造去噪预训练任务，训练模型从损坏输入恢复原始文本。⁴²

6.3 T5: 把任务统一成 text-to-text

T5 的思想更进一步：把各种 NLP 任务都改写成 text-to-text 格式。输入是文字，输出也是文字；分类、翻译、摘要、问答都可以统一到同一套框架中。课程展示 T5 使用 C4 (Colossal Clean Crawled Corpus) 作为大规模训练语料，并比较不同 corruption rate 与 span length 的设置。

⁴²视频画面时间区间：约 00:48:41-00:48:58；字幕说明 BART 将多种破坏方法一起使用，经验上可能带来更好结果。

T5 – Comparison

- Transfer Text-to-Text Transformer (T5)
- Colossal Clean Crawled Corpus (C4)

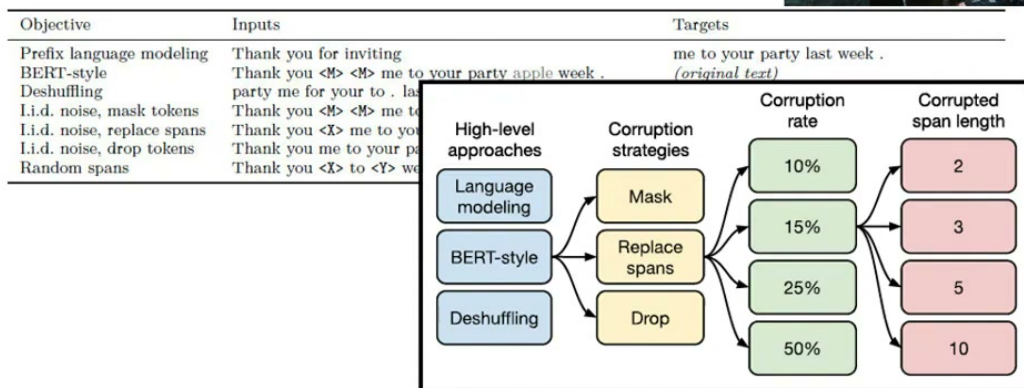


图 23: T5 将多类任务统一成 text-to-text，并系统比较不同预训练目标、corruption 策略与资料设定。⁴⁴

从 BERT 到 T5 的主线

BERT 代表 encoder-only 的理解式预训练；MASS/BART 代表 encoder-decoder 的去噪重建；T5 则把任务接口统一为 text-to-text。它们共享同一个核心精神：从大规模原始文本中构造训练目标，再把学到的表示迁移到下游任务。

6.4 本章小结

BERT 不是自监督学习的终点。它之后的 MASS、BART、T5 等模型把“遮蔽再恢复”的思想推广到序列到序列生成，并尝试统一 NLP 任务接口。理解这些模型时，最重要的是抓住 corruption 与 reconstruction 的关系：怎样破坏输入，就会影响模型被迫学习什么能力。

7 总结与延伸

本讲把 BERT 放在自监督学习的大框架中解释。BERT 的核心不是“一个很大的网络”这么简单，而是一套训练和迁移范式：

1. 先从无标签文本中构造预训练任务，例如 MLM 和 NSP/SOP。
2. 用 Transformer encoder 学到上下文相关的 token 表示。

⁴⁴视频画面时间区间：约 00:50:11–00:50:25；字幕说明 C4 语料规模很大，下载、存储和前处理都需要显著成本。

3. 再根据下游任务的输入输出形式，接上合适任务头并微调。
4. 通过多任务 benchmark 检查表示是否具有通用性。

从机制上看，BERT 的四类用法可以压缩成一个表：

任务类型	输入输出	BERT 用法
整句分类	一个序列 → 一个类别	取 [CLS] 表示接分类器
序列标注	一个序列 → 等长标签序列	每个 token 输出接分类器
双句分类	两个序列 → 一个类别	两句合并输入，取 [CLS]
抽取式问答	问题 + 文章 → 起点/终点	对文章位置预测 start/end 分布

课程最后给出的延伸很关键：BERT 之后，模型不只追求更高 GLUE 分数，也开始关注更通用的生成式接口、更有效的预训练目标、更低的训练成本，以及模型能力在训练过程中的形成顺序。换句话说，自监督学习从“如何用无标签资料训练模型”发展到“如何设计一个可迁移、可扩展、可解释的基础模型训练系统”。

继续学习时的三条线

第一条线是预训练目标：比较 MLM、causal LM、denoising、span corruption 等目标各自逼迫模型学习什么。第二条线是架构：比较 encoder-only、decoder-only、encoder-decoder 的适用任务。第三条线是迁移方式：比较 full fine-tuning、冻结特征、prompting、adapter、LoRA 等方法如何把基础模型接到具体任务上。

本讲的重点可以浓缩为一句话：BERT 用自监督任务从文本中学通用表示，再用微调把表示分化为具体能力；这条路线后来扩展成现代基础模型的核心范式之一。