

自监督式学习（三）

BERT 的奇闻轶事：能力来源、多语言迁移与隐藏语言向量



基于李宏毅老师《机器学习》2025 课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 24 分 13 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=24>

目录

1 为什么 BERT 会有用	3
1.1 同一个字在不同上下文中有不同 embedding	3
1.2 用 cosine similarity 检查语义聚类	4
1.3 分布语义假设: You shall know a word by the company it keeps	5
1.4 Contextualized word embedding	6
1.5 本章小结	7
2 奇怪实验: BERT 是否只是懂语义	7
2.1 把 BERT 用到蛋白质、DNA、音乐	8
2.2 英文预训练参数作为初始化	9
2.3 结果: BERT 仍然有帮助	10
2.4 可能的解释路径	11
2.5 本章小结	12
3 多语言 BERT 与零样本跨语言迁移	12
3.1 多语言填空模型	12
3.2 Zero-shot Reading Comprehension	13
3.3 一种解释: 跨语言 embedding 对齐	14
3.4 训练并不容易: 资料量与突然下降的 loss	16
3.5 本章小结	18
4 语言信息到底藏在哪里	18
4.1 跨语言对齐与语言识别的矛盾	19
4.2 语言向量: 平均 embedding 的差	20
4.3 把英文 embedding 推向中文	21
4.4 本章小结	23
5 总结与延伸	23

1 为什么 BERT 会有用

上一讲讲的是 BERT 怎么预训练、怎么微调。这一讲追问一个更底层的问题：为什么一个通过填空题训练出来的模型，拿去做情感分析、问答、词性标注，甚至跨语言任务时会有用？最常见的解释是：BERT 的输出向量不是普通编号，而是能表示 token 在上下文中的意义。

1.1 同一个字在不同上下文中有不同 embedding

课程从“果”这个字开始。中文里“果”可以指可吃的水果，也可以出现在“苹果电脑”“苹果手机”里。字面上都是同一个字，但语义不同。BERT 的关键能力之一，是同一个 token 放在不同句子里，输出的向量可以不同。




图 1: 同一个“果”在“吃苹果”和“苹果手机”两种上下文中，BERT 输出的 embedding 可以落在不同语义区域。²

这和早期静态词向量不同。静态词向量会给每个词一个固定向量，因此同一个词在任何句子里都一样。BERT 经过 self-attention 编码后，每个位置的输出会综合周围 token，所以它更像是“这个词在这句话里的意义”，而不是“这个词在词表里的编号”。

BERT 表示的是 token-in-context

BERT 的输出不是单纯的 word embedding，而是 contextualized embedding。它同时依赖 token 本身和它所在的上下文，因此能区分同形异义、语境差异和句中角色。

²视频画面时间区间：约 00:01:20-00:01:50；字幕说明同一个“果”因为上下文不同，对应 embedding 会非常不一样。

1.2 用 cosine similarity 检查语义聚类

为了验证这个说法，课程收集多个包含“果”的句子，把这些句子送进 BERT，再取出每个“果”的 embedding，计算两两之间的 cosine similarity。

若 h_i, h_j 是两个“果”的向量，cosine similarity 为

$$\cos(h_i, h_j) = \frac{h_i^\top h_j}{\|h_i\| \|h_j\|}$$

符号说明：

- h_i, h_j ：两个不同句子中目标 token 的 BERT 输出向量。
- $h_i^\top h_j$ ：两个向量的内积。
- $\|h_i\|, \|h_j\|$ ：向量长度，用来消除尺度影响。
- 数值越大，表示两个向量方向越接近，通常被解读为语义越相似。

中文学习网 bilibili

Why does BERT work?




图 2: 把多个含“果”的句子送入 BERT，再比较不同“果”字 embedding 的 cosine similarity。³

结果很符合直觉：表示水果的“果”彼此更相似，表示苹果电脑或苹果公司的“果”彼此更相似，而这两群之间的相似度较低。

³视频画面时间区间：约 00:02:05–00:02:47；字幕说明收集多句含“果”的句子，分别取出对应向量并计算相似度。




图 3: “果”的 embedding 相似度矩阵形成两块结构: 水果语义聚在一起, 苹果公司语义聚在一起。
5

1.3 分布语义假设: You shall know a word by the company it keeps

课程接着引用语言学家 John Rupert Firth 的名句: “You shall know a word by the company it keeps.” 一个词的意义可以从它经常一起出现的词看出来。若“果”周围常出现“吃”“树”“茶”, 它可能与水果相关; 若周围常出现“电脑”“专利”“股价”, 它可能与苹果公司相关。

⁵ 视频画面时间区间: 约 00:03:22-00:04:16; 字幕说明前五个“果”代表可吃的苹果, 后五个代表苹果电脑, BERT 自己把两类语义分开。

Why does BERT work?

You shall know a word by
the company it **ke**eps



John Rupert Firth




图 4: Firth 的分布语义观点: 词义可由上下文揭示; BERT 在学填空题时, 很可能也在从上下文抽取这类信息。⁷

这解释了为什么 MLM 有用。为了猜被遮住的 token, BERT 必须理解周围词的约束; 为了理解周围词, 它又必须把语法和语义编码进表示中。填空题表面简单, 但当语料足够大、上下文足够复杂时, 它会逼迫模型学到许多语言规律。

1.4 Contextualized word embedding

课程把 BERT 的表示称为 contextualized word embedding。它可以看作早期 word embedding 的进阶版: 不是只给词一个静态向量, 而是让向量随上下文变化。

⁷视频画面时间区间: 约 00:04:51-00:05:45; 字幕说明一个词汇的意思取决于上下文, 而 BERT 做填空题时也许就在学习从上下文抽取资讯。




图 5: BERT 输出的是 contextualized word embedding: 同一个词在不同上下文中会得到不同向量。
9

这只是一个解释，不是完整答案

“BERT 学到语义”是有证据的，因为 embedding 中确实能看到语义聚类。但本讲后半会强调：这不一定是 BERT 有用的全部原因。预训练参数、模型结构、优化动态和资料规模，也可能提供额外贡献。

1.5 本章小结

本章给出 BERT 有用的常见解释：通过填空任务，BERT 学会从上下文中抽取语义信息，输出 contextualized embedding。同一个 token 的向量会随语境变化，语义相近的用法在向量空间中也更接近。不过这只是第一层解释，后面会看到一些实验让这个解释变得没那么简单。

2 奇怪实验：BERT 是否只是懂语义

课程接下来讲一个“会让人睡不着”的实验：把在英文文本上预训练的 BERT 拿去做蛋白质、DNA、音乐分类。乍看之下，这完全不合理。英文 BERT 学的是英文填空，DNA 序列和音乐片段并没有自然语言语义；如果 BERT 有用只是因为它懂英文，那它不应该帮上忙。

⁹ 视频画面时间区间：约 00:07:22–00:08:04；字幕说明 BERT 是考虑上下文的 word embedding 进阶版，因此输出向量称为 contextualized word embedding。

2.1 把 BERT 用到蛋白质、DNA、音乐

实验的基本想法是：把非语言序列编码成一串“像文字一样”的 token，再套用 BERT 的分类范式。课程先用 DNA 举例。DNA 序列由 A、T、C、G 组成；可以把这四个符号随机映射到英文词汇，例如 A 对应 *we*，T 对应 *you*，C 对应 *he*，G 对应 *she*。这样一串 DNA 就被转换成一串英文 token。



<https://arxiv.org/abs/2103.07162>

This work is done by 高瑋聰

Why does BERT work?

- Applying BERT to **protein, DNA, music classification**



图 6: 实验把 BERT 应用于蛋白质、DNA、音乐分类，挑战“BERT 有用只是因为懂语言语义”的简单解释。¹¹

¹¹ 视频画面时间区间：约 00:08:23–00:08:52；字幕说明将训练在文字上的 BERT 拿来作蛋白质、DNA 或音乐分类。

DNA sequence → A G A C



图 7: DNA 中的 A/T/C/G 可随机映射成英文词汇, 从而把 DNA 序列包装成 BERT 可读取的 token 序列。¹³

2.2 英文预训练参数作为初始化

接下来使用和普通文本分类一样的架构: 序列前面加 [CLS], 送入 BERT, 取 [CLS] 向量接线性层分类。差异在于, BERT 的预训练参数来自英文填空任务, 而输入其实是被随机映射后的 DNA 或其他非语言序列。

¹³ 视频画面时间区间: 约 00:09:21–00:10:19; 字幕说明 A/T/C/G 对应到哪些英文词并不重要, 随机映射也可以, 关键是把 DNA 变成一串文字。

Why does BERT work?

<https://arxiv.org/abs/2103.07162>

This work is done by 高瑋聰




图 8: DNA 分类仍使用 BERT 分类架构; BERT 本体由英文预训练参数初始化, 而不是从随机参数开始。¹⁵

这看起来很荒谬: 输入 token 对 BERT 来说已经失去自然语言意义, 英文语义知识似乎派不上用场。若结果仍然变好, 说明 BERT 的好处至少不完全来自“看懂英文内容”。

2.3 结果: BERT 仍然有帮助

实验结果显示, 在若干蛋白质、DNA、音乐分类任务中, 使用英文预训练 BERT 的初始化, 经常比随机初始化更好。课程强调, 这个现象没有特别好的解释, 但它提示我们: BERT 的能力来源可能包含更普遍的序列建模 inductive bias、优化起点、层级表示结构, 甚至只是更好的参数分布。

¹⁵ 视频画面时间区间: 约 00:10:35–00:11:23; 字幕说明模型结构与分类任务相同, 只是 BERT 由英文填空预训练模型初始化。

Why does BERT work?

• Applying BERT to **protein, DNA, music classification**

	Protein			DNA				Music
	localization	stability	fluorescence	H3	H4	H3K9ac	Splice	composer
specific	69.0	76.0	63.0	87.3	87.3	79.1	94.1	-
BERT	64.8	74.5	63.7	83.0	86.2	78.3	97.5	55.2
re-emb	63.3	75.4	37.3	78.5	83.7	76.3	95.6	55.2
rand	58.6	65.8	27.5	75.6	66.5	72.8	95	36



图 9: 在蛋白质、DNA、音乐等非语言分类任务中，英文预训练 BERT 仍可能优于随机初始化，说明 BERT 的好处不只来自懂英文语义。¹⁷

不要把这个实验误解成“语义不重要”

这个实验不是否认 BERT 学到语义。前面的“果”实验已经显示 BERT embedding 中有语义结构。它真正说明的是：语义解释不是完整解释。预训练 BERT 可能同时提供语义知识、序列处理结构、优化优势和参数初始化优势。

2.4 可能的解释路径

可以从几条线理解这个现象。

- **初始化效应**：预训练参数可能处在比随机参数更容易优化的位置，即使输入 token 的语义被打乱，也能帮助下游训练。
- **序列结构效应**：BERT 通过 self-attention 处理长序列关系，DNA、蛋白质、音乐也都是序列，可能共享某些统计结构。
- **表示空间效应**：预训练让层与层之间形成稳定的尺度、归一化和梯度传播特性，迁移到其他序列任务时仍有用。
- **任务头效应**：下游分类仍然使用 [CLS] 聚合序列信息，这个机制可能本身就适合多种序列分类。

这些解释都不是最终答案，但它们共同提醒我们：大模型有效性常常不是单一因素造成的。课程把这类现象称为“奇闻轶事”，其实是在训练我们对模型机制保持怀疑。

¹⁷ 视频画面时间区间：约 00:11:50-00:12:47；字幕说明红色的 BERT 结果较好，作者用此提醒 BERT 为什么会好仍有很大研究空间。

2.5 本章小结

本章通过非语言序列实验，挑战“BERT 有用只是因为懂语义”的解释。英文预训练 BERT 居然能帮 DNA、蛋白质、音乐分类，说明预训练模型的迁移能力可能来自语义之外的因素。这个结论不推翻语义解释，而是把它放回更大的机制图景中。

3 多语言 BERT 与零样本跨语言迁移

课程后半进入 multilingual BERT (mBERT 或 Multi-BERT)。它的训练方式很朴素：把许多语言的文本都拿来做题。Google 的多语言 BERT 使用 104 种语言预训练。真正神奇的是：它可以用英文 QA 资料微调，然后在中文 QA 上表现不错。

3.1 多语言填空模型

多语言 BERT 的预训练目标仍然是 MLM。不同的是，训练语料不只包含英文，也包含中文、德文、法文等多种语言。模型看见不同语言的句子，都要学会填空。




图 10: 多语言 BERT 在多种语言上做填空题，学习共享的多语言表示空间。¹⁸

这本身还不奇怪。奇怪的是，模型似乎可以把某种语言中学到的任务能力迁移到另一种语言。例如只用英文问答资料 fine-tune，却能回答中文问题。

¹⁸ 视频画面时间区间：约 00:13:44–00:14:17；字幕说明多语言 BERT 用许多语言做填空题，Google 的版本包含 104 种语言。

3.2 Zero-shot Reading Comprehension

Zero-shot 跨语言阅读理解的设定如下：预训练阶段使用 104 种语言；微调阶段只给英文 QA 资料；测试阶段直接给中文 QA。若模型能成功，就说明它不仅学会了英文 QA 的任务格式，还能把“如何做问答”迁移到中文表示上。

手发科技自学实验室 bilibili

Zero-shot Reading Comprehension




图 11: Zero-shot reading comprehension：用英文 QA 资料训练 Multi-BERT，再直接测试中文 QA。

20

²⁰视频画面时间区间：约 00:14:21–00:14:47；字幕说明拿英文 QA 资料训练后，模型自动学会中文 QA，中文资料集使用 DRCD。

Zero-shot Reading Comprehension

- English: SQuAD, Chinese: DRCD

Model	Pre-train	Fine-tune	Test	EM	F1
QANet	none	Chinese	Chinese	66.1	78.1
BERT	Chinese	Chinese		82.0	89.1
	104 languages	Chinese		81.2	88.7
		English		63.3	78.8
		Chinese + English		82.6	90.1

F1 score of Human performance is 93.30%

This work is done by 劉記良、許宗嫻
<https://arxiv.org/abs/1909.09587>

图 12: 跨语言 QA 结果显示, Multi-BERT 即使只在英文 QA 上微调, 也能在中文测试中取得相当表现。²²

零样本迁移的关键

任务监督来自英文, 但测试语言是中文。模型能迁移, 表示它在预训练中学到的表示空间让不同语言之间存在某种对齐, 使英文任务头可以作用到中文表示上。

3.3 一种解释: 跨语言 embedding 对齐

课程给出直觉解释: 也许对 mBERT 来说, 不同语言中意义相同的词, embedding 会靠近。例如“兔”和 rabbit 靠近, “跳”和 jump 靠近, “鱼”和 fish 靠近, “游”和 swim 靠近。若语义相同的词在向量空间中对齐, 英文任务头就可能迁移到中文。

²² 视频画面时间区间: 约 00:14:53-00:16:15; 字幕比较 QANet、中文预训练/中文微调、104 语言预训练/英文微调等设定。

Cross-lingual Alignment?




图 13: 跨语言迁移的一种解释: 不同语言中意义相同的词在 embedding 空间中靠近, 因此任务知识可以跨语言共享。²⁴

为了量化这件事, 可以用 Mean Reciprocal Rank (MRR) 衡量同义词翻译是否互为近邻。若一个英文词的最近邻中, 对应中文词排名越前, MRR 越高, 表示跨语言对齐越好。

²⁴ 视频画面时间区间: 约 00:16:35–00:17:19; 字幕说明 rabbit/兔、jump/跳等同义词可能在 Multi-BERT 表示空间中靠近。




图 14: MRR 越高表示跨语言同义词越靠近; Google 的 Multi-BERT 在多种语言上显示较强对齐。
26

3.4 训练并不容易: 资料量与突然下降的 loss

课程讲了一个训练细节: 实验室自己训练 Multi-BERT 时, 最初每种语言只用 20 万句, 跨语言对齐效果不好。后来把资料加到每种语言 100 万句, 训练时间变长很多, loss 甚至在两天内几乎不降, 正要放弃时突然下降。最终结果显示, 资料量增加后 alignment 才明显学起来。

²⁶视频画面时间区间: 约 00:17:35-00:18:18; 字幕说明深蓝色柱代表 Google 的 104 语言 Multi-BERT, MRR 高表示不同语言同义词向量更接近。

The training is also challenging ...



图 15: Multi-BERT 训练过程中 loss 可能长时间不降，随后突然下降；这种现象显示大规模训练的优化过程并不直观。²⁸

²⁸视频画面时间区间：约 00:19:07-00:20:01；字幕说明增加资料后训练时间大幅增加，loss 跑了两天才突然下降，完整实验要一周以上。




图 16: 资料量从每语言 20 万句增加到 100 万句后, 跨语言对齐明显改善, 说明某些能力需要足够资料规模才会出现。³⁰

规模导致现象显现

课程强调, 过去可能不是没有类似能力, 而是资料量和运算资源不足, 所以观察不到。某些模型现象不是小规模实验的线性外推, 而是在足够规模后才突然变得明显。

3.5 本章小结

多语言 BERT 的奇妙之处在于, 它能把英文任务监督迁移到中文等其他语言。一个合理解释是跨语言 embedding 对齐: 不同语言中意义相同的词被放到相近位置。但这个能力依赖足够大的资料与训练规模, 小模型或小资料未必自然出现同样现象。

4 语言信息到底藏在哪里

如果 mBERT 真把同义词跨语言对齐, 那么会产生一个悖论: 如果 rabbit 和“兔”几乎一样, jump 和“跳”几乎一样, 那模型为什么不会在英文句子里填中文词? 它为什么知道现在应该用英文填空, 而不是把不同语言混在一起?

³⁰ 视频画面时间区间: 约 00:20:01-00:20:17; 字幕说明资料变多后 alignment 学起来, 资料量是不同语言对齐的关键因素。

4.1 跨语言对齐与语言识别的矛盾

课程用 “Weird???” 引出这个问题。mBERT 似乎一方面让不同语言同义词靠近，另一方面又保留语言身份，否则它无法正确做单一语言的填空。




图 17: 悖论：若不同语言同义词向量接近，模型如何仍知道当前句子属于哪一种语言？³¹

³¹ 视频画面时间区间：约 00:20:51–00:21:07；字幕提出疑问：若不同语言同义符号很接近，为什么模型不会混用语言填空？




图 18: 如果 embedding 完全语言无关, 重建时就知道应输出哪种语言; 事实说明语言信息并未被完全抹掉。³³

这说明 mBERT 的表示至少包含两部分信息: 一部分是跨语言共享的语义结构, 另一部分是语言身份。前者让 zero-shot 迁移成为可能, 后者让模型知道应该用哪种语言输出。

4.2 语言向量: 平均 embedding 的差

课程提到一个实验: 把大量英文词汇输入 mBERT, 取它们 embedding 的平均; 再把大量中文词汇输入 mBERT, 取平均。两者相减, 可以得到一个近似表示“英文到中文差距”的向量。把这个向量加到英文句子的 embedding 上, 模型会像读到中文一样进行填空。

³³视频画面时间区间: 约 00:21:15–00:21:45; 字幕说明模型能做英文填空和中文填空, 代表它并没有完全抹掉语言资讯。

Where is Language?

This work is done by 劉記良、許宗嫻、莊永松




图 19: 把中文平均 embedding 与英文平均 embedding 相减, 可得到类似语言方向的向量; 加到英文表示上会改变模型感知的语言。³⁵

可写成

$$v_{zh-en} = \frac{1}{|\mathcal{V}_{zh}|} \sum_{w \in \mathcal{V}_{zh}} h(w) - \frac{1}{|\mathcal{V}_{en}|} \sum_{w \in \mathcal{V}_{en}} h(w)$$

符号说明:

- $\mathcal{V}_{zh}$: 中文 token 集合。
- $\mathcal{V}_{en}$: 英文 token 集合。
- $h(w)$: token w 经过 mBERT 得到的表示。
- v_{zh-en} : 近似从英文表示空间指向中文表示空间的语言差向量。


4.3 把英文 embedding 推向中文

课程展示真实例子: 输入英文句子 “There is no one who can help me”, 再把语言差向量加到 embedding 上。BERT 原本读入的是英文, 但经过向量偏移后, 它的输出开始混合中文词, 例如把 “no one” 往 “无人”、把 “me” 往 “我” 的方向转换。

³⁵ 视频画面时间区间: 约 00:21:52-00:22:34; 字幕说明英文 embedding 平均与中文 embedding 平均相减后, 可把英文表示推向中文表示。

If this is true ...


This work is done by 劉記良、許宗嫻、莊永松
<https://arxiv.org/abs/2010.10041>



Input (en)	The girl that can help me is all the way across town. There is no one who can help me.
Ground Truth (zh)	能帮助我的女孩在小镇的另一边。没有人能帮助我。。
en→zh, $\alpha = 1$	. 孩, can 来我是all the way across 市。。 There 是无人人can help 我。
en→zh, $\alpha = 2$	. 孩的的家我是这个人的市。。 他是他人人的到我。
en→zh, $\alpha = 3$	。。 的的的他是个的的, 。。: 他是他人, 的。他。

图 20: 对英文句子的 embedding 加上语言方向后, mBERT 会把原本英文输入部分转成中文式输出。³⁷

³⁷视频画面时间区间: 约 00:22:37-00:23:23; 字幕说明英文句子进入模型后, 加上蓝色语言向量, BERT 会觉得读到的是中文句子。



Unsupervised token-level translation 😊

图 21: 这种 embedding shift 可产生粗糙的 token-level translation, 说明语言身份在表示空间中具有可操作方向。³⁹

mBERT 表示不是纯语义, 也不是纯语言

多语言 BERT 的 embedding 同时包含跨语言语义对齐和语言身份信息。语义对齐让任务可以跨语言迁移; 语言信息让模型知道该用哪种语言恢复 token。二者不是互斥关系, 而是叠加在同一个表示空间里。

4.4 本章小结

本章揭示 mBERT 的更细机制: 不同语言的同义词可以靠近, 但语言身份没有消失。通过平均 embedding 差构造语言向量, 可以在表示空间中把英文句子推向中文式输出。这说明大模型表示空间里不仅有语义维度, 也可能存在可操作的语言方向。

5 总结与延伸

本讲围绕“BERT 的奇闻轶事”展开, 但这些轶事都指向同一个核心问题: BERT 的能力到底从哪里来?

第一, BERT 确实学到上下文语义。相同 token 在不同语境中得到不同 embedding, 相似语义会形成向量聚类, 这与分布语义假设一致。

³⁹视频画面时间区间: 约 00:23:35-00:24:06; 字幕说明虽然翻译并不好, 但实验显示 multilingual BERT 中仍藏有语言资讯。

第二，BERT 的好处不只来自语义。英文预训练 BERT 能帮 DNA、蛋白质、音乐分类，说明预训练参数可能还提供优化优势、序列建模结构和更好的初始化。

第三，多语言 BERT 展示了跨语言迁移能力。用英文 QA 微调、直接测试中文 QA 能工作，说明不同语言的表示可以在某种程度上对齐。

第四，跨语言对齐并不等于语言信息消失。mBERT 仍知道输入属于哪种语言；语言身份可以表现为 embedding 空间中的方向，甚至可以通过向量偏移做粗糙的 token-level translation。

现象	表面解释	更深的问题
“果”的 embedding 分群	BERT 学到上下文语义	语义如何在层中形成
DNA/音乐也能迁移	预训练是好初始化	迁移到底来自结构还是资料
英文 QA 迁移到中文	多语言表示对齐	对齐需要多少资料与算力
语言向量可偏移	语言身份藏在 embedding 中	表示空间有哪些可控方向

继续深入的方向

可以沿三条线继续读。第一条线是 representation probing：用探针或相似度分析模型是否编码词性、句法、语义、语言身份。第二条线是 transfer learning：区分语义迁移、优化迁移、结构迁移和资料规模效应。第三条线是 multilingual representation：研究跨语言对齐、语言向量、zero-shot transfer 与低资源语言适配。

这节课真正的结论不是“BERT 很神奇”，而是：当模型、资料和训练规模足够大时，表示空间会出现很多可测、可利用、但未必直观的结构。理解这些结构，比只记住 BERT 的训练公式更接近现代自监督模型的核心。