

自监督式学习（四）

GPT 的野望：next-token prediction 与 in-context learning



基于李宏毅老师《机器学习》2025 课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 17 分 03 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=25>

目录

1 从 BERT 到 GPT	3
1.1 Next-token prediction	3
1.2 Decoder-only 与 causal mask	5
1.3 本章小结	6
2 生成能力与 GPT 的使用方式	6
2.1 为什么 GPT 会生成文章	6
2.2 不只是微调: GPT 的更狂使用法	7
2.3 Few-shot learning	9
2.4 Few-shot、one-shot 与 zero-shot	10
2.5 本章小结	12
3 Beyond Text: 自监督学习不只用于文字	12
3.1 自监督学习的更大地图	13
3.2 图像自监督: SimCLR 与 BYOL	13
3.3 语音版 BERT 与 GPT	15
3.4 Speech GLUE: SUPERB	16
3.5 本章小结	18
4 总结与延伸	18

1 从 BERT 到 GPT

本讲承接 BERT 系列，转向另一个自监督学习代表：GPT。BERT 的预训练任务是填空，也就是给一句话遮住某些 token，再让模型猜回来；GPT 改成预测下一个 token。这个差异看似小，却导致完全不同的使用方式：BERT 更像理解式 encoder，GPT 更像自回归生成器。

课程大纲

Outline



BERT series



GPT series

图 1: 课程从 BERT 系列转向 GPT 系列；GPT 的核心任务是预测接下来会出现的 token。¹

1.1 Next-token prediction

假设训练资料中有一句“台湾大学”。GPT 训练时会从一个起始符号 <BOS> 开始，预测第一个 token “台”；再给它 <BOS> 和 “台”，预测“湾”；再给它 <BOS>、“台”、“湾”，预测“大”；如此一路往后。

¹ 视频画面时间区间：约 00:00:01–00:00:36；字幕说明 BERT 做填空题，而 GPT 的任务是预测下一个 token。




图 2: GPT 从 <BOS> 开始，输出隐藏向量，再用线性层和 softmax 预测下一个 token。²

若一段 token 序列为 $x_1, x_2, \dots, x_T$ ，GPT 最大化的条件机率可写为

$$p_{\theta}(x_1, \dots, x_T) = \prod_{t=1}^T p_{\theta}(x_t | x_{<t})$$

训练损失为

$$\mathcal{L}_{\text{LM}} = - \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t})$$

符号说明：

- x_t : 第 t 个 token。
- $x_{<t}$: 位置 t 之前的所有 token。
- $p_{\theta}(x_t | x_{<t})$: 模型根据前文预测第 t 个 token 的机率。
- θ : GPT 模型参数。

²视频画面时间区间：约 00:00:51–00:01:44；字幕说明用 <BOS> 的 embedding 预测 “台”，并用 cross entropy 训练。




图 3: 自回归训练把一句话拆成一连串预测任务: 给前缀, 预测下一个 token。³

1.2 Decoder-only 与 causal mask

课程强调, GPT 架构像 Transformer decoder, 但去掉 encoder-decoder cross-attention, 保留 masked self-attention。预测某个位置时, 模型只能看见当前位置之前的 token, 不能偷看未来答案。

³视频画面时间区间: 约 00:01:44–00:02:33; 字幕说明训练会反复预测 “台” “湾” “大” “学”, 实际训练使用大量句子。




图 4: GPT 使用类似 decoder 的 masked attention: 预测当前 token 时不能看见未来 token。⁴

BERT 与 GPT 的关键差异

BERT 同时看左右上下文，适合得到双向理解表示；GPT 只看左侧前文，适合逐 token 生成。二者都是自监督学习，但自监督目标决定了模型的结构偏好与使用方式。

1.3 本章小结

GPT 的训练目标极其简单：给前文，预测下一个 token。这个目标让它自然具备生成能力，也让它必须使用 causal mask，避免训练时偷看未来。和 BERT 相比，GPT 少了填空式双向理解，多了自回归续写能力。

2 生成能力与 GPT 的使用方式

next-token prediction 的直接结果是生成能力。只要模型能预测下一个 token，就可以把预测结果接回输入，再预测下一个，如此循环，生成一整段文字。

2.1 为什么 GPT 会生成文章

课程用 GPT 写独角兽新闻的经典例子说明：给模型一个新闻开头，它会不断预测下一个 token，最后生成看起来完整的假新闻。生成能力不是额外加上的模块，而是 next-token prediction 反复执

⁴视频画面时间区间：约 00:02:42–00:03:20；字幕说明 GPT 像 Transformer decoder，并通过 mask 避免预测时看到后续词汇。

行的结果。



图 5: GPT 可以通过反复预测下一个 token 生成完整文字；独角兽新闻是早期 GPT 系列的知名展示。⁶

生成过程可写成：

1. 输入前缀 $x_{<t}$ 。
2. 模型输出 $p_{\theta}(x_t | x_{<t})$ 。
3. 从分布中选出或采样一个 token $\hat{x}_t$ 。
4. 把 $\hat{x}_t$ 接到前缀后面，继续预测。

生成不是保证真实

GPT 生成的是“在训练分布下看起来合理的下一个 token”，不是事实数据库查询。早期独角兽新闻之所以有代表性，正是因为它展示了模型可以生成流畅却虚构的文本。

2.2 不只是微调：GPT 的更狂使用法

GPT 当然也可以像 BERT 一样，后面接一个分类器再 fine-tune。但课程指出，GPT 系列论文提出了更激进的使用方式：不调参数，只把任务说明和少量示例写进 prompt，让模型通过上下文“看懂”任务。

⁶视频画面时间区间：约 00:03:24–00:04:20；字幕说明 GPT 可不断预测下一个 token 产生文章，并以独角兽假新闻作为代表例子。

How to use GPT?

第一部份：詞彙和結構

本部份共 15 題，每題含一個空格。請就試題冊上 A、B、C、D 四個選項中選出最適合題意的字或詞，標示在答案紙上。

例：

It's eight o'clock now. Sue _____ in her bedroom.

- A. study
- B. studies
- C. studied
- D. is studying

正確答案為 D，請在答案紙上塗黑作答。

图 6: 课程提出“如何使用 GPT”的问题：除了接分类器微调之外，GPT 还有更接近人类考试说明的使用方式。⁸

这类使用方式像考试。考卷先告诉你题型规则，再给几个例题，最后给新题。GPT 的 prompt 也可以这样组织：先写任务说明，再写若干输入输出范例，最后写待完成输入，让模型续写答案。

⁸视频画面时间区间：约 00:04:53–00:05:48；字幕说明 GPT 也可接 classifier，但论文中采用了更激进的想法。

How to use GPT?

第一部份：詞彙和結構

本部份共 15 題，每題含一個空格。請就試題冊上 A、B、C、D 四個選項中選出最適合題意的字或詞，標示在答案紙上。

Description

例：

It's eight o'clock now. Sue _____ in her bedroom.

- A. study
- B. studies
- C. studied
- D. is studying

正確答案為 D，請在答案紙上塗黑作答。

图 7: Prompt 可以包含任务说明、范例和待回答问题；GPT 通过续写文本来给出答案。⁹

2.3 Few-shot learning

以翻译为例，prompt 可以写成：

```
Translate English to French:  
sea otter => loutre de mer  
peppermint => menthe poivree  
plush giraffe => girafe peluche  
cheese =>
```

训练时 GPT 没有人告诉它“这是翻译任务”，也没有针对翻译做 gradient descent。它只学过续写。但在推理时，prompt 中的例子让它推断出当前格式，接着续写出“cheese”的法文。

⁹视频画面时间区间：约 00:06:05–00:07:05；字幕把 GPT 使用方式类比为考试：读说明、看范例、再举一反三作答。




图 8: Few-shot prompting 在上下文中提供多个示例，让 GPT 从格式中推断任务并续写答案。¹⁰


In-context learning

GPT 文献把这种方式称为 in-context learning。它不是传统意义上的训练，因为模型参数没有更新；所谓“学习”发生在上下文里，模型根据 prompt 中的说明和示例临时推断任务。

2.4 Few-shot、one-shot 与 zero-shot

如果 prompt 中给多个例子，称为 few-shot；只给一个例子，称为 one-shot；不给例子，只给任务说明，称为 zero-shot。这些都属于 in-context learning 的不同强度版本。

¹⁰ 视频画面时间区间：约 00:07:23–00:08:16；字幕说明训练时并没有教翻译，只是在 prompt 中给几个翻译例子并要求模型补完。



"In-context" Learning

图 9: Few-shot、one-shot、zero-shot 的区别在于 prompt 中给多少示例；共同点是都不做 gradient descent。¹²

课程提醒，这个目标是否真正达成要看任务。有些任务 GPT 确实能靠 prompt 完成，例如简单算术；有些逻辑推理任务仍表现很差。模型规模越大，平均表现通常越好，但不是所有能力都会随规模平滑解决。

¹² 视频画面时间区间：约 00:08:37–00:09:26；字幕说明 in-context learning 不调模型参数，并引出 one-shot 与 zero-shot。




图 10: GPT-3 论文展示参数规模增加时, few-shot/one-shot/zero-shot 平均表现提升, 但不同任务差异很大。¹⁴

Prompting 与 fine-tuning 的差异

Fine-tuning 改变模型参数, 适合把模型专门调到某个任务上; prompting 不改变参数, 适合快速指定任务格式。二者不是互斥关系, 现代系统常把预训练、指令微调、对齐训练与 prompt 设计结合使用。

2.5 本章小结

GPT 的野望在于: 模型只通过 next-token prediction 预训练, 却希望在推理时读懂任务说明和示例, 直接完成新任务。few-shot、one-shot、zero-shot 与 in-context learning 的核心都是“把任务写进上下文”, 而不是每个任务都重新训练模型。

3 Beyond Text: 自监督学习不只用于文字

课程最后把视野从文字扩展到图像和语音。BERT 和 GPT 只是自监督学习的一部分, 主要属于 prediction 类方法; 图像中有对比学习, 语音中也可以做遮蔽、预测和下游 benchmark。

¹⁴ 视频画面时间区间: 约 00:10:22-00:11:12; 字幕说明参数从 0.1B 增至 175B 后平均正确率提高, 但某些逻辑推理任务仍很差。

3.1 自监督学习的更大地图

课程展示一张图，把 NLP、speech、CV 中的自监督方法放在一起。BERT/GPT 位于 prediction 这一支，但 CV 中有 SimCLR、MoCo、BYOL 等 contrastive 或 related 方法，speech 中也有 CPC、TERA、Mockingjay、wav2vec 等模型。




图 11: 自监督学习远不止 BERT/GPT; NLP、speech、CV 中各自发展出预测、对比、资料中心等 多类方法。¹⁶

3.2 图像自监督: SimCLR 与 BYOL

图像没有天然 token 序列，但可以构造不同视角的同一张图，要求模型把同一图片的不同增强版本拉近，把不同图片拉远。SimCLR 是典型对比学习方法。课程没有展开细节，只指出它非常有名，概念可以自行读论文理解。

¹⁶视频画面时间区间: 约 00:11:37-00:12:16; 字幕说明 BERT/GPT 只是自监督学习的一小块，还有更多方向等待探索。

Image - SimCLR

<https://arxiv.org/abs/2002.05709>

<https://github.com/google-research/simclr>




图 12: SimCLR 通过图像增强和对比目标学习表示：同一图片的不同视角应接近，不同图片应分开。

18

BYOL 则更反直觉：它不依赖传统负样本对比，却仍能学到强表示。课程也坦率地说，这类方法“为什么 work”并不总是直观，甚至看起来像有明显漏洞，但实验结果有效。

¹⁸ 视频画面时间区间：约 00:12:21–00:12:36；字幕说明影像自监督中有著名方法 SimCLR，课程只做概览。

Image - BYOL

Bootstrap your own latent:

A new approach to self-supervised Learning

<https://arxiv.org/abs/2006.07733>




图 13: BYOL 是图像自监督中反直觉但有效的方法，显示深度学习中常有机制尚未完全解释的成功经验。²⁰

3.3 语音版 BERT 与 GPT

语音也可以套用类似思想。语音版 BERT 可以遮住一段声音，让模型猜被遮住的片段；语音版 GPT 可以根据前面的声音预测接下来会出现的声音信号。也就是说，自监督目标不依赖“文字”本身，而依赖能否从资料内部构造预测任务。

²⁰ 视频画面时间区间：约 00:12:36–00:13:13；字幕说明 BYOL 看起来不该成功，但实际曾取得很强结果。




图 14: 语音中也可以设计 BERT 式遮蔽预测与 GPT 式下一段声音预测, 从而训练语音表示模型。
22

3.4 Speech GLUE: SUPERB

课程指出, 语音自监督领域需要类似 GLUE 的 benchmark。GLUE 在 NLP 中把多个语言理解任务组合起来评估模型; 语音领域也需要一个跨任务 benchmark, 测试模型是否能处理内容、说话人、情绪、语义等不同信息。


²²视频画面时间区间: 约 00:13:20-00:14:02; 字幕说明语音也可做填空题或预测下一段声音, 已有许多相关研究。

Speech GLUE - SUPERB

- **Speech processing Universal PERFORMANCE Benchmark**
 - Will be available soon
- **Downstream:** Benchmark with 10+ tasks
 - The models need to know how to process content, speaker, emotion, and even semantics.
- **Toolkit:** A flexible and modularized framework for self-supervised speech models.
 - <https://github.com/s3prl/s3prl>

图 15: SUPERB 是语音版 GLUE 的构想：用多个下游任务评估自监督语音模型的通用能力。²³

²³ 视频画面时间区间：约 00:14:22-00:15:17；字幕说明语音领域缺少类似 GLUE 的 benchmark，因此提出 Speech processing Universal PERFORMANCE Benchmark。



<https://github.com/andi611/Self-Supervised-Speech-Pretraining-and-Representation-Learning>

图 16: SUPERB 试图统一多种上游自监督模型和多类语音下游任务，包括识别、语义、说话人、情绪等。²⁵

自监督学习的共同核心

无论文字、图像还是语音，自监督学习都在问同一个问题：能否从资料本身构造训练信号，让模型先学通用表示，再迁移到下游任务？

3.5 本章小结

自监督学习不是 NLP 专属。文字里有 BERT/GPT，图像里有 SimCLR/BYOL，语音里有遮蔽预测、下一段预测和 SUPERB 这样的 benchmark。它们表面任务不同，但都试图减少人工标签依赖，让模型从大规模原始资料中学习可迁移表示。

4 总结与延伸

本讲用 GPT 收束自监督学习中的文字主线。BERT 和 GPT 的差异，可以压缩成一张对照表：

²⁵ 视频画面时间区间：约 00:16:05–00:16:56；字幕说明 SUPERB 从多种下游任务全方位检测模型理解人类语言的能力，并提供工具包。

维度	BERT	GPT
预训练目标	遮蔽填空，预测被盖住的 token	给前文，预测下一个 token
上下文方向	双向上下文	只看左侧前文
典型架构	Transformer encoder	Transformer decoder-like, causal mask
典型用途	表示学习、分类、标注、抽取式问答	续写、生成、prompt-based task solving
任务适配	多用 fine-tuning 或任务头	可 fine-tune, 也可 in-context learning

GPT 的关键启发是：只要 next-token prediction 学得足够好，模型就可能在 prompt 中读任务说明、看范例、再续写答案。这不是传统监督学习，也不是普通 fine-tuning，而是一种把任务临时写进上下文的使用模式。

同时，课程最后提醒我们不要把自监督学习等同于文字模型。prediction、contrastive learning、masked reconstruction、benchmark-driven evaluation 都可以出现在图像与语音中。BERT/GPT 只是更大自监督图谱中的两条主线。

后续学习建议

若继续深入 GPT，可以重点看三件事。第一是语言模型目标如何从 next-token prediction 发展到 instruction tuning 和 alignment。第二是 in-context learning 为什么会出现，是否等价于隐式学习算法。第三是跨模态自监督如何把文字、图像、语音放到统一表示或统一生成框架中。

本讲的核心结论是：GPT 把“预测下一个 token”推到极致，得到生成能力和 in-context learning；而自监督学习的更大野心，是把这种从资料本身学习的范式推广到所有模态。