

语音与影像上的神奇自督导式学习模型

Self-supervised Learning for Speech and Image



基于李宏毅老师《机器学习 2025》课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 1 小时 21 分 58 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=27>

目录

1 从文字自督导到语音与影像	3
1.1 复习：文字版自督导的使用方式	3
1.2 语音版 BERT：从未标注语音学表示	3
1.3 SUPERB：语音表示的综合评测	4
1.4 影像版自督导：不只用于分类	5
1.5 本章小结	7
2 Generative Approaches：遮住一部分，再还原它	7
2.1 从 BERT/GPT 到语音 masking	7
2.2 Predicting future：语音版 GPT	9
2.3 影像上的生成式方法	9
2.4 本章小结	10
3 Predictive Approaches：设计一个不需人工标签的前置任务	10
3.1 影像：预测旋转角度	11
3.2 影像：预测局部上下文关系	11
3.3 Predict simplified objects：先简化，再预测	12
3.4 本章小结	12
4 Contrastive Learning：拉近正样本，推远负样本	13
4.1 基本思想	13
4.2 SimCLR：用资料增强制造正样本	14
4.3 MoCo：memory bank 与 momentum encoder	14
4.4 语音：CPC 与 wav2vec 系列	15
4.5 wav2vec 2.0：连续输入与量化目标	17
4.6 把 BERT 也看成对比学习	18
4.7 负样本选择并不简单	19
4.8 本章小结	20
5 Bootstrapping 与 Extra Regularization：没有负样本也能学吗	20
5.1 Bootstrapping：只用正样本的风险	20
5.2 Predictor、copy 与 stop-gradient	21
5.3 Extra regularization：直接防止 collapse	23
5.4 本章小结	25
6 总结与延伸	25

6.1	五类方法的概念压缩	26
6.2	跨模态迁移的真正难点	26
6.3	实践上的选择	26

1 从文字自督导到语音与影像

本讲把前面几讲的自督导式学习从文字推广到语音和影像。核心问题是：文字里的 BERT、GPT 可以靠未标注文本学到可迁移表示；那么语音和影像能不能也靠大量未标注数据学到通用表示，再迁移到下游任务？

1.1 复习：文字版自督导的使用方式

文字里的典型流程是：先用未标注文本训练 BERT，再把 BERT 的输出接到下游模型。以情感分类为例，BERT 先把输入句子转换成一串 contextual representation，再由下游模型判断正面或负面。下游任务可以是分类、问答、序列标注等；BERT 负责提供强表示，下游模型负责读取这些表示。




图 1: 文字版自督导的典型用法：先用未标注文本训练 BERT，再把 BERT 表示交给下游模型¹

这个框架有两个关键点。第一，预训练资料不需要人工标签，只需要大量自然文本。第二，预训练目标不一定等于下游目标；BERT 预训练时做填空，下游却可以做情感分类、问答或推理。自督导式学习的价值正在这里：用容易取得的资料构造训练信号，学到可迁移表示。

1.2 语音版 BERT：从未标注语音学表示

课程接着做类比：如果有大量未标注语音讯号，能不能训练出「speech version of BERT」？这里的输入不再是 token，而是语音波形或声学特征序列。模型输出一串语音表示，像 BERT 输出文字表示一样，供后续任务使用。

¹视频画面时间区间：约 00:02:15–00:02:30。

Self-supervised Learning for Speech




图 2: 语音自督导的目标是用未标注语音训练 speech version of BERT，使模型学到可迁移语音表示²

预训练完成后，可以把 speech BERT 的输出交给 speech recognition 模型，得到文本结果。它也可以用于 speaker identification、emotion recognition、keyword spotting 等任务。关键思想和文字一样：先用大量未标注资料学表示，再用少量标注资料适配任务。

Self-supervised Learning for Speech




图 3: Speech BERT 的表示可以输入下游模型，例如把语音讯号转换成文字的语音辨识任务³

1.3 SUPERB: 语音表示的综合评测

语音表示是否通用，需要 benchmark 检验。SUPERB (Speech processing Universal PERFORMANCE Benchmark) 把语音任务分成多类：content、speaker、paralinguistic、semantic、synthesis 等。它不

²视频画面时间区间：约 00:03:45–00:04:00。

³视频画面时间区间：约 00:05:00–00:05:15。

只看语音辨识，也看说话人、情绪、意图、语音增强与分离等任务。




图 4: SUPERB 用多种下游任务评估语音自督导表示，覆盖内容、说话人、语义、合成等维度⁴

为什么语音 benchmark 要很宽


语音讯号同时包含「说了什么」「谁说的」「怎么说的」「语气情绪」「录音环境」等信息。一个好的语音自督导模型不应该只服务语音辨识，还应该能迁移到说话人辨识、情绪辨识、语音增强、语音转换等不同任务。

1.4 影像版自督导：不只用于分类

影像自督导的下游任务同样很多，包括 image recognition、object detection、semantic segmentation、visual navigation 等。课程强调，影像自督导不是只为了分类，而是为了学到能够服务多种视觉任务的 representation。

⁴视频画面时间区间：约 00:08:15–00:08:30。


Self-supervised Learning for Image



- How Well Do Self-Supervised Models Transfer? <https://arxiv.org/abs/2011.13377>
- Scaling and Benchmarking Self-Supervised Visual Representation Learning <https://arxiv.org/abs/1905.01235>

图 5: 影像自督导表示可迁移到辨识、侦测、语义分割与视觉导航等多种任务⁵

近年来 visual self-supervised representation learning 的表现持续提升，在部分设定中甚至超过 supervised learning 基线。图中的横轴是论文时间，纵轴是相对监督式学习的表现；不同颜色代表不同任务或评测方式。课程用这张图说明：自督导不再只是「没有标签时的替代品」，而是可以成为强大的通用预训练方法。



Source of image: <https://arxiv.org/abs/2110.09327>

图 6: Visual SSL 方法持续进步，在多项视觉任务上逼近甚至超过监督式学习基线⁶

⁵视频画面时间区间：约 00:12:00–00:12:15。

⁶视频画面时间区间：约 00:15:15–00:15:30。

本讲的五类方法

课程把语音和影像自督导方法整理成五类: generative approaches、predictive approaches、contrastive learning、bootstrapping approaches、extra regularization。它们都在回答同一个问题: 没有人工标签时, 怎样构造一个足够有用、又不会太容易的训练目标。

1.5 本章小结

文字、语音和影像的自督导式学习有共同骨架: 先在大量未标注资料上预训练, 再把表示迁移到下游任务。但三种模态的资料结构不同。文字是离散 token, 语音是连续时间讯号, 影像是空间结构与像素细节。因此同样叫「自督导」, 具体训练目标会很不一样。

2 Generative Approaches: 遮住一部分, 再还原它

第一类方法是 generative approaches。它的直觉和 BERT/GPT 很接近: 模型看到输入的一部分, 要生成或还原被遮住、被省略、未来会出现的内容。文字中可以预测 token; 语音和影像也可以做类似事情, 但难点在于连续讯号和高维细节。

2.1 从 BERT/GPT 到语音 masking

课程用 BERT 系列和 GPT 系列做引子。BERT 式方法遮住一部分输入并重建, GPT 式方法根据过去预测未来。把这套思想搬到语音, 就是遮住部分声学特征, 要求模型根据上下文还原。



1. Generative Approaches

图 7: Generative approaches 对应文字中的 BERT/GPT 系列: 遮住一部分或根据过去预测未来⁷

以 Mockingjay 为例, 输入语音中有些 frame 被 mask, 模型要学习重建原始声学特征。它类似 BERT 的 masked language modeling, 但预测对象不是词表中的 token, 而是连续声学向量。

⁷ 视频画面时间区间: 约 00:16:15–00:16:30。




图 8: 语音 masking 方法遮住部分声学特征，并训练模型重建被遮住的部分⁸

语音和文字不同：相邻声学特征非常平滑。如果只遮住很小片段，模型可能靠左右邻近 frame 的局部连续性轻易猜出答案，学不到高层语义。因此语音 masking 常遮连续片段，或遮特定维度，迫使模型利用更宽的上下文。




图 9: 语音 masking 需要更有挑战性的遮罩策略，例如遮连续时间片段或遮特定维度⁹

⁸ 视频画面时间区间：约 00:18:30–00:18:45。

⁹ 视频画面时间区间：约 00:21:45–00:22:00。

重建目标不能太容易

如果被遮住的信息可以靠局部平滑性直接插值出来，模型可能只学到低层讯号规律，而不是语音内容、说话人或语义。自督导目标的设计要避免「题目太简单」，否则 representation 的迁移价值会有限。

2.2 Predicting future: 语音版 GPT

GPT 式思路是根据过去预测未来。语音中也可以要求模型根据前面的声学片段预测未来 frame。课程提醒，和文字 next token prediction 不同，语音中通常要预测更远的未来，例如 $n \geq 3$ ，才比较有意义；因为预测紧邻 frame 太容易。




图 10: 语音 predicting future 根据过去声学特征预测未来，通常需要预测较远的 frame 才有挑战性¹⁰

2.3 影像上的生成式方法

影像也可以做生成式目标。Image GPT 和 masked image modeling 把影像切成 patch 或像素序列，再做 autoregressive 或 masked prediction。预训练后，可以用 linear probe 或 fine-tuning 检验表示是否能用于分类。

¹⁰ 视频画面时间区间：约 00:24:30–00:24:45。

How about image?




图 11: 影像中的 GPT/BERT 式方法把图像转换成 patch 或像素序列，再做生成或遮罩预测¹¹

但课程也指出，语音和影像包含大量难以生成的细节。像素、纹理、背景、噪声和声学细节未必都和下游任务有关。如果目标是精确重建原始输入，模型可能把容量花在低层细节，而不是学可迁移的抽象语义。

Generative approach 的优缺点

优点是训练目标自然，资料本身就提供答案；缺点是重建高维连续讯号可能太困难，也可能迫使模型关注和下游任务无关的细节。语音和影像中的 generative objective 往往需要 masking 策略、离散化或降维设计配合。

2.4 本章小结

Generative approaches 的共同思想是「遮住或省略一部分，让模型补回来」。文字中补 token，语音中补声学特征或未来 frame，影像中补像素或 patch。它们最直观，但在语音和影像上必须小心：目标太容易，模型学不到高层表示；目标太细，模型又可能被低层重建牵着走。

3 Predictive Approaches: 设计一个不需人工标签的前置任务

第二类方法是 predictive approaches。它们不一定要重建原始输入，而是人为设计一个可自动产生标签的任务，让模型为了解这个任务学到有用 representation。关键在于：任务要能由资料本身生成标签，同时又和语义结构有关。

¹¹ 视频画面时间区间：约 00:26:00–00:26:15。

3.1 影像：预测旋转角度

一个经典例子是 predicting rotation。把同一张图旋转 0° 、 90° 、 180° 、 270° ，模型要预测旋转角度。标签不需要人工标注，因为旋转角度是我们自己施加的变换；但模型若要判断方向，必须理解影像中的结构。




图 12: Predicting rotation 用自动生成的旋转角度作为标签，训练模型理解影像结构¹²

3.2 影像：预测局部上下文关系

另一类任务是 context prediction。给模型两个 patch，让它预测它们在原图中的相对位置。这个任务迫使模型理解局部区域之间的空间关系，例如某块区域应该在另一块区域的上方、下方或旁边。




图 13: Context prediction 让模型根据局部 patch 预测相对位置，从空间关系中学习视觉表示¹³

¹² 视频画面时间区间：约 00:29:15–00:29:30。

¹³ 视频画面时间区间：约 00:31:30–00:31:45。

课程也提到，语音中有类似想法：不一定直接还原完整连续讯号，而是预测简化后的结构、类别或上下文关系。这样可以避开精细生成的困难。

3.3 Predict simplified objects: 先简化，再预测

语音和影像可以先做 feature extraction 或 clustering，把连续、复杂的输入变成较简单的离散目标，再让模型预测这些目标。语音中的 HuBERT、BEST-RQ，影像中的 DeepCluster，都可以放在这个思路下理解。




图 14: Predict simplified objects 先把输入特征聚类或离散化，再训练模型预测简化后的目标¹⁴

这类方法的要点不是「聚类本身很神奇」，而是聚类把困难的原始讯号重建问题变成较稳定的类别预测问题。模型不用复原每个细节，只需预测抽象后的类别或 cluster index，更容易学到下游有用的结构。

Predictive approach 和 generative approach 的区别

Generative approach 常要求模型还原输入本身；predictive approach 则设计一个代理任务，例如旋转角度、patch 相对位置、cluster index。后者不一定保留全部低层细节，但可能更直接鼓励模型学习结构性信息。

3.4 本章小结

Predictive approaches 的重点是「设计任务」。标签不来自人工，而来自我们对输入做的变换或简化。旋转预测、上下文预测、cluster 预测都属于这类方法。好的 predictive objective 要在两件事之间平衡：足够容易训练，但不能容易到只靠低层捷径；足够贴近语义，但不需要人工标签。

¹⁴ 视频画面时间区间：约 00:34:30-00:34:45。

4 Contrastive Learning: 拉近正样本，推远负样本

第三类方法是 contrastive learning。它不要求模型生成输入，也不一定设计显式类别标签，而是定义相似与不相似：同一资料的不同视图应该接近，不同资料的视图应该远离。

4.1 基本思想

Contrastive learning 需要 positive pair 和 negative pair。Positive pair 通常来自同一资料的不同变换，例如同一张图片的两个增强版本；negative pair 来自不同资料。训练目标是让 positive pair 的表示尽量接近，让 negative pair 尽量远。




图 15: Contrastive learning 让 positive pair 的表示接近，让 negative pair 的表示远离¹⁵

常见的 InfoNCE 形式可以写成：

$$\mathcal{L}_i = -\log \frac{\exp(\text{sim}(z_i, z_i^+)/\tau)}{\exp(\text{sim}(z_i, z_i^+)/\tau) + \sum_{j=1}^K \exp(\text{sim}(z_i, z_j^-)/\tau)}$$

符号说明：

- z_i ：当前样本的表示。
- z_i^+ ：positive sample 的表示。
- z_j^- ：第 j 个 negative sample 的表示。
- $\text{sim}(\cdot, \cdot)$ ：相似度函数，常用 dot product 或 cosine similarity。
- τ ：temperature，控制 softmax 的尖锐程度。

¹⁵视频画面时间区间：约 00:37:15–00:37:30。

4.2 SimCLR: 用资料增强制造正样本

SimCLR 的做法是对同一张图做随机裁切、颜色扰动、模糊等 data augmentation，得到两个不同视图，把它们当作 positive pair。不同图像的增强版本则作为 negative pair。模型必须学到对增强不敏感、对语义差异敏感的表达。




图 16: SimCLR 通过资料增强建立 positive pair，并把不同资料作为 negative pair¹⁶

这个做法的关键在 augmentation。增强不能太弱，否则任务太容易；也不能太强，否则 positive pair 的语义可能被破坏。课程提到，如果增强后看起来和原图差太多，模型被迫拉近不该相近的表示，训练目标会变得不合理。


4.3 MoCo: memory bank 与 momentum encoder

MoCo 关注 negative samples 的组织方式。它用 queue 或 memory bank 存放大量负样本表示，并用 momentum encoder 产生稳定的 key representation。这样可以在较小 batch 下获得更多 negative examples。

¹⁶ 视频画面时间区间：约 00:39:45-00:40:00。

MoCo

<https://arxiv.org/abs/1911.05722>



MoCo v2 <https://arxiv.org/abs/2003.04297>

图 17: MoCo 使用 memory bank 或 momentum encoder, 让 contrastive learning 获得更多稳定的 negative samples¹⁷

4.4 语音: CPC 与 wav2vec 系列

语音中的 CPC 与 wav2vec 可以看成 contrastive learning for speech。模型根据前文表示预测未来表示, 并在候选向量中区分真正未来片段和负样本。它不一定直接重建波形, 而是通过对比目标学习能预测未来结构的 representation。




图 18: CPC 与 wav2vec 通过区分真实未来片段和负样本, 学习语音表示¹⁸

¹⁷ 视频画面时间区间: 约 00:41:15-00:41:30。

¹⁸ 视频画面时间区间: 约 00:44:15-00:44:30。

VQ-wav2vec 进一步引入 quantization，把连续语音表示转换成离散 token。离散 token 可以作为后续 BERT-like 模型的输入，形成「先离散化，再做 masked prediction」的路线。




图 19: VQ-wav2vec 把连续语音表示量化成离散 token，使语音可进入类似 BERT 的训练流程¹⁹

Discrete BERT 把 VQ-wav2vec 产生的离散 token 当成输入，再用 BERT 架构做遮罩预测。这条线把语音问题转成更接近文字问题：先把连续声音离散化，再对离散序列做自监督。




图 20: Discrete BERT 固定前级 VQ-wav2vec encoder，再用 BERT 架构处理离散语音 token²⁰

¹⁹ 视频画面时间区间：约 00:46:00–00:46:15。

²⁰ 视频画面时间区间：约 00:47:15–00:47:30。

4.5 wav2vec 2.0: 连续输入与量化目标

wav2vec 2.0 把特征 encoder、context network 与 quantized target 联合训练。输入仍然是连续语音特征，部分位置被 mask；目标端则使用量化后的离散目标，通过 contrastive loss 区分正确目标和负样本。




图 21: wav2vec 2.0 将连续输入、遮罩 context encoder 与量化目标结合起来共同训练²¹

课程强调两个设计点：连续输入很关键，量化目标也会改善 performance。换句话说，wav2vec 2.0 不是简单地「全部离散化」或「全部连续化」，而是在输入端保留连续声学细节，在目标端用量化类别提供更稳定的对比信号。




图 22: wav2vec 2.0 的经验结论：连续输入很关键，量化目标有助于提升表现²²

²¹ 视频画面时间区间：约 00:49:45–00:50:00。

4.6 把 BERT 也看成对比学习

课程给出一个有趣视角：BERT 的 masked token prediction 也可以被看成一种分类或对比。被 mask 的位置要在词表中选择正确 token，正确 token 是 positive，其他 token 是 negative。差别在于，文字的负样本集合是有限词表；语音的负样本空间是连续且巨大。




图 23: BERT 的 masked token prediction 可被视为在词表中区分正确 token 与其他 token²³

分类和 contrastive 的形式也很接近。分类模型把表示和每个类别的 embedding 比较，再做 softmax；contrastive learning 把表示和正负样本 embedding 比较。二者都在学习相似度，只是「候选集合」的来源不同。

²²视频画面时间区间：约 00:52:15–00:52:30。

²³视频画面时间区间：约 00:55:45–00:56:00。

Alternative way to understand Wav2vec 2.0

- Classification vs. Contrastive




图 24: 分类与对比学习都可看成相似度比较: 分类比较类别 embedding, 对比学习比较正负样本 embedding²⁴

4.7 负样本选择并不简单

在文字分类里, 负样本可以是词表中的其他 token, 数量有限; 在语音里, 只要不是当前被 mask 的声音片段, 理论上都可能是负样本, 空间近乎无限。负样本太容易, 模型学不到细粒度区分; 负样本太难, 可能把本应相近的语义拉远。

Alternative way to understand Wav2vec 2.0




图 25: 语音中的 negative examples 数量难以穷举, 和文字词表分类不同²⁵

²⁴ 视频画面时间区间: 约 00:58:30-00:58:45。

²⁵ 视频画面时间区间: 约 01:02:15-01:02:30。

图中展示了负样本选择的困境：负样本应该够难，但又不能难到把同类或语义相近资料当成必须远离的对象。这个问题促使后续方法尝试避开 negative examples。



Selecting Negative Examples is not trivial ...

- The negative examples should be hard enough. But cannot be too hard ...




图 26: Negative examples 既要足够困难，又不能把应相近的样本强行推远²⁶

Contrastive learning 的隐含假设

Contrastive learning 假设 positive pair 真的应该接近，negative pair 真的应该远离。但在真实语音和影像中，两个不同样本可能共享语义、说话人、场景或内容。负样本选择若不当，会把有用的相似性破坏掉。

4.8 本章小结

Contrastive learning 用相似度学习取代显式生成：正样本靠近，负样本远离。SimCLR 强调增强，MoCo 强调负样本队列和 momentum encoder，CPC/wav2vec 系列把这种思想搬到语音。它的关键难点是负样本：没有好负样本，任务太容易；负样本太强或语义冲突，训练目标又会伤害 representation。

5 Bootstrapping 与 Extra Regularization：没有负样本也能学吗

既然 negative examples 难选，课程接着介绍不依赖负样本的路线。这里有两类：bootstrapping approaches 通过 teacher/student 或 predictor 避免 collapse；extra regularization 则显式加入统计约束，让表示既保持不变性，又避免全部塌缩成同一个向量。

5.1 Bootstrapping：只用正样本的风险

Bootstrapping approaches 想避开 negative examples，只要求同一资料的两个增强视图表示接近。这听起来简单，但会遇到 collapse：如果 encoder 对所有输入都输出同一个向量，那么所有 positive pair 都非常接近，loss 很低，却完全没有学到有用表示。

²⁶ 视频画面时间区间：约 01:06:15–01:06:30。

Learning without negative examples

4. Bootstrapping Approaches

图 27: Bootstrapping approaches 试图在不使用 negative examples 的情况下学习表示²⁷




图 28: 只拉近 positive pair 会产生 collapse 风险: 所有输入都输出同一向量也能满足目标²⁸

5.2 Predictor、copy 与 stop-gradient

BYOL、SimSiam 等方法用不对称结构避免 collapse。图中一边是 encoder，另一边包含 predictor；训练时只更新某一侧，再把参数复制或移动平均到另一侧。这个不对称设计和 stop-gradient 是关键，否则模型容易塌缩。

²⁷ 视频画面时间区间：约 01:07:30–01:07:45。

²⁸ 视频画面时间区间：约 01:09:00–01:09:15。




图 29: Bootstrapping 方法用 predictor、copy 或 stop-gradient 建立不对称训练，避免表示塌缩²⁹

课程提供了另一个理解角度：bootstrapping 类似 knowledge distillation。Teacher 固定或慢速更新，student 学习接近 teacher 的输出；随着训练进行，student 又逐渐成为新的 teacher。Data2vec 也可用这种 teacher/student 框架理解。




图 30: Bootstrapping 可被理解为 teacher/student 式知识蒸馏：student 追随 teacher，teacher 再随 student 更新³⁰

总结页把影像和语音中的代表方法放在一起：影像中有 BYOL、SimSiam；语音中有 Data2vec，student 从 teacher 的多层表示中学习。核心是不用负样本，也能通过结构设计和 teacher/student 关系学表示。

²⁹ 视频画面时间区间：约 01:11:15–01:11:30。

³⁰ 视频画面时间区间：约 01:14:45–01:15:00。

Bootstrapping Approaches

- Image
 - Bootstrap your own latent (BYOL)
 - <https://arxiv.org/abs/2006.07733>
 - Simple Siamese (SimSiam)
 - <https://arxiv.org/abs/2011.10566>
- Speech
 - Data2vec: the student learns from multiple layers of the teacher
 - <https://arxiv.org/abs/2202.03555>




图 31: BYOL、SimSiam 与 Data2vec 都可看作不依赖负样本的 bootstrapping 方法³¹

5.3 Extra regularization: 直接防止 collapse

另一条路线是 extra regularization。Barlow Twins、VICReg 这类方法仍让 positive pair 接近，但额外加入 variance、invariance、covariance 等约束，明确防止表示塌缩。




图 32: Extra regularization 方法不靠 negative examples，而靠额外统计约束避免 collapse³²

Invariance 要求同一资料的不同增强视图表示接近；variance 要求每个表示维度在 batch 中有足够变动，不能所有样本都输出同一个常数。若 variance 太小，就代表模型塌缩。

³¹ 视频画面时间区间：约 01:16:15–01:16:30。

³² 视频画面时间区间：约 01:18:00–01:18:15。




图 33: Invariance 拉近 positive pair; variance 要求各维度有足够变化, 从而避免所有表示相同³³

Covariance regularization 进一步要求不同维度之间不要高度相关, 特别是 off-diagonal covariance 接近 0。这样做鼓励表示维度携带互补信息, 而不是多个维度重复同一件事。




图 34: Covariance regularization 要求不同表示维度去相关, 避免信息冗余并帮助防止 collapse³⁴

可以用一个简化目标理解 VICReg/Barlow Twins 的精神:

$$\mathcal{L} = \lambda_{\text{inv}} \mathcal{L}_{\text{inv}} + \lambda_{\text{var}} \mathcal{L}_{\text{var}} + \lambda_{\text{cov}} \mathcal{L}_{\text{cov}}$$

符号说明:

- $\mathcal{L}_{\text{inv}}$: 让同一资料的两个视图表示接近。

³³ 视频画面时间区间: 约 01:19:15–01:19:30。

³⁴ 视频画面时间区间: 约 01:20:30–01:20:45。

- $\mathcal{L}_{\text{var}}$: 要求每个维度有足够 variance, 防止常数输出。
- $\mathcal{L}_{\text{cov}}$: 让不同维度去相关, 减少冗余。
- $\lambda_{\text{inv}}, \lambda_{\text{var}}, \lambda_{\text{cov}}$: 三项损失的权重。

5.4 本章小结

Bootstrapping 和 extra regularization 都试图绕开 negative examples。前者用不对称结构、teacher/student、stop-gradient 或 moving average 让模型不塌缩；后者直接加 variance/covariance 等统计约束。它们说明，自督导学习不一定非要靠负样本，但必须有机制阻止「所有输入都变成同一个表示」。

6 总结与延伸

课程最后用表格把五类方法在影像和语音中的代表模型对应起来：generative、predictive、contrastive、bootstrapping、regularization。真正重要的不是背模型名，而是理解每类方法怎样从未标注资料中制造学习信号。



	Image	Speech / Audio
Generative	GPT for image	Mockingjay, APC
Predictive	Rotation Prediction, etc.	HuBERT
Contrastive	SimCLR, MoCo	CPC, Wav2vec series
Bootstrapping	BYOL, SimSiam	Data2vec
Regularization	Barlow Twins, VICReg	DeLoRes

图 35: 课程总结：五类自督导方法在影像和语音中都有对应代表模型³⁵

³⁵ 视频画面时间区间：约 01:21:00–01:21:15。

6.1 五类方法的概念压缩

方法类别	核心问题	代表想法
Generative	遮住或省略一部分后，能否还原？	Masking、reconstruction、future prediction
Predictive	能否设计自动标签的前置任务？	Rotation prediction、context prediction、cluster prediction
Contrastive	哪些样本应接近，哪些应远离？	SimCLR、MoCo、CPC、wav2vec 系列
Bootstrapping	不用负样本时如何避免 collapse？	BYOL、SimSiam、Data2vec、teacher/student
Regularization	如何显式约束表示不塌缩？	Barlow Twins、VICReg、variance/covariance

6.2 跨模态迁移的真正难点

文字、语音和影像都能做自督导，但不能简单复制训练目标。文字是离散 token，BERT 可以直接在词表上分类；语音是连续、平滑、时间相关的讯号，遮一个很短片段可能太容易，预测原始波形又太细；影像是高维空间讯号，像素重建可能浪费容量在低层细节。每个模态都要重新设计「什么被遮住」「预测什么」「正负样本如何定义」「如何避免 collapse」。

6.3 实践上的选择

如果任务需要保留细节，例如增强、分离或生成，generative objective 可能合适。如果希望 representation 更抽象，predictive 或 contrastive 方法往往更直接。如果负样本可自然取得，contrastive learning 很强；如果负样本难定义，bootstrapping 或 regularization 会更有吸引力。若目标是建立一个通用 backbone，就需要像 SUPERB 或多视觉任务评测那样，确认表示是否真的迁移到不同类型任务。

最终 takeaway

自督导式学习的核心不是「没有标签也训练模型」这么简单，而是把资料自身转化成有信息量的训练目标。语音和影像上的 SSL 方法之所以丰富，是因为不同模态的结构不同：有时要还原，有时要预测，有时要对比，有时要防止 collapse。理解这些目标如何制造学习信号，比记住单个模型名更重要。