

异常检测（二）：分类器信心分数

Using Classifier Confidence for Open-set Anomaly Detection



基于李宏毅老师《机器学习 2025》课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 14 分 09 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=30>

目录

1 有标签设定：从普通分类器出发	3
1.1 为什么分类器能提供线索	3
1.2 从 closed-set 到 open-set	3
1.3 本章小结	4
2 用 confidence threshold 做异常检测	4
2.1 决策规则	4
2.2 阈值的意义	5
2.3 本章小结	5
3 如何定义 confidence score	5
3.1 最大类别分数	6
3.2 负熵作为信心	6
3.3 分数定义对比	7
3.4 本章小结	7
4 实验现象：简单 baseline 有用，但会过度自信	7
4.1 未知输入也可能得到高分	8
4.2 分布层面的观察	8
4.3 本章小结	9
5 展望：直接学习 confidence	9
5.1 从后处理到模型内建	10
5.2 和校准问题的关系	10
5.3 本章小结	11
6 总结与延伸	11
6.1 本讲核心压缩	11
6.2 实践建议	11
6.3 和下一步的连接	11

1 有标签设定：从普通分类器出发

上一讲把异常检测按资料设定分成几类。本讲先处理“有标签”的情况：训练资料属于若干已知类别，模型可以训练一个普通分类器；测试时，输入可能来自已知类别，也可能来自训练时没有见过的未知类别。目标不是只判断它属于哪个已知类，而是还要判断它是否应该被拒绝为 unknown 或 anomaly。




图 1: 有标签设定示例：先训练一个已知类别分类器，再思考如何用它判断输入是否来自已知分布¹

1.1 为什么分类器能提供线索

普通分类器输入 x ，输出类别 $\hat{y}$ 。若分类器看到的是训练分布内的样本，它通常应该对某个类别很有把握；若看到训练时没有见过的类型，它可能会犹豫，输出分布比较平均。这个直觉让我们想到：也许可以把分类器的信心分数当作异常检测分数。

在 open-set recognition 中，分类器不只需要回答“这是哪一个已知类别”，还要回答“它是否属于任何已知类别”。若它不属于已知类别，就应该输出 unknown 或 anomaly。

本讲 baseline

已有一个分类器时，最简单的异常检测 baseline 是：用分类器对最可能类别的信心分数 $c(x)$ 判断输入是否正常。信心高，认为是 normal；信心低，认为是 anomaly。

1.2 从 closed-set 到 open-set

Closed-set classification 假设测试样本一定来自训练类别之一。因此 softmax 分类器无论看到什么输入，都会在已知类别中选一个答案。Open-set anomaly detection 则放宽这个假设：测试样本可

¹ 视频画面时间区间：00:01:45–00:02:00。

能不属于任何已知类别，模型必须有能力拒绝。


这正是本讲的重点：若普通分类器只能输出类别，怎样把它改造成能拒绝未知输入的检测器？课程采用的方法是附加一个 confidence score。

1.3 本章小结

有标签异常检测可以从普通分类器开始，但不能停在普通分类器。分类器给出的类别 $\hat{y}$ 只回答“最像哪个已知类”，confidence score 才可能回答“到底像不像任何已知类”。因此，本讲后续全部围绕如何定义、使用和改进 confidence score 展开。

2 用 confidence threshold 做异常检测

分类器不仅可以输出类别，也可以输出一个信心分数 $c(x)$ 。这个分数代表模型对当前分类结果的把握程度。若 $c(x)$ 高于阈值 λ ，就把输入当作 normal；若 $c(x)$ 低于阈值，就当作 anomaly。



Anomaly Detection:

$$f(x) = \begin{cases} \text{normal}, & c(x) > \lambda \\ \text{anomaly}, & c(x) \leq \lambda \end{cases}$$

Created with EverCam.
<http://www.camdemy.com>

图 2: 分类器输出类别和信心分数；异常检测可用阈值 λ 把低信心输入判为 anomaly²

2.1 决策规则

课程中的规则可以写成：

$$f(x) = \begin{cases} \text{normal}, & c(x) > \lambda, \\ \text{anomaly}, & c(x) \leq \lambda. \end{cases}$$

符号说明：

²视频画面时间区间：00:03:00–00:03:15。

- $c(x)$: 分类器对输入 x 的信心分数。
- λ : 阈值, 通常需要用 development set 决定。
- $f(x)$: 最终异常检测输出。

这个规则非常直接, 但它把问题转移到了两个新问题上: 第一, $c(x)$ 如何定义? 第二, λ 如何选择? 若信心分数定义不可靠, 阈值再怎么调也只能治标; 若阈值选择不合理, 正常样本和异常样本之间会产生大量误报或漏报。

2.2 阈值的意义

阈值 λ 控制保守程度。阈值高, 只有非常有信心的输入才被接受为 normal, 误报可能增加, 但漏报可能减少; 阈值低, 模型更愿意接受输入为 normal, 误报减少, 但可能漏掉异常。

development set 应该长什么样

理想情况下, development set 要尽量模拟测试时 normal 和 anomaly 的组成。如果完全没有异常样本, 阈值只能根据正常验证集的分数的分布设定, 例如选一个较低分位数作为拒绝边界; 但这样无法保证未来异常一定会落在阈值外。

2.3 本章小结

用 confidence threshold 做异常检测的框架很简单: 分类器给出 $c(x)$, 阈值 λ 决定 normal 或 anomaly。它是一个很实用的 baseline, 因为不需要额外训练复杂模型。但它的成败高度依赖 confidence score 是否真的能反映“输入是否来自已知分布”。

3 如何定义 confidence score

分类器通常输出一个类别分布:

$$p(y = k | x), \quad k = 1, \dots, K$$

其中 K 是已知类别数。最直觉的 confidence score 是最大类别概率:

$$c_{\max}(x) = \max_k p(y = k | x)$$




图 3: 最简单的 confidence score 是输出分布中的最大类别分数；分数高代表模型更确信某个类别³

3.1 最大类别分数

若分类器对某张图片输出 (0.97, 0.01, 0.01, 0.01)，最大类别分数为 0.97，模型非常有信心。若输出接近 (0.24, 0.26, 0.25, 0.25)，最大分数只有 0.26，表示模型无法明显偏向任何已知类。

最大类别分数的优点是简单、可解释、无需改模型。它的缺点是 softmax 分数不一定校准。模型可能对分布外输入也给出很高的最大概率，尤其是深度网络在训练时没有被明确教过“遇到未知输入时要低信心”。

3.2 负熵作为信心

另一种方法是看输出分布的 entropy：

$$H(p) = - \sum_{k=1}^K p_k \log p_k$$

若分布尖锐，entropy 小，模型较有信心；若分布平均，entropy 大，模型较没信心。因此可以使用负熵作为信心：

$$c_{\text{ent}}(x) = -H(p(y | x))$$

³视频画面时间区间：00:05:30-00:05:45。




图 4: confidence 可由最大类别分数或负熵估计；两者都从输出分布的集中程度衡量模型把握⁴

最大类别分数只看最高的那一类；entropy 会看整个分布。若一个输出分布有两个很高的类别，最大分数可能仍不低，但 entropy 会反映这种不确定性。课程也指出，在文献和实践中，不同简单分数之间的差异未必总是很大；真正的问题常常是分类器的输出分布本身是否可靠。

3.3 分数定义对比

分数	计算方式	主要特点
最大类别分数	$\max_k p_k$	最简单，常作为第一 baseline
负熵	$-\sum_k p_k \log p_k$ 的相反数	考虑整个分布是否集中
温度校准后分数	调整 softmax 温度后再取分数	可改善校准，但需要验证集
专门 confidence head	模型直接输出 $c(x)$	更灵活，但需要额外训练设计

3.4 本章小结

confidence score 可以由分类器输出分布构造，最常见的是最大类别概率和负熵。它们都把“输出分布是否集中”当作信心来源。这个想法直观且容易实现，但要记住：softmax 分数不是天然可靠的概率信心，它只是模型在已知类别之间分配的相对分数。

4 实验现象：简单 baseline 有用，但会过度自信

课程用已训练好的角色分类器做实验。对训练分布内的图片，模型通常会给出很高分数；对分布外图片，分数多数会降低。这个结果说明 confidence score baseline 确实有信号。但实验也显示，它

⁴ 视频画面时间区间：00:06:45–00:07:00。

不是万无一失的。

4.1 未知输入也可能得到高分

有些分布外图片会被分类器以很高信心归到某个已知类别。原因可能是输入在某些低层特征上和某个已知类别相似，也可能是模型只学到了局部纹理、颜色或形状捷径。因为训练时模型只被要求在已知类别之间分类，它没有被明确惩罚“对未知输入过度自信”。



图 5: 未知输入有时仍会得到很高 confidence；这暴露了直接使用 softmax 分数的风险⁵

这正是 open-set recognition 的核心麻烦。Closed-set classifier 被迫在已知类别中选择答案，所以它看到未知输入时也会输出一个已知类别。若 softmax 分布恰好尖锐，最大类别分数就会误导我们，让 anomaly 被当成 normal。

4.2 分布层面的观察

课程进一步比较信心分数分布：已知分布内样本的 confidence 大多集中在接近 1 的区域；分布外样本的 confidence 更分散，整体较低，但仍有一部分样本分数很高。也就是说，confidence score 在统计上可区分两群样本，但个别样本上会出错。

⁵ 视频画面时间区间：00:09:15–00:09:30。




图 6: 已知分布和分布外样本的 confidence 分布有明显差异, 但分布外样本仍可能出现高 confidence⁶

这个结果给了一个务实结论: 若你手上已经有分类器, 使用最大 softmax score 做异常检测是值得尝试的第一个 baseline。它非常简单, 计算成本低, 很多时候效果不差。但它不能被当成最终保证, 尤其是在安全、医疗、金融等高风险应用里。

softmax confidence 的根本限制

Softmax 分数回答的是“在已知类别中, 哪一类相对最大”, 不是“输入是否属于已知分布”。两者在分布内样本上常常一致, 但在分布外样本上可能分离。

4.3 本章小结

实验说明两件事同时成立: 第一, 分类器信心分数确实包含异常检测信号; 第二, 分类器可能对未知输入过度自信。它适合做快速 baseline, 却需要校准、阈值验证或更专门的方法来提升可靠性。


5 展望: 直接学习 confidence

课程最后提到一种更进一步的方向: 不要先训练分类器、再事后从输出分布硬凑 confidence, 而是在训练模型时就让网络直接输出 confidence。这样模型的目标不只是分类正确, 还包括估计自己对当前输入的把握。

⁶视频画面时间区间: 00:11:45-00:12:00。

Outlook: Network for Confidence Estimation

- Learning a network that can directly output confidence



Terrance DeVries, Graham W. Taylor, Learning Confidence for Out-of-Distribution Detection in Neural Networks, arXiv, 2018

Created with EverCam
<http://www.camdemy.com>

图 7: 展望方向: 训练一个网络直接输出分类结果和 confidence, 使 confidence estimation 成为模型目标的一部分⁷

5.1 从后处理到模型内建

前面的最大分数和负熵都属于后处理: 模型原本只为分类训练, confidence 是我们从输出分布中额外计算出来的。直接学习 confidence 则把 $c(x)$ 变成模型输出的一部分:

$$\text{model}(x) \rightarrow (p(y | x), c(x))$$

这种设计的好处是模型可以学习“什么时候应该不确定”。例如, 它可能在输入远离训练分布、特征冲突或类别边界模糊时降低 confidence。坏处是训练目标更复杂, 需要更谨慎的数据和损失设计。

5.2 和校准问题的关系

Confidence estimation 和 calibration 密切相关。一个校准良好的模型, 预测 0.8 正确率的样本集合中, 应大约有八成真的预测正确。但异常检测要求更进一步: 不仅要知道分类是否可能错, 还要知道输入是否来自训练分布之外。

两种不确定性

分类别不确定性是“这个输入像多个已知类中的哪一个”; 分布外不确定性是“这个输入是否根本不属于已知世界”。异常检测更关心后者, 而普通 softmax 分数主要反映前者。

⁷ 视频画面时间区间: 00:14:00-00:14:09。

5.3 本章小结

直接学习 confidence 是对简单 baseline 的升级。它承认一个事实：如果模型没有被训练去表达“不知道”，就很难指望它自然地在未知输入上低信心。未来的 open-set 和 out-of-distribution 方法，常常都围绕如何让模型知道自己的知识边界展开。

6 总结与延伸

本讲给出了有标签异常检测的第一种实用路线：拿一个分类器，计算 confidence score，用阈值决定 normal 或 anomaly。它是非常好的第一 baseline，因为简单、便宜、实现快；但它也暴露了 softmax classifier 的局限：分布外输入仍可能得到高 confidence。

6.1 本讲核心压缩

概念	说明
Open-set setting	测试样本可能不属于任何训练类别，分类器要能拒绝 unknown。
Confidence score	用来衡量模型对当前分类结果的把握程度。
Threshold rule	$c(x) > \lambda$ 判 normal, $c(x) \leq \lambda$ 判 anomaly。
Maximum score	取 softmax 输出中的最大类别概率作为 confidence。
Negative entropy	输出分布越集中，entropy 越小，confidence 越高。
Overconfidence	未知输入也可能被分类器高信心归到已知类。
Learned confidence	训练模型直接输出 confidence，而不是只做后处理。

6.2 实践建议

如果已经有一个分类器，先试最大 softmax score 是合理的。它能快速建立 baseline，也能帮助你看清资料分布：已知样本的分数是否集中？未知样本是否整体偏低？两者是否有可用阈值？如果 baseline 已经很好，复杂方法未必必要；如果 baseline 高误报或高漏报，就需要考虑校准、temperature scaling、专门的 OOD 方法、直接学习 confidence，或改用非分类器路线。

最重要的一句话

分类器信心分数是异常检测的好起点，但不是可靠性的终点。它告诉我们模型在已知类别之间有多确信，却不保证模型真的知道输入是否来自已知分布。

6.3 和下一步的连接

本讲处理的是有标签、已有分类器的情境。后续若进入无标签或 clean/polluted 设定，分类器 confidence 可能不再可用，方法会转向重建误差、密度估计、距离度量或其他 one-class 技术。学习时可以继续抓住三个问题：分数怎么定义，阈值怎么选，模型为什么会对未知样本犯错。