

异常检测（五）：无标签设定与机率模型

Unlabeled Anomaly Detection with Density-based Scoring



基于李宏毅老师《机器学习 2025》课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 12 分 17 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=33>

目录

1 Case 2: 没有标签时的异常检测	3
1.1 从分类问题变成相似性问题	3
1.2 为什么需要无标签设定	3
1.3 本章小结	3
2 Twitch Plays Pokémon: 从集体游戏到异常玩家	4
2.1 为什么游戏会困难	4
2.2 异常检测之后不一定要删除异常	5
2.3 本章小结	5
3 把玩家表示成 feature vector	6
3.1 例子中的两个行为特征	6
3.2 特征选择本身就是假设	7
3.3 本章小结	7
4 问题形式化: 相似就是 normal, 不相似就是 anomaly	7
4.1 与有标签设定的差异	8
4.2 相似性可以有不同定义	8
4.3 本章小结	9
5 用机率分数和阈值做异常检测	9
5.1 密度阈值规则	9
5.2 阈值仍然需要验证	10
5.3 本章小结	10
6 二维行为分布的直观解释	10
6.1 从图上读出正常行为	11
6.2 边际分布不等于联合分布	11
6.3 本章小结	11
7 高密度与低密度: 谁更异常	12
7.1 为什么需要数值化分数	12
7.2 密度模型的实际挑战	12
7.3 本章小结	13
8 总结与延伸	13

1 Case 2: 没有标签时的异常检测

前几讲讨论的设定大多还能借助分类器：训练资料有类别标签，模型可以先学会分类，再用 confidence score 判断输入是否来自已知分布。本讲进入另一种更困难、也很常见的设定：训练资料没有标签。我们手上只有一批样本

$$\{x^1, x^2, \dots, x^N\},$$

但不知道每笔样本属于哪个类别，也没有对应的 y 可以训练分类器。

在这种情况下，异常检测的目标不再是“分类器是否有把握”，而是“新的输入 x 是否像训练资料”。如果 x 和训练资料相似，就把它当作 normal；如果 x 明显不同，就把它当作 anomaly。课程把这称为没有标签的 case，也可以视为 unsupervised anomaly detection 的基本形式。

1.1 从分类问题变成相似性问题

有标签时，我们可以学习

$$p(y | x)$$

或训练一个 discriminative classifier。没有标签时， y 不存在或不可用，所以无法直接定义“分类正确”这件事。此时更自然的目标是学习训练资料本身的分布：

$$p(x).$$

这代表我们关心的是某种输入在训练资料世界中出现的可能性。如果某个 x 落在训练资料常见的区域， $p(x)$ 应该较大；如果它落在很少见的区域， $p(x)$ 应该较小。于是异常检测可以从 confidence threshold 转换成 density threshold：

$$f(x) = \begin{cases} \text{normal}, & P(x) \geq \lambda, \\ \text{anomaly}, & P(x) < \lambda. \end{cases}$$

本讲核心变化

有标签设定中，分数来自分类器 confidence；无标签设定中，分数来自资料分布或机率模型。前者问“模型认为它像哪一类”，后者问“这个输入本身常不常见”。

1.2 为什么需要无标签设定

很多实际应用中，正常行为资料容易收集，标签却很难取得。例如系统日志、用户行为、设备传感器、网络流量、交易记录等，通常可以累积大量样本，但不一定有人逐笔标注类别。更麻烦的是，异常类型可能非常多样，甚至未来才会出现，事先标出所有异常类别并不现实。

因此，无标签异常检测通常采用一种弱假设：训练资料大多数来自正常行为。模型不需要知道每个正常样本属于哪个细分类，只需要把“常见的正常行为区域”刻画出来。未来输入如果远离这个区域，就被视为可疑。

1.3 本章小结

没有标签时，异常检测不能再依赖分类器 confidence。问题会转化为：给定一批训练样本，学习什么样的输入像训练资料，什么样的输入不像训练资料。这个转化把重点从 $p(y | x)$ 移到 $p(x)$ ，也为后面的机率模型和密度估计铺路。

2 Twitch Plays Pokémon: 从集体游戏到异常玩家

课程用 Twitch Plays Pokémon 作为例子说明无标签异常检测。这个活动把宝可梦游戏直播到 Twitch 上，全世界玩家可以在聊天室输入上下左右、A、B 等指令，系统再根据大家的输入操控同一个游戏角色。参与人数最多时可达数万人，因此游戏过程会非常混乱。



图 1: Twitch Plays Pokémon: 大量玩家同时在聊天室输入指令，共同操控同一个宝可梦游戏¹

2.1 为什么游戏会困难

如果所有玩家都想通关，集体投票本身已经很难协调。更困难的是，有些玩家可能不熟悉游戏，有些玩家只是觉得乱按很有趣，还有些玩家可能带有恶意，故意输入不利于通关的指令。这些玩家在网络语境中常被称为 troll，课程翻译成“网络小白”。

从异常检测角度看，我们可以把多数认真通关的玩家视为 normal data，把明显不符合通关目标的玩家视为 anomaly。于是问题变成：在没有明确标签的情况下，能否从多数玩家行为中学习正常模式，再找出行为异常的玩家？

¹ 视频画面时间区间：00:01:15–00:01:30。

Twitch Plays Pokémon



- Why is the game so difficult?
- Probably because of “Troll” (網路小白)
 - Players that are not familiar with the game
 - Just for fun ...
 - Malicious players ...
- Assuming that most players want to complete the game (normal data for training)
 - Using anomaly detection, can we identify the “Troll” (anomaly)?
- Do we need to remove trolls?

In all, the players who don't want to complete the game.

Created with EverCam.
<http://www.camdemy.com>

图 2: 若假设多数玩家想完成游戏, 他们的行为可作为正常训练资料; 不想完成游戏或行为怪异的玩家可视为 anomaly²

2.2 异常检测之后不一定要删除异常

课程里还有一个值得注意的小提醒: 检测出 troll 之后, 是否要移除他们, 是另一个决策问题。有人可能认为如果没有这些混乱行为, Twitch Plays Pokémon 反而没有那么有趣; 也有人可能认为正是混乱和阻挠构成了游戏的社群体验。

这说明异常检测只负责给出“可疑程度”或“与多数行为是否相似”的判断, 不自动决定后续处置。实际系统也一样: 检测到异常交易, 不一定马上封号; 检测到异常设备信号, 不一定马上停机; 检测到异常玩家, 也不一定马上踢出。后续动作需要结合任务目标、误报代价和用户体验。

检测与处置要分开

Anomaly detector 给出的是分数或警报, policy 才决定如何处理警报。把两者混在一起, 容易让模型评估和业务决策互相污染。

2.3 本章小结

Twitch Plays Pokémon 提供了一个生动的无标签异常检测场景: 多数玩家行为构成训练资料, 少数不符合通关目标或行为怪异的玩家可能是 anomaly。这个例子也提醒我们, 异常检测不是道德审判或自动处罚, 它只是把“与多数行为不相似”的样本找出来。

²视频画面时间区间: 00:05:00–00:05:15。

3 把玩家表示成 feature vector

机器学习模型不能直接处理“一个玩家”这个抽象对象。要使用 anomaly detection，首先需要把每个玩家表示成一个向量：


$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \end{bmatrix}.$$

这一步叫 feature representation。它决定了模型看到的世界是什么样，也会影响后续异常分数是否有意义。



Problem Formulation

- Given a set of training data $\{x^1, x^2, \dots, x^N\}$
- We want to find a function detecting input x is *similar* to training data or not.



Created with EverCam.
<http://www.camdemy.com>

图 3: 把每个玩家表示成 feature vector，例如垃圾话比例、在无政府状态下发言的比例等³

3.1 例子中的两个行为特征

课程举了两个可能的特征：

- **垃圾话比例**：玩家在過去一段時間內輸入了多少與遊戲控制無關的內容。只有上下左右、A、B、Start 等指令會直接影響遊戲，其他內容可視為無關訊息。
- **无政府状态下发言比例**：Twitch Plays Pokémon 中存在不同控制模式。若某些玩家特別常在混亂模式下發言，可能反映其行為偏好。

因此，一个玩家可以被简化成二维向量：

$$x = \begin{bmatrix} \text{垃圾话比例} \\ \text{无政府状态发言比例} \end{bmatrix}.$$

当然，真实系统可以加入更多特征，例如指令重复率、与当前游戏状态矛盾的输入比例、短时间高频发言、是否跟随多数玩家等。本讲只用二维特征，是为了方便在图上画出分布。

³视频画面时间区间：00:06:30–00:06:45。

3.2 特征选择本身就是假设

特征不是中立的。选择“垃圾话比例”和“无政府状态发言比例”，就等于假设这些行为与 troll 倾向有关。如果真正的异常玩家很少发垃圾话，却总是在关键时刻输入错误方向，那么这两个特征可能抓不住他。反过来，一个正常玩家爱聊天，也可能被误判为异常。

因此，无标签异常检测通常比有标签分类更依赖特征工程或 representation learning。没有标签帮我们纠正模型，特征设计就更需要结合领域理解。

无标签不等于无假设

虽然训练资料没有标签，但模型仍然依赖假设：哪些特征代表正常行为，哪些差异值得视为异常。若特征选错，密度模型再精密也会在错误空间里做判断。

3.3 本章小结

无标签异常检测的第一步是把对象变成向量。以玩家为例，可以用垃圾话比例和无政府状态发言比例描述行为。这个向量空间决定了后续“相似”与“不相似”的含义，因此特征设计是异常检测系统的重要组成部分。

4 问题形式化：相似就是 normal，不相似就是 anomaly

有了 feature vector 之后，我们可以正式写出本讲的问题。给定训练资料


$$\{x^1, x^2, \dots, x^N\},$$

其中大多数样本被假设为正常。我们希望找到一个函数，判断新的输入 x 是否和训练资料相似：

$$g(x) = \begin{cases} \text{normal}, & x \text{ similar to training data,} \\ \text{anomaly}, & x \text{ different from training data.} \end{cases}$$

Problem Formulation

- Given a set of training data $\{x^1, x^2, \dots, x^N\}$
- We want to find a function detecting input x is *similar* to training data or not.



Created with EverCam.
http://www.camdemy.com

图 4: 无标签异常检测的问题形式化: 输入若类似训练资料则判为 normal, 若不同于训练资料则判为 anomaly⁴

4.1 与有标签设定的差异

有标签异常检测中, 训练资料可能带有类别标签, 分类器可以学会哪些输入属于已知类别。无标签设定中, 我们没有 y , 所以不能训练普通 classifier 来输出类别 confidence。这里的 anomaly detector 更像一个“相似性检测器”或“分布检测器”。

这种差异可以整理如下:

设定	可用资料	常见分数来源
有标签分类式异常检测	(x, y) , 正常类别标签	分类器 confidence, 如最大 softmax
有异常样本的设定	正常样本与部分异常样本	二元分类器或 cost-sensitive score
无标签异常检测	只有 $\{x^1, \dots, x^N\}$	资料密度、重建误差、距离或相似度

本讲聚焦密度式思路: 估计某个输入在训练资料分布中出现的机率。如果训练资料代表正常行为, 那么低机率样本就可能是异常。

4.2 相似性可以有不同定义

“相似”不是一个自动定义好的概念。它可以由距离决定, 例如离训练样本很近就算相似; 也可以由概率密度决定, 例如落在高密度区域就算相似; 还可以由重建误差决定, 例如 autoencoder 重建不好就算不相似。课程在这里采用概率模型, 是因为它可以把相似性变成一个清楚的数值 $P(x)$ 。

⁴ 视频画面时间区间: 00:07:15–00:07:30。

概率视角的好处是可解释：我们可以说某类玩家行为在历史资料中出现得多不多。若一个玩家位于高密度区域，他更像多数玩家；若位于低密度区域，他更可疑。

4.3 本章小结

无标签异常检测可以被形式化为“是否类似训练资料”的问题。由于没有类别标签，模型不再输出类别 confidence，而要学习训练资料本身的结构。概率模型给出一种清楚做法：用 $P(x)$ 衡量输入是否常见，再根据阈值判断 normal 或 anomaly。

5 用机率分数和阈值做异常检测

课程接着把 confidence threshold 的形式迁移到无标签设定。过去我们用 $c(x)$ 表示分类器 confidence；现在没有分类器，就用概率模型给出的 $P(x)$ 表示样本在训练分布中出现的可能性。




图 5: 用机率模型生成 $P(x)$: 若 $P(x) \geq \lambda$, 判为 normal; 若 $P(x) < \lambda$, 判为 anomaly⁵

5.1 密度阈值规则

规则可以写成：

$$f(x) = \begin{cases} \text{normal}, & P(x) \geq \lambda, \\ \text{anomaly}, & P(x) < \lambda. \end{cases}$$

这里的 λ 仍然是阈值，但它的意义和前几讲有所不同。前几讲阈值切的是分类器 confidence；本讲阈值切的是资料密度或机率。二者都把连续分数转换成二元决策，但分数来源不同。

⁵ 视频画面时间区间：00:08:00–00:08:15。

如果 $P(x)$ 很大，表示像 x 这样的行为在训练资料中常见；如果 $P(x)$ 很小，表示它落在训练资料稀疏区域。异常检测的直觉就是：正常行为应该集中在高密度区域，异常行为更可能出现在低密度区域。

5.2 阈值仍然需要验证

虽然公式很简单，但 λ 不是随意设定的。阈值太高，许多正常样本会被误报为异常；阈值太低，真正异常可能被放过。若有 development set，可以像前几讲一样调阈值；若没有异常标签，就只能结合业务容忍度，例如每天最多允许多少警报、希望抓住多极端的行为，或使用训练资料分数的低分位数作为初始阈值。

密度阈值的解释

$P(x)$ 不是在说“这个玩家是不是坏人”，而是在说“这种行为在训练资料中常不常见”。低 $P(x)$ 只代表行为罕见，是否需要处理仍取决于应用场景。

5.3 本章小结

无标签设定下，可以用机率模型估计 $P(x)$ ，再用阈值 λ 把输入分成 normal 和 anomaly。这个规则和 confidence threshold 形式相似，但含义不同：它不是模型对类别的把握，而是输入在训练分布中的常见程度。

6 二维行为分布的直观解释

为了让 $P(x)$ 更直观，课程使用真实资料画出二维分布。横轴是“说垃圾话”的比例，纵轴是“无政府状态发言”的比例。每一个点代表一个玩家。训练资料形成一个云状分布，密集区域代表常见玩家行为，稀疏区域代表少见行为。




图 6: 二维玩家行为分布与边际直方图：玩家行为并非均匀散布，而是集中在某些高密度区域⁶

6.1 从图上读出正常行为

图中可以看到，多数玩家集中在某些区域。例如垃圾话比例较低、无政府状态发言比例较高的区域有大量样本。这类行为在训练资料中常见，因此对应的 $P(x)$ 较大。反过来，如果某个玩家落在很少有点的位置，他的行为组合就比较罕见， $P(x)$ 较小。

这里的直觉不需要先知道复杂机率模型。人眼看散点图时，也会自然觉得密集区域“正常”、孤立点“奇怪”。机率模型只是把这个直觉数值化，让系统能自动给每个玩家一个 anomaly score。

6.2 边际分布不等于联合分布

图中还画了两个方向的直方图，分别显示每个特征自己的分布。但异常检测通常不能只看单一特征。一个玩家在垃圾话比例上可能不极端，在无政府状态发言比例上也不极端，但两个特征组合起来却很少见。真正的 $P(x)$ 应该刻画联合分布：

$$P(x) = P(x_1, x_2, \dots, x_d).$$

这点在高维资料中更重要。许多异常不是某一个特征特别大或特别小，而是特征组合不合常理。例如一个用户登录地点正常、时间也正常，但地点和时间的组合不正常；一笔交易金额不大、商户也常见，但组合起来很可疑。

6.3 本章小结

二维行为分布展示了密度式异常检测的核心直觉：训练资料密集处代表常见行为，稀疏处代表罕见行为。机率模型的任务，就是把这种“常见/罕见”的视觉判断变成每个输入的数值分数 $P(x)$ 。

⁶ 视频画面时间区间：00:09:00–00:09:15。

7 高密度与低密度：谁更异常

课程最后用几个红点说明 $P(x)$ 的解释。落在密集区域的点对应 $P(x)$ large，比较可能是正常玩家；落在稀疏区域或边缘区域的点对应 $P(x)$ small，比较可能是异常玩家。




图 7: 同一行为空间中的不同玩家：高密度区域 $P(x)$ large，稀疏区域 $P(x)$ small，更可能被判为 anomaly⁷

7.1 为什么需要数值化分数

有些点肉眼看起来很容易判断：明显落在密集区域就是正常，明显远离所有点就是异常。但实际系统常遇到边界案例。课程举的直觉问题是：如果一个玩家垃圾话比例较高，但多数时间都在无政府状态下发言；另一个玩家垃圾话比例稍低，但无政府状态发言比例很低，到底谁更异常？

这时就需要一个数值化方法，而不是只靠肉眼或规则。机率模型会根据整体资料分布给每个点一个分数。分数可以排序，也可以和阈值比较：

$$\text{score}(x) = -\log P(x)$$

通常也是常用写法。因为 $P(x)$ 越小， $-\log P(x)$ 越大，越异常。

7.2 密度模型的实际挑战

本讲还没有展开具体机率模型，但这里已经可以看到几个挑战：

- **高维困难**：特征维度越高，估计联合分布越难，资料也更稀疏。
- **正常资料污染**：训练资料若混入较多异常，模型可能把异常行为也学成正常。
- **特征尺度问题**：不同特征的尺度和分布不同，直接建模前通常需要标准化或变换。

⁷视频画面时间区间：00:11:30–00:11:45。

- 罕见不等于有害：低密度行为可能只是少见，不一定需要处罚。

这些挑战说明， $P(x)$ 提供的是原则，不是免费答案。真正系统仍要选择合适的特征、密度模型、阈值和后续策略。

7.3 本章小结

高密度区域代表训练资料中常见行为，低密度区域代表罕见行为。为了比较边界案例，需要把直觉转换成数值分数，例如 $P(x)$ 或 $-\log P(x)$ 。密度式异常检测的目标，就是让每个输入都能获得一个可排序、可阈值化的异常分数。

8 总结与延伸

这一讲把异常检测从有标签分类器推进到无标签资料。核心思想很朴素：如果没有类别标签，就不要再问分类器是否有 confidence，而要问输入是否像训练资料。用数学语言说，就是从 $p(y | x)$ 转向 $p(x)$ 。

Twitch Plays Pokémon 的例子说明了这个设定的实际含义。我们可以假设多数玩家想完成游戏，把他们的行为作为正常训练资料；再把每个玩家表示成 feature vector，例如垃圾话比例、无政府状态发言比例；最后用训练资料估计行为分布，给新玩家计算 $P(x)$ 。若 $P(x)$ 低于阈值，就把他标为可疑或 anomaly。

本讲最重要的几条结论是：

1. 无标签异常检测没有 y ，因此不能依赖普通分类器的 confidence。
2. 训练资料通常被假设为多数正常，模型要学习正常资料分布。
3. Feature vector 决定了“相似”的含义，是系统成败的关键。
4. 概率模型用 $P(x)$ 数值化常见程度，低密度样本更可能是 anomaly。
5. 检测结果不等于处置策略，低密度只代表罕见，不自动代表应该删除或惩罚。

和前几讲连起来看，异常检测有两条重要路线：若有标签和分类器，可以从 confidence score 出发；若没有标签，就要从资料分布出发。下一步通常会讨论如何真的估计 $P(x)$ ，例如用高斯模型、混合模型、非参数方法或神经生成模型。无论具体模型多复杂，基本逻辑都不变：正常资料定义高密度区域，异常检测寻找低密度输入。