

异常检测（六）：最大似然与高斯密度

Maximum Likelihood and Gaussian Density for Unlabeled
Anomaly Detection



基于李宏毅老师《机器学习 2025》课程整理
2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 12 分 18 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=34>

目录

1 从训练资料到密度函数	3
1.1 参数的意义	3
1.2 为什么不能直接数点	4
1.3 本章小结	4
2 最大似然：选择最能解释资料的参数	4
2.1 likelihood 不是同一个角度的机率	4
2.2 实际计算常用对数似然	4
2.3 本章小结	5
3 用高斯分布作为具体密度模型	5
3.1 均值和协方差的角色	5
3.2 把一般参数换成高斯参数	6
3.3 本章小结	6
4 似然大小与模型选择	6
4.1 最大似然如何体现“贴合资料”	7
4.2 为什么课程提到神经网络密度模型	7
4.3 本章小结	8
5 闭式解：平均值与协方差矩阵	8
5.1 例子中的参数值	8
5.2 为什么平均值不是全部	9
5.3 本章小结	9
6 用密度阈值做最终判定	9
6.1 密度热力图的解释	10
6.2 阈值就是一条等高线	10
6.3 本章小结	11
7 总结与延伸	11

1 从训练资料到密度函数

上一讲把无标签异常检测写成一个密度判断问题：若输入 x 在训练资料分布中常见，就判为 normal；若它很罕见，就判为 anomaly。本讲要回答更具体的问题：这个代表“常见程度”的机率密度函数到底怎么来？


课程从一个基本假设开始：我们收集到的训练资料

$$\{x^1, x^2, \dots, x^N\}$$

是从某个未知的 probability density function 采样出来的。这个密度函数写作 $f_\theta(x)$ ，其中 θ 是参数。参数 θ 决定了密度函数的形状；但一开始 θ 不知道，必须从训练资料中估计出来。

Maximum Likelihood

- Assuming the data points is sampled from a probability density function $f_\theta(x)$
 - θ determines the shape of $f_\theta(x)$
 - θ is unknown, to be found from data



$$L(\theta) = f_\theta(x^1)f_\theta(x^2) \cdots f_\theta(x^N)$$

Likelihood

$$\theta^* = \arg \max_{\theta} L(\theta)$$

Created with EverCam.
<http://www.camdemy.com>

图 1: 最大似然的基本框架：假设资料来自参数为 θ 的密度函数，并选择让训练资料最可能出现的参数¹

1.1 参数的意义

可以把 $f_\theta(x)$ 想成一张“正常行为地图”。某些区域密度高，代表训练资料常在那里出现；某些区域密度低，代表训练资料很少在那里出现。 θ 控制这张地图的形状，例如高密度区域在哪里、伸展方向是什么、分布有多宽。

在 Twitch Plays Pokémon 的例子中， x 是玩家行为向量，例如

$$x = \begin{bmatrix} \text{垃圾话比例} \\ \text{无政府状态发言比例} \end{bmatrix}.$$

密度函数 $f_\theta(x)$ 的任务，就是告诉我们某种玩家行为在正常玩家群体中出现的可能性有多高。

¹ 视频画面时间区间：00:03:00–00:03:15。

1.2 为什么不能直接数点

如果资料只有二维，而且样本很多，我们可以画散点图，用肉眼看出哪些区域密集。但真实机器学习问题往往维度很高，无法直接画出来；同时，新输入 x 可能从来没有在训练集中一模一样地出现过。我们不能只问“训练集中有没有这个点”，而要问“像这样的点在训练分布中合理吗”。

这就是密度模型的作用：它把离散训练样本推广成一个连续函数。只要给定一个新的 x ，即使训练时没见过，也可以代入 $f_{\theta}(x)$ 算出一个密度值。

无标签异常检测的建模目标

训练资料本身不提供类别标签，因此模型要学习的是资料分布，而不是类别边界。估计密度函数，就是把“哪些行为像训练资料”变成可计算的分数。

1.3 本章小结

本讲从“训练资料来自某个未知密度函数”这一假设出发。密度函数 $f_{\theta}(x)$ 描述正常资料在特征空间中的分布，参数 θ 决定它的形状。异常检测的第一步，就是用训练资料估计出合理的 θ 。

2 最大似然：选择最能解释资料的参数

既然 θ 未知，我们需要一个原则从资料中选出它。课程采用 maximum likelihood，也就是最大似然。核心想法是：选择一个参数 θ ，使得目前观察到的训练资料在这个密度函数下最可能被产生出来。

若假设训练样本独立同分布，训练集的 likelihood 可以写成

$$L(\theta) = f_{\theta}(x^1)f_{\theta}(x^2)\cdots f_{\theta}(x^N).$$

于是最大似然估计为

$$\theta^* = \arg \max_{\theta} L(\theta).$$

2.1 likelihood 不是同一个角度的机率

这里容易混淆： $f_{\theta}(x)$ 是在固定参数 θ 时，看某个资料点 x 的密度； $L(\theta)$ 则是把训练资料固定住，看不同参数 θ 对这些资料的解释能力。也就是说，likelihood 是关于参数的函数。

如果某个 θ 让训练资料大多落在高密度区域，那么每个 $f_{\theta}(x^n)$ 较大，乘积 $L(\theta)$ 也较大。若某个 θ 把高密度区域放错位置，训练资料落在低密度处，likelihood 就会小。

2.2 实际计算常用对数似然

课程画面中直接使用乘积形式，这是概念上最直观的写法。实际计算时，通常会取 $\log$ ：

$$\ell(\theta) = \log L(\theta) = \sum_{n=1}^N \log f_{\theta}(x^n).$$

取对数不会改变最大值的位置，因为 $\log$ 是单调递增函数；但它能把乘积变成加总，避免大量小数相乘导致数值下溢，也更方便求导优化。

最大似然的直觉

Maximum likelihood 不是寻找“看起来最平滑”的分布，也不是寻找覆盖范围最大的分布，而是寻找最能让已观察训练资料出现的参数。它把“拟合训练分布”变成一个优化问题。

2.3 本章小结

最大似然提供了估计密度模型参数的标准方法：定义训练资料在参数 θ 下的 likelihood，再选择让 likelihood 最大的 θ^* 。在无标签异常检测中，这一步相当于用正常训练资料拟合出一张正常行为的密度地图。

3 用高斯分布作为具体密度模型

为了让最大似然更具体，课程接着选择 Gaussian distribution 作为密度函数。对 D 维向量 x ，多变量高斯分布写作

$$f_{\mu, \Sigma}(x) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\}.$$

其中 μ 是 mean, Σ 是 covariance matrix.




图 2: 多变量 Gaussian distribution: 输入是向量 x , 输出是采样到 x 的密度, 参数为 mean μ 与 covariance matrix Σ ²

3.1 均值和协方差的角色

μ 决定分布中心在哪里。对于玩家行为资料, 它表示“典型玩家行为”的中心位置, 例如平均垃圾话比例和平均无政府状态发言比例。

Σ 决定分布的形状、宽窄和方向。若某个方向变异大, 分布会沿那个方向拉长; 若两个特征相关, 椭圆形高密度区域会倾斜。直观地说, Σ 告诉模型哪些方向上的变化是正常的, 哪些方向上的偏离更少见。

²视频画面时间区间: 00:05:00–00:05:15。

公式中的二次项

$$(x - \mu)^T \Sigma^{-1} (x - \mu)$$

可以理解成一种考虑协方差结构的距离。离 μ 越远，或者沿着资料本来很少变化的方向偏离越多，密度通常越低。

3.2 把一般参数换成高斯参数

前面一般写作 $f_{\theta}(x)$ 。若选择高斯分布，参数 θ 就具体变成

$$\theta = (\mu, \Sigma).$$

likelihood 也变成

$$L(\mu, \Sigma) = f_{\mu, \Sigma}(x^1) f_{\mu, \Sigma}(x^2) \cdots f_{\mu, \Sigma}(x^N).$$

最大似然目标相应变成

$$\mu^*, \Sigma^* = \arg \max_{\mu, \Sigma} L(\mu, \Sigma).$$

3.3 本章小结

高斯分布提供了一个具体的密度模型。它用 μ 表示正常资料中心，用 Σ 表示资料分布的形状和相关性。选择高斯后，无标签异常检测就变成估计 μ 与 Σ ，再用得到的密度函数判断新输入是否常见。

4 似然大小与模型选择

同一批训练资料，在不同的 μ 和 Σ 下会得到不同的 likelihood。课程图中用两个椭圆直观说明：如果高斯分布的高密度区域覆盖了训练资料主要集中的地方，likelihood 就大；如果高密度区域放在资料稀疏处，likelihood 就小。




图 3: 不同高斯参数会给训练资料不同 likelihood: 高密度区域贴合资料时 L 大, 放错位置时 L 小³

4.1 最大似然如何体现“贴合资料”

假设一个高斯分布的 μ 位于训练资料密集区域，并且 Σ 的形状和资料云的伸展方向相近。此时大量训练样本都有较高的 $f_{\mu,\Sigma}(x^n)$ ，乘积 $L(\mu, \Sigma)$ 会较大。

反过来，如果 μ 放在偏离资料云的位置，或者 Σ 太窄、方向不对，许多训练样本会落在低密度区域。即使有少数点被解释得很好，整体 likelihood 仍可能很小。最大似然因此鼓励模型解释整批训练资料，而不是只解释其中某几个点。

4.2 为什么课程提到神经网络密度模型

画面中也提到一个旁支问题：如果 $f_\theta(x)$ 不是高斯，而是由 neural network 定义， θ 就会是网络参数。这当然也可以做，现代生成模型、normalizing flow、energy-based model 等都可以被用来估计复杂密度。但这些方法超出本讲范围。




图 4：密度函数也可以由神经网络参数化，但本讲先使用高斯分布作为简单可解的例子⁴

本讲选择高斯，是为了让整条流程清楚而可手算：定义密度、写出 likelihood、求出参数、用阈值检测异常。它不代表真实资料一定长得像高斯。

模型假设会限制检测能力

如果真实正常资料分布明显不是高斯，例如多峰、弯曲、强边界或长尾，那么单一高斯可能拟合不好。密度模型的错误会直接影响异常分数。

³ 视频画面时间区间：00:07:30–00:07:45。

⁴ 视频画面时间区间：00:08:30–00:08:45。

4.3 本章小结

Likelihood 衡量某组参数对整批训练资料的解释能力。高斯高密度区域越贴合训练资料，likelihood 越大。课程使用高斯是为了说明最大似然流程；若资料分布更复杂，可以换成更复杂的密度模型，但原则仍是估计正常资料分布。

5 闭式解：平均值与协方差矩阵

对于高斯分布，最大似然估计有 closed-form solution，不需要复杂迭代。课程给出的结论是：

$$\mu^* = \frac{1}{N} \sum_{n=1}^N x^n,$$

$$\Sigma^* = \frac{1}{N} \sum_{n=1}^N (x^n - \mu^*)(x^n - \mu^*)^T.$$




图 5: 高斯最大似然的闭式解： μ^* 是训练资料平均， Σ^* 是围绕平均值的协方差矩阵⁵

5.1 例子中的参数值

在玩家行为二维例子中，课程算出

$$\mu^* = \begin{bmatrix} 0.29 \\ 0.73 \end{bmatrix}, \quad \Sigma^* = \begin{bmatrix} 0.04 & 0 \\ 0 & 0.03 \end{bmatrix}.$$

这表示平均玩家约有 0.29 的垃圾话比例，以及 0.73 的无政府状态发言比例。协方差矩阵在画面中近似为对角矩阵，代表两个特征在这个简化例子里没有显著交叉相关；两个对角值则描述各自方向上的变异程度。

⁵ 视频画面时间区间：00:10:15–00:10:30。

5.2 为什么平均值不是全部

只看 μ^* 不够，因为异常检测不仅关心中心在哪里，也关心资料如何散开。假如某个方向上的正常变异本来就很大，偏离中心一点并不奇怪；若某个方向上的正常变异很小，同样大小的偏离就更可疑。 Σ^* 正是用来表达这种方向性与尺度差异。

因此，高斯密度判断不是简单的欧氏距离判断。它考虑协方差结构，等价于在使用一种由 Σ^{-1} 加权的距离，也就是 Mahalanobis distance 的形式。

高斯密度的异常分数

在固定 μ^*, Σ^* 后， $f_{\mu^*, \Sigma^*}(x)$ 越小，输入越罕见。实际系统中常用 $-\log f_{\mu^*, \Sigma^*}(x)$ 作为异常分数，数值越大越异常。

5.3 本章小结

高斯最大似然估计有简单公式：均值是训练样本平均，协方差是样本围绕均值的平均外积。 μ^* 告诉我们正常资料中心， Σ^* 告诉我们正常资料如何扩散。两者合起来定义了后续异常检测所用的密度函数。

6 用密度阈值做最终判定

求出 μ^* 和 Σ^* 后，就得到了一个具体密度函数 $f_{\mu^*, \Sigma^*}(x)$ 。任何新玩家的行为向量 x ，即使训练时从未出现过，都可以代入这个函数得到一个密度值。




图 6: 拟合出 μ^*, Σ^* 后，可用高斯密度值与阈值 λ 判断 normal 或 anomaly⁶

⁶ 视频画面时间区间：00:10:30–00:10:45。

最终判定规则为

$$f(x) = \begin{cases} \text{normal}, & f_{\mu^*, \Sigma^*}(x) > \lambda, \\ \text{anomaly}, & f_{\mu^*, \Sigma^*}(x) \leq \lambda. \end{cases}$$

这跟前几讲的 confidence threshold 形式很像，但分数来源不同：这里不是分类器 confidence，而是高斯密度值。

6.1 密度热力图的解释

课程把二维平面上每一点的 $f_{\mu^*, \Sigma^*}(x)$ 都算出来，用颜色表示密度大小。颜色越偏红、越深，表示密度越高，行为越像一般玩家；颜色越浅、越偏蓝，表示密度越低，行为越罕见。




图 7: 密度热力图：颜色代表 $f_{\mu^*, \Sigma^*}(x)$ 的大小，红色高密度区域更像 normal，蓝色低密度区域更可疑⁷

这张图把 $P(x)$ 的直觉可视化了：训练样本密集的区域，模型给出较高密度；远离密集区域的位置，模型给出较低密度。若资料是高维的，我们无法直接画出这张图，但模型仍然可以给每个输入算出数值。

6.2 阈值就是一条等高线

在二维图中，阈值 λ 可以看成密度热力图上的一条 contour line。等高线内侧密度大于阈值，被判为 normal；外侧密度小于或等于阈值，被判为 anomaly。

⁷ 视频画面时间区间：00:11:15–00:11:30。




图 8: 阈值 λ 对应密度图上的一条等高线：线内高密度区域为 normal，线外低密度区域为 anomaly⁸

课程最后用两个点说明：一个玩家虽然垃圾话比例较高，但常在无政府状态下发言，可能落在高密度区，因此仍是 normal；另一个玩家垃圾话比例不高，却很刻意地不在无政府状态下发言，落在低密度区，可能更异常。这个例子说明异常不一定由单一特征决定，而可能来自特征组合。

阈值仍由任务决定

λ 可以用 development set 选择，也可以根据可接受警报量或风险偏好设定。密度模型给出分数，阈值决定行动边界。

6.3 本章小结

拟合高斯后，异常检测就变成计算 $f_{\mu^*, \Sigma^*}(x)$ 并与阈值比较。二维时，阈值是一条等高线；高维时，它对应一个高维密度边界。低密度样本代表罕见行为，更可能被标为 anomaly。

7 总结与延伸

这一讲完整补上了无标签异常检测中“如何得到 $P(x)$ ”的问题。流程可以整理成：

1. 假设训练资料来自某个密度函数 $f_{\theta}(x)$ 。
2. 用 likelihood 衡量参数 θ 对训练资料的解释能力。
3. 选择最大化 likelihood 的参数 θ^* 。
4. 在本讲的具体例子中，选择高斯分布，参数为 μ 和 Σ 。
5. 用闭式解得到 μ^* 与 Σ^* 。

⁸视频画面时间区间：00:12:00-00:12:15。

6. 对新输入计算 $f_{\mu^*, \Sigma^*}(x)$ ，再用阈值 λ 判定 normal 或 anomaly。

这条路线的优点是清楚、可解释、容易实现。它把“像不像训练资料”变成了密度值，也能在二维图上用热力图和等高线直观展示。它的限制也同样清楚：单一 Gaussian 假设可能太简单，真实资料可能多峰、非线性或高维稀疏；如果特征表示不合适，密度估计也会偏离真正想检测的异常。

因此，P33 和 P34 合在一起给出的不是某一个最终模型，而是一套基本范式：无标签异常检测先定义特征空间，再拟合正常资料分布，最后用低密度作为异常信号。后续若换成混合高斯、核密度估计、autoencoder 或神经生成模型，本质仍是在回答同一个问题：新输入是否落在正常资料高密度区域。