

异常检测（七）：多特征、重建误差与总结

More Features, Auto-encoders, and Concluding Remarks



基于李宏毅老师《机器学习 2025》课程整理
2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 6 分 01 秒


链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=35>

目录

1 加入更多特征	3
1.1 例子中的五维特征	3
1.2 特征越多，模型越依赖表示质量	4
1.3 本章小结	4
2 用对数密度比较玩家	4
2.1 三个玩家的分数直觉	5
2.2 异常是相对于分布而言	5
2.3 本章小结	6
3 展望：用自动编码器做异常检测	6
3.1 训练阶段：学会重建正常资料	6
3.2 测试阶段：正常样本可重建	7
3.3 异常样本：重建失败	7
3.4 本章小结	8
4 其他经典方法	8
4.1 One-class SVM	9
4.2 Isolated Forest	9
4.3 本章小结	9
5 异常检测小节总括	9
5.1 有标签：open-set recognition	10
5.2 无标签：clean 与 polluted	10
5.3 本章小结	11
6 总结与延伸	11

1 加入更多特征

前两讲用两个特征描述 Twitch Plays Pokémon 玩家：垃圾话比例和无政府状态发言比例。P35 一开始强调，这只是为了画图方便；真实系统中，特征可以更多。只要你认为某个行为与“正常玩家或异常玩家”的判断有关，就可以把它加入 feature vector。


$$f(x) = \begin{cases} normal, f_{\mu^*, \Sigma^*}(x) > \lambda \\ anomaly, f_{\mu^*, \Sigma^*}(x) \leq \lambda \end{cases}$$

More Features

- x_1 : Percent of messages that are spam (說垃圾話)
- x_2 : Percent of button inputs during anarchy mode (無政府狀態發言)
- x_3 : Percent of button inputs that are START (按 START 鍵)
- x_4 : Percent of button inputs that are in the top 1 group (跟大家一樣)
- x_5 : Percent of button inputs that are in the bottom 1 group (唱反調)

Created with EverCam.
<http://www.camdemy.com>

图 1: 更多玩家行为特征：除了垃圾话比例和无政府状态发言比例，还可加入按 START、跟随多数、唱反调等比例¹

1.1 例子中的五维特征

课程列出一个五维玩家向量：

$$x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix},$$

其中可以包括：

- x_1 ：说垃圾话的比例。
- x_2 ：在无政府状态下输入按钮的比例。
- x_3 ：按 START 键的比例。
- x_4 ：输入与多数玩家一致的比例。
- x_5 ：输入与多数玩家相反的比例。

¹ 视频画面时间区间：00:00:45–00:01:00。

这些特征背后都有行为直觉。例如，如果有人不断按 START 键，游戏会一直打开道具栏，导致大家什么也做不了；这可能是可疑行为。如果一个玩家常常跟多数人唱反调，也可能代表他不是认真通关的正常玩家。

1.2 特征越多，模型越依赖表示质量

加入更多特征可以让模型看到更丰富的行为模式，但也带来风险。特征太少，模型可能漏掉关键异常；特征太多，若样本数量不足，密度估计会更困难。特别是在高斯模型中，维度越高，需要估计的协方差参数越多，资料稀疏问题越明显。

因此，特征扩展不是“越多越好”，而是要让每个特征都有合理语义，并且能从资料中稳定估计分布。异常检测很依赖 feature engineering，因为模型最终判断的是“这个向量在训练分布中常不常见”。

多特征的核心问题

异常常常不是单一特征极端，而是多个特征组合起来少见。加入更多特征的目的，是让模型能看见这种组合异常。

1.3 本章小结

玩家行为可以从二维扩展到多维，例如加入按 START、跟随多数、唱反调等指标。更多特征能表达更细行为，但也提高密度估计难度。无标签异常检测的关键，不只是选择模型，也包括选择能表达正常行为结构的特征。

2 用对数密度比较玩家

在多维特征下，仍然可以用上一讲的密度函数给每个玩家打分。课程提到实际计算时会取 $\log$ ，因为密度值通常非常小。用对数密度可以避免数值太小，也方便比较。




图 2: 把多维玩家特征代入密度模型并取 log，得到可比较的分数；分数越高，越像训练资料²

2.1 三个玩家的分数直觉

课程比较了几个合成玩家。第一个玩家垃圾话比例低、常在无政府状态下发言、少按 START，并且总是和大家一致，不唱反调，算出的 log score 约为 -16 。第二个玩家其他部分类似，但从跟大家一样、还常唱反调，分数降到约 -22 ，因此更可疑。

有趣的是第三个玩家：他并不是百分之百跟大家一样，而是只有约七成时间跟多数一致。模型反而给他更高分，约为 2 。原因是，在真实训练资料中，几乎没有人永远都和跟大家一模一样。一个人总是完全跟随多数，反而显得不真实；偶尔不同，才更像普通玩家。

这说明密度模型不是简单地把“看起来好”的特征推到极端。它学习的是训练资料实际分布。若训练资料中“永远跟大家一样”很少见，那么这种行为也可能低密度。

2.2 异常是相对于分布而言

这个例子很重要：异常并不等于“某个规则违反得最多”。一个玩家可能在每个单独特征上都看似合理，但组合起来极罕见；另一个玩家可能某个特征不完美，却更符合真实分布。密度模型的优势正是在于能从整体分布角度打分。

若使用异常分数

$$s(x) = -\log f(x),$$

则 log density 越低，异常分数越高。系统可以根据阈值把高异常分数玩家标为 anomaly。

不要把特征极端化当成正常

正常行为往往有自然波动。若某个输入在所有“好特征”上都完美，反而可能不像真实资料。密度模型看的是训练分布，而不是人工规则的理想点。

² 视频画面时间区间：00:03:15–00:03:30。

2.3 本章小结

多特征密度模型可以给每个玩家一个 log score。分数反映的是输入在训练分布中的常见程度，而不是某个单一规则是否最好。真实正常行为通常有变异，因此“过于完美”的行为也可能低密度。

3 展望：用自动编码器做异常检测

前面使用的是 generative model 或 density model，例如 Gaussian distribution。课程接着快速展望另一类深度学习方法：autoencoder。Autoencoder 不一定直接估计密度，而是通过“能不能重建输入”来判断输入是否来自正常分布。




图 3: Autoencoder 训练：encoder 将输入压成 code，decoder 从 code 重建输入，目标是让输出尽量接近输入³

3.1 训练阶段：学会重建正常资料

以辛普森图片为例，训练资料全是正常图片。Autoencoder 包含两部分：

- **Encoder**：把输入图片压缩成一个 code，也就是较低维或中间表示。
- **Decoder**：从 code 还原出原来的图片。

训练目标是让重建结果尽量接近输入：

$$\mathcal{L}_{\text{rec}}(x) = \|x - \hat{x}\|^2$$

或使用其他重建损失。因为训练时只看过正常资料，autoencoder 会特别擅长重建正常资料的结构。

³视频画面时间区间：00:04:00–00:04:15。

3.2 测试阶段：正常样本可重建

当测试输入仍然是正常资料，例如另一张辛普森图片，encoder 可以把它压成熟悉的 code，decoder 也能还原出接近原图的结果。




图 4: 正常输入经过 autoencoder 后可以被较好重建，因此 reconstruction loss 较小⁴

这时 reconstruction loss 小，代表输入符合训练资料中学到的结构。系统可以把低重建误差视为 normal 信号。

3.3 异常样本：重建失败

如果输入是异常图片，例如不是辛普森风格的图，autoencoder 训练时没有学过如何表示和还原这种结构。经过 encoder 和 decoder 后，输出可能模糊、失真，和原图差很多。

⁴视频画面时间区间：00:04:30-00:04:45。

Outlook: Auto-encoder




图 5: 异常输入无法被正常训练出来的 autoencoder 良好重建; large reconstruction loss 可作为 anomaly 信号⁵

因此可以使用规则:

$$f(x) = \begin{cases} \text{normal}, & \mathcal{L}_{\text{rec}}(x) \leq \lambda, \\ \text{anomaly}, & \mathcal{L}_{\text{rec}}(x) > \lambda. \end{cases}$$

这里的分数不再是 density, 而是 reconstruction loss。低误差表示像训练资料, 高误差表示不像训练资料。

重建误差也不是万能

Autoencoder 有时也能重建异常样本, 尤其模型容量太大或异常与正常结构接近时。因此它仍需要 validation、阈值选择和任务评估。

3.4 本章小结

Autoencoder 提供了另一种无标签异常检测思路: 用正常资料训练重建模型, 测试时看输入是否能被良好重建。正常样本通常 reconstruction loss 小, 异常样本 loss 大。它不直接估计 $P(x)$, 但同样在衡量输入是否符合训练资料结构。

4 其他经典方法

课程还提到, 异常检测并不只属于 Gaussian 或 autoencoder。机器学习中有许多专门为 novelty detection、outlier detection 设计的方法, 例如 one-class SVM 和 isolated forest。


⁵ 视频画面时间区间: 00:05:00-00:05:15。



More ...


Source of images: https://scikit-learn.org/stable/modules/outlier_detection.html#outlier-detection

One-class SVM



Ref: <https://papers.nips.cc/paper/1723-support-vector-method-for-novelty-detection.pdf>

Isolated Forest



Ref: <https://cs.nju.edu.cn/zhoush/zhoush.files/publication/icdm08/>

图 6: 其他异常检测方法示例: one-class SVM 与 isolated forest 都可只用正常资料学习异常边界⁶

4.1 One-class SVM

One-class SVM 的想法是: 只给模型正常资料, 让它学习一个包围正常资料的边界。边界内被视为 normal, 边界外被视为 novelty 或 anomaly。它适合特征已经比较清楚、资料量中等的场景。

和 Gaussian 不同, one-class SVM 不要求资料一定符合某个单一高斯分布; 它更像是在特征空间中寻找一个能覆盖正常资料主要区域的边界。

4.2 Isolated Forest

Isolated forest 是基于树的方法。它的核心直觉是: 异常点通常更容易被随机切分孤立出来。通过多棵随机树观察一个点被隔离所需的路径长度, 可以得到异常分数。越容易被隔离的点, 越可能是 anomaly。

这种方法在表格型资料中很常见, 训练和推论都相对高效, 也不需要强高斯假设。

4.3 本章小结

异常检测有多种模型路线: 密度估计、重建误差、边界学习、树模型隔离等。它们的共同目标都是从训练资料中学习 normal 的结构, 再给新输入一个“是否不寻常”的分数。

5 异常检测小节总结

P35 最后用一张图总结了异常检测的几种设定。训练资料可以写成

$$\{x^1, x^2, \dots, x^N\}.$$

⁶视频画面时间区间: 00:05:30-00:05:45。

根据是否有标签、训练资料是否干净，方法会不同。




图 7: 异常检测总结: 有标签时可做 open-set recognition; 无标签时还要区分训练资料 clean 或 polluted⁷

5.1 有标签: open-set recognition

如果训练资料有标签

$$\{(x^1, y^1), (x^2, y^2), \dots, (x^N, y^N)\},$$

可以训练分类器。测试时，输入可能不属于任何训练类别，因此分类器需要能输出 unknown。这就是前面讲的 open-set recognition。常见 baseline 是使用 classifier confidence，再用阈值判断是否拒绝。

5.2 无标签: clean 与 polluted

如果没有标签，就进入无标签异常检测。这里还要区分训练资料是否干净：

- **Clean**: 训练资料全部或几乎全部是 normal。此时可以学习 normal 分布、重建 normal 样本，或学习 normal 边界。
- **Polluted**: 训练资料中混入少量 anomaly。此时模型更难，因为异常可能被当作训练分布的一部分学进去。

P33-P35 主要聚焦 clean training data: 多数或全部训练样本正常。若训练资料 polluted，就需要更鲁棒的方法，例如对离群点不敏感的估计、迭代清洗、弱监督或更谨慎的阈值设定。

⁷ 视频画面时间区间: 00:05:45–00:06:00。

5.3 本章小结

异常检测不是单一问题，而是一组设定。是否有标签、是否有异常样本、训练资料是否干净、错误代价如何，都会改变方法选择和评估方式。理解设定，比盲目套某个模型更重要。

6 总结与延伸

P29-P35 这一组异常检测笔记可以按三条主线记忆。

第一条是有标签/open-set 路线：已有分类器时，可以从 confidence score 出发，用阈值判断 normal 或 anomaly。但 confidence 可能被捷径特征欺骗，因此需要 development set、阈值选择、cost table、AUC，以及对过度自信的警惕。

第二条是无标签/density 路线：没有标签时，要学习训练资料本身的分布。P33 把问题写成“输入是否类似训练资料”，P34 用最大似然和 Gaussian density 具体说明如何得到密度分数，P35 则说明可以加入更多特征并用 log density 比较样本。

第三条是替代模型路线：不一定只能估计高斯密度，也可以用 autoencoder 的 reconstruction loss、one-class SVM 的边界、isolated forest 的隔离难易度等方法。不同模型输出的分数不同，但最终都要转化成“是否异常”的判断。

实践中，一个完整异常检测系统至少要回答这些问题：

1. 训练资料有没有标签？有没有异常样本？训练资料是否干净？
2. 输入应该用哪些特征或表示？
3. 模型输出什么异常分数：confidence、density、reconstruction loss、distance，还是 isolation score？
4. 阈值如何选择？false alarm 和 missing 哪个代价更高？
5. 检测到 anomaly 后，是报警、人工复核、拒绝，还是仅记录？

这也是异常检测和普通分类最不同的地方：模型只是其中一部分，资料设定、评估指标、错误代价和后续处置同样决定系统是否可靠。