

机器学习的可解释性（上）：为什么神经网络可以正确分辨宝可梦和数码宝贝

Explainable Machine Learning: Local Explanation, Saliency Map, and Shortcut Learning



基于李宏毅老师《机器学习 2025》课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 49 分 08 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=36>

目录

1 为什么需要可解释的机器学习	3
1.1 正确答案不等于智能	3
1.2 高风险应用中的责任问题	4
1.3 解释也能改进模型	4
1.4 本章小结	4
2 可解释性与模型能力之间的张力	5
2.1 简单模型未必足够强	5
2.2 决策树的例子：可解释也可能变复杂	5
2.3 解释的目标不是完全理解一切	6
2.4 本章小结	7
3 Local Explanation 与 Global Explanation	7
3.1 Local explanation：解释单次决策	8
3.2 Global explanation：解释整体概念	8
3.3 输入成分的重要性	8
3.4 本章小结	9
4 Saliency Map：用局部变化衡量重要性	9
4.1 遮挡法的直觉	10
4.2 Gradient saliency	10
4.3 Saliency map 要解释的是模型，不一定解释世界	11
4.4 本章小结	12
5 案例：宝可梦与数码宝贝分类器	12
5.1 任务设定	12
5.2 高准确率本身并不说明理由正确	13
5.3 Saliency map 暴露模型捷径	14
5.4 现实资料集也会出现类似问题	16
5.5 本章小结	17
6 Saliency Map 的限制	17
6.1 Noisy Gradient 与 SmoothGrad	17
6.2 Gradient Saturation	18
6.3 本章小结	19
7 神经网络如何处理输入资料	20
7.1 隐藏层可视化	20
7.2 Attention 可视化不等于完整解释	21
7.3 Probing：用探针测试隐藏表示	22
7.4 语音合成中的 probing 示例	23
7.5 本章小结	25

8 总结与延伸	25
8.1 拓展阅读	26

1 为什么需要可解释的机器学习

本讲进入第九节：机器学习的可解释性。课程一开始就点出一个容易被忽略的问题：模型答对，不等于模型真的理解。一个分类器可以在测试集上表现很好，却可能只是抓到了训练资料里的捷径、背景、格式或标注习惯。只有当我们追问“模型为什么这么判断”时，才有机会知道它是不是用到了真正可靠的依据。



Why we need Explainable ML?

- Loan issuers are required by law to explain their models.
- Medical diagnosis model is responsible for human life. Can it be a black box?
- If a model is used at the court, we must make sure the model behaves in a nondiscriminatory manner.
- If a self-driving car suddenly acts abnormally, we need to explain why.

图 1: 可解释性需求的几个典型场景：贷款、医疗、司法、自驾车等系统不能只给出决策结果，还要能说明原因。¹

1.1 正确答案不等于智能

在一般的机器学习任务中，我们常用 accuracy、loss、AUC 等指标衡量模型。但这些指标只能告诉我们模型在某个资料分布上是否答对，不能告诉我们模型答对的理由。若模型的理由错误，它在新的环境中就可能突然失效。

例如影像分类器可能把“病灶”判断成某个类别，其实依据的是医院影像左下角的文字标记；动物分类器可能看起来会认马，其实只是抓住资料集图片中经常出现的边框或背景。只看最终答案时，这些问题会被高准确率掩盖；看解释时，才可能露出模型实际依赖的线索。

可解释性要回答的问题

可解释机器学习不是单纯把模型内部所有参数列出来，而是要回答人真正关心的问题：模型为什么给出这个输出？它依赖了哪些输入成分？这个理由是否合理？如果理由不合理，模型还能不能被信任？

¹ 视频画面时间区间：00:03:45–00:04:00。

1.2 高风险应用中的责任问题

课程列出多个现实场景来说明可解释性的重要性。贷款系统若拒绝某人申请，法律和业务上都可能要求说明拒绝原因；医疗诊断模型若影响人的生命，不能只是一个黑盒分数；司法场景中，模型必须避免歧视性行为；自驾车突然急刹、导致乘客受伤时，也需要追查系统为何做出该动作。

这些场景共同说明，模型输出不仅是技术结果，也是现实决策的一部分。越是高风险场景，越不能只问“模型准不准”，还要问“模型用什么理由准”。如果理由不能被审查，部署者、用户和受影响的人都很难判断系统是否可靠。

1.3 解释也能改进模型

可解释性的另一个作用，是帮助开发者修正模型。课程用漫画说明：如果我们知道模型答案错在哪里，就可以有针对性地修改资料、特征、模型结构或训练方法；如果完全不知道模型内部发生什么，就只能盲目调参。




图 2: 解释不仅服务于使用者，也服务于模型开发：知道模型错因，才可能修正它。²

这和调试程序很像。程序输出错了，如果有日志、堆栈和中间变量，我们能定位问题；如果程序只给一个最终结果，调试会困难得多。深度学习模型虽然不是传统程序，但解释方法可以起到类似“调试窗口”的作用，让我们看到模型在输入中抓到了什么、在隐藏层中保留了什么、在输出前依赖了什么。

1.4 本章小结

可解释性的重要性来自三件事：第一，正确答案不保证模型用了正确理由；第二，高风险决策需要责任、审查和信任；第三，解释能帮助开发者发现资料偏差和模型捷径。换句话说，可解释性不是装饰性的报告，而是检查模型是否真的可靠的一组工具。

² 视频画面时间区间：00:05:00–00:05:15。

2 可解释性与模型能力之间的张力

接着，课程讨论一个常见观点：既然深度网络难解释，是否应该只用简单、可解释的模型？李宏毅老师的态度比较明确：不能因为模型是黑盒，就放弃更强的模型；合理目标应该是让强大的模型变得可解释，而不是为了可解释性刻意使用能力不足的模型。



Interpretable v.s. Powerful

- Some models are intrinsically interpretable.
 - For example, linear model (from weights, you know the importance of features)
 - But not very powerful.
- Deep network is difficult to interpretable. Deep networks are black boxes ... but powerful than a linear model.

We don't want to use a more powerful model because it is a black box.

This is “cut the feet to fit the shoes.” (削足適履)

图 3: 线性模型等方法较易解释，但通常不够强；深度网络难解释，却可能更有能力。课程提醒不要因为黑盒问题就回避强模型。³

2.1 简单模型未必足够强

线性模型有天然的可解释性：从权重大小可以看出每个特征对输出的影响。如果输入特征本身有清楚语义，这种解释非常直接。例如贷款模型中，收入、负债比例、信用记录等特征的权重可以说明模型如何做判断。

但简单模型的表达能力有限。许多真实问题并不是几个线性权重就能描述的，影像、语音、语言这类复杂资料尤其如此。若为了可解释性强行使用过弱模型，可能会得到一个容易解释但效果不好的系统。课程把这种做法比喻为“削足适履”：为了适应解释的鞋子，把模型能力的脚削掉。

2.2 决策树的例子：可解释也可能变复杂


决策树常被拿来当作可解释模型的代表。每个节点问一个问题，例如某个特征是否大于阈值；输入一路向左或向右，最后落到叶节点得到预测。单棵小树确实容易解释，因为它像一组 if-else 规则。

但真实使用时，单棵决策树通常并不够强。实践中更常用 random forest，也就是大量决策树组成的集合。此时单棵树的解释性被集成模型的复杂性削弱了：我们不再只看一条清楚路径，而是要理解许多树共同投票的结果。

³视频画面时间区间：00:07:15–00:07:30。

Interpretable v.s. Powerful

- A tree can still be terrible!



- We use a forest!



图 4: 决策树看似解释性强, 但实践中常使用 random forest; 一旦模型变成许多树的集合, 解释性也会下降。⁴

“可解释模型”不是绝对标签

一个模型是否可解释, 取决于模型规模、输入特征语义、使用方式和解释对象。小型线性模型很容易解释, 大型集成树模型就未必; 神经网络很难直接解释, 但可以通过专门方法观察输入重要性、隐藏层表示和决策行为。

2.3 解释的目标不是完全理解一切

课程随后把目标说得更实际: 我们并不一定要“完全知道模型如何工作”。人类大脑本身也不是完全可解释的, 但我们仍然信任很多人类决策。可解释机器学习的目标, 是给出足够有用、足够让人安心、足够能帮助调试和审查的理由。

⁴视频画面时间区间: 00:11:30-00:11:45。



Goal of Explainable ML

- Completely know how an ML model works?
 - We do not completely know how brains work!
 - But we trust the decision of humans!

The Copy Machine Study (Ellen Langer, Harvard University)

“Excuse me, I have 5 pages. May I use the Xerox machine?”

60% accept

<https://jamesclear.com/wp-content/uploads/2015/03/copy-machine-study-ellen-langer.pdf>

图 5: Copy Machine Study 被用来说明：人在很多情境下并不要求完整因果机制，只需要一个可接受的理由。⁵

课程引用 Copy Machine Study：有人排队使用影印机时，如果请求“我只有五页，可以先用吗”，接受率约为 60%；如果加上一个看似理由的句子“因为我赶时间”，接受率会上升。重点不是这个实验本身，而是它揭示了一种人机互动现实：解释常常服务于人的接受、信任和沟通。

解释的“够用性”

好解释未必是完整机制证明。对用户而言，解释可能是让人理解、让人安心、让人知道如何申诉或修正；对工程师而言，解释可能是暴露模型捷径、资料偏差或隐藏层行为。不同对象需要不同粒度的解释。

2.4 本章小结


可解释性和模型能力之间存在张力，但不是非此即彼。简单模型更容易解释，却可能能力不足；复杂模型更强，却需要额外解释方法。课程的主张是：不要因为黑盒而放弃强模型，而要发展方法，让强模型的行为能被局部检查、整体理解和实际调试。

3 Local Explanation 与 Global Explanation

可解释机器学习可以分成两大类：local explanation 和 global explanation。前者解释某个特定输入的某次预测，后者解释模型整体学到的规律。本讲前半段主要聚焦 local explanation，也就是“为什么模型认为这张图片是猫”“它看的是图片中的哪一块”。

⁵ 视频画面时间区间：00:14:45–00:15:00。

Explainable ML



Local Explanation

Why do you think this image is a cat?

Global Explanation

图 6: 可解释性分成 local explanation 与 global explanation: 前者解释单个输入的决策, 后者解释模型整体规则或概念。⁶

3.1 Local explanation: 解释单次决策

Local explanation 的问题形式是: 给定一个输入 x 和模型输出 y , 模型为什么在这一次做出这个判断? 例如输入一张猫的照片, 分类器输出 “cat”, 我们追问的是这张图里哪些像素、区域或局部结构促成了 “cat” 这个答案。

这种解释非常适合调试模型。例如模型把一张狗图判断为狗, 如果解释显示它关注的是狗脸、耳朵、身体轮廓, 开发者会比较安心; 如果解释显示它关注的是图片角落的水印, 就说明模型可能学到了错误捷径。

3.2 Global explanation: 解释整体概念

Global explanation 的问题更抽象: 模型心中的 “猫” 长什么样? 模型整体使用了哪些概念区分类别? 哪些 neuron、filter 或 hidden representation 对应到哪些可理解的语义? 这不针对某一张特定图片, 而是试图理解模型总体上学到的表示。


本讲标题问 “为什么神经网络可以正确分辨宝可梦和数码宝贝”, 主要是 local explanation 的案例; 下一讲 “机器心中的猫长什么样子” 更接近 global explanation。

3.3 输入成分的重要性

为了做 local explanation, 一个直观方法是问: 输入中哪个 component 对决策最关键? 在影像中, component 可以是像素、patch、segment 或物件区域; 在文字中, component 可以是词或 token; 在语音中, component 可以是某段时间频谱。

⁶视频画面时间区间: 00:17:15–00:17:30。

Which component is critical?



Which component is critical for making decision?

图 7: 用输入成分重要性解释图片分类: 如果遮住某个区域后模型信心大幅下降, 该区域可能是关键依据。⁷

最朴素的做法是遮挡或修改输入局部, 然后观察模型输出变化。例如把灰色方块放到图片不同位置, 如果遮住狗脸时模型不再认为图中有狗, 而遮住背景时输出变化很小, 就说明狗脸区域对这次决策更重要。


3.4 本章小结

Local explanation 问“这个输入为什么得到这个输出”, global explanation 问“模型整体学到了什么规则或概念”。本讲后面的 saliency map、遮挡实验和宝可梦案例, 都属于 local explanation: 它们试图指出某次预测中哪些输入区域真正影响了模型。

4 Saliency Map: 用局部变化衡量重要性

Local explanation 的代表方法之一是 saliency map。它把输入中每个位置的重要性可视化出来: 越亮、越显著的位置, 表示模型输出对该位置越敏感。课程先从遮挡法讲起, 再进一步介绍用 gradient 得到 saliency map。

⁷ 视频画面时间区间: 00:18:30–00:18:45。



Reference: Zeiler, M. D., & Fergus, R. (2014). Visualizing and understanding convolutional networks. In *Computer Vision—ECCV 2014* (pp. 818-833)

图 8: 遮挡不同位置并观察输出变化, 可以得到一张类似热力图的解释: 模型真正依赖的区域会更亮。⁸

4.1 遮挡法的直觉

遮挡法的逻辑很直接。假设模型看到一张图后认为它是博美狗。我们在图片上依次放置灰色方块, 遮住不同区域, 然后重新计算模型对“博美狗”的信心。如果遮住某个区域后信心大幅下降, 说明该区域对判断很重要; 如果遮住后几乎没有变化, 说明该区域不是关键依据。

这种方法的优点是直观, 几乎不需要理解模型内部结构; 缺点是计算成本高, 因为要对许多遮挡版本重复前向传播。遮挡粒度也会影响解释结果: 方块太大, 解释粗糙; 方块太小, 噪声可能变多。

4.2 Gradient saliency

更常见的方法是用 gradient。设模型对目标类别 c 的输出分数为 $e_c(x)$, 输入图像是

$$x = (x_1, x_2, \dots, x_N),$$

其中每个 x_i 可以代表某个像素或像素通道。把第 i 个输入成分微小改变 Δx_i 后, 输出变化近似为

$$\Delta e_c \approx \frac{\partial e_c(x)}{\partial x_i} \Delta x_i.$$

符号含义如下:

$e_c(x)$ 模型对类别 c 的输出分数, 可以是 logit 或其他未归一化分数。

x_i 输入的第 i 个成分, 例如某个像素值。

$\frac{\partial e_c}{\partial x_i}$ 输出分数对该输入成分的敏感度。

⁸ 视频画面时间区间: 00:20:30–00:20:45。

Δe_c 输入微小改变后，目标类别分数的近似变化。


因此可以把 saliency score 写成

$$S_i = \left| \frac{\partial e_c(x)}{\partial x_i} \right|.$$

符号含义如下：

S_i 第 i 个输入成分的重要性分数。

$|\cdot|$ 取绝对值，表示无论提高还是降低目标分数，只要影响大就重要。



Karen Simonyan, Andrea Vedaldi, Andrew Zisserman, "Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps", ICLR, 2014

图 9: Gradient saliency 使用输出对输入像素的偏导数衡量重要性，白亮区域表示模型输出对该位置更敏感。⁹

4.3 Saliency map 要解释的是模型，不一定解释世界

Saliency map 画出来的不是“客观上哪里重要”，而是“这个模型在这次预测中对哪里敏感”。两者可能一致，也可能不一致。若一张狗图中 saliency map 亮在狗脸上，解释看起来合理；若亮在背景水印上，说明模型确实依赖了水印，而不是说水印真的定义了狗。

Saliency map 的正确读法

Saliency map 不是把模型变成真理裁判，而是把模型的依赖关系暴露出来。它告诉我们模型在看什么，不保证模型看得对。

⁹ 视频画面时间区间：00:24:45–00:25:00。

4.4 本章小结

Saliency map 的核心思想是衡量输入局部对输出的影响。遮挡法通过反复修改输入观察输出变化；gradient 法通过偏导数估计每个输入成分的敏感度。它们都属于 local explanation，目的不是证明模型一定合理，而是检查模型实际依赖的线索。

5 案例：宝可梦与数码宝贝分类器

课程中最有趣的案例，是训练一个神经网络区分宝可梦和数码宝贝。这个任务看似玩笑，但非常适合作为可解释性案例：模型可以得到很高正确率，但 saliency map 显示它学到的东西并不一定是我们以为的“角色形状”或“画风差异”。



图 10: 案例主题：训练模型区分 Pokémon 与 Digimon，并追问模型到底凭什么分对。¹⁰

5.1 任务设定

资料来源是网络上的宝可梦图片和数码宝贝图片。训练时，模型看到两类角色图像；测试时，给模型新的角色图像，要求它判断属于宝可梦还是数码宝贝。这个设定表面上是二分类问题，输入是图片，输出是两个类别之一。

¹⁰视频画面时间区间：00:25:30–00:25:45。

Task

Pokémon images: <https://www.Kaggle.com/kvpratama/pokemon-images-dataset/data>

Digimon images:

<https://github.com/DeathReaper0965/Digimon-Generator-GAN>



Testing
Images:

图 11: 任务输入包含宝可梦与数码宝贝图片；模型需要对测试图片做二分类。¹¹

如果只看任务形式，我们很容易想象模型学到的是角色设计差异：宝可梦可能更圆润、更简洁，数码宝贝可能更复杂、更机械。但这只是人的猜测。模型到底学到什么，需要解释方法来检查。

5.2 高准确率本身并不说明理由正确

课程中随便搭了一个卷积网络，训练结果非常好：training accuracy 约为 98.9%，testing accuracy 约为 98.4%。如果只看准确率，这个模型似乎已经解决了问题。

¹¹ 视频画面时间区间：00:26:30–00:26:45。

Experimental Results

```
model = Sequential()
model.add(Conv2D(32, (3, 3), padding='same', input_shape=(120,120,3)))
model.add(Activation('relu'))
model.add(Conv2D(32, (3, 3)))
model.add(Activation('relu'))
model.add(MaxPooling2D(pool_size=(2, 2)))

model.add(Conv2D(64, (3, 3), padding='same'))
model.add(Activation('relu'))
model.add(Conv2D(64, (3, 3)))
model.add(Activation('relu'))
model.add(MaxPooling2D(pool_size=(2, 2)))

model.add(Conv2D(256, (3, 3), padding='same'))
model.add(Activation('relu'))
model.add(Conv2D(256, (3, 3)))
model.add(Activation('relu'))
model.add(MaxPooling2D(pool_size=(2, 2)))

model.add(Flatten())
model.add(Dense(1024))
model.add(Activation('relu'))
model.add(Dense(2))
model.add(Activation('softmax'))
```

Training Accuracy: 98.9%

Testing Accuracy: 98.4%

图 12: 宝可梦/数码宝贝分类器取得很高训练与测试准确率，但高准确率还不能说明模型用了合理特征。¹²

然而，可解释性的重点正是在这里出现：当模型高准确率时，我们更应该问它为什么答对。因为高准确率可能来自真正语义，也可能来自资料收集过程中的偏差。如果模型只是抓住偏差，它在换一个资料来源后就可能崩掉。

5.3 Saliency map 暴露模型捷径

为了知道模型依据什么区分两类，课程画出 saliency map。直觉上，如果模型真的学会了角色特征，亮点应该集中在角色的眼睛、身体、翅膀、机械结构等位置。但画面显示，模型关注的区域和预期并不完全一致。

¹²视频画面时间区间：00:28:00–00:28:15。

Saliency Map




图 13: 宝可梦/数码宝贝分类器的 saliency map: 解释结果显示模型关注点可能并不是角色语义本身。¹³

随后课程揭示原因: 很多宝可梦图片是 PNG, 带透明背景; 很多数码宝贝图片是 JPEG, 没有透明背景。当 PNG 被载入或转换时, 透明背景可能变成黑色或特定颜色。模型就可以利用背景格式差异区分类别, 而不需要真正理解角色长什么样。

¹³ 视频画面时间区间: 00:28:45-00:29:00。

More Examples ...

- PASCAL VOC 2007 data set



This slide is from: GCPR 2017 Tutorial — W. Samek & K.-R. Müller

图 14: 真正的捷径: 宝可梦图片多为透明背景 PNG, 数码宝贝图片多为 JPEG; 模型可能根据背景颜色或格式痕迹分类。¹⁴

这就是典型的 shortcut learning。模型没有违反训练目标, 因为它确实找到了能降低训练误差的特征; 问题在于这个特征不是我们希望模型使用的语义。若未来输入来自重新处理过的图片, 背景差异消失, 模型性能可能大幅下降。

高准确率可能来自资料捷径

监督学习优化的是训练目标, 而不是人的意图。只要某个背景、格式、水印或资料收集习惯能帮助降低 loss, 模型就可能使用它。可解释性方法的价值之一, 就是把这种捷径找出来。

5.4 现实资料集也会出现类似问题

课程进一步举出 PASCAL VOC 2007 的例子。某些马的图片下方带有相似文字或边框, 模型可能借此判断“这是马”, 而不是学习马的身体形状。这说明 shortcut learning 不是玩具资料集才有的问题, 真实 benchmark 也可能包含资料偏差。

¹⁴ 视频画面时间区间: 00:29:45–00:30:00。

Limitation: Noisy Gradient



Gazelle
(瞪羚)

图 15: PASCAL VOC 示例：模型可能把图片中的背景或文字痕迹当作类别线索，而不是学到物件本身。¹⁵

这对资料集建设很重要。若训练集和测试集来自同一来源，捷径可能在测试集上仍然有效，模型分数看起来很好；但部署环境一变，捷径失效，模型就会暴露问题。因此，解释方法也可以反过来帮助我们审查资料集。

5.5 本章小结

宝可梦/数码宝贝案例说明：模型可以用非常高的准确率“答对”，但理由却不符合人的期待。Saliency map 暴露了模型可能依赖背景格式差异，而不是角色语义。这正是可解释性最有价值的地方：它让我们看到模型实际学到的 shortcut，并提醒我们重新检查资料、任务设定和评估方式。

6 Saliency Map 的限制

Saliency map 有用，但不是万能解释。课程接着讲两个常见限制：noisy gradient 和 gradient saturation。它们说明 gradient-based explanation 本身也可能不稳定或误导，需要谨慎解读。

6.1 Noisy Gradient 与 SmoothGrad


普通 gradient saliency 有时非常噪。图像中会出现很多散乱亮点，让人难以判断真正重要区域。这不一定意味着模型真的同时依赖所有这些点，也可能是梯度在局部过于敏感、受到噪声影响。

¹⁵ 视频画面时间区间：00:30:30-00:30:45。


Limitation: Noisy Gradient



Gazelle
(瞪羚)



Typical



SmoothGrad

SmoothGrad: Randomly add noises to the input image, get saliency maps of the noisy images, and average them.

<https://arxiv.org/abs/1706.03825>

图 16: Noisy gradient 的问题: 普通 saliency map 可能很噪; SmoothGrad 通过对加噪图片求平均, 使显著区域更稳定。¹⁶

SmoothGrad 的想法是: 给同一张输入图片加入多次随机噪声, 分别计算 saliency map, 再把这些 map 平均。若某个区域是真正稳定的重要线索, 它在多次扰动后仍然会显著; 若某些亮点只是局部噪声, 平均后会被削弱。

可以把它写成

$$\bar{S}(x) = \frac{1}{M} \sum_{m=1}^M S(x + \epsilon_m), \quad \epsilon_m \sim \mathcal{N}(0, \sigma^2 I).$$

符号含义如下:

$S(\cdot)$ 对某个输入计算出的 saliency map。

ϵ_m 第 m 次加入的随机噪声。

M 采样次数。

$\bar{S}(x)$ 多次 saliency map 平均后的解释结果。

6.2 Gradient Saturation

第二个限制是 gradient saturation。课程用“大象鼻子长度”举例: 如果模型对“大象”类别的分数已经在某一区域饱和, 继续改变鼻子长度时, 输出变化可能很小, 因此梯度接近零。此时 saliency map 会显示鼻子不重要, 但这并不代表鼻子真的不是判断大象的重要线索。

¹⁶ 视频画面时间区间: 00:32:15–00:32:30。

Limitation: Gradient Saturation

Gradient cannot always reflect importance




图 17: Gradient saturation: 当输出分数进入饱和区, 梯度可能接近零, 从而低估真正重要的输入因素。¹⁷

这个问题说明, 梯度衡量的是“在当前点附近微小变化的局部敏感度”, 而不是“这个因素在整体决策中是否重要”。如果模型已经非常确信输入是大象, 局部再改变一点鼻子长度可能不会改变分数, 但鼻子仍可能是模型形成判断的重要条件。

一种改进方向是 integrated gradients. 它不是只看当前点的局部梯度, 而是从一个 baseline 输入一路积分到当前输入, 累积沿途梯度:

$$\text{IG}_i(x) = (x_i - x'_i) \int_0^1 \frac{\partial F(x' + \alpha(x - x'))}{\partial x_i} d\alpha.$$

符号含义如下:

x 当前输入。

x' baseline 输入, 例如全黑图或零向量。

$F(\cdot)$ 模型输出分数。

α 从 baseline 到当前输入的插值比例。

$\text{IG}_i(x)$ 第 i 个输入成分的 integrated gradient 重要性。

6.3 本章小结

Saliency map 是观察模型决策的重要工具, 但它也会受噪声、局部梯度和饱和效应影响。解释方法本身也需要被理解和验证。一个成熟的可解释性分析, 不应该只看一张漂亮热力图, 而要结合多种解释方法、资料检查和任务知识。

¹⁷ 视频画面时间区间: 00:34:15–00:34:30。

7 神经网络如何处理输入资料

课程后半段从“解释单次预测”扩展到“观察网络内部”。我们可以把神经网络看成一层层处理输入的系统：每一层都把资料转成新的表示。可解释性的一个方向，就是观察这些隐藏表示中保留了什么信息、丢掉了什么信息、形成了什么结构。




图 18: 观察隐藏层的一种流程：把每层高维输出降维到二维，再用可视化方法看表示是否产生结构。
¹⁸

7.1 隐藏层可视化

以语音模型为例，输入可以是 acoustic feature，例如 MFCC。第一层、第二层到更高层都会输出一组隐藏向量。若每层有 100 个 neuron，每个时间片就对应一个 100 维向量。为了画在二维平面上，可以使用 PCA 或 t-SNE 把这些高维向量降到二维。

这样做的目的不是得到一个严格证明，而是观察表示是否更有结构。例如原始声学特征可能受说话人、音量、录音环境影响很大；经过模型隐藏层后，表示可能更接近语音内容或音素结构，而不是只反映原始声波差异。

¹⁸ 视频画面时间区间：00:36:00–00:36:15。

How a network processes the input data?

A. Mohamed, G. Hinton, and G. Penn,
“Understanding how Deep Belief Networks Perform
Acoustic Modelling,” in ICASSP, 2012.

- Visualization
Colors: speakers




图 19: 语音模型隐藏层可视化示例：输入声学特征与第八层隐藏表示在二维降维图中的结构不同。¹⁹

7.2 Attention 可视化不等于完整解释

Transformer 之后，attention weight 常被拿来画图解释模型：某个 token attend 到哪些 token，看起来像模型“关注”了哪里。但课程提醒，attention visualization 不能直接等同于 explanation。Attention 是模型计算过程中的一部分，却不一定完整代表因果贡献。

¹⁹ 视频画面时间区间：00:39:00–00:39:15。

How a network processes the input data?

- Visualization




图 20: Attention 权重可以被可视化, 但 attention 本身不必然等于解释; 它只是模型内部机制的一种观察窗口。²⁰

原因在于, 模型输出还经过后续层、非线性、残差连接、归一化和其他参数。一个位置的 attention 权重大, 不代表最终决策一定主要由它决定; 权重小, 也不代表没有影响。因此, attention 图可以提供线索, 但不能单独作为模型解释的全部证据。

7.3 Probing: 用探针测试隐藏表示

除了肉眼看图, 还可以用 probing。Probing 的做法是: 取模型某一层 hidden representation, 接一个简单分类器, 测试这个表示中是否包含某种信息。例如在 BERT 的某层表示上训练 POS classifier, 看看它是否能预测词性; 训练 NER classifier, 看看是否能识别地点、人名等实体。

²⁰ 视频画面时间区间: 00:39:45–00:40:00。

How a network processes the input data?

- Probing




图 21: Probing 方法：在模型隐藏层上接小分类器，检查 hidden representation 是否包含词性、实体等信息。²¹

如果探针很容易从某层表示中预测出词性，说明该层表示很可能编码了词性相关信息。但这里也有陷阱：探针分类器本身不能太强。如果探针太复杂，它可能自己学会任务，而不是证明原本的 hidden representation 已经清楚包含该信息。

Probing 的常见误读

Probing 只能说明某种信息“可被读出”，不一定说明模型原本在最终决策中“使用了”这种信息。探针强度、资料设定和对照实验都会影响结论。

7.4 语音合成中的 probing 示例

课程最后用 text-to-speech 的例子说明 probing。输入是一段语音或文字，模型内部有多层 representation。我们可以把每一层的表示拿出来，接上不同探针，测试它们是否包含 speaker information、phoneme information、word identity 或其他属性。

²¹ 视频画面时间区间：00:41:15–00:41:30。

How a network processes the input data?

- Probing




图 22: TTS 或语音模型中的 probing: 把不同层的表示拿出来, 测试其中是否保留说话人、内容或语音结构信息。²²

这类分析可以回答“信息在网络中怎样流动”。例如低层可能更接近声学细节, 高层可能更接近文字内容或语义; 某些层可能保留说话人信息, 某些层则更倾向于去除说话人差异。对模型压缩、迁移学习、可控生成和错误分析都很有帮助。

²² 视频画面时间区间: 00:43:45–00:44:00。

What does a network layer hear? Analyzing hidden representations of end-to-end ASR through speech synthesis

<https://arxiv.org/abs/1911.01102>

<https://youtu.be/6gtN7H-pWr8>




图 23: 隐藏表示分析示例: 比较不同层、不同输入条件下的信息保留与变化, 观察模型内部表示如何重组。²³

7.5 本章小结

解释神经网络不仅可以看输入哪一块重要, 也可以看隐藏层如何表示资料。可视化方法把高维表示降到二维, 帮助观察结构; attention 图提供模型内部连接线索, 但不能直接等同解释; probing 用小分类器测试 hidden representation 中是否包含特定信息。它们共同说明, 可解释性是一组工具, 而不是单一方法。

8 总结与延伸

P36 的核心主线可以压缩成一句话: 模型答对并不够, 我们还要知道它为什么答对。可解释机器学习就是为这个问题准备的一套方法。

从现实需求看, 可解释性服务于信任、责任和调试。贷款、医疗、司法、自驾车等场景不能只给一个结果; 开发者也需要解释来发现资料偏差和模型捷径。从模型选择看, 简单模型较易解释但未必强, 复杂模型更强但需要解释工具。合理目标不是为了可解释性放弃强模型, 而是让强模型有可检查的行为。

从方法看, 本讲主要介绍 local explanation。遮挡法和 saliency map 都在回答“输入中哪个成分影响了这次决策”。Gradient saliency 用输出对输入的偏导数衡量局部敏感度; SmoothGrad 通过加噪平均降低噪声; integrated gradients 试图缓解局部饱和导致的误判。它们有用, 但都需要谨慎解读。

宝可梦与数码宝贝案例是本讲最关键的警示: 模型可以在训练集和测试集上都接近满分, 却只是抓住 PNG 透明背景与 JPEG 背景这类格式差异。这个例子把“高准确率不等于正确理由”讲得

²³ 视频画面时间区间: 00:46:15–00:46:30。

非常具体。可解释性不是锦上添花，而是在模型看起来表现很好时，帮我们问出更深一层的问题。

最后，课程把解释扩展到网络内部。隐藏层可视化、attention visualization 和 probing 都可以观察模型怎样处理输入资料。但这些方法也不是最终答案：attention 不一定是解释，probing 只能说明信息可被读出，二维可视化也可能受降维方法影响。可解释性分析最可靠的做法，是把多种证据放在一起看，并始终结合任务背景和资料来源。

本讲带走的判断原则

当模型表现很好时，不要马上问“能不能上线”，先问三个问题：它看了什么？它为什么这样判断？如果资料来源或环境改变，这个理由还成立吗？这三个问题，是可解释机器学习最朴素也最实用的价值。

8.1 拓展阅读

本讲涉及的几个方向可以继续深入：

- **Saliency Map 与 SmoothGrad**：关注输入局部敏感度，以及如何降低梯度解释的噪声。
- **Integrated Gradients**：用路径积分缓解 gradient saturation，让解释不只依赖当前点的局部梯度。
- **Attention is not Explanation**：理解为什么 attention 权重不能直接等同于因果解释。
- **Probing Classifier**：研究 hidden representation 中可读出的语言、语音或语义信息，同时注意探针本身带来的偏差。