

机器学习的可解释性（下）：机器心中的猫长什么样子

Global Explanation, Activation Maximization, Generator Constraint, and LIME



基于李宏毅老师《机器学习 2025》课程整理

2026 年 6 月 8 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 22 分 45 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=37>

目录

1 从 Local Explanation 到 Global Explanation	3
1.1 Global explanation 的问题形式	3
1.2 本章小结	4
2 Filter 到底侦测什么	4
2.1 从 feature map 反推输入图案	5
2.2 用 Gradient Ascent 求解	6
2.3 Filter 学到的是局部 pattern	6
2.4 本章小结	7
3 模型心中的数字长什么样	7
3.1 直接最大化类别输出	7
3.2 加入正则化：要求图片更像自然输入	9
3.3 正则化能改善，但也引入人为偏好	10
3.4 本章小结	11
4 用 Generator 约束解释结果	11
4.1 从像素空间转到 latent space	12
4.2 Generator prior 的好处与代价	13
4.3 本章小结	14
5 Outlook：用可解释模型模仿黑盒子	14
5.1 Surrogate model 的基本想法	15
5.2 LIME：局部可解释的模型无关解释	16
5.3 代理解释的边界	17
5.4 本章小结	18
6 总结与延伸	18
6.1 拓展阅读	18

1 从 Local Explanation 到 Global Explanation

上一讲主要讨论 local explanation：给定某一张图片和某一次预测，模型为什么判断它是猫？这类解释关心的是单个输入的局部原因，例如 saliency map 会指出图片中哪些区域影响了这一次分类。

本讲转向 global explanation。它不再只问“这张图为什么是猫”，而是问一个更整体的问题：模型心中的“猫”长什么样？卷积网络里的某个 filter 到底侦测什么 pattern？某个类别在模型内部对应怎样的输入形态？



图 1: Global explanation 的目标：解释整个模型，而不是只解释单个输入；典型问题是“模型认为猫应该长什么样”。¹

1.1 Global explanation 的问题形式

Global explanation 想理解模型整体规则。它可以问：

- 一个卷积层 filter 被什么输入图案强烈激活？
- 分类器心中的数字 0 到 9 分别像什么？
- 模型把“猫”“狗”“火山”等类别表示成什么视觉结构？
- 是否能用简单模型近似复杂黑盒模型的行为？

这些问题都不依赖某一张特定图片，而是试图从模型参数和反应中反推出模型的内部概念。若 local explanation 像是在问“这一次你为什么这样判断”，global explanation 就是在问“你平常到底学到了什么”。

¹ 视频画面时间区间：00:00:15–00:00:30。

Global explanation 的核心困难

模型内部概念不一定和人的概念对齐。我们说“猫”时想到耳朵、胡须、眼睛、身体轮廓；模型可能想到纹理、局部边缘、背景统计，甚至训练资料中的水印或格式偏差。Global explanation 的价值，就是把这种差异显现出来。

1.2 本章小结

Local explanation 解释某个输入的单个预测，global explanation 解释模型整体学到的概念。本讲的主要技术路线是 activation maximization：主动寻找一种输入，让模型内部某个 filter 或某个类别输出最大，从而观察模型最想看到什么。

2 Filter 到底侦测什么

课程先从卷积网络的 filter 讲起。CNN 中有许多 convolutional layer，每个 layer 有许多 filters。输入图片经过 filter 后，会得到 feature map；feature map 上某个位置的值大，通常表示该位置附近出现了 filter 偏好的 pattern。




图 2：卷积网络中的 filter 会对输入图片产生 feature map；feature map 中的大值代表该 filter 被局部图案强烈激活。²

²视频画面时间区间：00:01:15–00:01:30。

2.1 从 feature map 反推输入图案

假设我们关心第 k 个 filter。对输入图片 x ，该 filter 输出 feature map：

$$A^{(k)}(x) = [a_{ij}^{(k)}(x)],$$

其中 $a_{ij}^{(k)}(x)$ 是第 i, j 个空间位置的 activation。若某些位置 activation 很大，说明输入图片中相应位置有这个 filter 喜欢的图案。

为了知道 filter 喜欢什么，我们可以反过来找一张图片 x^* ，让这个 filter 的总 activation 尽量大：

$$x^* = \arg \max_x \sum_i \sum_j a_{ij}^{(k)}(x).$$

符号含义如下：

x^* 找出来的“最能刺激 filter 的图片”。

$a_{ij}^{(k)}(x)$ 第 k 个 filter 在位置 (i, j) 的 activation。

$\sum_i \sum_j$ 把整张 feature map 上所有位置的 activation 加起来。




图 3: Activation maximization: 寻找一张未知图片 x^* ，让目标 filter 的 feature map 总 activation 最大。³

这张 x^* 不是资料库中的真实图片，而是我们把像素本身当成变量，通过最佳化找出来的图片。换句话说，我们不是问“现有图片中哪张最能激活 filter”，而是直接问“如果可以自由生成一张图片，什么图案最能让 filter 兴奋”。

³ 视频画面时间区间：00:03:15–00:03:30。

2.2 用 Gradient Ascent 求解

这个问题可以用类似 gradient descent 的方法求解，但方向相反。平常训练模型时，我们常最小化 loss，所以沿负梯度方向更新；现在我们要最大化 activation，所以沿正梯度方向更新，也就是 gradient ascent。

若目标函数为

$$J(x) = \sum_i \sum_j a_{ij}^{(k)}(x),$$

则更新可写成

$$x \leftarrow x + \eta \nabla_x J(x).$$

符号含义如下：

$J(x)$ 当前图片对目标 filter 的总激活。

η 更新步长。

$\nabla_x J(x)$ 目标函数对输入像素的梯度。




图 4: 通过 gradient ascent 直接更新输入图片，使目标 filter 的 activation 越来越大。⁴

2.3 Filter 学到的是局部 pattern

课程以 digit classifier 为例展示结果。对较浅层的 filters 做 activation maximization 后，得到的图案往往是横线、斜线、边缘、弧线等基础视觉元素，而不是完整数字。这符合 CNN 的直觉：前面层通常学局部边缘和纹理，后面层才逐渐组合成更复杂的形状。

⁴视频画面时间区间：00:04:30-00:04:45。

What does a filter detect?

E.g., Digit classifier




图 5: 对 digit classifier 的 filter 做 activation maximization, 可以看到许多 filter 对线条、边缘、斜纹等局部 pattern 敏感。⁵

这类可视化可以帮助我们判断网络是否学到了合理的基础视觉结构。如果浅层 filters 完全没有边缘、纹理或方向性, 而是出现强烈噪声或资料集水印, 就可能暗示训练过程或资料本身有问题。

2.4 本章小结

理解 filter 的方法, 是把输入图片当作可优化变量, 寻找最能激活某个 filter 的图片。这个过程称为 activation maximization。它告诉我们 filter 偏好什么局部 pattern, 但要注意: 这只是从模型反应中抽出的图案, 不一定直接等于人类语义概念。

3 模型心中的数字长什么样

如果我们能问“filter 侦测什么”, 自然也可以问“某个类别在模型心中长什么样”。对 digit classifier 而言, 可以寻找一张图片 x^* , 使模型对数字 c 的输出分数最大。

3.1 直接最大化类别输出

设模型对类别 c 的输出分数为 $y_c(x)$ 。最直接的做法是:

$$x^* = \arg \max_x y_c(x).$$

符号含义如下:

$y_c(x)$ 输入图片 x 被模型判断为类别 c 的分数。

⁵视频画面时间区间: 00:06:15–00:06:30。

x^* 使该类别分数最大的图片。

直觉上，如果 $c = 3$ ，我们希望 x^* 看起来像一个清楚的 3；如果 $c = 8$ ，希望它像 8。但课程展示的结果并不理想：生成图片常常像噪声，人眼未必能看出数字。

What does a digit look like for CNN?

E.g., Digit classifier

$$X^* = \arg \max_X y_i \quad \text{Can we see digits?}$$





图 6: 直接最大化 digit classifier 的类别输出，得到的图片往往充满噪声，人眼不一定能看出数字形状。⁶

这其实呼应了前面 adversarial attack 的现象。神经网络可能对某些人眼看起来无意义的高频 pattern 非常有信心。只要这些 pattern 能刺激模型内部特征，模型就会给出高分；它不需要让图片符合人的视觉直觉。

⁶视频画面时间区间：00:07:45–00:08:00。

What does a digit look like for CNN?

Find the image that
maximizes class probability

$$X^* = \arg \max_X y_i$$



图 7: 不加限制地寻找最大类别分数, 模型可能认为某些噪声图像 “很像数字”, 但人类无法直接理解。⁷

Activation maximization 的基本陷阱

最大化模型输出, 得到的是 “模型会高分接受的输入”, 不一定是 “人类认为合理的输入”。如果不加限制, 最佳化过程可能找到模型的漏洞, 而不是找到人的语义概念。

3.2 加入正则化: 要求图片更像自然输入

为了让结果更像人类可理解的数字, 可以在目标函数中加入 regularization。课程中的思路是把 “图片应该像数字” 这件事硬塞进优化过程, 让最佳化不仅追求类别分数高, 也惩罚不自然的图片。

可以写成

$$x^* = \arg \max_x [y_c(x) + R(x)],$$

其中 $R(x)$ 是偏好自然图片的约束项。常见约束包括:

- 惩罚像素值过大, 让图片不要靠极端像素取胜。
- 惩罚相邻像素差异, 让图片更平滑。
- 使用 total variation 之类的约束, 让图像更像自然形状。
- 对输入做模糊、裁切、噪声平均等处理, 降低高频噪声。

⁷ 视频画面时间区间: 00:09:15–00:09:30。

What does a digit look like for CNN?

Find the image that maximizes class probability

$$X^* = \arg \max_X y_i$$



The image should look like a digit.

$$X^* = \arg \max_X y_i + R(X)$$

$$R(X) = - \sum_{i,j} |X_{ij}|$$

How likely
X is a digit




图 8: 加入 $R(x)$ 之类的正则化后, 优化目标不仅要求分类分数高, 也要求生成图像更像自然数字。⁸

符号含义如下:

$y_c(x)$ 模型对目标类别的输出分数。


$R(x)$ 对输入图片自然性的偏好或惩罚。

x^* 同时兼顾类别分数和自然性约束的优化结果。

3.3 正则化能改善, 但也引入人为偏好

加入许多 regularization 和 hyperparameter tuning 后, 生成结果会更容易看懂。例如对 ImageNet 类别做 activation maximization, 可以看到比较像 flamingo、pelican、hartebeest、billiard table 等类别的图像结构。

⁸ 视频画面时间区间: 00:11:00-00:11:15。



With several regularization terms, and hyperparameter tuning

<https://arxiv.org/abs/1506.06579>

图 9: 加入多种 regularization 与超参数调整后, activation maximization 结果会更像人类可识别的类别图像。⁹

但这也带来新的问题: 如果我们强行加入很多约束, 让图片看起来像人期待的样子, 那么解释到底来自模型, 还是来自我们设定的正则化? 课程对此态度很谨慎: 生成图像若不符合期待, 我们说方法不好; 为了让它符合期待, 又加入越来越多限制。这说明 global explanation 本身也会受到解释方法设计的影响。

正则化不是中立的

正则化可以让解释更可读, 但它也把人的先验放进了解释结果。越强的先验越能生成漂亮图片, 却越难判断这些形状到底是模型原本学到的, 还是解释方法塑造出来的。

3.4 本章小结

直接最大化类别输出可以揭示模型高分接受什么输入, 但结果可能是噪声。加入正则化能让图片更像人类可理解的对象, 却会引入人为偏好。因此, activation maximization 的结果需要被当作“模型与解释方法共同产生的证据”, 而不是模型内部概念的绝对照片。

4 用 Generator 约束解释结果

课程接着介绍另一种让生成图片更自然的方法: 不直接在像素空间中找 x , 而是在一个生成器的 latent space 中找 z 。生成器可以由 GAN、VAE 等模型训练得到, 它把低维向量 z 转成较自然的图片 $x = G(z)$ 。

⁹ 视频画面时间区间: 00:12:15-00:12:30。

Constraint from Generator




图 10: 先训练一个 image generator, 将低维向量 z 映射成图片 $x = G(z)$, 用生成器限制搜索空间。¹⁰

4.1 从像素空间转到 latent space

直接优化像素空间的问题在于, 自由度太高。模型可以找到奇怪噪声图案, 因为像素空间里绝大多数点并不像自然图片。若用生成器限制 $x = G(z)$, 最佳化只能在生成器能产生的图片范围内搜索, 结果通常更接近自然图像。

新的目标可以写成

$$z^* = \arg \max_z y_c(G(z)), \quad x^* = G(z^*).$$

符号含义如下:

G 训练好的图片生成器。

z 低维 latent vector。

$y_c(G(z))$ 分类器对生成图片属于类别 c 的分数。

x^* 通过最佳 latent vector 生成出的解释图片。

¹⁰ 视频画面时间区间: 00:13:45–00:14:00。

Constraint from Generator




图 11: 不再直接优化图片 x , 而是优化 latent vector z , 让生成器输出的图片能最大化分类器的目标类别分数。¹¹

4.2 Generator prior 的好处与代价

这种方法的好处是生成图片更自然。因为 G 学过真实图片分布, 它会把搜索限制在较像真实图像的 manifold 上。若分类器认为某个生成图像非常像火山、蚂蚁或建筑类别, 人类也更可能看出对应视觉结构。

¹¹ 视频画面时间区间: 00:15:00–00:15:15。




图 12: 使用 generator constraint 后, 可以得到更像自然图片的类别可视化结果, 例如 redshark、ant、monastery、volcano 等。¹²

但代价是解释依赖生成器。生成器本身也有训练资料、模型能力和偏差。如果 G 不会生成某些形态, 解释结果就不会包含这些形态; 如果 G 偏好某些风格, activation maximization 结果也会被这种风格影响。因此 generator prior 让解释更可读, 但并没有消除解释方法的主观设计。

Generator constraint 的限制

生成器让搜索空间更自然, 但解释结果同时反映分类器和生成器。若生成器有偏差, 最后看到的“模型心中的图像”也会带着这种偏差。

4.3 本章小结

Generator constraint 的核心, 是把解释搜索从像素空间转到生成器的 latent space。这样能减少噪声和不自然图案, 让结果更像真实图片。但它也把生成器的先验引入解释过程, 因此仍然需要谨慎解读。

5 Outlook: 用可解释模型模仿黑盒子


最后, 课程展望另一类解释方法: 用较简单、可解释的模型去模仿复杂黑盒模型的行为。如果一个线性模型能在某个范围内输出和黑盒模型相近的结果, 我们就可以分析线性模型的权重, 间接理解黑盒在这个范围内做了什么。

¹² 视频画面时间区间: 00:16:15–00:16:30。



Outlook

Using an interpretable model to mimic the behavior of an uninterpretable model.



<https://youtu.be/K1mWgthGS-A>

<https://youtu.be/OjqIVSwly4k>

图 13: Outlook: 把复杂模型当作黑盒子, 尝试用简单可解释模型模仿它的输入输出行为。¹³

5.1 Surrogate model 的基本想法

设黑盒模型为 $f(x)$, 可解释模型为 $g(x)$ 。我们希望在关心的输入范围内, 让

$$g(x) \approx f(x).$$

符号含义如下:

f 原始复杂模型, 例如深度网络。

g 可解释代理模型, 例如线性模型或小决策树。

$\approx$ 在某个资料区域或局部邻域内输出尽量接近。

如果 g 是线性模型:


$$g(x) = w^\top x + b,$$

我们就可以通过权重 w 分析哪些特征对黑盒输出更重要。这个解释不直接打开黑盒内部, 而是用“行为相似的可解释替身”来理解黑盒。

¹³ 视频画面时间区间: 00:17:30–00:17:45。

Outlook

Using an interpretable model to mimic the behavior of an uninterpretable model.



<https://youtu.be/K1mWgthGS-A>

<https://youtu.be/OjqIVSwly4k>

图 14: 若线性模型能模仿黑盒模型的输出, 就可以通过线性权重解释黑盒模型在该区域的行为。¹⁴

5.2 LIME: 局部可解释的模型无关解释

课程提到的经典方法是 LIME, 全名是 Local Interpretable Model-Agnostic Explanations。它的关键词有三个:


- **Local**: 只在某个输入附近解释, 不要求全局模仿整个黑盒。
- **Interpretable**: 使用线性模型、小树等人类较容易理解的模型。
- **Model-Agnostic**: 不依赖黑盒模型内部结构, 只需要能查询输入输出。

¹⁴ 视频画面时间区间: 00:18:45–00:19:00。



Outlook

Using an interpretable model to mimic the behavior of an uninterpretable model.



Local Interpretable Model-Agnostic Explanations (LIME)

<https://youtu.be/K1mWgthGS-A>

<https://youtu.be/OjqIVSwly4k>

图 15: LIME 的思路: 在目标输入附近采样扰动, 查询黑盒输出, 再训练局部线性模型尽量拟合黑盒行为。¹⁵

LIME 通常会在某个输入 x_0 附近采样许多扰动样本, 得到黑盒输出 $f(x)$, 再用一个简单模型 g 拟合这些局部样本。常见目标可写成

$$\mathcal{L}(g) = \sum_{x \in \mathcal{N}(x_0)} \pi_{x_0}(x) (f(x) - g(x))^2 + \Omega(g).$$

符号含义如下:

x_0 要解释的目标输入。

$\mathcal{N}(x_0)$ x_0 附近的扰动样本集合。

$\pi_{x_0}(x)$ 距离权重, 越接近 x_0 的样本权重越大。

$\Omega(g)$ 对解释模型复杂度的惩罚, 鼓励 g 简单可解释。

5.3 代理解释的边界

代理模型解释有一个关键限制: 它解释的是“代理模型怎样近似黑盒”, 不一定等于黑盒内部真正的机制。如果局部区域选得不好、扰动样本不合理、线性模型拟合不佳, 解释就可能偏离黑盒实际行为。LIME 的强处是 model-agnostic 和直观, 弱点则是对采样、距离度量和局部范围较敏感。

不要把 surrogate 当成原模型本身

代理模型的解释只有在 fidelity 足够高时才有意义。若代理模型无法模仿黑盒输出, 再解释代理模型权重就没有太大价值。

¹⁵ 视频画面时间区间: 00:20:00–00:20:15。

5.4 本章小结

用可解释模型模仿黑盒，是另一条可解释性路线。它不直接可视化 filter 或生成输入，而是从输入输出行为出发，用简单模型近似复杂模型。LIME 是代表方法之一，强调局部、模型无关和可解释，但它的可靠性取决于局部拟合质量。

6 总结与延伸

P37 讨论的是 global explanation：我们不只想知道某次预测为什么发生，还想知道模型整体学到了什么。课程从 CNN filter 出发，展示如何通过 activation maximization 找出最能激活某个 filter 的输入图案；再推广到类别层面，试图反推出模型心中的数字或物体。

本讲最重要的技术思想是“把输入当作变量”。平常训练时，我们固定输入、更新模型参数；解释时，我们固定模型、更新输入，让某个 filter activation 或类别分数最大。这个角色互换非常关键：它让我们能够主动询问模型“你最想看到什么”。

但答案并不总是漂亮。直接最大化输出往往得到噪声，因为模型可能对人类无意义的高频 pattern 很敏感。加入 regularization、total variation 或 generator constraint 可以让图像更自然，却也引入人的先验和生成器偏差。因此 activation maximization 的结果应该被看作解释证据，而不是模型内心世界的绝对还原。

最后的 LIME 展望提醒我们，可解释性不只有可视化一条路。我们也可以用简单可解释模型模仿黑盒行为，尤其是在某个局部区域内解释输入输出关系。这类方法适合模型不可访问或结构复杂的场景，但解释质量取决于代理模型是否真的拟合黑盒。

本讲的压缩理解

Global explanation 的核心问题是“模型整体学到了什么”。Activation maximization 从模型内部反推出输入图案，generator constraint 用自然图像先验限制搜索，LIME 则用可解释代理模型近似黑盒行为。三者都在解释模型，但每一种解释都带着方法本身的假设。

6.1 拓展阅读

可以继续深入的方向包括：

- **Feature Visualization**：研究如何可视化神经网络 filters、neurons 和类别方向。
- **DeepDream**：通过放大神经网络内部 activation 生成梦境般图像，是 activation maximization 的著名应用。
- **GAN/VAE Prior for Explanation**：用生成模型约束解释图像，使结果更接近自然图片。
- **LIME 与 SHAP**：从模型无关角度解释黑盒模型的输入输出行为。