

来自人类的恶意攻击（上）： Adversarial Attack 基本概念

Image Adversarial Examples, Perturbation Constraints, and
FGSM



基于李宏毅老师《机器学习 2025》课程内容整理
2026 年 6 月 9 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 29 分 49 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=39>

目录

1	为什么要研究来自人类的恶意攻击	3
1.1	从自然错误到有意欺骗	3
1.2	图像分类中的直观例子	4
1.3	攻击成功的含义	5
1.4	本章小结	8
2	攻击问题的形式化描述	8
2.1	固定模型, 更新输入	9
2.2	Non-targeted attack	9
2.3	Targeted attack	10
2.4	本章小结	11
3	不可感知扰动与距离约束	11
3.1	距离约束	11
3.2	L2 范数与 L-infinity 范数	12
3.3	为什么同样的 L2 可能感知效果不同	13
3.4	完整的约束优化问题	14
3.5	本章小结	15
4	用梯度下降攻击输入	15
4.1	从原图开始	15
4.2	更新后投影回约束集合	16
4.3	优化方法与约束方法可以分开理解	17
4.4	本章小结	17
5	FGSM 与 iterative FGSM	18
5.1	一次更新的想法	18
5.2	为什么用 sign	19
5.3	Iterative FGSM	20
5.4	White-box 与 black-box 的过渡	20
5.5	本章小结	21
6	总结与延伸	21
6.1	和前后课程的连接	22
6.2	本讲之后可以继续追问的问题	22

1 为什么要研究来自人类的恶意攻击

本讲从一个很现实的问题开始：我们已经训练了很多神经网络，也可能在作业、实验或产品中得到很高的测试正确率；但是一旦模型被放到真实世界，它面对的输入就不一定是自然分布中随机抽来的干净样本。某些输入可能是人刻意设计出来的，目标不是被模型正确处理，而是专门绕过、误导或欺骗模型。



Motivation

- You have trained many neural networks.
- We seek to deploy neural networks in the real world.
- Are networks robust to the inputs that are built to fool them?
 - Useful for spam classification, malware detection, network intrusion detection, etc.

图 1: 课程动机：模型部署到真实世界后，输入可能来自有意规避检测的人，典型场景包括垃圾邮件分类、恶意软件侦测与网络入侵检测。¹

1.1 从自然错误到有意欺骗

普通的泛化错误通常来自数据分布差异、训练资料不足、模型容量限制或标注噪声。对抗攻击不同，它假设输入的构造者知道模型会做某种判断，并主动寻找模型的弱点。也就是说，错误不再只是模型“偶然没学好”，而是有人把输入推向模型最脆弱的方向。

这件事在安全相关任务中特别重要。例如垃圾邮件过滤器不是在判断一批无辜邮件，而是在面对会改写标题、正文、链接和附件格式的发送者；恶意软件检测器面对的也不是固定样本，而是会被攻击者反复修改、混淆和打包的程序；入侵检测系统面对的流量同样可能被伪装。只要模型本身成为防线，输入就可能反过来针对模型设计。

Adversarial attack 的基本视角

对抗攻击不是单纯问“模型在测试集上准不准”，而是问“当输入被有目的地修改时，模型是否仍然可靠”。这个视角把机器学习从静态评测带到博弈场景：模型做决策，攻击者观察决策规则或输出，再构造更会骗人的输入。

¹视频画面时间区间：00:01:00–00:01:15。

1.2 图像分类中的直观例子

课程用图像分类作为入口。假设我们有一个已经训练好的影像辨识系统，输入一张猫的照片，网络输出类别分布，并把它判断为 Tiger Cat。图像本身可以看成是一个很长的向量，每个像素或每个通道的数值都是向量中的一个维度。攻击者要做的事情，是在这个向量上加一个很小的扰动。

手机摄影自学课堂 Bilibili

Example of Attack




图 2: 图像攻击的基本形式：原始猫图像输入分类器，攻击者在像素向量上加入小扰动，希望改变分类器输出。²

如果扰动足够小，人眼可能看不出来图像已经被改动。没有被加扰动的原图通常称为 benign image；被加上扰动、用来误导模型的图像称为 attacked image 或 adversarial image。这里的核心张力是：对人来说，两张图几乎一样；对模型来说，两张图可能落在完全不同的决策区域。

²视频画面时间区间：00:03:00–00:03:15。

Example of Attack




图 3: Benign image 与 attacked image: 在原图上加入小扰动后, 人眼仍看到猫, 但模型输出可能被推向其他类别。³

1.3 攻击成功的含义

“让模型犯错”可以有宽松和严格两种含义。宽松的要求是模型不要再输出原来的类别即可, 例如猫不要再被判成猫; 严格的要求是模型必须输出攻击者指定的目标类别, 例如必须把猫判成海星。后者更难, 因为攻击不仅要离开原类别, 还要走向指定类别。

³视频画面时间区间: 00:04:45–00:05:00。

Example of Attack

Network

= ResNet-50

The target is "Star Fish"




图 4: Non-targeted 与 targeted 的区别: 前者只要求输出不是原类别, 后者要求输出成为指定类别, 例如 Star Fish。⁴

课程展示的例子说明, 这并不是只存在于概念上的可能性。原本被 ResNet-50 判断为 Tiger Cat 的猫图, 在加入人眼几乎看不出的扰动后, 可以被高置信度地判断为 Star Fish。更进一步, 同一张猫图还可以被推向 Keyboard 等其他指定类别。

⁴视频画面时间区间: 00:06:15–00:06:30。

Example of Attack

Network

= ResNet-50

The target is "Keyboard"




图 5: 指定目标为 Star Fish 的攻击示例: 攻击后图像视觉上仍像猫, 但模型输出变为 Star Fish。⁵




图 6: 指定目标为 Keyboard 的攻击示例: 只要换一组扰动, 同一张猫图也可以被推向另一个目标类别。⁶

⁵ 视频画面时间区间: 00:07:30-00:07:45。

这种现象说明模型并不是简单地“看懂了猫”，而是学到了一个从像素空间到类别分数的复杂函数。人类视觉觉得无关紧要的微小方向，在这个函数里可能对应非常大的输出变化。攻击者利用的正是这种人类感知空间和模型决策空间之间的不一致。




图 7: 扰动强度与错误标签示例：不同扰动可以让模型输出 Persian cat、fire screen 等不同结果，部分图像在人眼看来已经明显变坏。⁷

不要把“模型犯错”误解为“图像已经变成另一类”

对抗攻击中的关键不是图像真的变成了海星或键盘，而是模型的决策函数被扰动推到了这些类别。人类语义没有随模型输出一一起改变，这正是问题严重之处。

1.4 本章小结

对抗攻击研究的是有目的的输入修改。它关心的不是模型在自然测试集上的平均表现，而是模型在面对刻意构造的输入时是否稳健。图像攻击的基本现象是：对人眼几乎不变的图像，对神经网络可能变成完全不同的类别。这个现象揭示了人类感知、训练数据分布和模型决策边界之间的裂缝。

2 攻击问题的形式化描述

要把攻击从现象变成算法，需要先定义符号。课程中的设定是：网络已经训练完成，参数固定；攻击者不再更新模型参数，而是更新输入图像本身。原图记为 x^0 ，模型对原图的输出记为 $y^0 = f(x^0)$ ；攻击后图像记为 x ，模型输出记为 $y = f(x)$ 。

⁶ 视频画面时间区间：00:08:45–00:09:00。

⁷ 视频画面时间区间：00:09:45–00:10:00。

2.1 固定模型，更新输入

普通训练是找一组参数，使模型在训练资料上 loss 小。对抗攻击则相反：模型参数已经固定，攻击者在输入空间里找一个新输入，让模型输出满足攻击目标。

$$y^0 = f(x^0), \quad y = f(x).$$

符号含义如下：

x^0 原始干净输入，例如一张没有被攻击的猫图。

x 攻击者构造的新输入，通常要求与 x^0 足够接近。

f 已训练好的神经网络，参数在攻击过程中固定。

y^0 模型在原始输入上的输出分布。

y 模型在攻击输入上的输出分布。

这里最重要的差别是优化对象变了。训练时更新的是权重 w, b ；攻击时更新的是输入 x 。因此，如果我们可以对输入求梯度，就可以把图像本身当成可优化变量。

2.2 Non-targeted attack

Non-targeted attack 只要求模型离开原本输出。若原图被模型判断为猫，攻击者只要让攻击后输出不是猫即可。课程用一个 loss 来刻画这个目标：让攻击后输出 y 和原输出 $\hat{y}$ 越远越好。若 $e(\cdot, \cdot)$ 表示两个分布之间的差距，例如交叉熵，则可以把要最小化的目标写成负距离。




图 8: Non-targeted attack 的形式：固定网络参数，寻找攻击输入，使模型输出远离原来的类别分布。

8

⁸ 视频画面时间区间：00:11:00–00:11:15。

$$x^* = \arg \min_x L(x), \quad L(x) = -e(y, \hat{y}).$$

符号含义如下：

x^* 攻击者最终找到的 adversarial input。

$L(x)$ 攻击用的目标函数。这里写成最小化形式。

$y = f(x)$ 当前攻击输入的模型输出。

$\hat{y}$ 原本希望模型保持的输出，课程图中可理解为原类别 cat。

$e(y, \hat{y})$ 衡量 y 与 $\hat{y}$ 差异的函数，例如交叉熵。

由于 $L(x)$ 前面有负号，最小化 $L(x)$ 等价于让 $e(y, \hat{y})$ 变大，也就是让当前输出远离原类别。直观地说，non-targeted attack 的优化方向是“不要再像猫”。

2.3 Targeted attack

Targeted attack 还要求输出接近攻击者指定的目标类别。以猫图为例，攻击者不仅希望模型不要输出 cat，还希望模型输出 fish。于是目标函数要同时包含两件事：远离原类别，接近目标类别。

$$L(x) = -e(y, \hat{y}) + e(y, y^{\text{target}}).$$

符号含义如下：

y^{target} 攻击者指定的目标类别分布，例如 fish。

$-e(y, \hat{y})$ 让输出远离原类别。

$e(y, y^{\text{target}})$ 让输出接近目标类别。

最小化这个 $L(x)$ 时，第一项鼓励模型离开 cat，第二项鼓励模型靠近 fish。Targeted attack 因此比 non-targeted attack 更有方向性，也通常更难。




图 9: Targeted loss 与不可感知约束：攻击输入既要让输出远离原类别、接近目标类别，又要与原图距离不超过 epsilon。⁹

攻击目标的两个层次

Non-targeted attack 只需要制造错误，targeted attack 需要制造指定错误。前者对应“不要是原答案”，后者对应“必须是我指定的错误答案”。在比较攻击成功率时，必须先确认使用的是哪一种目标，否则数字没有可比性。

2.4 本章小结

对抗攻击可以看成固定模型后的输入优化问题。模型参数不动，攻击者更新输入 x 。Non-targeted attack 让模型输出远离原类别；targeted attack 让模型输出远离原类别同时接近指定目标类别。形式化目标函数把“欺骗模型”转成了可优化的问题，但它还没有解决另一个关键要求：攻击后的输入必须看起来仍然像原输入。

3 不可感知扰动与距离约束

如果攻击者可以任意修改图像，攻击就没有意义。把一张猫图直接换成海星图，当然可以让模型输出海星，但那不是对抗样本。对抗攻击真正有意思的地方在于：攻击输入 x 必须与原始输入 x^0 足够接近，使人类不容易察觉差别。

3.1 距离约束

课程用一个统一约束表达“不可感知”：

⁹视频画面时间区间：00:13:30-00:13:45。

$$d(x^0, x) \leq \epsilon.$$

符号含义如下：

$d(x^0, x)$ 原图与攻击图之间的距离函数。

ϵ 允许的最大扰动半径，也就是攻击预算。

$d(x^0, x) \leq \epsilon$ 攻击后图像必须落在原图附近的一个可接受区域内。

这个约束不是纯数学装饰，它承担了人类感知假设：如果两张图的距离小于某个阈值，人类就不容易看出扰动。实际研究中，这个假设并不完美，因为人眼对不同纹理、亮度、边缘和语义区域的敏感度不同；但范数约束提供了一个可计算、可复现实验设定。

3.2 L2 范数与 L-infinity 范数

设扰动为

$$\Delta x = x - x^0.$$

符号含义如下：

x^0 原始图像向量。

x 攻击后的图像向量。

Δx 每个像素或通道的改变量。

常见距离包括 L_2 范数与 L_∞ 范数：

$$d_2(x^0, x) = \|\Delta x\|_2 = \sqrt{(\Delta x_1)^2 + (\Delta x_2)^2 + \dots},$$

$$d_\infty(x^0, x) = \|\Delta x\|_\infty = \max_i |\Delta x_i|.$$

符号含义如下：

d_2 欧氏距离，衡量所有像素改变量的整体能量。

d_∞ 最大坐标距离，衡量任意单个像素被改动的最大幅度。

i 像素向量中的坐标索引。

Non-perceivable

$$d(\mathbf{x}^0, \mathbf{x}) \leq \varepsilon$$

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \end{bmatrix} - \begin{bmatrix} x_1^0 \\ x_2^0 \\ x_3^0 \\ \vdots \end{bmatrix} = \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \\ \Delta x_3 \\ \vdots \end{bmatrix}$$

$\mathbf{x} \quad \mathbf{x}^0 \quad \Delta \mathbf{x}$

- L2-norm

$$\begin{aligned} d(\mathbf{x}^0, \mathbf{x}) &= \|\Delta \mathbf{x}\|_2 \\ &= (\Delta x_1)^2 + (\Delta x_2)^2 + (\Delta x_3)^2 \dots \end{aligned}$$

- L-infinity

$$\begin{aligned} d(\mathbf{x}^0, \mathbf{x}) &= \|\Delta \mathbf{x}\|_\infty \\ &= \max\{|\Delta x_1|, |\Delta x_2|, |\Delta x_3|, \dots\} \end{aligned}$$




图 10: 不可感知扰动的距离定义: L2 范数汇总所有像素改变量, L-infinity 范数关注单个像素的最大改变量。¹⁰

3.3 为什么同样的 L2 可能感知效果不同

课程强调, 距离公式和人类感知并不完全等价。假设一张极小图像只有四个像素。有两种改法: 第一种是每个像素都改一点点; 第二种是只改一个像素, 但改很多。它们的 L_2 距离可能相同, 因为平方和一样; 但人眼可能更容易注意到第二种, 因为一个像素变化太大。

¹⁰ 视频画面时间区间: 00:16:00-00:16:15。

Non-perceivable

$$d(x^0, x) \leq \varepsilon$$

• L2-norm

$$\begin{aligned} d(x^0, x) &= \|\Delta x\|_2 \\ &= (\Delta x_1)^2 + (\Delta x_2)^2 + (\Delta x_3)^2 \dots \end{aligned}$$

• L-infinity

$$\begin{aligned} d(x^0, x) &= \|\Delta x\|_\infty \\ &= \max\{|\Delta x_1|, |\Delta x_2|, |\Delta x_3|, \dots\} \end{aligned}$$

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \end{bmatrix} - \begin{bmatrix} x_1^0 \\ x_2^0 \\ x_3^0 \\ \vdots \end{bmatrix} = \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \\ \Delta x_3 \\ \vdots \end{bmatrix}$$

$x \quad x^0 \quad \Delta x$




图 11: 相同 L2、不同 L-infinity 的直觉: 所有像素小幅变化与单个像素大幅变化可能有相同 L2, 但后者更容易被注意到。¹¹

这就是 L_∞ 常被用于图像对抗攻击的原因之一。它限制每个像素最多只能改 ϵ , 避免出现少数像素被大幅篡改。若所有坐标都被限制在 $[-\epsilon, \epsilon]$ 内, 攻击图像会落在以 x^0 为中心的一个高维方块中。

范数约束只是人类感知的近似

L_2 和 L_∞ 都是方便计算的数学约束, 不等于真正的人类视觉系统。它们能让实验可比较, 却不能保证所有小范数扰动都不可见, 也不能保证所有可见扰动都语义重要。理解这一点有助于避免把“满足范数约束”误读成“人类一定看不出来”。

3.4 完整的约束优化问题

把攻击目标与不可感知约束合并后, 攻击可以写成:

$$x^* = \arg \min_{d(x^0, x) \leq \epsilon} L(x).$$

符号含义如下:

x^* 满足扰动预算的最优攻击输入。

$d(x^0, x) \leq \epsilon$ 可接受扰动集合。

$L(x)$ non-targeted 或 targeted 攻击目标函数。

这个式子压缩了對抗攻击的核心: 既要讓 $L(x)$ 足够小, 也就是让模型被误导; 又不能讓 x 离 x^0 太远, 否則攻击不再“隱蔽”。后续所有算法大体都在回答两个问题: 如何优化 $L(x)$, 以及如何在更新后仍然满足约束。

¹¹ 视频画面时间区间: 00:18:30–00:18:45。

3.5 本章小结

不可感知约束把攻击和普通篡改区分开来。 L_2 范数衡量整体扰动能量， L_∞ 范数限制单个像素最大变化。课程用四像素例子说明，同样的数学距离可能对应不同感知效果，因此范数只是近似。完整攻击问题是带约束的输入优化：在 $d(x^0, x) \leq \epsilon$ 的范围内，让模型输出达到攻击目标。

4 用梯度下降攻击输入

既然攻击问题已经写成优化问题，自然可以用梯度下降。这里的梯度下降和训练神经网络很像，但对象不同：训练时用梯度更新参数；攻击时用梯度更新输入。课程特别强调这一点，因为它是理解白箱攻击的关键。

4.1 从原图开始

攻击输入通常从原图 x^0 开始，而不是从随机图像开始。原因很直接：我们希望最终的 x 与 x^0 接近，从原图出发更容易留在约束范围内，也更容易保持人眼语义不变。



$$x^* = \arg \min L(x)$$

Gradient Descent




图 12: 攻击算法从原图开始，更新的是输入而不是网络参数；这与普通训练中更新权重与偏置的过程相反。¹²

若 g_t 表示当前输入处 loss 对输入的梯度，普通迭代可以写成：

$$x^t \leftarrow x^{t-1} - \eta g_t.$$

符号含义如下：

x^t 第 t 次更新后的攻击输入。

¹²视频画面时间区间：00:21:00–00:21:15。

g_t 在 x^{t-1} 处计算得到的梯度。

η 学习率或步长。

$-\eta g_t$ 让目标函数下降的更新方向。

如果 $L(x)$ 是前面定义的攻击 loss，沿负梯度方向更新就会让输入更容易达到攻击目标。对于 targeted attack 和 non-targeted attack，具体梯度方向会由各自的 $L(x)$ 决定。

4.2 更新后投影回约束集合

直接做梯度下降可能让 x 跑出允许扰动范围。课程给出一个朴素但有效的办法：每次更新后检查距离，如果 $d(x^0, x) > \epsilon$ ，就把更新后的点修回约束集合中。这个“修回去”的操作通常称为 projection 或 clipping。



$$x^* = \arg \min_{\underline{d(x^0, x) \leq \epsilon}} L(x)$$

Gradient Descent

Start from original image x^0

For $t = 1$ to T

$$x^t \leftarrow x^{t-1} - \eta g$$

If $d(x^0, x) > \epsilon$

图 13: 带约束的梯度下降：每次更新输入后检查是否超过扰动预算，若超过则把输入修回可行区域。¹³

伪代码可以概括为：

```
 $x^0 \leftarrow \text{original image},$ 
for  $t = 1, \dots, T$  :
     $x^t \leftarrow x^{t-1} - \eta g_t,$ 
    if  $d(x^0, x^t) > \epsilon$ ,  $x^t \leftarrow \text{fix}(x^t).$ 
```

符号含义如下：

T 迭代次数。

fix 把点拉回约束集合的操作。

¹³ 视频画面时间区间：00:23:30–00:23:45。

$d(x^0, x^t) > \epsilon$ 表示当前攻击输入已经超过扰动预算。

在 L_∞ 约束下, projection 很容易理解: 把每个像素的改变量夹在 $[-\epsilon, \epsilon]$ 内即可。也就是说, 若某个坐标相对原图增加太多, 就截断到 $+\epsilon$; 减少太多, 就截断到 $-\epsilon$ 。




图 14: L_∞ 约束下的投影直觉: 更新后的点若跑出以原图为中心的方形区域, 就被拉回边界或内部。¹⁴

攻击算法的共同骨架

很多图像对抗攻击方法都可以看成同一个骨架: 定义一个攻击 loss, 选择一个扰动约束, 从原图开始沿梯度更新输入, 并在必要时把输入投影回允许区域。不同论文往往是在 loss、优化器、步长、投影方式或约束集合上做变化。

4.3 优化方法与约束方法可以分开理解

课程在这里提醒, 文献中的攻击算法看起来很多, 但差异常常落在两个位置: 一是优化方法不同, 例如普通梯度下降、动量方法或只走一步; 二是约束不同, 例如 L_2 、 L_∞ 或其他感知距离。把这两部分拆开看, 算法就不再显得杂乱。

例如, 使用同一个 targeted loss 时, 可以选择 L_∞ 约束, 也可以选择 L_2 约束; 使用同一个 L_∞ 约束时, 可以做多步投影梯度下降, 也可以做后面要讲的一步 FGSM。攻击方法的名字不同, 背后的问题结构仍然相同。

4.4 本章小结

对抗攻击可以用梯度下降直接优化输入。算法从原图 x^0 开始, 每一步根据 loss 对输入的梯度更新 x , 然后检查是否超过扰动预算。若超过, 就把输入投影回约束集合。这样做把“骗过模型”和

¹⁴ 视频画面时间区间: 00:25:15–00:25:30。

“看起来仍像原图”同时纳入迭代过程。许多攻击方法的差别，可以理解为优化步骤和约束集合的不同组合。

5 FGSM 与 iterative FGSM

Fast Gradient Sign Method, 简称 FGSM, 是课程在本讲重点介绍的第一个经典攻击方法。它的精神非常简单：既然一般方法要迭代更新输入，那 FGSM 就尝试只更新一次，用一次足够有方向性的扰动快速造成攻击。

5.1 一次更新的想法

FGSM 仍然从约束优化问题出发：

$$x^* = \arg \min_{d(x^0, x) \leq \epsilon} L(x).$$

符号含义如下：

x^* 攻击后图像。

$L(x)$ 攻击目标函数。

ϵ 最大允许扰动。

普通投影梯度下降会做 T 次更新；FGSM 把 T 改成 1。课程用“一击必杀”的直觉来解释它：只根据原图附近的梯度方向走一步，看看是否已经足以跨过模型决策边界。

哔哩哔哩

Attack Approach

$$x^* = \arg \min_{d(x^0, x) \leq \epsilon} L(x)$$

Fast Gradient Sign Method (FGSM)

<https://arxiv.org/abs/1412.6572>

Start from original image x^0

For $t = 1$ ~~to T~~

$$x^t \leftarrow x^{t-1} - \eta g$$



图 15: FGSM 的核心想法：把原本多次迭代的输入更新改为一次更新，希望一击就找到成功攻击图像。¹⁵

¹⁵ 视频画面时间区间：00:26:30–00:26:45。

5.2 为什么用 sign

在 L_∞ 约束下，我们关心的是每个像素最多可以改 ϵ 。如果只更新一次，并希望在允许范围内尽可能大地推动 loss，最直接的做法就是让每个坐标都沿梯度符号方向走到边界。

课程图中写成

$$g = \begin{bmatrix} \text{sign}\left(\frac{\partial L}{\partial x_1} \Big|_{x=x^{t-1}}\right) \\ \text{sign}\left(\frac{\partial L}{\partial x_2} \Big|_{x=x^{t-1}}\right) \\ \vdots \end{bmatrix}, \quad \text{sign}(t) = \begin{cases} 1, & t > 0, \\ -1, & t \leq 0. \end{cases}$$

符号含义如下：

g 梯度符号向量，每个坐标只保留正负方向。

$\frac{\partial L}{\partial x_i}$ loss 对第 i 个输入坐标的偏导。

$\text{sign}(\cdot)$ 符号函数，只输出 +1 或 -1。

网络安全攻防实验室 Bilibili

Attack Approach

$$x^* = \arg \min_{d(x^0, x) \leq \epsilon} L(x)$$

Fast Gradient Sign Method (FGSM)

<https://arxiv.org/abs/1412.6572>

Start from original image x^0


For $t = 1$ to T

$$x^t \leftarrow x^{t-1} - \eta g$$

ϵ

$$\begin{bmatrix} +1 \\ -1 \\ +1 \\ \vdots \end{bmatrix}$$

L -infinity



$$g = \begin{bmatrix} \pm 1 \cdot \text{sign}\left(\frac{\partial L}{\partial x_1} \Big|_{x=x^{t-1}}\right) \\ \pm 1 \cdot \text{sign}\left(\frac{\partial L}{\partial x_2} \Big|_{x=x^{t-1}}\right) \\ \vdots \end{bmatrix}$$

$\text{if } t > 0, \text{sign}(t) = 1; \text{otherwise, sign}(t) = -1$

图 16: FGSM 的 sign-gradient 形式：每个像素按 loss 梯度的正负方向移动，移动幅度由 epsilon 控制。¹⁶

若采用“增加分类 loss”的常见写法，FGSM 常被写成

$$x^{\text{adv}} = x^0 + \epsilon \text{sign}(\nabla_x J(\theta, x^0, y_{\text{true}})).$$

符号含义如下：

x^{adv} FGSM 生成的攻击图像。

¹⁶ 视频画面时间区间：00:28:15–00:28:30。

J 原分类任务的训练 loss，例如交叉熵。

θ 固定的模型参数。

y_{true} 原始正确标签。

ϵ 每个像素坐标允许的最大改变量。

这个式子和课程中“最小化攻击 loss”的写法方向可能看起来相反，是因为 $L(x)$ 的定义可以吸收正负号。关键不是记某一个符号，而是理解：FGSM 用输入梯度的符号决定每个像素该往哪边推，并一次性推到 L_∞ 预算边界。

5.3 Iterative FGSM

FGSM 只走一步，速度快，但可能不够强。Iterative FGSM 把一步拆成多步：每次走一个较小步长，再投影回 L_∞ 约束集合。它介于普通投影梯度下降和 FGSM 之间，仍然使用 sign-gradient，但不把全部预算一次用完。

可以写成：

$$x^{t+1} = \Pi_{B_\infty(x^0, \epsilon)} \left(x^t + \alpha \operatorname{sign}(\nabla_x J(\theta, x^t, y_{\text{true}})) \right).$$

符号含义如下：

α 每一步的攻击步长，通常小于 ϵ 。

$\Pi_{B_\infty(x^0, \epsilon)}$ 投影操作，把点投回以 x^0 为中心、半径为 ϵ 的 L_∞ 球。

$B_\infty(x^0, \epsilon)$ 所有满足 $\|x - x^0\|_\infty \leq \epsilon$ 的输入集合。

从几何上看，一步 FGSM 会直接把点推向 L_∞ 方框的某个角落；iterative FGSM 则可以多次观察梯度变化，逐步调整方向。因此它通常比单步 FGSM 更强，但也更慢，并且需要更多模型梯度访问。

5.4 White-box 与 black-box 的过渡

本讲最后出现 white-box v.s. black-box 的标题页。课程在这一页只做过渡：前面讲的攻击都默认我们知道网络参数，可以对输入求梯度，这属于 white-box attack。若攻击者不知道模型参数，只能观察输出或查询接口，就进入 black-box attack。下一讲会进一步讨论神经网络能否躲过人类更深的恶意。

White Box v.s. Black Box

- In the previous attack, we know the network parameters θ

$$\mathbf{g} = \begin{bmatrix} \text{sign}\left(\frac{\partial L}{\partial x_1} \Big|_{x=x^{t-1}}\right) \\ \text{sign}\left(\frac{\partial L}{\partial x_2} \Big|_{x=x^{t-1}}\right) \\ \vdots \end{bmatrix}$$



图 17: White-box 与 black-box 的过渡：本讲方法默认知道网络参数并能计算梯度，后续会讨论信息更少时的攻击。¹⁷

FGSM 的“快”来自强假设

FGSM 很快，是因为它假设能拿到模型梯度，并且用一次线性近似决定扰动方向。若模型不可见、梯度不可得，或 loss landscape 在原图附近非常非线性，单步 sign-gradient 的效果就可能下降，需要多步攻击、替代模型或查询式黑箱方法。

5.5 本章小结

FGSM 是把带约束输入优化压缩成一步的攻击方法。它在 L_∞ 约束下使用梯度符号，让每个像素沿能改变 loss 的方向移动 ϵ 。Iterative FGSM 则把一次大步改成多次小步，每步后投影回可行区域，通常攻击更强但成本更高。本讲的这些方法建立在 white-box 假设上，也就是攻击者知道模型并能取得梯度。

6 总结与延伸

P39 建立的是图像对抗攻击的基础框架。课程从真实世界部署中的恶意输入谈起，再用猫图攻击说明：神经网络的决策边界可能和人类感知不一致。对人眼来说几乎一样的两张图，模型可能给出完全不同的标签；而且攻击可以是 non-targeted，也可以是 targeted。

从数学上看，本讲把攻击写成一个带约束优化问题：

$$x^* = \arg \min_{d(x^0, x) \leq \epsilon} L(x).$$

¹⁷ 视频画面时间区间：00:29:30–00:29:45。

符号含义如下：

$L(x)$ 描述攻击目标的 loss，例如远离原类别或接近目标类别。

$d(x^0, x) \leq \epsilon$ 描述不可感知扰动的约束。

x^* 在攻击目标和扰动约束之间折中后得到的攻击输入。

这个式子是本讲最重要的压缩理解。它同时包含三件事：第一，模型参数固定，攻击更新输入；第二，攻击输入必须让模型输出偏离期望；第三，攻击输入不能离原图太远。后面的梯度下降、projection、FGSM 和 iterative FGSM 都是在这个式子上选择不同的求解方式。

本讲的核心压缩

对抗攻击不是魔法，而是输入空间中的约束优化。模型已经训练好，攻击者利用 loss 对输入的梯度，在人类不易察觉的扰动范围内移动图像，让模型输出跨过决策边界。

几个容易混淆的点值得特别记住：

- Non-targeted attack 只要求模型不要输出原类别；targeted attack 要求模型输出指定目标类别。
- L_2 与 L_∞ 都是感知相似性的近似，不是真正的人类视觉模型。
- 攻击时更新的是输入 x ，不是网络参数 θ 。
- Projection 的作用是维持不可感知约束，避免梯度更新把图像改得太远。
- FGSM 是单步 sign-gradient 攻击；iterative FGSM 是多步 sign-gradient 加投影。
- 本讲默认 white-box，即知道模型参数并能计算输入梯度。

6.1 和前后课程的连接

前一页 P38 讨论 NLP 上的 adversarial attack，核心难点来自离散 token 空间；P39 回到图像场景，核心优势是输入空间连续、可微，因而可以直接对输入做梯度优化。两者共同的问题是：怎样在“人类认为基本没变”的前提下，让模型输出发生显著变化。

下一讲自然会进入更复杂的设定。若攻击者不知道模型参数，如何进行 black-box attack？若防御者知道有攻击，能否通过 adversarial training、输入预处理、检测器或鲁棒模型设计抵御？这些问题都建立在本讲的基础上：先理解对抗样本如何被构造，才能讨论模型如何躲过它们。

6.2 本讲之后可以继续追问的问题

后续学习可以沿着三条线展开。第一，攻击更强：多步优化、动量、不同范数、不同目标函数能否提高成功率？第二，攻击更现实：不知道模型、查询次数有限、输入经过压缩或随机化时还能否攻击？第三，防御更可靠：模型是否真的学到了人类语义，还是只是在局部扰动上被训练得更平滑？

这些问题的共同底层仍然是本讲的那句式子：在约束集合里优化输入。只要这件事成立，模型鲁棒性就不能只靠标准测试准确率判断，而必须放到对抗环境中检验。