

来自人类的恶意攻击（下）：黑箱攻击与防御

Black-box Transferability, Physical Attacks, Backdoors, and Defense



基于李宏毅老师《机器学习 2025》课程内容整理
2026 年 6 月 9 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 46 分 33 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=40>

目录

1 从白箱攻击到黑箱攻击	3
1.1 白箱攻击依赖梯度	3
1.2 黑箱攻击的问题设定	4
1.3 Proxy network 与迁移攻击	5
1.4 本章小结	6
2 为什么黑箱攻击可以成功	6
2.1 迁移攻击结果表	6
2.2 Ensemble attack	7
2.3 共同边界的直觉	7
2.4 One-pixel attack	8
2.5 Universal adversarial attack	9
2.6 本章小结	10
3 攻击不只发生在图片里	11
3.1 语音与自然语言	11
3.2 物理世界攻击的额外约束	11
3.3 交通标志攻击	13
3.4 本章小结	15
4 更宽的攻击面: Reprogramming 与 Backdoor	15
4.1 Adversarial reprogramming	15
4.2 Backdoor 发生在训练阶段	16
4.3 本章小结	17
5 被动防御: 先处理输入	17
5.1 Smoothing	17
5.2 Image compression 与 generator	18
5.3 Randomization	19
5.4 本章小结	20
6 主动防御: Adversarial Training	21
6.1 把攻击样本加入训练	21
6.2 为什么它像 data augmentation	22
6.3 局限: 能否挡住新攻击	22
6.4 本章小结	22
7 总结与延伸	22
7.1 后续问题	24

1 从白箱攻击到黑箱攻击

P39 讲过 FGSM 和 iterative FGSM。那些方法默认攻击者知道模型参数，并且能对输入计算梯度。本讲从这个假设开始追问：如果模型部署在网络服务中，参数没有公开，攻击者只能看到输入输出，那么攻击是否就不可能了？答案是否定的。黑箱攻击不仅可能，而且在许多情况下相当有效。

1.1 白箱攻击依赖梯度

白箱攻击的关键是知道网络参数。以 FGSM 为例，攻击者需要计算 loss 对输入坐标的偏导，再取符号方向，把扰动加到图片上。若没有参数，就不能直接反向传播得到这个梯度。




图 1: 白箱攻击的前提: FGSM 需要知道模型参数, 才能计算 loss 对输入的梯度并生成扰动。¹

用公式写, 白箱攻击常见的一步扰动是:

$$x^{\text{adv}} = x + \epsilon \text{sign}(\nabla_x L(f_\theta(x), y)).$$

符号含义如下:

x 原始输入图片。

x^{adv} 攻击后输入。

ϵ 扰动预算。

f_θ 参数为 θ 的目标模型。

L 攻击或分类 loss。

$\nabla_x L$ loss 对输入图片的梯度。

¹ 视频画面时间区间: 00:00:30–00:00:45。

这里 θ 必须可用，否则无法直接计算 $\nabla_x L$ 。这也是很多人一开始会有的直觉：只要不公开模型参数，攻击者就不能做 FGSM，系统似乎就安全了。

1.2 黑箱攻击的问题设定

黑箱攻击正是针对“参数不可得”的情境。攻击者可能只能调用 API，知道模型会返回类别、分数或排名，却不知道网络结构、训练资料和参数。课程用线上模型和作业评测系统做类比：你知道有一个模型在做判断，但不知道助教或服务端到底用了哪一个架构。

White Box v.s. Black Box

- In the previous attack, we know the network parameters θ
 - This is called **White Box Attack**.
- You cannot obtain model parameters in most online API.
- Are we safe if we do not release model? ☺
- No, because **Black Box Attack** is possible. ☹

$$g = \begin{bmatrix} \text{sign}\left(\frac{\partial L}{\partial x_1} \Big|_{x=x^{t-1}}\right) \\ \text{sign}\left(\frac{\partial L}{\partial x_2} \Big|_{x=x^{t-1}}\right) \\ \vdots \end{bmatrix}$$


图 2: 黑箱攻击问题：攻击者拿不到线上模型参数，但仍然希望构造能骗过目标模型的输入。²

黑箱设定可以概括为：

$$\text{known: } x, f_{\text{target}}(x) \quad \text{unknown: } \theta_{\text{target}}, \nabla_x L(f_{\theta_{\text{target}}}(x), y).$$

符号含义如下：

f_{target} 被攻击的目标模型。

θ_{target} 目标模型参数，攻击者无法取得。

$f_{\text{target}}(x)$ 查询输入后观察到的输出。

$\nabla_x L$ 白箱攻击需要但黑箱攻击拿不到的梯度。

黑箱攻击的难点不是攻击目标消失了，而是优化资讯变少了。攻击者仍然想找 x^{adv} ，只是不能直接使用目标模型的梯度。

² 视频画面时间区间：00:01:45–00:02:00。

1.3 Proxy network 与迁移攻击

课程介绍的第一个黑箱方法是训练一个 proxy network。若攻击者拥有目标任务的训练资料，或者能收集到相似资料，就可以自己训练一个替代模型。然后攻击者不攻击目标模型，而是对白箱可见的 proxy model 做攻击，再把生成的 attacked object 拿去测试目标模型。

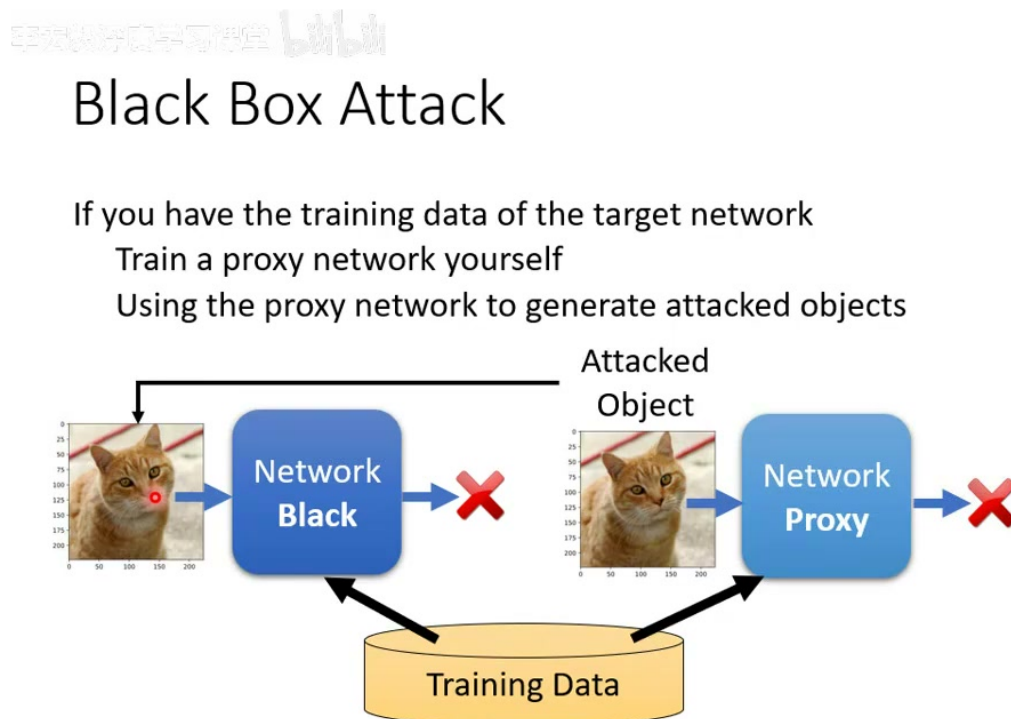


图 3: Proxy network 思路：先训练一个替代模型，在替代模型上生成攻击样本，再把攻击样本送到目标黑箱模型。³

可以写成：

$$\tilde{x} = A(\tilde{f}, x, y), \quad \text{test whether } f_{\text{target}}(\tilde{x}) \text{ is fooled.}$$

符号含义如下：

$\tilde{f}$ 攻击者自己训练的 proxy model。

A 白箱攻击算法，例如 FGSM 或 iterative FGSM。

$\tilde{x}$ 在 proxy model 上生成的攻击样本。

f_{target} 真正要攻击的黑箱模型。

这种做法的核心现象叫 transferability。也就是说，一个模型上生成的对抗样本，可能迁移到另一个模型上仍然有效。若 proxy 与 target 训练资料、任务或架构相近，迁移成功率往往更高。

黑箱攻击的第一层惊讶

不公开参数并不等于安全。只要攻击样本能在模型之间迁移，攻击者就可以绕过“拿不到目标梯度”的限制：先攻击自己训练的 proxy，再把结果拿去攻击目标模型。

³ 视频画面时间区间：00:03:00–00:03:15。

1.4 本章小结

白箱攻击依赖模型参数和输入梯度；黑箱攻击拿不到这些资讯，但仍然可以利用 proxy network。迁移攻击把“攻击目标模型”改写成“攻击一个相似模型，再利用对抗样本的迁移性”。这说明安全不能只依赖隐藏参数，因为模型之间可能共享相似的脆弱方向。

2 为什么黑箱攻击可以成功

课程接着用文献结果和决策边界图解释 transferability。不同神经网络虽然架构不同，但它们在同一个任务上训练，学到的特征和局部决策边界可能有相似之处。于是，在一个网络上能造成错误的方向，到了另一个网络上也可能仍然接近有效方向。

2.1 迁移攻击结果表

课程展示的表格来自黑箱攻击文献。横轴是被攻击的目标模型，纵轴是 proxy model。表中数字是攻击后的 accuracy，数字越低表示攻击越成功。对角线是白箱攻击，因为 proxy 和 target 是同一个模型；非对角线是黑箱迁移攻击。

Black Box Attack <https://arxiv.org/pdf/1611.02770.pdf>

		Be Attacked				
Proxy		ResNet-152	ResNet-101	ResNet-50	VGG-16	GoogLeNet
	ResNet-152	0%	13%	18%	19%	11%
	ResNet-101	19%	0%	21%	21%	12%
	ResNet-50	23%	20%	0%	21%	18%
	VGG-16	22%	17%	17%	0%	5%
	GoogLeNet	39%	38%	34%	19%	0%

(lower accuracy → more successful attack)

图 4: 迁移攻击结果表：proxy 与目标模型不同也能攻击成功，表中 accuracy 越低代表攻击越有效。

表格的重点不在某一个具体百分比，而在非对角线仍然很低。换句话说，即使攻击者不知道目标模型，只用另一个网络当 proxy，也可能显著降低目标模型准确率。课程特别提醒，若直接用相同模型攻击，相当于白箱攻击，成功率自然很高；真正值得注意的是不同模型之间的迁移。

⁴ 视频画面时间区间：00:04:45–00:05:00。

2.2 Ensemble attack

如果攻击者不知道目标模型是哪一个，可以更进一步：同时攻击多个 proxy model。攻击者构造一个样本，让它在多个替代网络上都能成功，再拿去攻击目标模型。这样的攻击往往比只依赖单一 proxy 更稳，因为它寻找的是多个模型共同脆弱的方向。



Black Box Attack

<https://arxiv.org/pdf/1611.02770.pdf>

Be Attacked

	ResNet-152	ResNet-101	ResNet-50	VGG-16	GoogLeNet
ResNet-152	0%	13%	18%	19%	11%
ResNet-101	19%	0%	21%	21%	12%
ResNet-50	23%	20%	0%	21%	18%
VGG-16	22%	17%	17%	0%	5%
GoogLeNet	39%	38%	34%	19%	0%

(lower accuracy → more successful attack)

Ensemble Attack

	ResNet-152	ResNet-101	ResNet-50	VGG-16	GoogLeNet
-ResNet-152	0%	0%	0%	0%	0%
-ResNet-101	0%	1%	0%	0%	0%
-ResNet-50	0%	0%	2%	0%	0%
-VGG-16	0%	0%	0%	6%	0%
-GoogLeNet	0%	0%	0%	0%	5%

图 5: Ensemble attack: 同时攻击多个 proxy model, 寻找能跨模型迁移的共同脆弱方向。⁵

一个简单的 ensemble loss 可以写成:

$$L_{\text{ens}}(x) = \sum_{m=1}^M \alpha_m L_m(x).$$

符号含义如下:

M proxy model 的数量。

L_m 第 m 个 proxy model 上的攻击 loss。

α_m 第 m 个 proxy 的权重。

L_{ens} 多模型合并后的攻击目标。

最小化或最大化这个 ensemble loss 时, 攻击方向不再只服务于某一个模型, 而是服务于一组模型。若目标黑箱模型也学到了类似特征, 它被攻击成功的概率就会提高。

2.3 共同边界的直觉

课程用二维示意图解释为什么攻击可能这么容易。图中多个网络在同一张输入附近的决策区域并不完全相同, 但某些方向是类似的。随机方向移动时, 各个网络仍可能保持原类别; 但沿着能攻击

⁵ 视频画面时间区间: 00:08:00-00:08:15。

VGG-16 的方向移动，也可能靠近其他网络的错误区域。



The attack is so easy! Why?




图 6: 迁移性的决策边界直觉: 不同模型的局部边界可能方向相近, 使一个模型上的攻击方向迁移到其他模型。⁶

这并不意味着所有网络决策边界都一样, 而是说它们在高维输入空间里可能共享一些非鲁棒特征。若多个模型都依赖这些特征, 攻击者只需找到能破坏这些特征的扰动, 就能跨模型生效。

Transferability 的本质

迁移性来自模型之间的共同归纳偏好。相同任务、相似数据和相近训练目标会让不同模型学到部分相似特征。对抗扰动如果打中了这些共享特征, 就不只会骗过一个模型。

2.4 One-pixel attack

课程还介绍了 one-pixel attack。它看起来更极端: 只改一个像素, 也可能让影像辨识系统发生错误。这个例子用来说明, 模型对输入空间中某些局部变化可能异常敏感。不过课程也指出, one-pixel attack 造成的错误有时不像猫变成海星那样荒谬, 可能只是把图像推向视觉上仍有些关联的类别。

⁶ 视频画面时间区间: 00:11:00-00:11:15。

One pixel attack

Source of image:

<https://arxiv.org/abs/1710.08864>



Video: <https://youtu.be/tfpKIZIWidA>



图 7: One-pixel attack 示例：只改变单个像素，也可能显著改变影像辨识系统输出。⁷

One-pixel attack 的价值不只是攻击强度，而是提醒我们：模型的脆弱性不一定需要大面积扰动。即使扰动维度非常小，只要方向正好击中模型的敏感区域，也可能造成输出变化。

2.5 Universal adversarial attack

更强的概念是 universal adversarial attack。前面大多数攻击都是针对单张图定制化扰动：每张图片都有自己的 attack signal。Universal attack 则希望找到一个通用扰动，把同一个扰动加到很多不同图片上，都能让模型犯错。

⁷ 视频画面时间区间：00:14:15–00:14:30。



Black Box Attack is also possible!

图 8: Universal adversarial attack: 同一个扰动加到许多不同图片上, 都可能让模型输出错误。⁸

可以写成:

$$\Pr_{x \sim \mathcal{D}} [f(x + \delta) \neq f(x)] \geq \rho, \quad \|\delta\| \leq \epsilon.$$

符号含义如下:

δ 通用扰动, 同一份扰动用于许多输入。

$\mathcal{D}$ 输入图片分布。

ρ 期望达到的攻击成功率阈值。

ϵ 通用扰动的大小限制。

Universal attack 的威胁更高, 因为它不像单图攻击那样需要为每个输入重新优化。若同一个扰动能反复使用, 攻击成本会显著下降, 也更接近真实攻击者可能采用的批量策略。

2.6 本章小结

黑箱攻击成功的关键是迁移性。单一 proxy 可以迁移, 多个 proxy 的 ensemble attack 往往更稳。决策边界图说明, 不同模型可能共享部分脆弱方向。One-pixel attack 和 universal attack 则进一步提醒我们, 扰动可以很小, 也可以高度通用。模型看似复杂, 但在某些高维方向上可能仍然非常脆弱。

⁸ 视频画面时间区间: 00:15:15–00:15:30。

3 攻击不只发生在图片里

课程随后把视野扩展到图像以外和物理世界。对抗攻击不是计算机视觉独有的问题，只要模型输入可以被有目的地修改，语音、文字、传感器读数、真实世界物体都可能成为攻击面。

3.1 语音与自然语言

课程用“Beyond Images”提醒：语音处理和自然语言处理也有对抗攻击。例如一个检测合成语音的系统，原本能判断某段声音是机器合成；若在声音中加入人耳不易察觉的微小噪声，检测系统就可能误判。NLP 中也存在类似现象，只是扰动发生在 token、词、字符或句子层面。



图 9: Beyond Images：对抗攻击也会出现在语音处理与自然语言处理任务中，而不只存在于图像分类。⁹

图像、语音和文字的共同点是，模型输入与人类感知之间存在差距。图像中是像素范数和视觉语义的差距；语音中是波形扰动和听觉感知的差距；文字中是离散符号变化和语义保持之间的差距。攻击者利用这些差距，让模型看到和人类不同的东西。

3.2 物理世界攻击的额外约束

虚拟图像攻击只需要让数字图像变坏；物理世界攻击更难，因为扰动必须经过真实世界的拍摄、打印、光照、距离、角度和相机解析度。课程举的第一类例子是对人脸辨识系统的攻击：设计一副特殊眼镜，让人戴上后被模型误认为其他身份。

⁹视频画面时间区间：00:17:45–00:18:00。

Attack in the Physical World




图 10: 物理世界中的人脸辨识攻击: 攻击扰动被做成可佩戴眼镜, 目标是骗过真实拍摄条件下的人脸模型。¹⁰

这类攻击要考虑三个问题。第一, 扰动不能只对单张照片有效, 而要在不同角度、距离和表情下仍然有效。第二, 相邻像素之间特别剧烈的变化未必能被相机准确捕捉。第三, 扰动必须能被现实材料复现, 例如打印机能否打印出那些颜色。

¹⁰ 视频画面时间区间: 00:21:00–00:21:15。

Attack in the Physical World



- An attacker would need to find perturbations that generalize beyond a single image.
- Extreme differences between adjacent pixels in the perturbation are unlikely to be accurately captured by cameras.
- It is desirable to craft perturbations that are comprised mostly of colors reproducible by the printer.

图 11: 物理攻击需要考虑可制造性、相机解析度和跨拍摄条件泛化, 不能只在一张数字图片上成功。¹¹

可以把物理攻击写成期望形式:

$$\arg \max_{\delta \in \mathcal{S}} \mathbb{E}_{t \sim \mathcal{T}} [L(f(t(x, \delta)), y_{\text{target}})].$$

符号含义如下:

δ 实体扰动, 例如眼镜图案或贴纸。

$\mathcal{S}$ 可制造、可打印、可佩戴的扰动集合。

$\mathcal{T}$ 光照、角度、距离、相机等真实变化分布。

$t(x, \delta)$ 扰动经过真实拍摄条件后的输入。

y_{target} 攻击者希望模型输出的目标。

这个式子强调: 物理攻击不是只优化一个干净输入, 而是优化经过许多真实变换后的平均效果。能在数字空间成功的扰动, 未必能穿过真实世界这层噪声。

3.3 交通标志攻击

课程还展示了交通标志攻击。相比把整张牌大幅改造, 更隐蔽的攻击是只做很小的形状改变, 例如把限速 35 的数字局部拉长, 让自动驾驶系统或辅助驾驶模型读成更高速度。

¹¹ 视频画面时间区间: 00:23:30–00:23:45。

Attack in the Physical World



read as an 85-mph sign

https://youtu.be/4uGV_frj0UA

<https://www.mcafee.com/blogs/other-blogs/mcafee-labs/model-hacking-adas-to-pave-safer-roads-for-autonomous-vehicles/>

图 12: 交通标志上的隐蔽攻击: 通过很小的形状改动, 让限速标志被模型读成另一种速度。¹²

Attack in the Physical World



read as an 85-mph sign

https://youtu.be/4uGV_frj0UA

<https://www.mcafee.com/blogs/other-blogs/mcafee-labs/model-hacking-adas-to-pave-safer-roads-for-autonomous-vehicles/>

图 13: 交通标志攻击的车载演示: 模型把被改动的限速牌读成更高速度, 导致车辆行为发生风险。¹³

¹² 视频画面时间区间: 00:25:15-00:25:30。

这类例子说明，对抗攻击一旦进入物理世界，风险就不只停留在分类准确率。模型输出可能连接到真实动作，例如开门、识别身份、刹车或加速。因此，安全评估必须把“模型是否会被数字扰动骗过”和“扰动是否能在真实世界复现”一起考虑。

3.4 本章小结

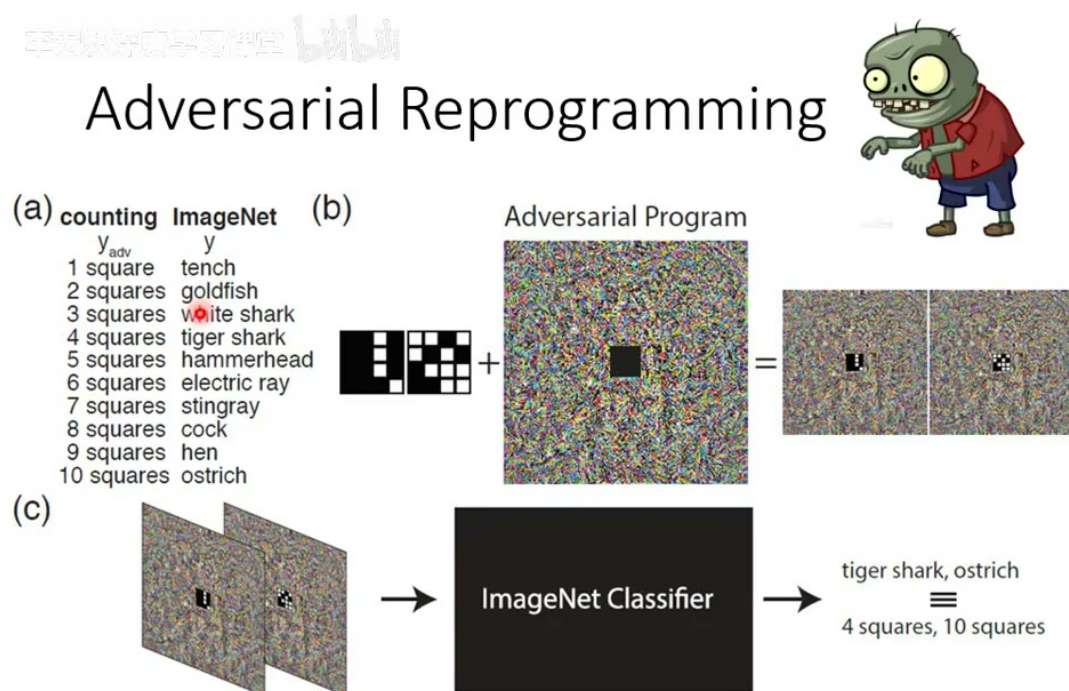
对抗攻击可以超越图像，进入语音、文字和物理世界。物理攻击比数字攻击更难，因为扰动要通过现实世界的变换和制造限制；但它的风险也更直接，因为模型输出可能影响真实行为。眼镜、交通标志等例子说明，对抗攻击不是实验室里的奇技淫巧，而是部署系统必须面对的安全问题。

4 更宽的攻击面：Reprogramming 与 Backdoor

前面的攻击大多发生在测试阶段：模型已经训练好，攻击者改输入，让模型输出错误。课程接着介绍两个更宽的攻击面：adversarial reprogramming 和 backdoor。它们提醒我们，攻击不一定只是“给一张图加噪声”，也可能是重用模型、污染训练资料或让模型内部留下触发机制。

4.1 Adversarial reprogramming

Adversarial reprogramming 的想法很特别：不训练一个新模型，而是把既有模型当成一个可被“重新编程”的系统。攻击者设计一个 adversarial program，把原本的任务输入嵌入到一张特殊图像中，让已经训练好的 ImageNet 分类器输出可被解释成另一个任务的答案。



<https://arxiv.org/abs/1806.11146>

图 14: Adversarial reprogramming: 把新任务输入嵌入到特殊扰动中，借用既有 ImageNet 分类器完成另一种任务。¹⁴

¹³ 视频画面时间区间：00:26:15–00:26:30。

¹⁴ 视频画面时间区间：00:28:00–00:28:15。

它的形式可以抽象成：

$$z = P_\phi(u), \quad \hat{a} = R(f(z)).$$

符号含义如下：

u 原本任务的输入，例如一个计数任务图像。

P_ϕ 攻击者学习出的 adversarial program，把 u 嵌入到目标模型可接受的输入格式中。

f 已训练好的原始模型，例如 ImageNet classifier。

R 把原模型输出重新映射成新任务答案的规则。

$\hat{a}$ 新任务的预测答案。

这和普通对抗样本不完全一样。普通攻击是让模型对原任务出错；reprogramming 则试图把模型的能力挪作他用。它显示出大模型或预训练模型可能有意想不到的可复用性，也可能被构造输入引导到非原定用途。

4.2 Backdoor 发生在训练阶段

Backdoor attack 则把攻击提前到训练阶段。攻击者在训练数据里加入少量带触发器的样本，并把它们标成攻击者指定的类别。模型训练完成后，正常输入表现看起来没问题；但只要测试输入带有触发器，就会被模型输出成指定类别。



“Backdoor” in Model

<https://arxiv.org/abs/1804.00792>

- Attack happens at the training phase




图 15: Backdoor attack: 训练资料中混入带触发器且标成目标类别的样本，模型训练后会在测试时对触发器产生指定误判。¹⁵

可以写成：

¹⁵ 视频画面时间区间：00:30:45–00:31:00。

$$\mathcal{D}' = \mathcal{D} \cup \{(T(x_i), y_{\text{target}})\}_{i=1}^K.$$

符号含义如下：

$\mathcal{D}$ 原始干净训练资料。

$T(x_i)$ 对样本 x_i 加上触发器后的输入。

y_{target} 攻击者指定的目标标签。

K 被投毒的样本数量。

$\mathcal{D}'$ 被污染后的训练资料。

Backdoor 的危险在于隐蔽性。模型在普通测试集上可能仍然准确，因此很难从标准 accuracy 发现问题；只有当输入带有特定触发器时，模型才会进入攻击者想要的错误行为。

测试时攻击与训练时攻击不同

测试时攻击修改的是部署后的输入；backdoor 修改的是训练资料或训练流程。前者考验模型局部鲁棒性，后者考验数据来源、供应链和训练过程可信度。只检查测试准确率不足以发现训练阶段后门。

4.3 本章小结

Adversarial reprogramming 和 backdoor 展示了更宽的攻击面。Reprogramming 借用既有模型完成非原定任务；backdoor 则通过训练资料污染，让模型在触发器出现时执行指定错误。它们都说明，对抗安全不能只盯着像素扰动，还要关心模型用途、数据来源和训练流程。

5 被动防御：先处理输入

课程后半转向 defense。防御可以粗略分成 passive defense 和 proactive defense。被动防御不改变模型训练方式，而是在输入进入模型前做处理，希望削弱或移除攻击信号。主动防御则在训练阶段就把攻击纳入考虑。

5.1 Smoothing

最简单的被动防御之一是 smoothing。对抗扰动往往是高频、细小、分散的信号；图像平滑可以削弱这类信号。课程展示的例子中，原本被攻击成 Keyboard 的图像经过 smoothing 后，模型又回到 tiger cat。




图 16: Smoothing 作为被动防御：模糊化输入可能削弱攻击信号，使模型输出回到原类别附近。¹⁶

被动防御可以写成：

$$\hat{y} = f(h(x)).$$

符号含义如下：

x 原始输入，可能已经被攻击。

h 输入预处理函数，例如 smoothing、compression 或 denoising。

f 原本的分类模型。

$\hat{y}$ 预处理后得到的模型输出。

这个方法直观、便宜，也常常有效。但它有副作用：平滑不仅会去掉攻击噪声，也可能去掉图像中对分类有用的细节。课程中也提醒，平滑之后正确类别的置信度可能下降。

5.2 Image compression 与 generator

另一类被动防御是压缩或重建。图像压缩会丢掉一些细节，微小攻击噪声可能随之消失。Generator 方法则试图把输入重新生成一遍，让生成器保留主要语义，却不复现攻击扰动。

¹⁶视频画面时间区间：00:34:30-00:34:45。

Passive Defense

Image Compression



<https://arxiv.org/abs/1704.01155>
<https://arxiv.org/abs/1802.06816>

Generator

<https://arxiv.org/abs/1805.06605>




图 17: Image compression 与 generator 防御：通过压缩或重建输入，尝试移除微小攻击扰动。¹⁷

Generator 防御的理想形式是：

$$x_{\text{clean}} \approx G(E(x_{\text{adv}})), \quad f(x_{\text{clean}}) \approx f(x^0).$$

符号含义如下：

x_{adv} 攻击输入。

E 将输入映射到潜在表示或内部条件的过程。

G 生成器或重建模型。

x_{clean} 经过重建后的输入。

x^0 原始干净输入。

这类方法的希望是：生成器学到自然图像流形，攻击噪声不在自然流形上，因此重建时会被去除。问题是，如果攻击者知道防御流程，也可以把预处理一起纳入攻击优化。

5.3 Randomization

被动防御还可以引入随机性，例如随机缩放、随机 padding，再随机选择一种变换后的图片送入 CNN。攻击者若不知道具体随机结果，构造稳定攻击会更难。

¹⁷ 视频画面时间区间：00:36:45–00:37:00。

Passive Defense - Randomization




图 18: Randomization 防御：对输入做随机缩放和随机 padding，让攻击者难以精确适配固定预处理流程。¹⁸

随机防御可以表示为：

$$\hat{y} = f(h_r(x)), \quad r \sim \mathcal{R}.$$

符号含义如下：

r 随机种子或随机变换选择。

$\mathcal{R}$ 随机变换分布。

h_r 由 r 决定的预处理函数。

但课程指出，随机防御也不是根本解决。若攻击者知道随机分布，可以对随机性取期望，构造在平均意义下仍然有效的攻击。也就是说，随机性增加攻击成本，却不必然提供安全保证。

被动防御的共同弱点

被动防御常把攻击信号当成噪声去除，但攻击者可以把防御流程也看成模型的一部分。如果预处理可微、可估计或分布可知，攻击就可能绕过它。防御方法不能只在弱攻击下有效，还要在知道防御细节的强攻击者面前评估。

5.4 本章小结

被动防御通过处理输入来削弱攻击，包括 smoothing、compression、generator 重建和 randomization。它们的优点是容易加到既有系统前面，缺点是可能损伤正常输入，也可能被自适应攻击绕过。被动防御更像临时缓冲层，而不是彻底解决模型脆弱性的办法。

¹⁸ 视频画面时间区间：00:37:45–00:38:00。

6 主动防御: Adversarial Training

主动防御的代表是 adversarial training。它不只是把输入处理一下，而是在训练阶段主动生成对抗样本，把模型的弱点加入训练资料，让模型学会抵抗这些攻击。

6.1 把攻击样本加入训练

课程中的流程是：给定训练集，先训练模型；然后对训练样本生成 adversarial input；再把原始样本和 adversarial input 放在一起更新模型。这本质上是一种 data augmentation，只是增强出来的样本不是随机裁切或翻转，而是针对当前模型弱点构造的。



Proactive Defense

Adversarial Training

Training a model that is robust to adversarial attack.

Given training set $\mathcal{X} = \{(\mathbf{x}^1, \hat{y}^1), (\mathbf{x}^2, \hat{y}^2), \dots, (\mathbf{x}^N, \hat{y}^N)\}$

Using $\mathcal{X}$ to train your model

For $n = 1$ to N

Find adversarial input $\tilde{\mathbf{x}}^n$ given $\mathbf{x}^n$ by an attack algorithm

We have new training data

$$\mathcal{X}' = \{(\tilde{\mathbf{x}}^1, \hat{y}^1), (\tilde{\mathbf{x}}^2, \hat{y}^2), \dots, (\tilde{\mathbf{x}}^N, \hat{y}^N)\}$$

Using both $\mathcal{X}$ and $\mathcal{X}'$ to update your model

Find the problem

图 19: Adversarial training: 对训练样本生成 adversarial input，再把原始样本和攻击样本一起用于更新模型。¹⁹

标准形式常写成 min-max 优化：

$$\min_{\theta} \sum_{i=1}^N \max_{\|\delta_i\| \leq \epsilon} \ell(f_{\theta}(x_i + \delta_i), y_i).$$

符号含义如下：

θ 模型参数。

(x_i, y_i) 第 i 个训练样本与标签。

δ_i 针对样本 x_i 生成的扰动。

ϵ 扰动预算。

¹⁹ 视频画面时间区间：00:42:30–00:42:45。

ℓ 训练 loss，例如交叉熵。

内层最大化负责“找问题”：在扰动范围内找到让模型最容易犯错的输入。外层最小化负责“修问题”：更新模型参数，使模型在这些困难输入上也表现好。

6.2 为什么它像 data augmentation

普通 data augmentation 通过平移、裁切、翻转等方式扩充训练集，让模型对自然变化更稳健。Adversarial training 也是扩充训练集，只是扩充方式由攻击算法决定。它有针对性地加入模型当前最怕的样本，迫使模型在决策边界附近变得更平滑。

课程图中用新训练资料 $\mathcal{X}'$ 表示由对抗样本组成的数据集，再用 $\mathcal{X}$ 和 $\mathcal{X}'$ 一起更新模型。这个过程可以反复迭代：模型更新后，攻击者再找新的弱点；再把新的对抗样本加入训练。

6.3 局限：能否挡住新攻击

课程特别提出一个问题：adversarial training 能不能应对新的攻击算法？如果训练时只见过某一种攻击，模型可能只对这种攻击变强；当攻击方法改变，新的脆弱方向仍然可能出现。因此，adversarial training 的效果依赖于内层攻击是否足够强、是否覆盖了真正危险的扰动集合。

Adversarial training 的核心矛盾

它是目前最重要的主动防御思想之一，但成本很高，而且防御范围受训练时攻击算法限制。训练越强，计算越贵；攻击集合定义越窄，模型越可能只学会防某几种已知攻击。

6.4 本章小结

Adversarial training 把攻击纳入训练流程，用对抗样本扩充训练集。它比被动防御更主动，因为模型本身会学习在攻击输入上保持正确。其核心形式是 min-max 优化：内层找最坏扰动，外层训练模型抵抗扰动。它的限制是计算成本高，并且未必能覆盖未来出现的新攻击。

7 总结与延伸

P40 的主线是：攻击者的能力不必局限在白箱、数字图片和测试阶段；防御者也不能只依赖隐藏参数或简单预处理。课程先说明，不知道目标模型参数时仍然可以做 black-box attack，因为对抗样本可以在模型之间迁移。Proxy network、ensemble attack 和 shared boundary 的直觉共同说明：不同模型可能共享某些脆弱特征。

随后，课程把攻击范围扩展到 one-pixel、universal perturbation、语音、NLP 和物理世界。物理攻击特别重要，因为它要求扰动经过真实拍摄和制造约束后仍然有效，也因为可能影响真实系统行为。再往后，adversarial reprogramming 和 backdoor 说明攻击面不只在测试输入，也可能在模型用途和训练资料中。




图 20: 课程总结: 已知参数时攻击很容易, 黑箱攻击也可能成功; 防御包括被动和主动两类, 攻防方法仍在持续演化。²⁰

防御部分给出两个层次。Passive defense 先处理输入, 例如 smoothing、compression、generator 和 randomization; 它们容易部署, 但可能被自适应攻击绕过。Proactive defense 则以 adversarial training 为代表, 把攻击样本加入训练, 让模型主动学习鲁棒性。两者都不是一劳永逸, 因为攻击者会根据防御继续调整方法。

本讲的核心压缩

隐藏参数、过滤输入、随机预处理都只能提高攻击成本, 不能自动带来安全。对抗攻防是一场不断变化的博弈: 攻击者寻找模型共享弱点, 防御者必须假设攻击者会观察、适应并绕过当前防线。

几个关键 takeaway 如下:

- Black-box attack 可以通过 proxy network 和 transferability 实现。
- Ensemble attack 寻找多个模型共同脆弱方向, 迁移性通常更强。
- Universal perturbation 显示同一扰动可能影响大量输入。
- Physical attack 要考虑光照、角度、相机解析度和可制造性。
- Backdoor attack 发生在训练阶段, 标准测试准确率未必能发现。
- Passive defense 容易部署, 但容易被自适应攻击纳入优化。
- Adversarial training 是主动防御, 但成本高, 且依赖训练时攻击覆盖面。

²⁰视频画面时间区间: 00:46:15–00:46:30。

7.1 后续问题

本讲最后强调，攻击与防御仍在演化。后续可以继续追问：如何定义真正接近人类感知的扰动集合？如何评估一个防御是否抵抗自适应攻击？如何在大模型、语音、文本和多模态系统中做鲁棒性测试？如何检查训练资料和供应链中的 backdoor 风险？这些问题都没有简单答案，但它们共同说明，机器学习系统一旦进入真实世界，就必须把恶意输入视为基本环境，而不是边缘案例。