

领域自适应概述

Domain Shift, Domain Adaptation, Domain Adversarial
Training, and Generalization



基于李宏毅老师《机器学习 2025》课程内容整理
2026 年 6 月 9 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 34 分 32 秒


链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=44>

目录

1	Domain Shift: 训练分布与测试分布不一样	3
1.1	一个数字识别例子	3
1.2	Domain adaptation 要解决什么	4
1.3	不同类型的分布变化	5
1.4	本章小结	6
2	Domain Adaptation 的问题设定	6
2.1	Source labeled 与 target limited labeled	7
2.2	Unsupervised domain adaptation	8
2.3	与 transfer learning 的区别	9
2.4	本章小结	9
3	基本想法: 学到 Domain-Invariant Features	9
3.1	什么是 domain-invariant feature	10
3.2	忽略域差异, 而不是忽略类别	10
3.3	本章小结	11
4	Domain Adversarial Training	11
4.1	Label predictor: 保留分类能力	11
4.2	Domain classifier: 判断 feature 来自哪里	12
4.3	Feature extractor: 骗过 domain classifier	12
4.4	Gradient reversal layer	14
4.5	实验结果	15
4.6	本章小结	16
5	限制: 对齐分布不一定对齐类别	16
5.1	Marginal alignment 的风险	17
5.2	Decision boundary 的重要性	18
5.3	本章小结	19
6	Outlook: 更复杂的领域自适应与泛化	20
6.1	Closed-set、partial 与 open-set	20
6.2	Universal domain adaptation	20
6.3	Domain generalization	21
6.4	本章小结	22
7	总结与延伸	22

1 Domain Shift: 训练分布与测试分布不一样

前面的机器学习课程大多默认训练资料和测试资料来自同一个分布。我们在训练集上学一个分类器，期望它能泛化到测试集；只要模型容量、正则化和训练策略合适，这个假设通常已经足够。但现实系统经常遇到另一种情况：训练时看到的是一种资料，部署时遇到的是另一种资料。这个差异就是 domain shift。



The results are from: <http://proceedings.mlr.press/v37/ganin15.pdf>

图 1: 常规监督学习默认训练资料和测试资料来自相同或相近分布，因此训练好的分类器可以直接用于测试。¹


1.1 一个数字识别例子

课程用数字识别做直观例子。若模型只在黑白手写数字上训练，然后测试时仍是类似的黑白数字，准确率可以很高。但若测试资料变成彩色背景、不同风格或不同域的数字，模型可能突然掉点。它并不是完全不会识别数字，而是学到的特征和新域中的干扰因素纠缠在一起。

¹视频画面时间区间：00:00:45–00:01:00。



You have learned a lot about ML. Training a classifier is not a big deal for you. 😊



The results are from: <http://proceedings.mlr.press/v37/ganin15.pdf>

Domain shift: Training and testing data have different distributions.

图 2: 同一个数字识别任务中, 训练域是黑白数字, 测试域变成彩色数字后, 准确率明显下降。²

用分布语言写, 常规监督学习希望:

$$P_{\text{train}}(x, y) \approx P_{\text{test}}(x, y).$$

Domain shift 则意味着:

$$P_s(x, y) \neq P_t(x, y),$$

其中 s 表示 source domain, t 表示 target domain。目标不是换一个任务, 而是在同一个任务下, 让模型从 source domain 迁移到 target domain。


1.2 Domain adaptation 要解决什么

若什么都不做, 直接把 source model 拿去 target domain 上测试, 表现可能很差。Domain adaptation 的问题就是: 能不能利用 source domain 的标注资料, 以及 target domain 中有限的资料, 让模型在 target domain 上表现得比直接迁移更好?

²视频画面时间区间: 00:02:00-00:02:15。



You have learned a lot about ML. Training a classifier is not a big deal for you. 😊



The results are from: <http://proceedings.mlr.press/v37/ganin15.pdf>

Domain shift: Training and testing data have different distributions.



Domain adaptation

Transfer learning: <https://youtu.be/qD6iD4TFsdQ>

图 3: 当训练域和测试域不同, 直接迁移会失败; domain adaptation 尝试利用目标域资料修正这种落差。³

最典型的设定是:

$$\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}, \quad \mathcal{D}_t^u = \{x_j^t\}_{j=1}^{n_t},$$

source domain 有大量 labeled data, target domain 有大量 unlabeled data, 甚至只有少量 labeled data。真正想最小化的是 target risk:

$$R_t(h) = \mathbb{E}_{(x,y) \sim P_t} [\ell(h(x), y)],$$

但 target label 很少, 所以不能直接在目标域完整监督训练。

1.3 不同类型的分布变化

Domain shift 不只可能发生在输入分布 $P(x)$, 也可能发生在标签分布 $P(y)$ 或条件分布 $P(y|x)$ 。课程用数字类别比例变化说明: source domain 中可能某些数字多, target domain 中另一些数字多; 这会让分类器的先验偏好发生问题。

³视频画面时间区间: 00:03:15–00:03:30。

Domain Shift




图 4: Domain shift 不只包含输入样式变化, 也可能包含不同类别在 source 与 target 中出现比例不同。⁴

常见分布变化可以粗略分成:

Covariate shift $P_s(x) \neq P_t(x)$, 但 $P_s(y | x) \approx P_t(y | x)$ 。例如同样识别数字, 但图像风格变了。

Label shift $P_s(y) \neq P_t(y)$, 类别比例改变, 但每个类别的视觉或语义定义大致相同。

Concept shift $P_s(y | x) \neq P_t(y | x)$, 同一个输入模式在不同域中可能对应不同标签。这种情况最难, 单纯对齐特征可能不够。

Domain adaptation 的基本前提

领域自适应通常假设 source 和 target 任务有关, 标签空间相同或高度重叠, 而且存在某种可迁移结构。若两个域的任务语义完全不同, 强行对齐分布只会把模型推向错误方向。

1.4 本章小结

Domain shift 指训练资料和部署资料来自不同分布, 导致模型在测试域表现下降。Domain adaptation 希望利用 source labeled data 与 target unlabeled / few-labeled data 学到适合 target domain 的模型。它与普通监督学习的差别, 在于真正关心的是 target risk, 但 target labels 很少。

2 Domain Adaptation 的问题设定

课程接着用一条“对目标域了解多少”的横轴来描述不同场景。若目标域有大量标注资料, 就不太需要 domain adaptation, 直接用目标域资料训练即可; 若目标域完全未知, 则更接近 domain generalization; domain adaptation 通常处在中间: 目标域有一些信息, 但标注有限。

⁴视频画面时间区间: 00:04:30-00:04:45。

Domain Adaptation




图 5: 若 target domain 有大量 labeled data, 直接在目标域训练即可; domain adaptation 关注标注有限的情况。⁵

2.1 Source labeled 与 target limited labeled

半监督或少量标注的 target domain 设定可写成:

$$\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}, \quad \mathcal{D}_t^l = \{(x_j^t, y_j^t)\}_{j=1}^{m_t}, \quad m_t \ll n_s.$$

一个朴素想法是把 source data 和少量 target labeled data 混在一起训练。但如果 target labeled data 太少, 模型容易 overfit 少数目标域样本; 如果 source data 远多于 target data, 模型又可能仍偏向 source domain。

⁵ 视频画面时间区间: 00:07:00-00:07:15。

Domain Adaptation




图 6: 目标域少量标注资料可以帮助适应, 但也容易过拟合, 因此不能简单把少量 target label 当万能解法。⁶

这就是 domain adaptation 的核心张力: source labels 可靠但分布不同, target samples 分布正确但标签稀缺。

2.2 Unsupervised domain adaptation

很多经典方法关注 unsupervised domain adaptation (UDA):

$$\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}, \quad \mathcal{D}_t^u = \{x_j^t\}_{j=1}^{n_t}.$$

target domain 没有标签, 但有大量样本。例如系统上线后能收集用户输入, 却无法马上给每个输入标注正确答案。课程图中用 “大量 unlabeled target data + 少量 labeled target data” 表示现实中常见的混合情形。

⁶ 视频画面时间区间: 00:08:15–00:08:30。




图 7: 现实中常见的目标域信息: 大量未标注 target data, 加上少量 labeled target data。⁷

UDA 的关键问题是: 没有 target labels 时, 模型怎么知道自己在 target domain 上的分类边界是否正确? 这也是后面 domain adversarial training 会遇到限制的原因。

2.3 与 transfer learning 的区别

Domain adaptation 和 transfer learning 很接近, 但侧重点不同。Transfer learning 常强调 “从一个任务或大模型迁移知识到另一个任务”, 任务可以不同; domain adaptation 更强调 “任务相同或标签空间相同, 但资料分布不同”。

例如从 ImageNet 预训练迁移到医学影像分类, 是 transfer learning; 从白天道路场景训练的交通标志模型迁移到夜晚道路场景, 任务不变但域变了, 更像 domain adaptation。

2.4 本章小结

Domain adaptation 处在 “完全有标注目标域” 和 “完全不知道目标域” 之间。典型 UDA 使用 source labeled data 与 target unlabeled data; semi-supervised DA 还会有少量 target labels。问题的关键是: 如何在充分标注目标域的情况下, 学到适合目标域的代表和决策边界。

3 基本想法: 学到 Domain-Invariant Features

如果 source 和 target 的原始输入分布不同, 一个自然想法是不要直接对原始输入分类, 而是先通过 feature extractor 抽取表示。我们希望抽出来的 feature 保留类别相关信息, 同时去掉域相关差异。

⁷ 视频画面时间区间: 00:09:30-00:09:45。




图 8: 基本想法: 让 source 与 target 经过 feature extractor 后具有相同分布, 同时保留分类所需信息。⁸

3.1 什么是 domain-invariant feature

设 feature extractor 为 F_θ , label predictor 为 C_ϕ 。模型不是直接预测:

$$y = C(x),$$

而是:

$$z = F_\theta(x), \quad y = C_\phi(z).$$

Domain adaptation 希望:

$$P_s(F_\theta(x)) \approx P_t(F_\theta(x)),$$

也就是 source 和 target 在 feature space 中对齐。若特征分布对齐, 而且 source 上学到的决策边界仍适用于 target, 那么模型就可以在 target domain 上泛化。

3.2 忽略域差异, 而不是忽略类别

以课程中的彩色数字为例, source 是黑白数字, target 是彩色数字。模型最好不要把“颜色”当作判断类别的关键特征, 而要抓住数字形状。也就是学会忽略颜色、背景、风格等 domain-specific factor。

但“忽略 domain”不能等于“忽略一切”。如果 feature extractor 把所有输入都压成同一个点, source 和 target 分布当然完全一样, 但 label predictor 已经无法分类。好的 feature 必须同时满足:

domain-invariant and label-discriminative.

⁸视频画面时间区间: 00:10:45-00:11:00。

两个目标必须同时成立

Domain adaptation 不是只做分布对齐。若 feature 只对齐但不可分类，模型无用；若 feature 可分类但强烈依赖 source-specific pattern，模型到 target 上会失败。

3.3 本章小结

领域自适应的基本方向是学习一个共享 feature space，让 source 和 target 在这个空间里看起来更接近，同时保留类别信息。Domain adversarial training 就是实现这个想法的一种代表方法。

4 Domain Adversarial Training

Domain Adversarial Neural Network (DANN) 把 domain adaptation 写成一个对抗训练问题。它有三部分：feature extractor、label predictor、domain classifier。Label predictor 要在 source labeled data 上正确分类；domain classifier 要判断一个 feature 来自 source 还是 target；feature extractor 则要骗过 domain classifier。




图 9: DANN 同时使用 source labeled data 与 target unlabeled data，二者都经过同一个 feature extractor。⁹

4.1 Label predictor: 保留分类能力

Source domain 有标签，所以 label loss 可以写成：

$$L_y(\theta_f, \theta_y) = \frac{1}{n_s} \sum_{i=1}^{n_s} \text{CE}(C_{\theta_y}(F_{\theta_f}(x_i^s)), y_i^s).$$

⁹视频画面时间区间：00:13:00–00:13:15。

这项只在 source labeled data 上计算，目标是让特征对分类有用。如果只有 domain alignment，没有 L_y ，模型可能学到无意义表示。

4.2 Domain classifier: 判断 feature 来自哪里

Domain classifier D_{θ_d} 读入 feature $z = F_{\theta_f}(x)$ ，输出它来自 source 的概率。令 domain label $d = 1$ 表示 source， $d = 0$ 表示 target，则 domain loss 为：

$$L_d(\theta_f, \theta_d) = -\frac{1}{n_s + n_t} \sum_i [d_i \log D_{\theta_d}(F_{\theta_f}(x_i)) + (1 - d_i) \log(1 - D_{\theta_d}(F_{\theta_f}(x_i)))] .$$

哔哩哔哩

Domain Adversarial Training





图 10: Domain classifier 是一个二元分类器，任务是判断 feature 来自 source domain 还是 target domain。¹⁰

若 domain classifier 很容易分辨 source/target，说明 feature distribution 仍有明显 domain gap；若它只能随机猜，说明 feature extractor 已经把两个域混得较像。

4.3 Feature extractor: 骗过 domain classifier

对 domain classifier 来说，它要最小化 L_d ，尽可能分清 source 和 target。对 feature extractor 来说，它要最大化 L_d ，让 domain classifier 分不清。这就是 adversarial 的来源。

¹⁰视频画面时间区间：00:14:15–00:14:30。



11

可以写成 min-max 目标:

$$\min_{\theta_f, \theta_y} [L_y(\theta_f, \theta_y) - \lambda L_d(\theta_f, \theta_d)], \quad \min_{\theta_d} L_d(\theta_f, \theta_d).$$

这里 λ 控制 domain alignment 的强度。对 θ_d , 训练方向是让 domain classifier 更准; 对 θ_f , 训练方向是让 domain classifier 更糊涂。

¹¹视频画面时间区间：00:15:45-00:16:00。

Domain Adversarial Training




图 12: DANN 同时包含 label loss 与 domain loss: 前者要求分类正确, 后者提供域对齐信号。¹²

4.4 Gradient reversal layer

实际实现常用 gradient reversal layer (GRL)。前向传播时 GRL 是恒等映射:

$$\text{GRL}(z) = z.$$

反向传播时, 它把来自 domain classifier 的梯度乘上 $-\lambda$:

$$\frac{\partial \text{GRL}}{\partial z} = -\lambda I.$$

这样可以在同一个计算图中实现:

$$\theta_d \leftarrow \theta_d - \eta \nabla_{\theta_d} L_d, \quad \theta_f \leftarrow \theta_f - \eta \nabla_{\theta_f} (L_y - \lambda L_d).$$

¹² 视频画面时间区间: 00:18:00-00:18:15。

Domain Adversarial Training




图 13: DANN 的核心是 min-max: domain classifier 学会分域, feature extractor 学会让它分不出来。¹³

4.5 实验结果

课程展示了 DANN 在多个视觉 domain adaptation benchmark 上的结果, 包括 MNIST、SVHN、synthetic signs、GTSRB 等。重点不是某个具体数字, 而是方法能在 source-only 与 target-only 之间显著改善目标域表现。

¹³ 视频画面时间区间: 00:19:30-00:19:45。

Domain Adversarial Training

Yaroslav Ganin, Victor Lempitsky, Unsupervised Domain Adaptation by Backpropagation, ICML, 2015

Hana Ajakan, Pascal Germain, Hugo Larochelle, François Laviolette, Mario Marchand, Domain-Adversarial Training of Neural Networks, JMLR, 2016

		MNIST	SYN NUMBERS	SVHN	SYN SIGNS
SOURCE					
TARGET					
		MNIST-M	SVHN	MNIST	GTSRB
METHOD	SOURCE	MNIST	SYN NUMBERS	SVHN	SYN SIGNS
	TARGET	MNIST-M	SVHN	MNIST	GTSRB
SOURCE ONLY		.5749	.8665	.5919	.7400
TRAIN ON TARGET		.9891	.9244	.9951	.9987

图 14: DANN 通过 domain adversarial training 在多个 source-to-target 设定中提升了 target domain 表现。¹⁴

读这类表时要注意三条基线:

Source only 只用 source labeled data 训练后直接测试 target。通常最弱。

Train on target 若有 target labels, 用目标域监督训练。通常是上界或强参考。

Domain adaptation 使用 source labels 与 target unlabeled data, 希望逼近 target supervised 的效果。

4.6 本章小结

DANN 用对抗训练实现 domain-invariant feature learning。Label predictor 确保特征可分类, domain classifier 检测域差异, feature extractor 通过反向梯度骗过 domain classifier。它是领域自适应中非常经典的框架, 但“对齐分布”本身仍有局限。

5 限制: 对齐分布不一定对齐类别

Domain adversarial training 的直觉很漂亮: source 和 target feature 分布越像, source 上学到的分类器越可能迁移。但课程特别提醒, 这个直觉并不总是成立。仅仅让 marginal feature distribution 对齐, 可能把不同类别混在一起, 或者让 target 样本落在错误决策边界附近。

¹⁴视频画面时间区间: 00:21:15–00:21:30。




图 15: 一个限制: source 与 target 的整体分布看似对齐, 但 target 样本可能仍被 source decision boundary 错分。¹⁵

5.1 Marginal alignment 的风险

DANN 主要让:

$$P_s(F(x)) \approx P_t(F(x)).$$

但分类真正需要的是 class-conditional alignment:

$$P_s(F(x) | y = k) \approx P_t(F(x) | y = k), \quad \forall k.$$

如果只对齐整体分布, 可能出现 class mismatch。例如 source 的 class 1 被对齐到 target 的 class 2 附近; domain classifier 分不出来两个域, 但 label predictor 的边界仍错。

¹⁵ 视频画面时间区间: 00:24:00-00:24:15。





图 16: 较理想的情况是 target data 不只与 source 对齐, 还要远离错误的 decision boundary。¹⁶

5.2 Decision boundary 的重要性

课程接着提到要考虑 decision boundary。直觉上, 目标域样本应该落在分类器有信心的区域, 而不是靠近决策边界。若目标域未标注样本经过模型后输出分布很平坦、entropy 很大, 说明模型不知道它属于哪一类, 边界可能穿过高密度区域。

¹⁶ 视频画面时间区间: 00:25:00-00:25:15。

Considering Decision Boundary



Used in Decision-boundary Iterative Refinement Training with a Teacher (DIRT-T) <https://arxiv.org/abs/1802.08735>

图 17: 考虑 decision boundary: 希望 target samples 的预测 entropy 小, 避免边界穿过目标域高密度区域。¹⁷

常见补充目标是 target entropy minimization:

$$L_{\text{ent}} = \frac{1}{n_t} \sum_{j=1}^{n_t} H(C(F(x_j^t))),$$

其中:

$$H(p) = - \sum_k p_k \log p_k.$$

最小化 L_{ent} 会鼓励模型在 target samples 上给出更确定的预测。DIRT-T、MCD 等方法都试图让 target decision boundary 更合理, 而不是只看 domain classifier 是否被骗过。

只骗过 domain classifier 不够

如果 feature extractor 只追求让 domain classifier 分不出 source/target, 可能会牺牲类别结构。好的 domain adaptation 还要让 target samples 避开错误边界, 并尽量保持 class-conditional alignment。

5.3 本章小结

DANN 的限制在于它主要对齐 marginal feature distributions。真正影响分类的是类别条件分布和决策边界位置。后续方法常加入 entropy minimization、pseudo-label、classifier discrepancy 或 teacher refinement, 让 target data 不只“像 source”, 还要落在正确类别区域。

¹⁷ 视频画面时间区间: 00:26:30-00:26:45。

6 Outlook: 更复杂的领域自适应与泛化

课程最后用一张 taxonomy 图说明, domain adaptation 有很多变体, 差别在于 source 和 target 的标签空间关系、目标域是否有标注、训练时是否能看到目标域资料。




图 18: Domain adaptation 的常见变体包括 closed-set、partial、open-set、universal 等设定。¹⁸

6.1 Closed-set、partial 与 open-set

最标准的是 closed-set domain adaptation: source 和 target 标签空间相同:

$$\mathcal{Y}_s = \mathcal{Y}_t.$$

Partial domain adaptation 中, target 标签空间是 source 的子集:

$$\mathcal{Y}_t \subset \mathcal{Y}_s.$$

此时如果强行把 source 中所有类别都对齐到 target, source-only 类别会产生负迁移。Open-set domain adaptation 则允许 target 中出现 source 没见过的新类别:

$$\mathcal{Y}_t \not\subset \mathcal{Y}_s.$$

这时模型不仅要分类已知类别, 还要识别 unknown target class。

6.2 Universal domain adaptation

Universal domain adaptation 更宽松: source 和 target 标签空间的重叠关系未知。模型不知道哪些 source classes 会出现在 target, 也不知道 target 是否含未知类别。因此它必须同时做 transfer 和 unknown detection。

¹⁸ 视频画面时间区间: 00:27:45–00:28:00。

Outlook




图 19: Universal domain adaptation 不预设 source 与 target 标签空间关系，需要同时处理共享类与未知类。¹⁹

这比 closed-set DA 更接近真实世界。部署时，目标域可能缺少某些训练类，也可能出现新类别；如果模型仍假设标签空间完全一致，就会把 unknown 样本硬分到已知类中。

6.3 Domain generalization

Domain generalization 更进一步：训练时根本看不到目标域资料。模型只能从多个 source domains 中学出跨域稳定特征，期望未来未知 target domain 也能泛化。

¹⁹视频画面时间区间：00:31:00–00:31:15。

Domain Generalization

<https://ieeexplore.ieee.org/document/8578664>




图 20: Domain generalization 中，训练时没有目标域资料，只能从多个 source domains 学跨域稳定规律。²⁰

若训练域集合为：

$$\{\mathcal{D}_s^{(1)}, \mathcal{D}_s^{(2)}, \dots, \mathcal{D}_s^{(m)}\},$$

目标是学一个模型 h ，在未来未知域 $\mathcal{D}_t^{\text{new}}$ 上也表现好：

$$\min_h \mathbb{E}_{\mathcal{D}^{\text{new}}} [R_{\mathcal{D}^{\text{new}}}(h)].$$

这类方法常依赖数据增强、元学习、风格随机化、因果特征学习或不变风险最小化。它比 domain adaptation 更难，因为没有 target samples 可用来对齐。

6.4 本章小结

领域自适应不是单一问题，而是一组问题族。Closed-set DA 假设标签空间相同；partial/open-set/universal DA 放宽标签空间关系；domain generalization 则连 target samples 都没有。实际应用中，必须先判断自己处在哪个设定，再选择方法。

7 总结与延伸

本讲从一个简单但常见的问题出发：训练资料和测试资料不同分布时，模型表现会明显下降。Domain adaptation 的目标，是在 source domain 有标注、target domain 标注稀缺或没有标注的情况下，让模型适应 target domain。

核心思路是学习 domain-invariant but label-discriminative features。DANN 通过 feature extractor、label predictor 和 domain classifier 组成对抗结构：label predictor 要 source 分类正确，domain

²⁰ 视频画面时间区间：00:34:00–00:34:15。

classifier 要分辨 source/target, feature extractor 则保留分类信息并骗过 domain classifier。这个框架用 gradient reversal layer 可以高效实现。

但本讲也强调了 DANN 的限制：让 source 和 target 的整体特征分布对齐，并不保证类别对齐，也不保证 target decision boundary 合理。好的 adaptation 还要考虑 class-conditional structure、entropy、pseudo-label 和 decision boundary。最后，domain adaptation 还有 closed-set、partial、open-set、universal 和 domain generalization 等多个变体；这些设定不同，方法和评价方式也不同。

从实践角度看，做领域自适应前最重要的是先界定问题：目标域是否可见？是否有少量标签？标签空间是否相同？domain shift 是输入风格变化、类别比例变化，还是概念本身变化？这些问题决定了“对齐特征”是否足够，也决定了模型上线后还需要怎样的监控和再训练机制。