

BERT 的三个故事：自监督模型的多功能性

Cross-lingual, Cross-discipline, and Pre-training on Artificial Data



基于李宏毅老师《机器学习 2025》课程内容整理
2026 年 6 月 9 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 53 分 42 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=45>

目录

1 自监督模型为什么看起来无所不能	3
1.1 自监督学习的最小形式	3
1.2 本章小结	4
2 故事一：多语言 BERT 的跨语言能力	4
2.1 英文训练、中文测试的实验现象	5
2.2 第一种解释：不同语言的语义表示被对齐	7
2.3 用 MRR 测量跨语言对齐	7
2.4 第二种解释：语言信息藏在整体方向中	9
2.5 这些分析有什么用	12
2.6 本章小结	12
3 故事二：从人类语言迁移到 DNA、蛋白质、音乐与语音问答	12
3.1 把非语言序列转成 BERT 可以读的 token	13
3.2 跨学科分类结果	14
3.3 预训练究竟帮了什么：优化与泛化	15
3.4 语音问答：第二个故事的延伸	16
3.5 本章小结	20
4 故事三：在人造资料上预训练	20
4.1 人工数据如何接到自然语言任务	20
4.2 随机数据、成对数据与 shuffle 数据	21
4.3 长距离阅读能力可能很关键	23
4.4 本章小结	24
5 三个故事的共同解释	24
5.1 层次一：表示空间的对齐	24
5.2 层次二：序列建模的通用能力	25
5.3 层次三：优化路径的改善	25
5.4 层次四：长距离上下文整合	25
5.5 本章小结	25
6 总结与延伸	25
6.1 与前后课程的连接	25
6.2 三个可以继续追问的问题	26

1 自监督模型为什么看起来无所不能

这堂课讨论一个看似夸张的问题：自监督模型到底有多么“万能”？课程没有从更大的模型、更大的资料量或更强的 benchmark 说起，而是用三个故事来展示一个更微妙的现象：模型只是在某一种形式的数据上做填空题，却可能在后来表现出跨语言、跨学科、甚至从人工规则数据迁移到自然语言任务的能力。

00:00:30 00:00:45

Outline




图 1: 课程主线由三个故事组成：跨语言能力、跨学科能力，以及用人工数据进行预训练。¹

三个故事的表面内容不同，但共同的问题是：**预训练到底让模型学到了什么？**如果 BERT 只是在做 masked language modeling，它为什么能迁移到没有看过的语言？如果它只看过人类语言，为什么能帮 DNA、蛋白质和音乐分类？如果预训练数据甚至不是自然语言，只是人工规则生成的 token sequence，它为什么仍然可能改善 GLUE 等自然语言任务？

本讲的核心视角

自监督预训练不只是在记住训练语料中的词汇知识。它还可能学到一些更抽象的能力，例如把符号映射到连续表示、利用上下文补全缺失信息、从长序列中整合远距离关系、以及让后续优化更容易。三个故事正是在不同实验设定下，逐步拆解这些能力。

为了避免把“有用”误读成“懂了人类语言”，本讲反复强调一件事：某个预训练模型在下游任务上有帮助，并不等于它学到了我们直觉中那种完整语义。很多实验结果更像是在说明，预训练提供了一组对学习有利的 inductive bias，使模型在 fine-tuning 时更容易找到好解。

1.1 自监督学习的最小形式

BERT 类模型的典型预训练任务是 masked language modeling。给定 token 序列

$$\mathbf{x} = (x_1, x_2, \dots, x_T),$$

随机遮住其中一部分位置 M ，模型看到未遮住的上下文 $\mathbf{x}_{\setminus M}$ ，并预测被遮住的 token：

$$\mathcal{L}_{\text{MLM}} = - \sum_{i \in M} \log p_{\theta}(x_i \mid \mathbf{x}_{\setminus M}).$$

¹视频画面时间区间：00:00:30–00:00:45。

其中 M 是被 mask 的位置集合, p_θ 是模型给出的条件分布。这个目标看起来很简单: 填空。但为了填对空格, 模型必须把局部上下文、句法线索、词义相关性、长距离依赖和语料统计都压进内部表示。




图 2: 多语言 BERT 的训练仍然是填空题, 只是训练资料来自多种语言; 同一个模型被迫在不同语言的 token 序列上学习补全。²

为什么“填空”可能很强

填空题不是简单的字典查表。若句子中出现“首都”“人口”“总统”“年份”等上下文, 模型要预测正确 token, 就必须组织世界知识、语义相似性和句法位置。随着语料规模变大, MLM 目标会把大量隐含结构压缩到表示空间中; 这也是后来三个故事能成立的背景。

1.2 本章小结

本讲用三个故事追问自监督预训练的能力来源。masked language modeling 的形式很朴素, 但为了完成这个目标, 模型必须建立可迁移的内部表示。后续三个故事分别从跨语言、跨学科和人工数据三个角度, 说明这些表示并不只是某个语料的表面统计。

2 故事一: 多语言 BERT 的跨语言能力

第一个故事讨论 multi-lingual BERT。直觉上, 如果模型要解决中文 QA, 就需要中文 QA 的训练资料; 如果只有英文 QA 的训练资料, 模型应该无法直接回答中文问题。多语言 BERT 的有趣之处在于: 它在很多语言上做过 MLM 预训练后, 可以在英文 QA 上 fine-tune, 再直接拿去测试中文 QA。这就是典型的 cross-lingual zero-shot transfer。

²视频画面时间区间: 00:01:00–00:01:15。

Cross-lingual Capability of Multi-lingual BERT



图 3: 跨语言问答设定: 多语言 BERT 先在多语言语料上预训练, 再用英文 QA 训练下游模型, 最后直接测试中文 QA。³

形式化地说, 设英文训练集为

$$\mathcal{D}_{\text{en}} = \{(q_i^{\text{en}}, d_i^{\text{en}}, a_i^{\text{en}})\}_{i=1}^n,$$

中文测试集为

$$\mathcal{D}_{\text{zh}} = \{(q_j^{\text{zh}}, d_j^{\text{zh}}, a_j^{\text{zh}})\}_{j=1}^m.$$

zero-shot transfer 的关键是: fine-tuning 阶段没有使用中文 QA 标注, 但测试时要求模型在中文资料上给出答案 span。若模型仍然表现不错, 说明它的表示空间中至少存在某种跨语言共享结构。

2.1 英文训练、中文测试的实验现象

课程展示了英语 SQuAD 与中文 DRCd 的问答实验。若用传统 QA 模型 QANet 且没有跨语言预训练, 中文测试表现明显较弱; 如果 BERT 在中文上预训练并在中文 QA 上 fine-tune, 表现最高, 这符合直觉。真正惊人的地方是: 多语言 BERT 即使 fine-tune 在英文 QA 上, 再测试中文 QA, 也能取得相当可用的表现。

³视频画面时间区间: 00:02:15-00:02:30。

Cross-lingual Capability of Multi-lingual BERT

- English: SQuAD, Chinese: DRCD

Model	Pre-train	Fine-tune	Test	EM	F1
QANet	none	Chinese	Chinese	66.1	78.1 ⁴
BERT	Chinese	Chinese		82.0	89.1
	104 languages	Chinese		81.2	88.7
		English		63.3	78.8
		Chinese + English		82.6	90.1

Tsung-yuan Hsu, Chi-liang Liu, Hung-yi Lee, Zero-shot Reading Comprehension by Cross-lingual Transfer Learning with Multi-lingual Language Representation Model, EMNLP, 2019

图 4: SQuAD 与 DRCD 的跨语言 QA 结果表明: 多语言 BERT 在英文 QA 上 fine-tune 后, 仍能迁移到中文 QA。⁴

这个现象后来已经不只出现在 QA。课程提到 XTREME benchmark: 它把 sentence classification、structured prediction、sentence retrieval、question answering 等任务放在统一跨语言评测中, 常见设定就是在英文上 fine-tune, 再测试其余语言。也就是说, 多语言迁移已经从“新奇发现”变成 NLP 里的常识性评估方式。

This is a common sense today

Cross-lingual TRansfer Evaluation of Multilingual Encoders (XTREME) benchmark

<https://sites.research.google/xtreme>




图 5: XTREME benchmark 将跨语言迁移标准化: 常见做法是在英文上 fine-tune, 然后在其他语言上测试。⁵

⁴视频画面时间区间: 00:04:15–00:04:30。

⁵视频画面时间区间: 00:06:00–00:06:15。

跨语言迁移的基本设定

跨语言 zero-shot 并不是模型看不见中文。模型在预训练阶段可能已经看过中文语料；zero-shot 指的是下游监督资料只来自英文。重点在于：英文下游任务学到的决策边界，能否套用到中文表示上。

2.2 第一种解释：不同语言的语义表示被对齐

一个自然解释是：多语言 BERT 学到的表示是 language-agnostic 的。比如英文的 **rabbit** 和中文的“兔”，英文的 **fish** 和中文的“鱼”，虽然表面符号不同，但在表示空间中可能靠得很近。这样一来，下游模型只要在英文表示上学会“某类语义对应答案”，中文表示若落在相近位置，就能被同一套决策规则处理。




图 6: 一种解释是语义对齐：不同语言中意思相近的词，在多语言 BERT 的表示空间中彼此接近。⁶

可以把这个想法写成 embedding alignment。对任意 token w ，从大量上下文中抽取它在 BERT 某一层的 contextualized representation，然后取平均：

$$\bar{\mathbf{h}}(w) = \frac{1}{N_w} \sum_{k=1}^{N_w} \mathbf{h}(w; \text{context}_k).$$

其中 N_w 是 token w 出现的上下文数量， $\mathbf{h}(w; \text{context}_k)$ 是该 token 在第 k 个上下文中的表示。若双语词典给出 $(w_{\text{en}}, w_{\text{zh}})$ ，就可以比较

$$\cos(\bar{\mathbf{h}}(w_{\text{en}}), \bar{\mathbf{h}}(w_{\text{zh}})) = \frac{\bar{\mathbf{h}}(w_{\text{en}})^\top \bar{\mathbf{h}}(w_{\text{zh}})}{\|\bar{\mathbf{h}}(w_{\text{en}})\| \|\bar{\mathbf{h}}(w_{\text{zh}})\|}.$$

如果正确翻译对在相似度排序中越靠前，就说明两种语言的词汇表示越对齐。

2.3 用 MRR 测量跨语言对齐

课程用双语词典说明 Mean Reciprocal Rank。对英文词 w_i ，先计算它与一组中文候选词的表示相似度，把所有中文候选按相似度排序。如果正确翻译排第 r_i 名，则该词贡献 $1/r_i$ ；对所有词取平

⁶ 视频画面时间区间：00:06:45–00:07:00。

均:

$$\text{MRR} = \frac{1}{N} \sum_{i=1}^N \frac{1}{r_i}.$$

其中 N 是词典中被评估的词对数量。MRR 越高，表示正确翻译越常出现在排序前面，跨语言 alignment 越好。




图 7: MRR 的计算方式: 根据双语词典检查正确翻译在相似度排序中的名次, 再取 reciprocal rank 的平均。⁷

实验结果显示, 多语言 BERT 的不同语言表示确实有明显对齐效果。更有意思的是, 一些传统 word embedding 方法在足够语料下也能出现对齐现象; 这提示我们不要把所有能力都神化为 Transformer 独有。预训练资料量、共享训练目标、语料统计和模型结构都会影响最终对齐程度。

⁷ 视频画面时间区间: 00:10:15–00:10:30。



方式有关。⁸

不要把 alignment 误读成“语言差异完全消失”

如果表示完全 language-agnostic，模型就无法知道应该用中文还是英文补空。可是多语言 BERT 在中文句子里通常会补中文，在英文句子里通常会补英文。也就是说，表示空间既包含跨语言共享语义，也保留语言身份信息。

2.4 第二种解释：语言信息藏在整体方向中

课程接着提出反问：如果不同语言的语义表示已经对齐，模型做 MLM 时怎么知道要补中文 token 还是英文 token？这说明表示里还必须保留 language information。一个实验性想法是：把某个语言所有 token 的平均表示当成该语言的向量，类似一个 language vector。

⁸视频画面时间区间：00:12:15-00:12:30。




图 9: 若 embedding 完全不带语言信息, 模型就无法决定在重建时输出中文还是英文; 因此语言身份仍然存在于表示中。⁹

对语言 ℓ 的 token 集合 $\mathcal{V}_\ell$, 可以定义平均语言向量:

$$\mu_\ell = \frac{1}{|\mathcal{V}_\ell|} \sum_{w \in \mathcal{V}_\ell} \bar{\mathbf{h}}(w).$$

若 μ_{zh} 和 μ_{en} 的差异代表语言身份, 那么

$$\Delta_{\text{zh} \leftarrow \text{en}} = \mu_{\text{zh}} - \mu_{\text{en}}$$

就可以看作“从英文表示移到中文表示”的方向。这个方向不一定是严格线性的语言翻译机制, 但它提供了一种分析表示空间的工具。

⁹ 视频画面时间区间: 00:15:00–00:15:15。




图 10: 把某一语言中所有 token 的平均 embedding 视为语言向量, 可以用来分析语言身份信息在表示空间中的位置。¹⁰

一个有趣实验是: 输入英文句子, 但在表示上加上从英文到中文的语言差异向量, 再让多语言 BERT 重建。课程展示的例子中, 模型可能输出中文句子。这并不是说 BERT 本身就是翻译系统, 而是说明表示空间中存在某些可操作的语言方向。




图 11: 在英文句子的表示上加入中文方向后, 再让多语言 BERT 重建, 可能得到中文输出; 这显示语言信息具有一定可分离性。¹¹

¹⁰ 视频画面时间区间: 00:16:00–00:16:15。

¹¹ 视频画面时间区间: 00:18:00–00:18:15。

2.5 这些分析有什么用

理解语言信息的位置不只是好奇心。若下游模型在英文表示上训练，测试中文时中文表示虽然语义相近，但仍可能带有语言偏移。一个应用方向是：在把中文表示送入英文下游模型前，先减掉中英文语言向量差异，让中文表示更像英文训练时的表示，从而改善跨语言迁移。




图 12: 跨语言下游任务的一个修正思路：将中文表示扣除中英文平均表示差异，使它更接近英文训练时的表示空间。¹²

这也给跨语言迁移一个更细致的图像：多语言 BERT 并不是把所有语言混成完全相同的表示，而是在共享语义与语言身份之间形成某种结构。zero-shot transfer 能成立，是因为下游任务需要的语义结构可以跨语言共享；但性能仍受语言偏移影响，因此对齐、校正和语言向量分析仍有意义。

2.6 本章小结

多语言 BERT 的跨语言能力可以从两个角度理解。第一，不同语言中语义相近的词在表示空间中会对齐，使英文训练的下游模型能处理中文表示。第二，模型仍保留语言身份信息，否则无法决定 MLM 重建时输出哪种语言。跨语言迁移的关键不是“语言差异不存在”，而是“共享语义结构足够强，语言偏移又可以被建模或修正”。

3 故事二：从人类语言迁移到 DNA、蛋白质、音乐与语音问答

第二个故事更反直觉：把在人类语言上预训练的 BERT，用到 DNA、蛋白质和音乐分类上。若 BERT 学到的只是英文单字和句法，它不应该对 DNA 序列有任何帮助；但实验显示，预训练的 BERT 往往比随机初始化更好。这逼我们重新思考：预训练模型提供的能力也许不局限于自然语言语义。

¹² 视频画面时间区间：00:21:30–00:21:45。



語

3.1 把非语言序列转成 BERT 可以读的 token

把每个碱基或片段映射成 BERT 词表中的 token。例如 A 对应 **we**，G 对应 **she**，C 对应 **he**。这样一段 DNA 就变成一串看起来不知所云的英文 token，然后输入 BERT 做分类。

图 14: DNA 序列可以通过任意映射变成 BERT token 序列, 再接线性分类器进行 DNA 分类。¹⁴

¹⁴视频画面时间区间：00:24:45-00:25:00。


这一步很关键：映射本身并不携带语义。若 A 映射到 `we`，并不是说 A 的生物学意义类似英文 `we`。实验真正比较的是：同样的下游任务与输入映射下，BERT 的预训练参数是否比随机初始化更有利。

不要把 token 映射解释成语义翻译

DNA 到英文 token 的映射只是为了使用 BERT 的输入接口。映射可以是任意的，不能把 `we`、`she` 等英文词的自然语言语义套到 DNA 碱基上。若预训练有帮助，它说明的是模型结构和参数状态带来一般性学习优势，而不是 BERT 真正理解了 DNA。

3.2 跨学科分类结果

课程展示的实验覆盖蛋白质、DNA 与音乐分类。比较对象包括：specific model、BERT、随机初始化等。结果的核心观察是：用预训练 BERT 初始化，通常优于随机初始化；即使任务不是自然语言，预训练仍能提供某些一般技能。



• Applying BERT to **protein, DNA, music classification**


	Protein			DNA				Music
	localization	stability	fluorescence	H3	H4	H3K9ac	Splice	composer
specific	69.0	76.0	63.0	87.3	87.3	79.1	94.1	-
BERT	64.8	74.5	63.7	83.0	86.2	78.3	97.5	55.2
re-emb	63.3	75.4	37.3	78.5	83.7	76.3	95.6	55.2
rand	58.6	65.8	27.5	75.6	66.5	72.8	95	36

图 15: 蛋白质、DNA 与音乐分类结果显示：预训练 BERT 往往比随机初始化的模型更好。¹⁵


从分类柱状图看，这种优势不是单一任务的偶然现象。DNA 分类、蛋白质分类和音乐分类都出现了不同程度的改善。课程据此提出一个解释：预训练模型学到了一些通用技巧，使它更容易在各种分类任务上被 fine-tune。

¹⁵ 视频画面时间区间：00:26:00–00:26:15。


Cross-discipline Capability



DNA Classification
(average 3 tasks)



Protein Classification
(average 4 tasks)




Music Classification

图 16: 不同任务平均结果进一步显示, 预训练带来的改善跨越 DNA、蛋白质和音乐序列分类。¹⁶

3.3 预训练究竟帮了什么: 优化与泛化


为了拆解“预训练有帮助”的来源, 课程区分 optimization 与 generalization. optimization 指训练过程中是否更容易把 loss 降下来; generalization 指训练后是否能在测试集上表现更好。两者相关但不同: 有时模型训练 loss 很低却过拟合, 有时模型训练过程本身就卡住。

Optimization




(b) fluorescence

Generalization



(a) H3K9ac



(b) localization

图 17: 优化曲线与泛化曲线显示: 预训练模型不仅可能让训练 loss 降得更顺, 也可能影响测试表现。¹⁷

¹⁶ 视频画面时间区间: 00:27:45-00:28:00。

¹⁷ 视频画面时间区间: 00:30:00-00:30:15。

用符号说, fine-tuning 的目标可写成

$$\min_{\theta} \frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(x_i), y_i).$$

随机初始化从 θ_{rand} 出发, 预训练初始化从 θ_{pre} 出发。即使两个模型结构完全相同, 优化路径也会不同:

$$\theta_{\text{rand}} \rightarrow \theta_{\text{rand}}^*, \quad \theta_{\text{pre}} \rightarrow \theta_{\text{pre}}^*.$$

预训练可能把参数放在一个更容易到达好解的区域, 也可能让模型的中间层已经具备适合序列任务的特征提取能力。

跨学科故事的关键结论

BERT 在非语言序列上有帮助, 不代表它理解生物学或音乐; 它更可能说明预训练给模型带来通用的序列建模能力、优化优势和表示组织能力。下游任务只要也需要处理 token 序列、长程依赖或分类边界, 这些能力就可能迁移。

3.4 语音问答: 第二个故事的延伸

课程随后把 cross-discipline 的想法延伸到 Speech Question Answering。传统 spoken SQuAD 常用 cascade pipeline: 先做 ASR, 把语音转成文字, 再用文本阅读理解模型找答案。这个做法的问题是, 最终 QA 表现会受到 ASR 错误率影响。




图 18: 传统语音问答常用 cascade: 语音先经 ASR 转文字, 再交给阅读理解模型找答案 span。¹⁸

另一个方向是 SpeechBERT: 把语音和文字一起放入类似 BERT 的模型, 直接预测答案在语音中的 start 与 end。它看起来更端到端, 但训练时仍需要语音与文字成对的数据, 也就是并没有完全摆脱 transcription 的需求。

¹⁸ 视频画面时间区间: 00:33:45-00:34:00。

Speech Question Answering

• Speech BERT

End-to-end, but
speech-text paired
data required




图 19: SpeechBERT 直接处理文字问题与语音内容，并预测答案 span；但训练仍依赖 speech-text paired data。¹⁹

课程的目标更大胆：训练资料中没有文字 transcription，只有语音问题、语音文件和答案 span，能不能训练端到端的语音问答？如果直接训练，很难；但若已有 HuBERT 这类自监督语音模型，就可以先把语音变成离散 token 或表示，再尝试让后续模型学习问答。

Training data

(no speech transcription)




图 20: 更困难的训练设定：训练资料没有 speech transcription，只给语音问题、语音文件和答案 span。²⁰

初始尝试显示，仅靠预训练语音模型如 HuBERT 并不能直接解决问题。课程中的 slide 写着 “It does not work / No semantic information”，强调 HuBERT 可能抽取了声学或内容相关表示，但未必已经具备足够的语义理解能力。

¹⁹ 视频画面时间区间：00:34:00–00:34:15。

²⁰ 视频画面时间区间：00:34:30–00:34:45。

Speech Question Answering




图 21: 只使用预训练语音模型并不能直接完成语音问答, 原因可能是表示中缺少足够的语义层次。²¹

一个改进是: 在预训练语音模型后面再叠几层 self-attention, 让模型有机会在离散语音 token 上进一步整合上下文、学习问题与文件之间的对应关系。这一步很像把文字 BERT 的序列建模能力借给语音 token。




图 22: 在预训练语音模型后追加 self-attention 层, 希望补上语义整合与问答推理能力。²²

更离奇也更有启发性的实验是: 把 HuBERT 输出的离散 token ID 直接当成文字 BERT 的输入 ID, 用预训练文本模型初始化后续模块。虽然这些 ID 与文字没有真实语义关系, 实验却显示结果大幅改善: 没有预训练时 F1 约为 6.12, 使用文本 BERT 预训练后 F1 可到约 54.22。

²¹ 视频画面时间区间: 00:36:00-00:36:15。

²² 视频画面时间区间: 00:37:15-00:37:30。




图 23: 将 HuBERT 的离散 token ID 接到预训练文本 BERT 后, 语音问答效果大幅提升; slide 中给出无预训练与文本预训练的 F1 对比。²³

与 cascade 方法相比, 这种方式的潜在优势是避免 ASR 错误传播。课程展示的图中, ASR 错误率上升会让基于 ASR 的 QA 表现下降; 而不依赖显式语音辨识的端到端语音 QA, 在高 ASR 错误条件下可能更有吸引力。




图 24: ASR 错误率越高, cascade 的语音 QA 越受影响; 不显式依赖 ASR 的方法提供了另一条路线。²⁴

²³ 视频画面时间区间: 00:39:45–00:40:00。

²⁴ 视频画面时间区间: 00:41:00–00:41:15。

3.5 本章小结

第二个故事说明，预训练模型的迁移能力可以跨出自然语言。BERT 用在人类语言以外的序列任务上，可能并不是因为它掌握了目标领域语义，而是因为预训练让模型具备了更好的初始化、序列组织能力和上下文整合能力。语音问答实验进一步显示，文字 BERT 的能力甚至可能通过离散 token 接口迁移到语音任务，尽管这种迁移的机制仍然值得继续研究。

4 故事三：在人造资料上预训练

第三个故事把问题推到更极端：如果预训练资料不是人类语言，而是人工规则产生的 token sequence，模型还能不能在自然语言任务上受益？这个设定的价值在于可控性。自然语言里同时混有语义、语法、世界知识、词频、长程依赖等因素，很难判断到底哪个因素让预训练有效；人工数据可以按规则逐项控制。




图 25: 人工数据预训练的实验设定：不再用人类语言预训练，而是用规则生成的 token sequence 训练模型，再测试 GLUE 等 NLP 任务。²⁵

4.1 人工数据如何接到自然语言任务

实验先用规则生成 token sequence，在这些序列上训练 BERT 做填空题。因为预训练语料不是自然语言，模型只认识人工 token ID。fine-tuning 到自然语言任务时，需要建立一个表，把自然语言词汇映射到人工 token ID。这个映射可以随机生成。

²⁵ 视频画面时间区间：00:42:15–00:42:30。




图 26: 人工 token sequence 先用来预训练 BERT；之后通过 token ID 映射，把自然语言句子转成模型能读的 ID。²⁶

这个设计很反直觉：如果 token ID 与英文词之间没有真实语义关系，为什么预训练还会有帮助？答案可能是，某些预训练资料不需要包含真实语义，也能训练出对下游任务有用的结构性能力。例如，模型学会在长序列中寻找规律、利用上下文位置、处理重复或配对关系，这些能力后来也能帮助自然语言任务。

人工数据实验的研究意义

人工数据不是为了替代真实语言语料，而是为了做因果拆解。通过改变生成规则，研究者可以观察哪些结构会让预训练有帮助，哪些结构没有帮助，从而推测自然语言预训练中真正关键的能力。

4.2 随机数据、成对数据与 shuffle 数据

课程展示的第一组结果比较英文预训练、随机人工数据、paired 数据与 shuffle 数据。纵轴是相对 train from scratch 的平均绝对提升；值越大，代表预训练越有帮助。英文预训练接近上界，完全随机的人工数据帮助较小，而某些有结构的人工数据可以带来接近英文预训练的提升。

²⁶ 视频画面时间区间：00:44:15–00:44:30。

Average absolute improvement (%)
compared to training from scratch





图 27: 人工数据预训练结果: 英文预训练效果最好; 纯随机数据帮助有限; 有结构的人工数据明显更有用。²⁷

paired 数据的规则是：生成句子时让 token 成对出现。若一个 token 出现，另一个位置会有与它配对的 token。这会迫使模型在做填空题时学习跨位置关系，而不是只依赖局部频率。实验显示，这类规则能带来相当明显的下游提升。

Average absolute improvement (%)
compared to training from scratch



- All the words in the generated sentences are paired.




图 28: paired 人工数据让 token 成对出现，迫使模型学习跨位置依赖，因此比无结构随机数据更有帮助。²⁸

另一种有效规则是 shuffle。先产生连续编号的 token sequence, 例如 $1, 2, \dots, 64$, 再在一定范围内打乱。模型必须利用较长范围内的 token 关系来预测被遮住的位置。实验显示, shuffle 数据也能带来接近 paired 数据的提升。

²⁷ 视频画面时间区间：00:46:00—00:46:15。

²⁸ 视频画面时间区间: 00:47:45-00:48:00。




图 29: shuffle 人工数据通过打乱连续编号序列制造长程依赖，效果接近 paired 数据。²⁹

4.3 长距离阅读能力可能很关键

课程最后展示了一个重要发现：shuffle 的范围越大，预训练效果越好。若只在长度为 4 的小范围内打乱，提升有限；当范围扩大到 64 时，提升显著增加。老师据此提出一个可能解释：让模型在预训练时被迫阅读较长范围、整合远距离关系，对自然语言任务很重要。




图 30: shuffle 范围越长，下游提升越明显；这提示长距离上下文整合可能是预训练成功的重要因素。³⁰

²⁹ 视频画面时间区间：00:49:45–00:50:00。

³⁰ 视频画面时间区间：00:52:15–00:52:30。

这个结论并不等于“长程依赖是唯一因素”。课程也强调目前没有非常精确的答案。人工数据实验只能说明：某些可控结构足以带来迁移收益；至于自然语言预训练究竟还依赖哪些因素，例如语义层次、词频结构、句法结构、世界知识、tokenization 方式等，仍然是开放问题。

人工数据故事给出的最保守结论

预训练的价值不必完全来自真实语义。只要预训练任务迫使模型学习某些对下游任务有用的序列处理能力，例如长距离依赖、位置关系和上下文补全，模型就可能在自然语言任务上获得更好的初始化。

4.4 本章小结

人工数据预训练把自监督学习从“语料越真实越好”的直觉中抽离出来。纯随机数据帮助有限，但带有配对关系或长程 shuffle 结构的数据可以显著改善下游 NLP 任务。这说明自监督预训练的关键能力至少部分来自序列结构学习，而不仅是自然语言语义记忆。

5 三个故事的共同解释

跨语言、跨学科和人工数据三个故事看似越来越离奇：先是英文到中文，再是语言到 DNA 与语音，最后甚至是人工 token 到自然语言任务。但它们都指向同一个问题：**预训练模型的可迁移能力来自哪些层次？**




图 31: 课程结尾回到三个故事：跨语言、跨学科和人工数据预训练，共同说明 self-supervised learning 仍有许多未解之谜。³¹

5.1 层次一：表示空间的对齐

跨语言故事展示的是表示空间对齐。同一语义在不同语言里可以落到相近区域，使英文下游模型能处理中文输入。但表示不是完全无语言差异的：语言身份也以某种方向或偏移保留下来。这里的迁移依赖“共享语义结构 + 可处理的语言偏移”。

³¹ 视频画面时间区间：00:53:30–00:53:42。

5.2 层次二：序列建模的通用能力

跨学科故事说明，预训练模型可能学到与具体语义无关的序列建模技巧。DNA、蛋白质、音乐和语音 token 都不是英文句子，但它们也是序列，也可能存在局部模式、远程依赖和分类相关结构。预训练参数提供的不是目标领域知识本身，而是处理序列任务的有利初始状态。

5.3 层次三：优化路径的改善

预训练还可能改变 fine-tuning 的优化几何。随机初始化的模型需要同时学会基本表示、序列交互和任务边界；预训练模型已经有一套可用的中间表示和注意力模式，因此下游训练更容易收敛到好解。跨学科曲线和语音问答实验都支持这种解释。

5.4 层次四：长距离上下文整合

人工数据故事特别突出长距离阅读能力。若预训练任务要求模型用很长范围的上下文来预测缺失 token，模型可能学到自然语言任务中也有用的能力。许多 NLP 任务，例如问答、推论、句子分类，都不只依赖局部词汇，而需要整合句子或段落中的多处信息。

仍然不能过度解释

这些实验说明预训练可以迁移，但没有证明模型拥有人类式理解。尤其在人造数据与跨学科任务中，提升可能来自优化、结构归纳偏置或长程依赖处理，而不是语义理解。解释模型能力时，应区分“任务表现提升”和“理解机制明确”。

5.5 本章小结

三个故事共同说明，自监督预训练的能力不是单一来源。它既可能来自语义对齐，也可能来自序列建模、长程依赖、优化初始化和可迁移的表示结构。越是离奇的实验，越提醒我们不要只用“模型记住了语言知识”解释预训练；真正的问题是找出哪些结构性能力在不同任务之间共享。

6 总结与延伸

本讲的表面主题是“BERT 的三个故事”，实质主题是自监督学习的可迁移性。第一个故事中，多语言 BERT 通过共享预训练目标，让不同语言的表示出现语义对齐，同时保留语言身份信息；因此英文下游模型可以迁移到中文，但迁移效果仍受语言偏移影响。第二个故事中，BERT 的预训练能力跨出自然语言，帮助 DNA、蛋白质、音乐和语音问答等任务，说明预训练提供的可能是更一般的序列建模与优化优势。第三个故事中，人工数据预训练进一步表明：即使没有真实语言语义，只要数据结构迫使模型学习长距离关系，也可能对自然语言任务有帮助。

可以把整堂课压缩成一句话：**自监督预训练的价值不只是知识，而是把模型放到一个更会读序列、更会利用上下文、更容易被下游任务塑形的状态。**

6.1 与前后课程的连接

前面讲 BERT、GPT 和各种自监督模型时，我们通常关注预训练任务本身：MLM、next token prediction、contrastive learning、masked acoustic modeling 等。本讲则更像是对这些任务的“拆机”：为什么一个看似简单的目标会产生超出原任务范围的能力？这与后续 domain adaptation、transfer learning、foundation model 和 representation analysis 都有直接关系。

6.2 三个可以继续追问的问题

1. **哪些能力真正来自语义，哪些来自结构？** 多语言迁移看起来依赖语义对齐，但人工数据说明非语义结构也很重要。区分二者需要更可控的实验。
2. **预训练主要改善 optimization 还是 generalization？** 如果预训练只是让训练更容易，和它真正学到可泛化知识，是两种不同解释。实际模型往往二者兼有。
3. **长距离上下文是否是自监督成功的核心因素？** shuffle 实验显示长范围关系很重要，但自然语言还包含语法、语义、篇章结构和世界知识。长程依赖可能是必要因素之一，而非完整答案。

实践启发

当一个预训练模型在新领域有效时，不要马上假设它“理解”了新领域。更务实的分析路径是：检查输入是否可表示为序列、任务是否需要长程上下文、fine-tuning 是否受益于更好初始化、以及预训练表示是否与下游决策边界相容。

这也是本讲最后的开放感所在：self-supervised learning 已经在很多任务上表现强大，但它为什么强、强在哪里、哪些能力可以被人工设计出来，仍然有许多未解之谜。三个故事不是给出最终答案，而是提供三把钥匙：看表示空间、看跨领域迁移、看可控人工数据。用这三把钥匙，我们可以更细地理解下一代预训练模型到底学到了什么。