

强化学习概述（三）：Actor-Critic

Value Function, Monte Carlo, Temporal Difference, Advantage,
and Shared Actor-Critic Networks



基于李宏毅老师《机器学习 2025》课程内容整理
2026 年 6 月 9 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 34 分 40 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=48>

目录

1 从 Policy Gradient 到 Actor-Critic	3
1.1 本章小结	4
2 Critic 与 Value Function	4
2.1 为什么 value 可以当 baseline	5
2.2 本章小结	6
3 如何估计 Value: Monte Carlo 与 Temporal Difference	6
3.1 Monte Carlo: 等 episode 结束后回头监督	6
3.2 Temporal Difference: 用一步转移 bootstrap	7
3.3 MC vs. TD: 为什么两者可能给出不同答案	8
3.4 本章小结	9
4 Version 3.5: 用 $V(s)$ 做 State-dependent Baseline	9
4.1 Advantage 的直觉	10
4.2 实际含义: 奖励高不一定动作好	11
4.3 本章小结	11
5 Version 4: TD Error 与 Advantage Actor-Critic	12
5.1 TD error 的意义	13
5.2 为什么这叫 Actor-Critic	13
5.3 本章小结	14
6 实现技巧、DQN 展望与课堂问答	14
6.1 共享 actor 与 critic 的前几层	14
6.2 DQN: 直接用 critic 决定动作的另一条线	15
6.3 随机环境下的 value 是期望值	16
6.4 Actor 的 distribution 从哪里来	17
6.5 本章小结	17
7 总结与延伸	17

1 从 Policy Gradient 到 Actor-Critic

前两讲已经把 reinforcement learning 的 actor 训练写成了一种带权重的分类问题。Actor 看到状态 s_t ，输出动作分布 $\pi_\theta(a | s_t)$ ；如果最后发现动作 a_t 对后续 reward 有帮助，就提高 $\pi_\theta(a_t | s_t)$ ；如果它伤害结果，就降低这个概率。形式上可以把 actor 的目标写成

$$L_{\text{actor}}(\theta) = - \sum_t A_t \log \pi_\theta(a_t | s_t),$$

其中 A_t 是第 t 步动作的权重，也就是这一步动作应该被鼓励还是被惩罚的强度。

P47 已经介绍了几种构造 A_t 的方法：从 immediate reward，到累计未来 reward，再到 discounted cumulative reward，最后再减去一个 baseline b 。这些版本都在回答同一个问题：如何把整场游戏的结果分配回每一步动作？P48 的关键推进是：baseline 不应该只是一个全局常数，而应该看当前状态。



Outline

What is RL? (Three steps in ML)

Policy Gradient

Actor-Critic

Reward Shaping

No Reward: Learning from Demonstration

图 1: 课程大纲从 Policy Gradient 推进到 Actor-Critic：本讲要引入一个评价 actor 的 critic，再用它改进 actor 的训练信号。¹

如果在一个状态 s_t 里，本来随便做一个动作就很容易拿高分，那么某一次拿到高分未必说明 a_t 特别好；反过来，如果状态本来很危险，最终只损失一点点也可能是好动作。也就是说，动作评价应该与状态难度绑定。Actor-Critic 的核心思想就是训练另一个模型 critic 来估计“在这个状态下，当前 actor 平均能做到什么水平”，再用实际结果与这个平均水平相减。

Actor-Critic 的一句话版本

Actor 负责决定怎么行动，critic 负责评价当前 actor 在某个状态下的平均表现。训练 actor 时，我们不只问“这一步之后的 return 是多少”，还问“它比当前状态下的平均 return 好多少”。这个相对差值就是 advantage。

¹ 视频画面时间区间：00:00:00-00:00:15。

本讲先定义 critic/value function，再讲如何用 Monte Carlo 或 Temporal Difference 估计 value，最后把 value 放回 policy gradient，得到常用的 Advantage Actor-Critic。

1.1 本章小结

P48 并不是另起炉灶，而是补上 P47 中 baseline 的精细版本。以前的 b 是全局平均；现在的 $V^\theta(s_t)$ 是 state-dependent baseline。这个替换让 actor 的训练信号从“绝对回报”变成“相对当前状态平均水平的优势”。

2 Critic 与 Value Function

Critic 的工作是评价 actor。假设当前 actor 的参数是 θ ，它的 policy 是 π_θ 。Critic 并不是抽象地判断某个画面好不好，而是判断：**如果 actor θ 看到状态 s ，接下来继续用这个 actor 与环境互动，预期可以得到多少 discounted cumulative reward。**

本讲采用最常用的一种 critic：value function，记为

$$V^\theta(s).$$

它的输入是 state 或 observation s ，输出是一个 scalar。这个 scalar 的语义是

$$V^\theta(s) = \mathbb{E}_{\pi_\theta} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s \right],$$

也就是从状态 s 开始，之后一直按照当前 actor π_θ 行动，能得到的折扣累计 reward 的期望值。

早发快学深度学习课堂 Bilibili

Critic

- Critic: Given actor θ , how good it is when observing s (and taking action a)
- Value function $V^\theta(s)$: When using actor θ , the discounted *cumulated* reward expects to be obtained after seeing s




图 2: Value function $V^\theta(s)$ 输入状态 s ，输出一个 scalar，用来估计 actor θ 从该状态继续行动时的 discounted cumulative reward。²

²视频画面时间区间：00:02:15–00:02:30。


这里上标 θ 很重要。 $V^\theta(s)$ 不是状态本身的绝对价值，而是**对某个 actor 而言的价值**。同一个游戏画面，对很强的 actor 可能意味着后面可以拿很多分；对很弱的 actor 可能意味着马上失败。因此 value function 必须随着被评价 actor 的变化而变化。



Critic

$$G'_1 = r_1 + \gamma r_2 + \gamma^2 r_3 + \dots$$

- Critic: Given actor θ , how good it is when observing s (and taking action a)
- Value function $V^\theta(s)$: When using actor θ , the discounted *cumulated* reward expects to be obtained after seeing s



The output values of a critic depend on the actor evaluated.

图 3: 同一个画面在不同 actor 下可能有不同 value: 好的 actor 看见还有很多目标的画面, 预计可以继续获得高 reward; 差的 actor 未必能做到。³

Value function 与 Q function

本讲聚焦 $V^\theta(s)$, 它只看 state, 不指定下一步 action。另一种常见 critic 是 $Q^\theta(s, a)$, 它评价“在 state s 先采取 action a , 之后再按照 actor θ 行动”的 expected return。Actor-Critic 这讲使用 V 来当 baseline; DQN 一类方法则更常直接使用 Q 来选动作。

2.1 为什么 value 可以当 baseline

在 policy gradient 中, 训练样本是 (s_t, a_t) , 权重是 A_t 。如果只用 discounted return G_t , 则

$$A_t = G_t.$$

这个数表示实际采样到的轨迹有多好。但 G_t 没有区分“状态本来就简单”和“动作真的特别好”。如果用 $V^\theta(s_t)$ 估计当前状态的平均水平, 那么

$$G_t - V^\theta(s_t)$$

就表示实际结果比平均水平高多少。这个差值更适合当作 actor 的训练权重, 因为 actor 真正应该学习的是: 在相同状态下, 哪些动作比平均抽样更值得增加概率。

³视频画面时间区间: 00:06:00-00:06:15。

2.2 本章小结

Critic/value function 输出的不是动作概率，而是一个状态的 expected return。它依赖当前 actor θ ，因此 actor 变了，critic 理论上也要重新适应。把 $V^\theta(s_t)$ 当成 baseline 后，policy gradient 的信号会从绝对好坏转为相对好坏。

3 如何估计 Value: Monte Carlo 与 Temporal Difference

Value function 本身也是一个需要训练出来的模型。给定一个状态 s_t ，我们希望 critic 输出接近真实的 expected return。但真实期望无法直接知道，因为它涉及未来所有可能轨迹。因此课程介绍两类经典估计方式：Monte Carlo based approach 与 Temporal Difference based approach。

3.1 Monte Carlo: 等 episode 结束后回头监督

Monte Carlo 的想法最直接：让 actor 从某个状态 s_t 开始继续玩到 episode 结束，把实际得到的 discounted return 当作监督信号。若从 t 开始到终止时刻 T 的 reward 是 $r_t, r_{t+1}, \dots, r_T$ ，则

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots + \gamma^{T-t} r_T.$$

然后训练 critic 让

$$V^\theta(s_t) \approx G_t.$$

对应的平方误差可以写成

$$L_{\text{critic}}^{\text{MC}} = \frac{1}{2} (V^\theta(s_t) - G_t)^2.$$



How to estimate $V^\theta(s)$

• Monte-Carlo (MC) based approach

The critic watches actor θ to interact with the environment.

After seeing s_a ,

Until the end of the episode,
the cumulated reward is G'_a




图 4: Monte Carlo based approach: 看到状态 s_t 后让 actor 继续与环境互动，直到 episode 结束，再用实际累计 reward G_t 作为 $V^\theta(s_t)$ 的 target。⁴

⁴ 视频画面时间区间：00:07:15–00:07:30。

MC 的优点是 target 很容易理解：它就是实际发生的完整结果。缺点也来自这里：必须等 episode 结束才能知道 target，而且单条 trajectory 的随机性很大。如果环境有随机性，或者 actor 自己是 stochastic policy，那么同一个 s_t 后面可能出现很多不同结果；一条样本的 G_t 只是其中一个 sample。

3.2 Temporal Difference: 用一步转移 bootstrap

Temporal Difference，简称 TD，不等待完整 episode。它只需要观察一步转移

$$(s_t, a_t, r_t, s_{t+1}),$$

就可以对 $V^\theta(s_t)$ 做更新。关键关系是 Bellman 式的自洽：

$$V^\theta(s_t) \approx r_t + \gamma V^\theta(s_{t+1}).$$

也就是说，从 s_t 开始的价值，应该等于当前立刻拿到的 reward，加上走到 s_{t+1} 后的未来价值。



How to estimate $V^\pi(s)$

- Temporal-difference (TD) approach

$\cdots s_t, a_t, r_t, s_{t+1} \cdots$

图 5: Temporal Difference based approach 只需要一段局部经验 (s_t, a_t, r_t, s_{t+1}) ，不必等整局结束。⁵

⁵视频画面时间区间：00:08:30–00:08:45。

How to estimate $V^\pi(s)$

• Temporal-difference (TD) approach




图 6: TD 使用 $V^\theta(s_t) \approx r_t + \gamma V^\theta(s_{t+1})$ 的关系来训练 critic；下一状态的 value 被拿来 bootstrap 当前状态的 target。⁶

TD 的 critic loss 可写成

$$L_{\text{critic}}^{\text{TD}} = \frac{1}{2} (V^\theta(s_t) - (r_t + \gamma V^\theta(s_{t+1})))^2.$$

实际实现时，右边的 $V^\theta(s_{t+1})$ 常被视作 target 的一部分，不让同一次反向传播同时追着两边跑；许多算法会用 target network、detach 或延迟更新来稳定训练。

MC 与 TD 的核心取舍

Monte Carlo 使用完整实际回报，bias 较小但 variance 较大，且必须等 episode 结束；TD 使用一步 reward 加下一状态的估计值，variance 较小且可在线更新，但 target 本身依赖 critic 的估计，因此会引入 bootstrap bias。

3.3 MC vs. TD：为什么两者可能给出不同答案

课程用 Sutton 书中的例子说明：即使观察同一批经验，MC 与 TD 也可能对某个状态给出不同 value。假设 critic 观察到若干 episode，其中从 s_b 出发多数时候 reward 为 1 后结束，少数时候 reward 为 0；因此 $V(s_b)$ 约为 $3/4$ 。但从 s_a 出发的那条完整经验刚好走到 s_b 后最终得到 0。

MC 只看从 s_a 出发那条完整 trajectory 的最终 return，因此会说

$$V_{\text{MC}}(s_a) = 0.$$

TD 则利用局部转移 $s_a \rightarrow s_b$ ，并认为

$$V_{\text{TD}}(s_a) \approx r + V(s_b) = 0 + \frac{3}{4} = \frac{3}{4}.$$

⁶视频画面时间区间：00:11:00–00:11:15。

MC v.s. TD

[Sutton, v2,
Example 6.4]

- The critic has observed the following 8 episodes

- $s_a, r = 0, s_b, r = 0, \text{END}$

- $s_b, r = 1, \text{END}$

$$V^\theta(s_b) = 3/4$$

- $s_b, r = 1, \text{END}$

- $s_b, r = 1, \text{END}$

$$V^\theta(s_a) = ? \quad 0? \quad 3/4?$$

- $s_b, r = 1, \text{END}$

- $s_b, r = 1, \text{END}$

$$\text{Monte-Carlo: } V^\theta(s_a) = 0$$

- $s_b, r = 1, \text{END}$

Temporal-difference:

- $s_b, r = 0, \text{END}$

(Assume $\gamma = 1$, and the actions are ignored here.)

$$V^\theta(s_a) = V^\theta(s_b) + r$$

$$3/4 \quad 3/4 \quad 0$$

图 7: Sutton 例子中, MC 使用从 s_a 出发的完整 sample 得到 $V(s_a) = 0$; TD 通过 $s_a \rightarrow s_b$ 的转移与 $V(s_b) = 3/4$ 得到 $V(s_a) = 3/4$ 。⁷

这个例子不是说 MC 或 TD 谁永远正确, 而是强调二者利用资料的方式不同。MC 尊重完整样本, 所以在样本少时可能被单条偶然结果影响; TD 尊重状态之间的局部关系, 所以可以更快把 s_b 的统计信息传回 s_a , 但前提是 $V(s_b)$ 的估计要可靠。

从估计角度看 TD

TD 可以被理解为“边学边猜”: critic 还没有真的看到从 s_t 到终局的所有结果, 却先用 s_{t+1} 的 value 来补上未来部分。这个技巧让 RL 可以做 online learning, 也让 value 在状态图上传播得更快。

3.4 本章小结

MC 和 TD 都是在训练 $V^\theta(s)$, 但 target 来源不同。MC 的 target 是完整 episode 的实际 return; TD 的 target 是 $r_t + \gamma V^\theta(s_{t+1})$ 。Actor-Critic 中常用 TD, 因为它不必等待整局结束, 也正好能导出后面的 TD error advantage。

4 Version 3.5: 用 $V(s)$ 做 State-dependent Baseline

回到 actor 的训练权重。P47 的 baseline 版本可以写成

$$A_t = G'_t - b,$$

⁷视频画面时间区间: 00:18:30-00:18:45。

其中 G'_t 表示 discounted return-to-go, b 是一个与 state 无关的平均值。P48 的 Version 3.5 把 b 换成 critic 输出：

$$A_t = G'_t - V^\theta(s_t).$$

这一步看起来只是把常数换成函数，但语义变化很大：baseline 从“整体平均表现”变成了“在这个 state 下当前 actor 的平均表现”。




图 8: Version 3.5: 训练 actor 时不再减固定 baseline b , 而是减去 critic 对当前状态的估计 $V^\theta(s_t)$ 。⁸

4.1 Advantage 的直觉

在状态 s_t 下, actor 实际采取了动作 a_t , 之后得到一个 sample return G'_t 。但如果同样在 s_t 下, 不一定采取 a_t , 而是按照 actor 的动作分布随机 sample 动作, 再继续玩下去, 会得到一个平均 return。这个平均 return 就是 $V^\theta(s_t)$ 。

因此

$$A_t = G'_t - V^\theta(s_t)$$

可以读成：

- 若 $A_t > 0$, 实际动作 a_t 比从当前 policy 随机抽动作的平均结果更好, 应提高 $\pi_\theta(a_t | s_t)$ 。
- 若 $A_t < 0$, 实际动作 a_t 比平均结果更差, 应降低 $\pi_\theta(a_t | s_t)$ 。
- 若 $A_t \approx 0$, 它大致只是平均水平, 更新幅度可以很小。

⁸视频画面时间区间: 00:21:00-00:21:15。

Version 3.5

$$\{s_t, a_t\} \quad A_t = G'_t - V^\theta(s_t)$$




图 9: Advantage 的直觉: G'_t 是实际 sample 的结果, $V^\theta(s_t)$ 是该状态下按 actor 分布行动的平均结果; 两者相减判断 a_t 是否 better than average。⁹

为什么 baseline 可以依赖 state

在 policy gradient 中, baseline 只要不依赖当前实际 action a_t , 就不会改变梯度期望, 只会改变 variance。 $V^\theta(s_t)$ 依赖 state, 但不依赖“这一次抽到的动作是哪一个”, 因此可以作为合法 baseline。它让训练更稳定, 同时保留 policy gradient 的方向。

4.2 实际含义: 奖励高不一定动作好

Version 3.5 带来的一个重要观念是: 高 return 不等于动作好, 低 return 也不等于动作差。动作的好坏必须放在同一个状态的背景下比较。例如:

- 简单状态下拿到 10 分, 但该状态平均能拿 20 分, 则 $A_t < 0$, 动作应被抑制。
- 困难状态下只拿到 -1 分, 但该状态平均是 -10 分, 则 $A_t > 0$, 动作反而值得鼓励。

这正是 advantage 的作用: 它把 credit assignment 从绝对分数改成相对分数。

4.3 本章小结

Version 3.5 的 actor loss 可以写成

$$L_{\text{actor}} = - \sum_t (G'_t - V^\theta(s_t)) \log \pi_\theta(a_t | s_t).$$

⁹视频画面时间区间: 00:24:45-00:25:00。

这里的 critic 不是直接替 actor 选动作，而是提供 state-dependent baseline。Actor 仍然学习动作分布；critic 负责告诉 actor：这次动作相对于当前状态的平均水平到底好不好。

5 Version 4: TD Error 与 Advantage Actor-Critic

Version 3.5 仍然有一个问题： G'_t 是单条 sample trajectory 的 return。它可能特别幸运，也可能特别倒霉。用一个 sample return 去减一个平均值 $V^\theta(s_t)$ ，variance 仍然可能很大。课程接着提出 Version 4：不要等整条 trajectory 的 G'_t ，而是把 G'_t 的未来部分替换成下一状态的 expected value。

从 s_t 采取 a_t 后，得到 immediate reward r_t ，并跳到 s_{t+1} 。从 s_{t+1} 往后，如果继续使用当前 actor，平均能得到 $V^\theta(s_{t+1})$ 。因此采取 a_t 后的 expected return 可以近似为

$$r_t + \gamma V^\theta(s_{t+1}).$$

把它与未指定动作前的平均 value $V^\theta(s_t)$ 相减，就得到

$$A_t = r_t + \gamma V^\theta(s_{t+1}) - V^\theta(s_t).$$

这个量也叫 TD error，通常记为

$$\delta_t = r_t + \gamma V^\theta(s_{t+1}) - V^\theta(s_t).$$




图 10: Version 4 把实际完整 return 的未来部分换成下一状态的 value：用 $r_t + \gamma V^\theta(s_{t+1}) - V^\theta(s_t)$ 作为 actor 的权重。¹⁰

¹⁰视频画面时间区间：00:26:00-00:26:15。




图 11: Advantage Actor-Critic 的常用形式: $A_t = r_t + \gamma V^\theta(s_{t+1}) - V^\theta(s_t)$, 也就是用 TD error 评价动作优劣。¹¹

5.1 TD error 的意义

δ_t 同时有两个解释:

- 对 critic 来说, 它是预测误差: 当前 value $V^\theta(s_t)$ 与 TD target $r_t + \gamma V^\theta(s_{t+1})$ 的差距。
- 对 actor 来说, 它是 advantage: 实际采取 a_t 后跳到的结果, 比当前状态平均水平更好还是更差。

若 $\delta_t > 0$, 说明采取 a_t 后的 immediate reward 加未来 value 高于 $V^\theta(s_t)$, 于是 actor 应增加 a_t 的概率; 若 $\delta_t < 0$, 则说明它低于平均, 应减少该动作概率。因此 actor loss 可以写成

$$L_{\text{actor}}^{\text{A2C}} = - \sum_t \delta_t \log \pi_\theta(a_t | s_t).$$

Actor-Critic 的训练循环

一次典型更新可以概括为: 用 actor 与环境互动得到 (s_t, a_t, r_t, s_{t+1}) ; 用 TD target 更新 critic; 计算 $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$; 把 δ_t 当作权重更新 actor。Critic 学得越准, actor 收到的 advantage 信号越可靠。

5.2 为什么这叫 Actor-Critic

在 Version 4 中, actor 与 critic 互相依赖:

¹¹ 视频画面时间区间: 00:28:00-00:28:15。

- Actor 决定采样哪些动作，也决定 critic 要评价哪一个 policy。
- Critic 给 actor 提供训练权重，告诉它哪些动作相对平均更好。
- Actor 更新后 policy 变了， $V^\theta(s)$ 的目标也随之改变，critic 需要继续追上新的 actor。

因此这不是先训练好一个永远不变的 critic，再训练 actor；更接近一个交替适应的过程。实际实现中常见做法是一边收集经验，一边同时优化 actor loss 与 critic loss。

Critic 不准会怎样

如果 critic 严重高估或低估某些状态，actor 会收到错误的 advantage 信号。例如 $V^\theta(s_t)$ 被低估时，很多普通动作都会看起来像好动作； $V^\theta(s_{t+1})$ 被高估时，actor 也可能错误地偏好通往该状态的动作。Actor-Critic 的稳定性很大程度取决于 critic 的质量。

5.3 本章小结

Version 4 把 Version 3.5 中的 $G'_t - V^\theta(s_t)$ 改写成 TD error:

$$\delta_t = r_t + \gamma V^\theta(s_{t+1}) - V^\theta(s_t).$$

这一步减少了等待完整 episode 的需求，也让 actor 与 critic 通过同一个 TD 信号连接起来。常见的 Advantage Actor-Critic 就是在这个公式上建立的。

6 实现技巧、DQN 展望与课堂问答

6.1 共享 actor 与 critic 的前几层

如果输入是游戏画面，actor 与 critic 都需要从同一张图中提取视觉特征。Actor 最后输出每个动作的分数或概率；critic 最后输出一个 scalar value。前面的视觉特征抽取网络很可能可以共用，尤其是 CNN 层。

Tip of Actor-Critic

- The parameters of actor and critic can be shared.




图 12: Actor 与 critic 可以共享前几层参数: 共同的特征抽取网络之后, actor head 输出动作分布, critic head 输出 value scalar。¹²

共享网络的好处是节省参数, 也让 actor 与 critic 使用相同的状态表示。但实现时要注意两个 loss 的平衡: actor loss、critic loss、entropy regularization 等项若尺度差异很大, 可能会让共享层偏向某一边。因此很多实现会写成

$$L = L_{\text{actor}} + c_v L_{\text{critic}} - c_H H(\pi_\theta),$$

其中 $H(\pi_\theta)$ 是 entropy, 用来鼓励探索, c_v, c_H 是调权重的系数。

6.2 DQN: 直接用 critic 决定动作的另一条线

课程结尾提到, RL 里还有一类方法更直接地使用 critic: critic 不只提供 baseline, 而是直接参与动作选择。最著名的例子是 Deep Q Network (DQN)。DQN 学的是

$$Q(s, a),$$

也就是在状态 s 先采取动作 a 后的 expected return。选动作时可以直接取

$$a^* = \arg \max_a Q(s, a).$$

这与本讲的 actor-critic 不同: actor-critic 保留一个显式 actor 来输出 policy, critic 主要辅助评价; DQN 则让 Q 本身承担选动作的核心角色。

¹² 视频画面时间区间: 00:29:15–00:29:30。

Outlook: Deep Q Network (DQN)

Video:

https://youtu.be/o_g9JUMw10c

https://youtu.be/2-zGCx4iv_k

<https://arxiv.org/abs/1710.02298>




图 13: DQN 展望：课程提到 DQN 及其大量变形，例如 DDQN、Dueling DDQN、Distributional DQN、Noisy DQN 与 Rainbow。¹³

图中 Rainbow 是一个代表性工作，它把多个 DQN 改进技巧组合起来。课程没有在本讲展开 DQN 细节，而是把它作为 RL 中另一条路线提示给同学。P48 的主线仍然是：如何用 critic 改进 policy gradient。

6.3 随机环境下的 value 是期望值

课堂问答中有一个重要澄清：如果环境具有随机性，那么看到同一个 observation 后，后面发生的事情不一定固定。 $V^\theta(s)$ 在这种情况下表示的是平均值/期望值，不是某一条确定路径的结果。形式上，

$$V^\theta(s) = \mathbb{E}[G_t | s_t = s, \pi_\theta],$$

期望同时包含 actor 抽动作的随机性与环境转移的随机性。

这也解释了为什么 sampling 在 RL 中非常关键。若训练过程中从未观察到某些状态或某些转移，critic 就无法凭空学会它们的 value；若 sample 覆盖不均，value 估计也会偏。老师特别强调，reinforcement learning 的最终表现与 sample 的好坏关系很大。

没有观察到的状态很难被正确训练

在监督学习中，训练资料覆盖不足会造成泛化问题；在 RL 中，这个问题更尖锐，因为资料本身由 actor 采样产生。Actor 若从不探索某些区域，critic 就缺乏这些区域的 value target，actor 也收不到关于这些动作的正确 advantage 信号。

¹³ 视频画面时间区间：00:29:30-00:29:45。

6.4 Actor 的 distribution 从哪里来

另一个问答涉及 actor 的动作分布。若 action 是离散的, actor 可以像 classifier 一样: 输入 state s , 输出每个 action 的 score, 再通过 softmax 变成概率分布

$$\pi_{\theta}(a | s) = \frac{\exp z_a(s)}{\sum_{a'} \exp z_{a'}(s)}.$$

实际行动时从这个分布中 sample, 训练时再根据 advantage 调整对应 action 的 log probability。这个观点把 RL 中的 actor 与分类模型连接起来: 差别不在网络形式, 而在监督信号不是人工标注的 label, 而是来自环境互动后的 reward 与 critic。

6.5 本章小结

实现 Actor-Critic 时, actor 与 critic 可以共享特征抽取层, 再分出两个 head。DQN 是另一类直接使用 critic/Q function 选动作的方法。课堂问答补充了两个容易误解的点: 随机环境下 V 是期望值; actor 的动作 distribution 通常由网络输出 score 后 softmax 得到。

7 总结与延伸

这一讲可以压缩成一条公式演化链:

$$A_t = G'_t - b \implies A_t = G'_t - V^{\theta}(s_t) \implies A_t = r_t + \gamma V^{\theta}(s_{t+1}) - V^{\theta}(s_t).$$

第一步仍是 P47 的固定 baseline; 第二步引入 critic, 让 baseline 依赖 state; 第三步使用 TD error, 把完整 sample return 换成一步 reward 加下一状态 value, 得到 Advantage Actor-Critic。

本讲最值得带走的观念

Actor-Critic 的 critic 不是为了取代 actor, 而是为了让 actor 知道“这次动作相对于当前状态的平均水平是否更好”。所以 advantage 不是 reward 本身, 而是相对评价; TD error 则是一个可以在线计算的相对评价。

从学习流程看, critic 解决的是评价问题, actor 解决的是决策问题。Critic 越能准确估计当前 actor 的 expected return, actor 的 policy gradient 权重就越有意义; actor 越能探索到有信息量的状态, critic 的训练资料就越充分。两者互相促进, 也互相拖累, 这正是 Actor-Critic 系列方法既强大又不总是稳定的原因。

下一段课程将进入 Reward Shaping。它关心的是另一个 RL 训练难点: 如果环境给的 reward 太稀疏、太延迟, actor 与 critic 都很难学习。Reward Shaping 会尝试重新设计或补充 reward, 让学习过程更容易获得有效信号。