

强化学习概述（四）：Reward Shaping

Sparse Reward, Hand-crafted Intermediate Rewards, and
Curiosity-driven Exploration



基于李宏毅老师《机器学习 2025》课程内容整理
2026 年 6 月 9 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 17 分 35 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=49>

目录

1 从 Actor-Critic 的公式看到 Sparse Reward	3
1.1 本章小结	4
2 Reward Shaping: 给学习过程补中间信号	4
2.1 Shaping 与真实目标的关系	5
2.2 本章小结	5
3 VizDoom 与手工奖励设计	5
3.1 手工 shaping 的局限	6
3.2 本章小结	7
4 Curiosity-driven Exploration: 把新奇性当作奖励	7
4.1 为什么要强调 meaningful	7
4.2 无外部 reward 时的探索	8
4.3 本章小结	9
5 Reward Shaping 的风险与使用原则	9
5.1 本章小结	9
6 总结与延伸	9

1 从 Actor-Critic 的公式看到 Sparse Reward

上一讲得到 Advantage Actor-Critic 的核心权重：

$$A_t = r_t + \gamma V^\theta(s_{t+1}) - V^\theta(s_t).$$

Actor 的更新依赖 A_t ： $A_t > 0$ 时提高动作 a_t 的概率， $A_t < 0$ 时降低它。因此强化学习能不能学起来，很大程度取决于环境能不能给出足够有信息量的 reward。



图 1: 课程从 Actor-Critic 转入 Reward Shaping: 问题不再是怎样用 reward 更新 actor, 而是 reward 本身是否足够有信息量。¹

Sparse reward 指的是大多数时间 $r_t = 0$, 只有极少数关键时刻才出现非零 reward。比如一个机械臂只有在真正把螺丝锁好时才得到正 reward, 其他所有动作都没有反馈; 又比如游戏中只有通关、杀敌或死亡时才有奖励, 探索、靠近目标、避开危险本身没有即时分数。




图 2: Sparse reward 下, 若大多数 $r_t = 0$, actor-critic 产生的训练权重缺乏区分度, 模型很难知道哪些动作是好是坏。²

¹ 视频画面时间区间: 00:00:00-00:00:15。

问题在于，当 reward 大量为零时，训练资料虽然仍然包含许多 state-action pair，但这些 pair 的标签几乎没有差异。对 actor 来说，很多动作都收到接近零的 advantage；对 critic 来说，许多状态的 value target 也差不多。学习过程会变得像在黑暗里试探：系统知道自己做了很多动作，却不知道哪些动作把它带向成功，哪些动作只是浪费时间。

Sparse reward 与 delayed reward 不完全一样

Delayed reward 强调好坏反馈来得晚；sparse reward 强调非零反馈出现得少。二者经常同时发生：真正有意义的 reward 很晚才出现，而且出现次数很少。这样的任务会严重放大 credit assignment 的难度。

1.1 本章小结

Actor-Critic 需要 reward 形成训练信号。若环境大部分时间给零 reward， A_t 很难区分动作好坏，critic 也缺乏可学习的 value target。Reward Shaping 正是为了解决这个反馈太稀疏的问题。

2 Reward Shaping: 给学习过程补中间信号

Reward Shaping 的基本想法很直接：在原始环境 reward 之外，人为设计额外 reward，引导 agent 更快发现有用行为。可以把训练时使用的 reward 写成

$$r_t^{\text{train}} = r_t^{\text{ext}} + \lambda r_t^{\text{shape}},$$

其中 r_t^{ext} 是环境原本给的外部 reward， r_t^{shape} 是设计者补充的 shaping reward， λ 控制它的强度。




图 3: Reward shaping: 当原始 reward 太稀疏时，开发者额外定义奖励来引导 agent，例如在机械臂锁螺丝任务中给中间动作反馈。³

直觉上，shaping reward 像是给学习者提供阶段性提示。最终目标可能是“完成任务”，但完成任务前需要许多子目标：靠近目标、保持姿态、避开障碍、拿到资源、不要空耗生命值等。如果这些中间动作完全没有反馈，agent 需要靠随机探索撞到完整成功轨迹；如果每个有意义的中间进展都有小奖励，学习速度通常会明显提高。

² 视频画面时间区间：00:00:45–00:01:00。

³ 视频画面时间区间：00:03:30–00:03:45。

Reward Shaping 的作用

Reward shaping 不是改变神经网络架构，而是改变训练信号。它把稀疏、延迟的最终奖励拆成更密集的中间反馈，让 actor 更早知道哪些行为方向值得探索，也让 critic 更容易估计不同状态的 value。

2.1 Shaping 与真实目标的关系

设计 shaping reward 时最危险的地方是：中间奖励必须服务于真实目标。若 shaping reward 与最终目标不一致，agent 会优化设计者给出的分数，而不是完成真正任务。例如若只奖励机器人手臂靠近某个位置，它可能学会停在附近而不完成装配；若只奖励游戏角色移动距离，它可能学会到处乱跑而不完成关卡。

因此 reward shaping 的难点不是“多给奖励”，而是“给对奖励”。好的 shaping reward 应该满足三个条件：

- 密集：比原始 reward 更频繁，让训练有足够反馈。
- 对齐：鼓励的行为确实提高最终任务成功率。
- 适度：不能大到压过原始目标，也不能小到没有训练效果。

2.2 本章小结

Reward shaping 通过额外设计 reward，让 agent 在到达最终目标前就能获得方向感。它能显著改善 sparse reward 任务，但也会带来 reward hacking 风险：agent 会忠实优化你写下的 reward，而不是你心里真正想要的行为。

3 VizDoom 与手工奖励设计


课程用 VizDoom 竞赛作为例子。Doom 类游戏中，最终胜负、击杀、死亡等信号相对稀疏；如果只依赖这些原始分数，agent 可能很久都学不到有效行为。因此实践中常把多种中间事件加入 reward。



图 4: VizDoom AI Competition 示例：Doom 环境提供了典型的稀疏/延迟反馈场景，因此经常需要设计额外 reward 来帮助学习。⁴

画面中的 reward table 展示了若干手工设计的 shaping 项。例如：

- living: 对单纯活着但没有进展施加小惩罚，避免 agent 什么都不做。
- health_loss: 失去生命值给负 reward，鼓励避开攻击。
- ammo_loss: 消耗弹药给负 reward，避免无意义开火。
- health_pickup: 捡到补血道具给正 reward。
- ammo_pickup: 捡到弹药给正 reward。
- movement / distance: 对移动距离或有效前进给小奖励，鼓励探索地图。



The screenshot shows a video titled "Reward Shaping" with a URL <https://openreview.net/forum?id=Hk3mPK5gg¬elid=Hk3mPK5gg>. It features a table of parameters and three diagrams illustrating the reward system.

Parameters	Description	FlatMap	CIGTrack1
living	Penalize agent who just lives	-0.008 / action	
health_loss	Penalize health decrement	-0.05 / unit	
ammo_loss	Penalize ammunition decrement	-0.04 / unit	
health_pickup	Reward for medkit pickup	0.04 / unit	
ammo_pickup	Reward for ammunition pickup	0.15 / unit	
dist.penalty	Penalize the agent when it stays	-0.03 / action	
dist_reward	Reward the agent when it moves	9e-5 / unit distance	

Below the table are three diagrams of a robot arm in a game environment. The first diagram shows the arm holding a medkit, with a red 'X' indicating a negative reward. The second diagram shows the arm holding a medkit, with a red 'X' indicating a negative reward. The third diagram shows the arm holding a medkit, with a red 'X' indicating a negative reward.

<https://bair.berkeley.edu/blog/2017/12/20/reverse-curriculum/>

图 5: 手工 reward shaping 示例: VizDoom 中对生存、损血、弹药、拾取物和移动距离设定不同奖励; 机械臂例子也说明中间信号会影响 agent 学到的行为。⁵

这些项看起来琐碎，但它们把人类对任务的理解写进了 reward。比如“失血不好”、“补血有用”、“只站着不动没意义”，这些都是人类一眼就知道的结构；如果完全交给 sparse reward，agent 需要大量样本才能从最终输赢中反推出这些规律。

Reward Shaping 本质上是注入先验知识

在 supervised learning 中，我们通过 label 告诉模型什么是正确答案；在 reward shaping 中，我们通过额外 reward 告诉 agent 哪些中间行为大概率通向成功。它不是免费的魔法，而是把人类对任务结构的理解显式写进训练过程。

3.1 手工 shaping 的局限

手工 reward 往往依赖任务经验，迁移性有限。一个 Doom 关卡中有效的奖励项，换到另一个关卡未必仍然有效；机械臂任务中有效的距离惩罚，换一个物体或目标姿态可能需要重新调。更麻烦的是，设计者很难穷尽所有边界情况，agent 可能找到意想不到的方式刷 shaping reward。

因此手工 shaping 常适合在任务结构明确、专家经验充分时使用；当环境复杂、目标开放或很难定义中间进度时，就需要更自动化的探索奖励。

⁴视频画面时间区间：00:06:45–00:07:00。

⁵视频画面时间区间：00:10:45–00:11:00。

3.2 本章小结

VizDoom 例子说明 reward shaping 可以把高层目标拆成可学习的局部信号。它能让 actor-critic 更快得到有效 advantage，但代价是需要人为设计，并且存在与真实目标不完全对齐的风险。

4 Curiosity-driven Exploration: 把新奇性当作奖励

课程后半段转向一种更自动的 reward shaping: curiosity-driven exploration。它的核心想法是，当 agent 看到新的、但有意义的东西时，给它额外 reward。这个 reward 不一定来自环境外部目标，而是来自 agent 自身的“好奇心”。



图 6: Curiosity-driven exploration: 当 agent 看到新的且有意义的状态时，给它额外 reward；课程引用 Pathak 等人的 ICML 2017 工作。⁶

可以把训练 reward 写成

$$r_t^{\text{train}} = r_t^{\text{ext}} + \beta r_t^{\text{int}},$$

其中 r_t^{int} 是 intrinsic reward。Curiosity 方法通常会训练一个预测模型：根据当前状态与动作预测下一状态的特征。如果预测误差很大，说明这个转移对 agent 来说还不熟悉，就给较高 intrinsic reward；如果模型已经能很好预测，说明它不再新奇，intrinsic reward 就下降。

Curiosity 的一个常见实现直觉

让 agent 学一个世界模型或特征预测模型。预测不准的地方代表“我还不了解这里”，于是给探索奖励；预测越来越准后，这个地方的新奇性降低，agent 会被推向更未知的区域。

4.1 为什么要强调 meaningful

画面中特别写着“new (but meaningful)”。只奖励新奇是不够的，因为环境里可能有很多无意义随机变化，例如噪声、闪烁纹理、不可控背景。如果 agent 因这些变化获得高 reward，它可能沉迷于不可预测但无用的刺激，而不探索真正有助于任务的结构。

⁶视频画面时间区间：00:12:30–00:12:45。

因此 curiosity 方法通常不会直接用 raw pixel prediction error 当 reward, 而会在学习到的 feature space 中衡量 prediction error。目标是让 intrinsic reward 更偏向可控、可学习、与环境动力学有关的新信息, 而不是纯噪声。

4.2 无外部 reward 时的探索

课程展示的例子中, curious agent 即使没有 extrinsic reward, 也能学会沿走廊移动、探索新区域; 相比之下, 随机探索很容易停留在局部, 无法形成持续探索策略。




图 7: Curiosity 与随机探索对比: curious agent 学会沿走廊移动, 而 random exploration 难以形成持续、有方向的探索。⁷




图 8: Curiosity A3C 与 vanilla A3C 对比: 在 hard exploration task 中, intrinsic reward 帮助 agent 找到更有效的探索行为。⁸

⁷ 视频画面时间区间: 00:15:45–00:16:00。

⁸ 视频画面时间区间: 00:16:15–00:16:30。

这类方法把 reward shaping 从“人手写规则”推进到“自动产生探索信号”。它不要求设计者提前知道每个中间目标，但仍然隐含了一个假设：探索新奇且可预测的环境结构，会提高未来解决任务的机会。

4.3 本章小结

Curiosity-driven exploration 是 reward shaping 的自动化版本：它用 intrinsic reward 鼓励 agent 接触新状态、学习环境动力学。它特别适合外部 reward 极度稀疏或完全缺失的环境，但必须避免把无意义噪声当作探索目标。

5 Reward Shaping 的风险与使用原则

Reward shaping 看似简单，但实际常常决定 RL 任务能不能训练起来。它的风险主要有三类。

1. **目标错位**：shaping reward 鼓励的行为与最终目标不一致，agent 会钻规则空子。
2. **尺度失衡**：shaping reward 太大时，agent 只优化中间分；太小时，又无法缓解 sparse reward。
3. **迁移失效**：在一个环境中有效的 shaping，在另一个环境中可能误导策略。

因此设计 reward 时需要区分 training reward 与 evaluation objective。训练时可以加入 shaping 帮助学习，但最终评估应回到真实任务目标。若 shaping 只是辅助，它不应该成为 agent 最终追求的全部。

Reward hacking 的基本教训

Agent 不会理解设计者的意图，只会优化数值 reward。任何 reward shaping 都是在定义一个可被优化的目标函数；若目标函数有漏洞，agent 可能会稳定地学到漏洞，而不是学到人类期待的行为。

5.1 本章小结

Reward shaping 是强工具，也是一把需要校准的工具。它能显著改善 sparse reward 的学习效率，但必须持续检查 shaping reward 是否与真实目标一致、尺度是否合适、是否引入可利用漏洞。

6 总结与延伸

本讲的主线是：Actor-Critic 已经告诉我们如何使用 reward，但如果 reward 太稀疏，学习信号本身就不够。Reward shaping 通过额外 reward 把最终目标拆成中间反馈，让 actor 更容易得到有方向的 advantage，让 critic 更容易学到 value。

本讲最值得带走的观念

RL 不是只靠算法公式就能解决问题；reward 的设计本身就是问题建模的一部分。Sparse reward 会让 agent 缺少学习信号，reward shaping 则是在训练过程中补充结构化反馈。

手工 shaping 依赖人类专家知识，适合目标结构清楚的任务；curiosity-driven exploration 则用 intrinsic reward 自动鼓励探索，适合外部 reward 稀疏甚至缺失的环境。两者都在做同一件事：让 agent 不必等到极少数最终反馈出现，才能知道自己是否走在有希望的方向上。

下一讲的大纲将继续进入“No Reward: Learning from Demonstration”。当环境连 reward 都没有，或者 reward 难以设计时，就需要从示范、模仿或偏好中学习行为目标。