

强化学习概述（五）：Learning from Demonstration

Imitation Learning, Behavior Cloning, Inverse Reinforcement Learning, and the GAN Analogy



基于李宏毅老师《机器学习 2025》课程内容整理
2026 年 6 月 9 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 27 分 08 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=50>

目录

1 从 Reward Shaping 走到 No Reward	3
1.1 本章小结	4
2 Imitation Learning 的基本设定	4
2.1 示范数据与监督资料的差别	5
2.2 本章小结	5
3 Behavior Cloning: 把模仿学习当监督学习	6
3.1 问题一: 专家只覆盖有限观察	6
3.2 问题二: 复制无关行为	7
3.3 本章小结	8
4 Inverse Reinforcement Learning: 反推出 Reward	8
4.1 基本原则: 老师总是最好的	9
4.2 迭代式 IRL	10
4.3 本章小结	11
5 IRL 与 GAN 的类比	11
5.1 IRL 为什么能缓解 behavior cloning 的问题	12
5.2 本章小结	12
6 机器人示例与延伸方向	12
6.1 本章小结	14
7 总结与延伸	14

1 从 Reward Shaping 走到 No Reward

前一讲讨论 sparse reward 与 reward shaping：当环境 reward 太少时，可以人为补充中间奖励，引导 agent 学习。但这一步本身也有困难：有些任务连 reward 都很难定义；有些任务即使写了 reward，也可能导致意料之外的行为。P50 处理的是更进一步的情况：如果 reward function 不可用，是否还能从专家示范中学习？



图 1: RL 大纲进入最后一块：No Reward: Learning from Demonstration。当 reward 难以定义或不可得时，改用专家示范提供学习信号。¹

这讲的动机与上一讲紧密相连。Reward shaping 的核心假设是：设计者知道哪些中间行为有助于最终目标。但在复杂任务中，设计 reward 可能比设计模型更难。例如机器人伦理、自动驾驶安全、开放环境中的长期目标，都很难写成简单、稳定、不会被钻空子的数值函数。

¹视频画面时间区间：00:00:00–00:00:15。

Motivation

- Even define reward can be challenging in some tasks.
- Hand-crafted rewards can lead to uncontrolled behavior.



Three Laws of Robotics:

1. A robot may not injure a human being or, through inaction, allow a human being to come to harm.
2. A robot must obey the orders given it by human beings except where such orders would conflict with the First Law.
3. A robot must protect its own existence as long as such protection does not conflict with the First or Second Laws.



restraining individual human behavior and sacrificing some humans will ensure humanity's survival

图 2: 动机: 某些任务中定义 reward 本身就很困难; 手工设计 reward 也可能导致不可控行为。课程用《I, Robot》式例子说明规则与真实意图可能不一致。²

图中提到机器人三定律，本意是保护人类，但如果系统错误理解“保护人类整体生存”，可能推导出限制个体自由甚至牺牲部分人的行为。这个例子强调：reward 或规则只要写得不完整，agent 就可能优化出设计者不想要的策略。

为什么要从示范学习

当 reward 难写时，人类专家往往可以直接示范正确行为。Learning from Demonstration 把问题从“告诉 agent 什么分数最高”改成“给 agent 看专家怎么做”，让行为本身成为学习信号。

1.1 本章小结

Reward shaping 仍然要求人类写 reward; Learning from Demonstration 则假设 reward 不可用，但专家 trajectory 可用。它适合那些目标难以精确定义、但人类能够演示或记录专家行为的任务。

2 Imitation Learning 的基本设定

在 imitation learning 中，actor 仍然可以与环境互动。它看到状态 s_t ，采取动作 a_t ，环境转移到 s_{t+1} 。不同的是：我们没有 reward function，不能用 policy gradient、actor-critic 或 reward shaping 直接训练。

取而代之的是专家示范资料：

$$\mathcal{D}_E = \{\hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_K\},$$

其中每条专家轨迹

$$\hat{\tau} = \{s_1, \hat{a}_1, s_2, \hat{a}_2, \dots\}$$

²视频画面时间区间：00:02:45–00:03:00。

记录了专家在不同状态下采取的动作。



Imitation Learning




图 3: Imitation learning: actor 可以与环境互动, 但 reward function 不可用; 我们拥有专家示范, 每条 $\hat{\tau}$ 是专家的一条 trajectory。³

课程给了两个直观例子:

- 自动驾驶: 记录人类驾驶员在道路画面下的方向盘、油门或动作决策。
- 机器人控制: 通过抓住机器人手臂或遥操作, 记录专家如何完成抓取、移动、装配等任务。

这些示范不直接告诉模型“这个动作得多少分”, 但告诉模型“在这个状态下, 专家选择了什么动作”。

2.1 示范数据与监督资料的差别

表面上, 专家轨迹像监督学习资料: 输入是 state, 标签是 expert action。可是它与普通监督学习有一个关键差别: 模型部署后会影响到自己未来看到的状态。分类器预测错一张图片, 不会改变下一张图片; 自动驾驶 actor 转错一点方向, 却会把车带到专家从未示范过的状态。

Sequential decision 的特殊性

Imitation learning 的资料不是独立同分布样本, 而是一条条由策略与环境交互产生的轨迹。一个小错误可能改变后续状态分布, 导致模型进入训练集中没有覆盖的区域。

2.2 本章小结

Imitation learning 的输入是专家轨迹, 目标是训练 actor 模仿专家行为。它看起来像监督学习, 但因为 actor 的动作会改变未来状态, 模仿学习必须处理分布漂移与错误累积。

³视频画面时间区间: 00:06:00-00:06:15。

3 Behavior Cloning: 把模仿学习当监督学习

最直接的方法叫 behavior cloning。做法是把专家轨迹拆成很多 state-action pair:

$$(s_i, \hat{a}_i),$$

然后训练 actor 在状态 s_i 下输出与专家动作 $\hat{a}_i$ 一样的动作。




图 4: Behavior cloning 的形式: 把专家轨迹中的状态 s_i 当输入, 专家动作 $\hat{a}_i$ 当标签, 训练 actor 输出动作 a_i 逼近 $\hat{a}_i$ 。⁴

若 action 是离散的, 可以用 cross-entropy:

$$L_{BC}(\theta) = - \sum_i \log \pi_{\theta}(\hat{a}_i | s_i).$$

若 action 是连续控制量, 例如方向盘角度或机械臂关节速度, 可以用均方误差:

$$L_{BC}(\theta) = \sum_i \|\pi_{\theta}(s_i) - \hat{a}_i\|_2^2.$$

Behavior cloning 简单、有效、容易实现。很多真实系统会先用 behavior cloning 做初始化, 再进入强化学习或其他 fine-tuning 流程。它的问题也很经典: 它只学“专家在专家状态下怎么做”, 却没有学“当自己犯错后该怎么恢复”。

3.1 问题一: 专家只覆盖有限观察

专家示范通常只覆盖专家会遇到的状态。如果专家开车从不偏离道路中心, 那么训练资料里几乎没有“车已经偏到路边”时应该怎么救回来。Behavior cloning 部署后, 只要模型犯一个小错误进入训练分布之外的状态, 预测就会变得不可靠; 错误再导致更偏的状态, 形成连锁反应。

⁴ 视频画面时间区间: 00:07:15–00:07:30。

Isn't it Supervised Learning?

- Self-driving cars as example

Yes, also known as *Behavior Cloning*




图 5: Behavior cloning 的第一个问题: 专家只 sample 到有限 observation。模型一旦偏离专家轨迹, 就可能进入没有训练资料覆盖的状态。⁵

这个现象常被称为 covariate shift 或 distribution shift:

$$p_{\text{train}}(s) \neq p_{\pi_{\theta}}(s).$$

训练时状态来自专家策略, 测试时状态来自模型自己的策略。若两者差距扩大, 监督学习训练出的局部动作预测就会失效。

3.2 问题二: 复制无关行为

第二个问题是: behavior cloning 会复制示范中的所有相关与无关行为。只要数据里出现了某个动作, 模型就可能把它当作任务所需行为学习下来。课程用电视剧片段说明: 如果专家在完成任务前做了很多无关动作, agent 也可能照抄这些动作。

⁵视频画面时间区间: 00:08:15-00:08:30。

More problem

The agent will copy every behavior, even irrelevant actions.



<https://www.youtube.com/watch?v=j2FSB3bseek>

图 6: Behavior cloning 的第二个问题: agent 会复制示范中的所有行为, 包括与任务无关的动作。⁶

这可以理解为因果问题。Behavior cloning 只看相关性: 专家在状态 s 做了动作 a , 于是模型学 $s \mapsto a$ 。它并不知道动作 a 是否真的对完成任务有因果贡献。若示范中包含习惯性动作、环境巧合或标注偏差, 模型可能把这些都当成目标行为。

Behavior cloning 的根本限制

Behavior cloning 学的是专家动作分布, 而不是专家背后的目标函数。它可以模仿表面行为, 却不一定理解哪些行为对目标有用、哪些只是示范过程中的偶然或无关动作。

3.3 本章小结

Behavior cloning 把 imitation learning 转成监督学习, 优点是简单直接; 缺点是容易受状态分布漂移影响, 也会复制无关行为。为了解决这些问题, 需要从“模仿动作”进一步走向“理解专家为什么这样做”。

4 Inverse Reinforcement Learning: 反推出 Reward

Inverse Reinforcement Learning, 简称 IRL, 尝试回答: 专家为什么会做这些动作? 它不直接训练 actor 模仿动作, 而是从专家 trajectory 中反推一个 reward function, 再用这个 reward function 训练 actor。

⁶视频画面时间区间: 00:11:00-00:11:15。

Inverse Reinforcement Learning




图 7: IRL 总览: 输入是环境与专家示范, 输出是 reward function; 再用这个 reward function 通过 RL 找到 optimal actor。⁷

普通 RL 的方向是

$$R \implies \pi^*,$$

给定 reward function, 找最优策略。IRL 的方向则是反过来:

$$\{\hat{t}_k\}_{k=1}^K \implies R,$$

从专家行为推测什么 reward 会让这些行为显得合理。得到 reward 后, 再用 RL 求一个能最大化该 reward 的 actor。

4.1 基本原则: 老师总是最好的

课程把 IRL 的原则写成一句话: **The teacher is always the best.** 也就是说, 我们假设专家示范比当前 actor 的行为更好。因此要找一个 reward function, 使专家 trajectory 的总 reward 高于 actor 自己采样出的 trajectory。

⁷ 视频画面时间区间: 00:13:00-00:13:15。

Inverse Reinforcement Learning

- Principle: **The teacher is always the best.**
- Basic idea:
 - Initialize an actor
 - In each iteration
 - The actor interacts with the environments to obtain some trajectories.
 - Define a reward function, which makes the trajectories of the teacher better than the actor.
 - The actor learns to maximize the reward based on the new reward function.

图 8: IRL 基本想法: 初始化 actor; 每轮让 actor 与环境互动得到轨迹; 定义一个 reward function, 使专家轨迹比 actor 轨迹更好; 再让 actor 最大化这个新 reward。⁸

可以把这个思想写成不等式。对专家轨迹 $\hat{\tau}$ 与 actor 轨迹 τ , 希望

$$\sum_t R_\phi(\hat{s}_t, \hat{a}_t) > \sum_t R_\phi(s_t, a_t).$$

其中 R_ϕ 是要学习的 reward model。它的任务不是直接判断单步动作是否与专家一样, 而是给整条轨迹评分, 让专家轨迹分数更高。

4.2 迭代式 IRL

一个简化的 IRL 训练循环如下:

1. 初始化一个 actor π_θ 。
2. 用 π_θ 与环境互动, 收集 actor 轨迹 $\{\tau_k\}$ 。
3. 学一个 reward function R_ϕ , 让专家轨迹得分高于 actor 轨迹。
4. 用新的 R_ϕ 通过 RL 更新 actor, 使 actor 获得更高 reward。
5. 重复以上步骤, 直到 actor 轨迹越来越接近专家轨迹。

这个流程比 behavior cloning 更绕, 但它试图恢复任务目标。若 reward 学得好, actor 不需要在每个状态都复制专家动作; 它只要找到能获得高 reward 的行为即可。这有助于避免复制无关动作, 也可能让策略具备更好的泛化能力。

⁸视频画面时间区间: 00:16:00–00:16:15。

IRL 学到的是 reward, 不是单步标签

Behavior cloning 学 $s \mapsto a$; IRL 学 $R(s, a)$ 或 $R(s)$ 。前者问“专家在这里做了什么”，后者问“什么目标会让专家这样做显得最优”。这就是两者的关键差异。

4.3 本章小结

IRL 假设专家示范是高质量行为, 通过学习 reward function 解释专家行为, 再用 RL 训练 actor。它的目标不是逐帧复制专家, 而是恢复专家背后的偏好或任务目标。

5 IRL 与 GAN 的类比

课程把 IRL 与 GAN 放在同一张图里对比。GAN 中有 generator G 与 discriminator D 。 D 会给真实样本高分、生成样本低分; G 学会产生能从 D 那里拿高分的样本。二者反复竞争, 最终 G 的输出逼近真实数据分布。

IRL 也有类似结构:

- expert trajectories 类似真实样本。
- actor trajectories 类似 generator 生成的样本。
- reward function 类似 discriminator, 给专家轨迹高 reward, 给 actor 轨迹低 reward。
- actor 类似 generator, 尝试生成能拿高 reward 的轨迹。




图 9: GAN 与 IRL 的类比: GAN 的 discriminator 区分 real/generated; IRL 的 reward function 区分 expert trajectory 与 actor trajectory, actor 再学习获得更高 reward。⁹

⁹视频画面时间区间: 00:18:45-00:19:00。

这个类比帮助理解为什么 IRL 常是交替训练：reward model 需要区分专家与当前 actor；actor 又会根据 reward model 改变行为。当 actor 变强后，旧 reward model 可能不再能清楚区分两者，于是需要继续更新 reward。

从 adversarial 角度看 IRL

Reward function 与 actor 形成一种对抗式循环：reward function 学会指出 actor 与专家的差距，actor 学会减少这个差距。这个思路后来发展出 Generative Adversarial Imitation Learning (GAIL) 等方法。

5.1 IRL 为什么能缓解 behavior cloning 的问题

Behavior cloning 要求 actor 在每个专家状态下输出相同动作；IRL 只要求 actor 产生高 reward 轨迹。因此：

- 若专家轨迹里有无关动作，reward model 可以不给这些动作高 reward，actor 不必复制它们。
- 若 actor 偏离专家轨迹，只要它仍能找到高 reward 行为，就不一定失败。
- 若同一目标有多种实现方式，IRL 允许 actor 找到不同但同样高分的策略。

当然，这依赖 reward model 学得合理。若 reward model 只学到表面差异，也可能产生新的 reward hacking 问题。

5.2 本章小结

IRL 与 GAN 的共同点是：都通过一个评分器指导生成器。GAN 的评分器是 discriminator，IRL 的评分器是 reward function；GAN 的 generator 生成样本，IRL 的 actor 生成轨迹。

6 机器人示例与延伸方向

课程最后回到机器人学习。机器人任务常常很难写 reward：人可以示范抓取、摆放、插入、开门等动作，但要把这些动作的每个中间状态写成 reward function 并不容易。因此 learning from demonstration 在机器人领域非常自然。



Robot

Chelsea Finn, Sergey Levine, Pieter Abbeel,
Guided Cost Learning: Deep Inverse Optimal
Control via Policy Optimization, ICML, 2016
<http://rll.berkeley.edu/gcl/>




图 10: 机器人示例: Guided Cost Learning / Deep Inverse Optimal Control 使用示范来学习 cost/reward, 再训练机器人执行任务。¹⁰

图中提到 Guided Cost Learning: Deep Inverse Optimal Control via Policy Optimization。这里的 cost learning 与 reward learning 是同一类思想: 通过示范推测什么状态或动作代价低, 然后训练策略去最小化代价。机器人抓取、倒水、移动物体等任务尤其适合这种框架, 因为人类可以示范, 但 reward 难以手写。

¹⁰ 视频画面时间区间: 00:23:00-00:23:15。



To Learn More ...

Visual Reinforcement Learning with Imagined Goals, NIPS 2018

<https://arxiv.org/abs/1807.04742>

Skew-Fit: State-Covering Self-Supervised Reinforcement Learning,
ICML 2020

<https://arxiv.org/abs/1903.03698>




图 11: 延伸阅读: 课程列出 Visual Reinforcement Learning with Imagined Goals、Skew-Fit 等机器人与自监督 RL 方向。¹¹

这些延伸方向与前几讲的主题互相连接:

- Reward shaping 试图手动补充学习信号。
- Curiosity 使用 intrinsic reward 自动鼓励探索。
- Learning from demonstration 通过专家行为提供目标信息。
- IRL/GAIL 进一步把专家行为转化成可优化的 reward 或判别信号。

6.1 本章小结

机器人任务体现了 learning from demonstration 的价值: 真实世界目标复杂, reward 难写, 但人类示范相对容易获得。IRL 与 cost learning 让系统从示范中恢复任务偏好, 再用 RL 或 policy optimization 学会执行。

7 总结与延伸

P50 可以总结成从浅到深的三层模仿学习:

expert actions $\implies$ behavior cloning
 $\implies$ reward / cost learning $\implies$ policy optimization.

Behavior cloning 直接模仿动作, 简单但容易受分布漂移和无关动作影响; IRL 则反推出 reward function, 再让 actor 学会最大化这个 reward。

¹¹ 视频画面时间区间: 00:24:45-00:25:00。

Concluding Remarks

What is RL? (Three steps in ML)

Policy Gradient

Actor-Critic

Sparse Reward

No Reward: Learning from Demonstration

图 12: 结语: RL 概述部分完成了从 policy gradient、actor-critic、sparse reward 到 learning from demonstration 的主线。¹²

本讲最值得带走的观念

当 reward 不可用时, 专家示范可以替代 reward 成为学习信号。Behavior cloning 模仿专家做了什么; IRL 尝试理解专家为什么这样做, 并把这种理解转成 reward function。

从整个 RL 小单元看, 课程逐步处理了三个困难: 如何从 reward 更新 actor, 如何在 reward 稀疏时补充信号, 如何在 reward 不存在时从示范恢复目标。下一阶段如果继续深入, 就会看到这些思想在真实机器人、自动驾驶、游戏 AI 与人类偏好学习中不断组合出现。

¹² 视频画面时间区间: 00:25:45–00:26:00。