

机器终身学习（一）：灾难性遗忘

Life-Long Learning, Sequential Tasks, Catastrophic Forgetting,
and Evaluation



基于李宏毅老师《机器学习 2025》课程内容整理
2026 年 6 月 9 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 31 分 59 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=53>

目录

1 终身学习的目标：让模型越学越多	3
1.1 真实应用中的持续反馈	3
1.2 本章小结	4
2 灾难性遗忘：顺序学习时旧能力突然掉落	4
2.1 遗忘与容量的区别	6
2.2 本章小结	6
3 bAbI QA 实验：顺序学习会把刚学会的东西冲掉	7
3.1 本章小结	9
4 两个看似简单的解法及其局限	9
4.1 Life-long Learning 与 Transfer Learning	11
4.2 本章小结	12
5 如何评价 Life-Long Learning	12
5.1 Performance Matrix: R_{ij}	13
5.2 Accuracy、Backward Transfer 与 Forward Transfer	14
5.3 本章小结	15
6 总结与延伸	15
6.1 本章小结	16

1 终身学习的目标：让模型越学越多

本讲进入 Life-Long Learning，也称 continual learning、never-ending learning 或 incremental learning。它关心的不是一次性训练一个固定任务，而是让机器像人一样，在不断出现的新任务中持续学习，并尽量保留过去已经学会的能力。

课程一开始用一个直观想象说明大众对 AI 的期待：模型先学会 task 1，接着学会 task 2，并且仍然会 task 1；再学会 task 3，同时保留前两个任务。若这种能力无限延伸，人们自然会联想到“机器越学越强”的未来图景。




图 1: 人们想象中的连续学习：机器学习 task 1 后会 task 1，继续学习 task 2 后会 task 1 与 task 2，再学习 task 3 后会 task 1、task 2 与 task 3。¹

但今天主流监督学习流程通常不是这样。标准做法是先收集一个固定训练集，训练一个模型，然后部署；若未来出现新任务或新分布，往往需要重新训练、微调，或者收集一批新数据再更新。这种流程不天然保证旧任务性能不掉。

1.1 真实应用中的持续反馈

现实系统更接近一个闭环：旧任务有 labelled data，新任务从线上环境逐渐出现，系统根据 online feedback 继续更新。比如客服系统可能先学习已有问题，再持续遇到新产品、新政策、新用户表达；推荐系统也会不断面对新商品、新偏好和新行为模式。

¹ 视频画面时间区间：00:02:15–00:02:30。

Life Long Learning in real-world applications




图 2: 真实应用中的 lifelong learning 闭环: 旧任务来自 labelled data, 新任务从 online 环境产生, 反馈再回流到模型更新。²

Life-long learning 因此要同时满足两个目标:

- **Plasticity**: 面对新任务时能学会新知识。
- **Stability**: 学新任务时不要破坏旧任务能力。

这就是 continual learning 中经典的 stability-plasticity dilemma。若模型太稳定, 它学不动新任务; 若模型太可塑, 它会快速覆盖旧知识。

终身学习不是单纯 fine-tuning

Fine-tuning 通常只要求新任务表现变好, 旧任务是否还能做不一定被关心。Life-long learning 明确要求: 学完后续任务后, 旧任务仍要尽量保留; 更理想时, 新旧任务之间还应互相迁移。

1.2 本章小结

Life-long learning 研究的是顺序任务中的持续学习能力。它的核心目标是让模型不断吸收新任务, 同时保留旧任务, 而不是每次更新都只服务当前任务。

2 灾难性遗忘: 顺序学习时旧能力突然掉落

课程用一个简单数字任务说明 catastrophic forgetting。模型先学习 task 1, 再学习 task 2; 两个任务都要求识别数字“0”, 但数据分布不同。模型结构本身并不小, 示例中是 3 层、每层 50 个神经元, 因此问题不在于“模型容量完全不够”。

²视频画面时间区间: 00:03:30-00:03:45。

Example







图 3: 灾难性遗忘的玩具设定: task 1 与 task 2 都是识别 “0”, 但输入分布不同; 模型有 3 层、每层 50 个神经元。³

如果模型先在 task 1 上训练, task 1 accuracy 可以达到约 90%。接着训练 task 2 后, task 2 accuracy 很高, 但 task 1 accuracy 从 90% 掉到约 80%。这就是 catastrophic forgetting: 模型学会了新任务, 却显著忘掉旧任务。

³视频画面时间区间: 00:04:45–00:05:00。



The network has enough capacity to learn both tasks.

图 4: 顺序训练导致遗忘: 先学 task 1 后再学 task 2, task 2 表现很好, 但 task 1 表现下降; 如果同时学习两个任务, 网络容量其实足够学会两者。⁴

图中还有一个关键对照: 若把 task 1 和 task 2 一起训练, 模型可以同时达到较好表现。这说明遗忘不一定来自容量不足, 而来自训练过程的顺序性。后训练的 task 2 梯度会改变原本服务 task 1 的参数, 使旧任务决策边界被破坏。

灾难性遗忘的直觉

神经网络的参数是共享的。学习新任务时, optimizer 只看当前任务 loss, 若没有任何机制提醒它旧任务也重要, 它就可能沿着降低新任务 loss 的方向更新参数, 而这个方向恰好提高旧任务 loss。

2.1 遗忘与容量的区别

如果一个模型无论怎么训练都无法同时做好 task 1 与 task 2, 那是容量或架构表达力的问题; 但课程示例中 simultaneous training 可以做好两个任务, 说明模型“可以”表示两者。问题是 sequential training 没有保存旧知识, 也没有约束新任务更新不要破坏旧知识。

因此, life-long learning 的难点不是简单地把模型变大。变大可能缓解冲突, 但不保证顺序训练不会覆盖旧能力。真正需要的是训练机制: 保存代表性旧数据、保护重要参数、为不同任务分配子空间、生成旧任务样本, 或在目标函数中显式惩罚遗忘。

2.2 本章小结

Catastrophic forgetting 是 continual learning 的核心障碍。模型顺序学习新任务时, 旧任务表现可能急剧下降; 这不一定是模型容量不足, 而是新任务训练破坏了旧任务参数配置。

⁴视频画面时间区间: 00:08:30-00:08:45。

3 bAbI QA 实验：顺序学习会把刚学会的东西冲掉

课程接着用 bAbI corpus 的 QA 任务作为更真实的例子。bAbI 中有 20 个问答任务，每个任务考察不同推理能力，例如 three argument relations、basic deduction 等。模型需要读一段短文，再回答问题。

自然语言推理 bAbI

Example

- QA: Given a document, answer the question based on the document.
- There are 20 QA tasks in bAbi corpus.

Task 5: Three Argument Relations Mary gave the cake to Fred. Fred gave the cake to Bill. Jeff was given the milk by Bill. Who gave the cake to Fred? A: Mary Who did Fred give the cake to? A: Bill	Task 15: Basic Deduction Sheep are afraid of wolves. Cats are afraid of dogs. Mice are afraid of cats. Gertrude is a sheep. What is Gertrude afraid of? A:wolves
---	--

- Train a QA model through the 20 tasks

图 5: bAbI QA 顺序任务设定：给定文档和问题，模型回答文档中的关系；数据集中共有 20 个 QA tasks，课程示例让模型依序学习这些任务。⁵

如果模型依序学习 20 个任务，它在刚学 task 5 时可以把 task 5 做好，但继续学习后续 task 后，task 5 accuracy 很快掉回接近 0。也就是说，机器不是“没有学会 task 5”，而是“学会后又忘掉了”。

⁵视频画面时间区间：00:11:00–00:11:15。

Example




图 6: bAbI 实验结果：顺序学习时，task 5 accuracy 在学习 task 5 后短暂升高，随后随着后续任务训练迅速下降；同时学习 20 个任务时整体 accuracy 可以维持较高水平。⁶

右侧同时训练的曲线说明：若训练时能同时看到所有任务，模型对 20 个任务都可维持较好表现。这再次支持一个判断：catastrophic forgetting 不是因为任务天然不可学，而是因为顺序训练缺乏保留机制。

⁶视频画面时间区间：00:13:30–00:13:45。



图 7: 课程用 “Catastrophic Forgetting” 概括这一现象：新知识像水一样不断灌入，却可能冲掉旧知识。⁷

不要把低最终准确率误读为“模型从未学会”

在顺序任务曲线中，一个任务的准确率可能先升高再下降。若只看最后一刻的低准确率，会误以为模型没有学过该任务；但中间峰值显示它曾经学会，只是在后续训练中遗忘。

3.1 本章小结

bAbI QA 例子说明，灾难性遗忘不仅出现在玩具数字任务，也会出现在涉及语言和推理的顺序任务中。顺序学习与同时学习之间的差距，正是 continual learning 要解决的问题。


4 两个看似简单的解法及其局限

面对 catastrophic forgetting，最直接的反应是：既然 simultaneous training 能避免遗忘，那就把所有任务的数据都留着，每次训练都用全部数据。课程称这种 multi-task training 可以看成 life-long learning 的上界，因为它拥有最理想的信息条件。


⁷ 视频画面时间区间：00:14:45–00:15:00。

forgetting LLL

Wait a minute



- Multi-task training can solve the problem!



- Multi-task training can be considered as the upper bound of LLL.

图 8: Multi-task training 可以缓解遗忘，但需要始终保留所有任务数据，并在训练时使用全部数据；这带来 storage issue 与 computation issue，因此可视为 LLL 的上界而非可行方案。⁸

Multi-task training 的局限很实际：

- **存储问题：**如果任务不断增加，保存 task 1 到 task 1000 的全部数据会越来越昂贵，也可能受隐私或合规限制。
- **计算问题：**每次新任务到来都用所有旧数据重新训练，计算成本会随任务数增长。
- **在线性不足：**真实系统常需要快速增量更新，而不是等所有任务凑齐后统一训练。

第二个看似简单的办法是：每个任务训练一个独立模型。这样 task 1 的模型不会被 task 2 的训练破坏，自然不会遗忘。

⁸视频画面时间区间：00:18:30-00:18:45。

Wait a minute

- Train a model for each task




图 9: 每个任务训练一个模型可以避免单模型内部的遗忘, 但模型数量会不断增长, 最终难以存储; 不同任务之间也无法共享和迁移知识。⁹

但每任务一个模型也不是 life-long learning 的理想解。一方面, 任务数量无限增长时模型存储不可控; 另一方面, task 2 不能利用 task 1 学到的知识, task 3 也不能继承前面任务的经验。它避免了遗忘, 但放弃了持续学习最有价值的部分: 跨任务知识积累。

4.1 Life-long Learning 与 Transfer Learning

课程特别区分 transfer learning 和 life-long learning。Transfer learning 关心的是: 我学过 task 1, 所以可以更快或更好地学 task 2; 但它不一定关心学完 task 2 后是否还会 task 1。Life-long learning 则要求: 即使已经学了 task 2, 也不要忘掉 task 1。

⁹视频画面时间区间: 00:19:45-00:20:00。

Life-Long v.s. Transfer




图 10: Transfer learning 只要求 task 1 帮助 task 2; life-long learning 还要求学完 task 2 后不忘 task 1。¹⁰

这一区分很重要。很多 fine-tuning 成功案例本质上是 transfer learning: 旧任务提供初始化, 新任务得到提升, 但旧任务性能可能被牺牲。Continual learning 要求更强, 它同时追求 forward transfer 与 backward retention。

4.2 本章小结

Multi-task training 是理想上界, 但依赖全部旧数据与大量计算; 每任务一个模型避免遗忘, 却无法扩展, 也不能迁移知识。Life-long learning 要在更现实的同时做到: 学新任务、保旧任务、尽量跨任务迁移。

5 如何评价 Life-Long Learning

要评价 continual learning, 首先需要一串任务。课程使用的例子包括 permuted MNIST 或 split MNIST: 前者给同一数字识别任务施加不同像素排列, 后者把数字类别拆成多个二分类任务。关键不是具体数据集, 而是评测过程: 任务按顺序出现, 模型学完每个任务后都要测试多个任务。

¹⁰ 视频画面时间区间: 00:22:15–00:22:30。

Evaluation

First of all, we need a sequence of tasks.




图 11: Life-long learning 评测需要一个 task sequence: 例如 permuted MNIST 的多个排列任务, 或 split MNIST 中按类别拆分的一系列任务。¹¹

5.1 Performance Matrix: R_{ij}

课程用 $R_{i,j}$ 记 after training task i 之后, 模型在 task j 上的表现。所有 $R_{i,j}$ 组成一个 performance matrix: 行表示训练进度, 列表示测试任务。初始随机模型在 task j 上的表现记为 $R_{0,j}$ 。

¹¹ 视频画面时间区间: 00:23:30-00:23:45。

<u>Evaluation</u>		Test on			
		Task 1	Task 2		Task T
$R_{i,j}$: after training task i , performance on task j					
If $i > j$,					
After training task i , does task j be forgot					
After Training	Rand Init.	$R_{0,1}$	$R_{0,2}$		$R_{0,T}$
	Task 1	$R_{1,1}$	$R_{1,2}$		$R_{1,T}$
	Task 2	$R_{2,1}$	$R_{2,2}$		$R_{2,T}$
	$\vdots$				
	Task T-1	$R_{T-1,1}$	$R_{T-1,2}$		$R_{T-1,T}$
	Task T	$R_{T,1}$	$R_{T,2}$		$R_{T,T}$

图 12: Performance matrix 的定义: $R_{i,j}$ 表示训练完 task i 后在 task j 上的性能; 当 $i > j$ 时可观察旧任务是否被忘记。¹²

这个矩阵把 continual learning 的几个问题统一起来:

- **当前任务学习:** 对角线 $R_{i,i}$ 表示刚学完 task i 后在该任务上的表现。
- **遗忘:** 若 $i > j$, 比较 $R_{i,j}$ 和 $R_{j,j}$, 可看后续训练是否让 task j 表现下降。
- **迁移:** 若 $i < j$, 比较 $R_{i,j}$ 和 $R_{0,j}$, 可看前面任务是否让尚未训练的 task j 变好。

5.2 Accuracy、Backward Transfer 与 Forward Transfer

最终平均 accuracy 通常看最后一行:

$$\text{Acc} = \frac{1}{T} \sum_{i=1}^T R_{T,i}.$$

它回答的是: 学完整个任务序列后, 模型平均还能做好多少任务。这个指标直观, 但不能区分“没学好”还是“学好后忘了”。

Backward Transfer 衡量后续任务训练对旧任务的影响:

$$\text{BWT} = \frac{1}{T-1} \sum_{i=1}^{T-1} (R_{T,i} - R_{i,i}).$$

若 $\text{BWT} < 0$, 表示最终表现低于刚学完旧任务时的表现, 通常代表遗忘; 若 $\text{BWT} > 0$, 则表示后续任务反而帮助旧任务变好, 这是一种正向 backward transfer。

Forward Transfer 衡量前面任务是否帮助未来任务:

$$\text{FWT} = \frac{1}{T-1} \sum_{i=2}^T (R_{i-1,i} - R_{0,i}).$$

¹² 视频画面时间区间: 00:27:15–00:27:30。

它比较的是：在还没训练 task i 前，模型因学过前面任务而在 task i 上比随机初始化好多少。若 $FWT > 0$ ，说明前面任务带来了可迁移知识。

Evaluation

$R_{i,j}$: after training task i , performance on task j

If $i > j$,
After training task i , does task j be forgot

If $i < j$,
Can we transfer the skill of task i to task j

		Test on			
		Task 1	Task 2		Task T
Rand Init.		$R_{0,1}$	$R_{0,2}$		$R_{0,T}$
After Training	Task 1	$R_{1,1}$	$R_{1,2}$		$R_{1,T}$
	Task 2	$R_{2,1}$	$R_{2,2}$		$R_{2,T}$
	$\vdots$				
	Task T-1	$R_{T-1,1}$	$R_{T-1,2}$		$R_{T-1,T}$
	Task T	$R_{T,1}$	$R_{T,2}$		$R_{T,T}$

$$\text{Accuracy} = \frac{1}{T} \sum_{i=1}^T R_{T,i}$$

$$\text{Backward Transfer} = \frac{1}{T-1} \sum_{i=1}^{T-1} R_{T,i} - R_{i,i}$$

$$\text{Forward Transfer} = \frac{1}{T-1} \sum_{i=2}^T R_{i-1,i} - R_{0,i}$$

图 13: 常见 continual learning 指标: final accuracy 看最终平均表现, backward transfer 衡量旧任务被后续任务影响的程度, forward transfer 衡量旧任务对未来任务的预帮助。¹³

只看 final accuracy 不够

两个模型 final accuracy 相同，可能一个是从未学好某些任务，另一个是学好后被遗忘。Performance matrix 与 BWT/FWT 能把学习、遗忘、迁移拆开看，更适合分析 continual learning 方法。

5.3 本章小结

Life-long learning 的评价核心是 task sequence 与 performance matrix。 $R_{i,j}$ 记录训练进度与测试任务的交叉表现；accuracy 看最终总体能力，BWT 看是否遗忘旧任务，FWT 看是否对未来任务有帮助。

6 总结与延伸

P53 的核心是提出 continual learning 的问题定义，而不是立刻给出完整解法。课程通过数字任务和 bAbI QA 任务说明：模型顺序学习时常会学新忘旧，这种 catastrophic forgetting 不是因为任务不可学，而是因为训练流程没有保护旧知识。

可以把本讲的逻辑压缩成三句话：

- **目标：**机器要不断学习新任务，并保留旧任务能力。

¹³视频画面时间区间：00:31:00–00:31:15。

- **困难：**顺序训练会让新任务梯度覆盖旧任务知识，造成 catastrophic forgetting。
- **评价：**需要用 task sequence 和 $R_{i,j}$ 矩阵同时衡量最终能力、遗忘和迁移。

这也解释了标题中的问题：今天的 AI 难以成为“不断自我成长”的系统，并不是因为单次任务能力不足，而是因为持续学习机制还不稳。一个模型可以在固定 benchmark 上很强，却仍可能在新任务微调后忘掉旧任务。真正的 life-long learning 需要在数据、优化、模型结构和记忆机制之间取得平衡。

后续方法的方向

常见 continual learning 方法大致包括 replay-based methods（保存或生成旧任务样本）、regularization-based methods（保护旧任务重要参数）、parameter-isolation methods（为不同任务分配不同参数子空间）与 dynamic architecture methods（随任务扩展或路由模型）。P53 先建立问题与评测，后续课程通常会再讨论解决策略。

6.1 本章小结

Life-long learning 要求模型在任务流中持续积累能力。Catastrophic forgetting 暴露出普通顺序训练的短板；multi-task training 和每任务一个模型又不够现实。评价时不能只看最终准确率，而要同时看遗忘和迁移。