

元学习（三）：各种非常规用法

Self-supervised、Knowledge Distillation、Domain
Generalization 与 Lifelong Learning



基于李宏毅老师《机器学习 2025》课程内容整理
2026 年 6 月 9 日

视频信息

频道：李宏毅深度学习课堂 (Bilibili)

时长：约 31 分 12 秒

链接：<https://www.bilibili.com/video/BV1TAtwzTE1S?p=57>

目录

1 四条关系：元学习作为上层训练设计	3
1.1 本章小结	3
2 Meta Learning 与 Self-supervised Learning	4
2.1 本章小结	6
3 Meta Learning 与 Knowledge Distillation	6
3.1 本章小结	10
4 Meta Learning 与 Domain Generalization	10
4.1 本章小结	13
5 Problem of Another Level: 元学习本身也会遇到域偏移	13
5.1 本章小结	14
6 Meta Learning 与 Lifelong Learning	14
6.1 本章小结	17
7 总结与延伸	17
7.1 本章小结	18

1 四条关系：元学习作为上层训练设计

P55 和 P56 已经说明，元学习的核心是从许多任务中学习“如何学习”。P57 不再只介绍某个元学习算法，而是展示元学习如何嵌入其他机器学习范式：self-supervised learning、domain generalization、knowledge distillation 和 lifelong learning。




图 1: 本讲的四条关系：Meta Learning vs. Self-supervised Learning、Meta Learning vs. Domain Generalization、Meta Learning vs. Knowledge Distillation、Meta Learning vs. Life-long Learning。¹

这些关系看起来分散，其实有一个共同模板：某个领域原本有一个人工设计或单层训练流程，元学习把它提升到 task-level 优化。

- 在 self-supervised learning 中，元学习可以帮助自监督预训练结果更贴近下游任务。
- 在 knowledge distillation 中，元学习可以让 teacher 学会“怎样教”。
- 在 domain generalization 中，元学习可以用多个源域模拟未知目标域。
- 在 lifelong learning 中，元学习可以学习抗遗忘的学习规则。

统一视角

元学习不是和这些范式竞争，而是可以作为上层机制改造它们：把“预训练目标、教师行为、域泛化策略、抗遗忘规则”视为可学习对象，用跨任务反馈来优化。

1.1 本章小结

P57 的重点是“元学习作为训练设计语言”。它把不同领域中的手工选择或单层目标，改写成跨任务、跨域或跨阶段的优化问题。

¹视频画面时间区间：00:00:45–00:01:00。

2 Meta Learning 与 Self-supervised Learning

Self-supervised learning 的典型代表是 BERT 及其后续模型。它通过大量未标注数据上的代理目标学习表示，例如 masked language modeling。MAML 一类方法则学习初始化参数，希望模型在少量下游任务样本上快速适应。两者都可能产生好初始化，但优化目标不同。




图 2: Self-supervised learning 与 learning to initialize 都能提供初始化: BERT 通过自监督代理目标学习表示, MAML family 通过任务级训练学习适合快速适应的初始化。²

课程指出, BERT 与 MAML 可以结合: 先用 self-supervised learning 得到 BERT 初始化, 再用 MAML 或 Reptile 进一步把初始化调整到更适合下游任务的区域。这样做的直觉是, BERT 善于利用大量未标注数据, 而 MAML 善于把初始化目标对齐到具体 task distribution。

Self-supervised learning 的限制在于: 代理目标和下游任务目标不一定一致。BERT 的 masked LM 目标并不等于情感分类、语义解析、意图识别或问答任务目标, 中间存在 learning gap。MAML 的优势是直接以 training tasks 的表现为目标, 但它需要准备许多带标注的 training tasks, 成本也更高。

²视频画面时间区间: 00:02:15-00:02:30。

Meta Learning vs. Self-supervised Learning




- Learn to achieve good performance on training tasks.
- Leverage training tasks.
- The self-supervised objectives are different from downstream tasks.
There is a “learning gap”.

图 3: BERT 与 MAML 的互补: BERT 的自监督目标与下游任务不同, 存在 learning gap; MAML 直接面向 training tasks 的表现, 但需要标注任务且计算量较大。³

在 TOPv2 语义解析实验中, 课程展示了用 BERT 作为初始化, 再用 Reptile 更新, 能够在低样本设定下带来更好的结果。这个结果说明: self-supervised learning 给出强表示, meta-learning 再把表示朝少样本任务适应方向推一段。

³视频画面时间区间: 00:07:15–00:07:30。

Meta Learning vs. Self-supervised Learning



Xilun Chen, Asish Ghoshal, Yashar Mehdad, Luke Zettlemoyer, Sonal Gupta, Low-Resource Domain Adaptation for Compositional Task-Oriented Semantic Parsing, EMNLP, 2020

图 4: BERT-Reptile 在 TOPv2 低样本语义解析中的结果: BERT 可作为 Reptile/MAML 类方法的初始化, 经过任务级更新后, 在样本较少时尤其可能更有优势。⁴

Self-supervised 与 meta-learning 的代价不同

Self-supervised learning 的优势是可利用大量未标注数据; meta-learning 的优势是任务目标对齐, 但通常需要标注的 training tasks。实际使用时常把两者组合, 而不是二选一。

2.1 本章小结

Self-supervised learning 提供强大的通用表示, meta-learning 提供面向 task distribution 的快速适应目标。二者可以串联: 先用未标注数据学表示, 再用任务级训练缩小代理目标与下游目标之间的 learning gap。

3 Meta Learning 与 Knowledge Distillation

Knowledge distillation 的基本形式是: 用大 teacher model 产生 soft label 或概率分布, 让小 student model 模仿。传统设定里, teacher 是为了分类准确率训练出来的; 它是否擅长 teaching, 并没有被直接优化。

⁴视频画面时间区间: 00:08:45-00:09:00。

Knowledge Distillation

Table 1. Knowledge distillation is not compatible with strong augmentation. (Das et al., 2020; Cui & Yan, 2021)

Augmentation	Teacher acc.	Student acc.
Normal	73.3	70.4
LabelSmooth (Szegedy et al., 2016)	73.3	68.1
Mixup (Zhang et al., 2017)	74.3	67.9
CutMix (Yun et al., 2019)	76.0	68.8

Table 2. Knowledge distillation suffers from teacher-student gap. (Mirzadeh et al., 2020; Cho & Hariharan, 2019)

Teacher	Teacher acc.	Student (ResNet20) acc.
ResNet32 (He et al., 2016)	71.0	70.8
ResNet56 (He et al., 2016)	73.3	70.4
ResNet110 (He et al., 2016)	75.4	70.5
ResNet164 (He et al., 2016)	75.8	69.9

图 5: 传统 knowledge distillation: 大 teacher model 输出软标签, 小 student model 通过交叉熵等目标模仿 teacher; 但 teacher 训练时通常没有被优化为“好老师”。⁵

这带来一个有趣现象: 分类准确率最高的 teacher 不一定教出最好的 student。课程引用表格说明, 当 teacher 与 student 差距过大时, distillation 可能受 teacher-student gap 影响; 有时较弱 teacher 反而更适合小 student 学习。

⁵视频画面时间区间: 00:11:45–00:12:00。

Knowledge Distillation

Table 1. Knowledge distillation is not compatible with strong augmentation. (Das et al., 2020; Cui & Yan, 2021)

Augmentation	Teacher acc.	Student acc.
Normal	73.3	70.4
LabelSmooth (Szegedy et al., 2016)	73.3	68.1
Mixup (Zhang et al., 2017)	74.3	67.9
CutMix (Yun et al., 2019)	76.0	68.8

Table 2. Knowledge distillation suffers from teacher-student gap. (Mirzadeh et al., 2020; Cho & Hariharan, 2019)


Teacher	Teacher acc.	Student (ResNet20) acc.
ResNet32 (He et al., 2016)	71.0	70.8
ResNet56 (He et al., 2016)	73.3	70.4
ResNet110 (He et al., 2016)	75.4	70.5
ResNet164 (He et al., 2016)	75.8	69.9

图 6: Knowledge distillation 中的 teacher-student gap: 更强的 teacher 不一定产生更强 student, 说明 teacher 的目标不应只看自身分类准确率, 还应看其教学效果。⁶

Meta-learning 可以把“教学效果”写进 teacher 的训练目标。Learn to Teach 的思想是: teacher 的好坏不只由 teacher 自己的 accuracy 决定, 而由 student 学完之后的 testing loss 决定。换句话说, teacher 要为学生的最终表现负责。

⁶ 视频画面时间区间: 00:12:45–00:13:00。

Learn to Teach



Wangchunshu Zhou, Canwen Xu, Julian McAuley, BERT Learns to Teach:
Knowledge Distillation with Meta Learning, ACL, 2022
Jihao Liu, Boxiao Liu, Hongsheng Li, Yu Liu, Meta Knowledge Distillation, arXiv, 2022

图 7: Learn to Teach: 用元学习思想训练 teacher, 让 teacher 的目标从自身分类表现转向 student 经 distillation 后的测试表现。⁷

抽象地写, teacher 参数为 ϕ , student 参数为 θ 。Student 先通过 distillation 从 teacher 学:


$$\theta'(\phi) = \text{TrainStudent}(\theta, \text{soft labels from teacher}_{\phi}).$$

外层目标再看 student 的验证或测试损失:

$$L_{\text{teach}}(\phi) = L_{\text{student}}(\theta'(\phi)).$$

于是 teacher 更新的方向, 不是“我自己预测更准”, 而是“我这样教, 学生之后表现更好”。

⁷ 视频画面时间区间: 00:13:30–00:13:45。



Wangchunshu Zhou, Canwen Xu, Julian McAuley, BERT Learns to Teach: Knowledge Distillation with Meta Learning, ACL, 2022
 Jihao Liu, Boxiao Liu, Hongsheng Li, Yu Liu, Meta Knowledge Distillation, arXiv, 2022

图 8: Learn to Teach 的外层目标: teacher 根据 student 学习后的 testing loss 被更新; temperature、soft label 形状或 teacher 输出都可能成为可学习教学策略。⁸

蒸馏中的 Meta 视角

传统蒸馏把 teacher 当成固定来源; meta distillation 把 teacher 看成可优化教学者。核心差异是评价指标从 teacher accuracy 转为 student-after-learning performance。

3.1 本章小结

Knowledge distillation 中, 元学习可以让 teacher 学会 teaching。它把 distillation 从“学生模仿老师”改成“老师根据学生学成后的表现调整教学方式”。这正是元学习常见的二层结构。

4 Meta Learning 与 Domain Generalization

Domain adaptation 与 domain generalization 都关心域迁移。区别在于: domain adaptation 往往允许接触目标域资料, 哪怕是少量未标注或少量标注; domain generalization 更困难, 训练时完全不知道目标域资料, 只能依靠多个源域训练出能泛化到未知域的模型。

⁸视频画面时间区间: 00:15:45-00:16:00。

Meta Learning for Domain Generalization




图 9: Domain adaptation/generalization 的资料条件: 目标域知识越少, 问题越困难; domain generalization 的关键是训练时没有 target domain data。⁹

如果目标域已知, 就可以直接把目标域表现作为 meta-objective。但 domain generalization 的目标域在训练时不可见, 因此要用源域模拟“未来未知域”。元学习的方法是: 从多个 training domains 中拿一些域作为 pseudo source, 另一些域作为 pseudo target, 训练学习算法在 pseudo target 上表现好。

⁹视频画面时间区间: 00:17:15–00:17:30。

Meta Learning for Domain Generalization




图 10: Meta learning for domain generalization: 多个 training domains 可用, 真实 target domain 训练时未知; 问题是如何训练 learning algorithm, 使模型能泛化到未知域。¹⁰

Meta Learning for Domain Generalization




图 11: 用源域构造 pseudo target domain: 例如用红色和黄色域训练模型, 再用蓝色域模拟目标域评价, 从而学习适合跨域泛化的初始化或学习规则。¹¹

¹⁰ 视频画面时间区间: 00:18:30–00:18:45。

这个思路与 few-shot meta-learning 类似：真实目标不能碰，于是训练时不断构造模拟任务。差别是任务单位从“类别/episode”变成“domain split”。Outer objective 不再只是新类别识别，而是源域训练后能否泛化到留出的伪目标域。

课程给出文本分类例子：训练任务来自若干语言或域，测试任务可能来自另一种语言。Meta-learning 通过跨域 episodic training，期望学到一个在未见域上仍能工作的模型或学习算法。

Problem of another level

- The training examples and testing examples may have different distributions.



Training Examples



Testing Examples

Huaxiu Yao, Longkai Huang, Linjun Zhang, Ying Wei, Li Tian, James Zou, Junzhou Huang, Zhenhui Li, Improving generalization in meta-learning via task augmentation, ICML, 2021

图 12: 文本分类中的 domain generalization 示例：用多语言/多域任务构造 meta-training，期望模型能泛化到训练阶段未见过的语言或域。¹²

4.1 本章小结

Domain generalization 中没有真实 target domain data，因此元学习用 training domains 构造 pseudo target domain，模拟未来未知域。它把“跨域泛化”写成 task/domain-level 的外层目标。

5 Problem of Another Level: 元学习本身也会遇到域偏移

课程特别强调一个更高层问题：如果 training tasks 与 testing tasks 本身来自不同分布，元学习也会失效。也就是说，meta-learning 解决的是某个 task distribution 内的快速适应；如果未来 task distribution 变了，learned learning algorithm 也可能过拟合旧分布。

¹¹ 视频画面时间区间：00:19:45–00:20:00。

¹² 视频画面时间区间：00:22:15–00:22:30。

Meta Learning vs. Life-long Learning



图 13: Problem of another level: training examples 与 testing examples 可以有不同分布, training tasks 与 testing tasks 也可能有不同分布; 元学习本身也需要面对更高层的 domain shift。¹³

这解释了为什么元学习和 domain adaptation/generalization 可以互相嵌套。Meta-learning 可以帮助 domain generalization, 但 meta-learning 自己也可能需要 domain adaptation: 如果训练任务和测试任务分布不同, 就要考虑 task augmentation、task-level domain adaptation 或更稳健的 meta-objective。

元学习不是免疫泛化问题

元学习把泛化目标从样本层级提升到任务层级, 但这不代表泛化问题消失。样本会有 distribution shift, task 也会有 distribution shift。只是在元学习中, 问题换到了更高层。

5.1 本章小结

“Problem of another level” 是本讲的关键提醒: 元学习可以处理普通模型的泛化问题, 但它自己也有 meta-level 泛化问题。训练任务分布和测试任务分布若不一致, learned learning algorithm 仍可能失败。

6 Meta Learning 与 Lifelong Learning

Lifelong learning 关注模型按顺序学习多个数据集或任务时的 catastrophic forgetting。前面 P53、P54 讨论过三类缓解方法: selective synaptic plasticity、additional neural resource allocation、memory replay。P57 的问题是: meta-learning 能否增强这些抗遗忘方法?

¹³视频画面时间区间: 00:23:45–00:24:00。

Regularization-based

Additional Neural Resource Allocation


Memory Replay

- There are already lots of research along each direction.

图 14: Lifelong learning 中缓解遗忘的三类方向: selective synaptic plasticity、additional neural resource allocation、memory replay; 本讲关注元学习是否能增强这些方法。¹⁴

以 regularization-based 方法为例，传统做法会人为设计某种重要性估计或正则项，限制新任务更新时破坏旧任务。元学习可以把“如何正则化、如何更新、如何选择保护强度”变成可学习对象。

¹⁴视频画面时间区间：00:25:00–00:25:15。



Nicola De Cao, Wilker Aziz, Ivan Titov, Editing Factual Knowledge in Language Models, EMNLP, 2021
 Anton Sinitsin, Vsevolod Plokhhotnyuk, Dmitriy Pyrkin, Sergei Popov, Artem Babenko, Editable Neural Networks, ICLR, 2020

图 15: Regularization-based + Meta: 用元学习寻找能避免 catastrophic forgetting 的学习算法, 使模型既能从新资料学习, 又能记住旧资料。¹⁵

这里的目標不只是当前任务准确率高, 而是一个序列目标: 模型学完 dataset 1, 再学 dataset 2 后, 仍要保留 dataset 1 的能力。外层 meta-objective 可以在许多任务序列上评价 “学完后是否遗忘”, 再更新学习算法。

抽象地写, 给定一个任务序列 $(\mathcal{T}_1, \mathcal{T}_2, \dots, \mathcal{T}_T)$, 学习算法 F_ϕ 依序更新模型:

$$\theta_t = F_\phi(\theta_{t-1}, \mathcal{T}_t).$$

外层目标可以评价最终模型在所有旧任务和新任务上的表现:

$$L_{\text{CL}}(\phi) = \sum_{t=1}^T L_{\mathcal{T}_t}(\theta_t).$$

若 F_ϕ 学得好, 它会在新任务可塑性和旧任务稳定性之间找到更好的更新规则。

但课程也提醒: 元学习可以帮助 lifelong learning, 元学习本身也可能遇到 lifelong learning 问题。若 meta-learning 依序看到不同任务分布, 它也可能只适应后来的任务分布, 忘掉早先任务分布。

¹⁵ 视频画面时间区间: 00:26:45–00:27:00。

Problem of Another Level

Chelsea Finn, Aravind Rajeswaran, Sham Kakade, Sergey Levine, Online Meta-Learning, ICML, 2019
Pauching Yap, Hippolyt Ritter, David Barber, Addressing Catastrophic Forgetting in Few-Shot Problems, ICML, 2021

图 16: 元学习可以帮助解决 lifelong learning, 但元学习本身也可能面临 catastrophic forgetting: 如果 meta-training tasks 按序到来, learned learning algorithm 也可能忘记旧任务分布。¹⁶

递归关系

Lifelong learning 需要学习抗遗忘规则; 元学习可以学习这样的规则。但如果元学习过程本身也按顺序接收任务, 就需要 continual meta-learning。问题并没有消失, 而是上移了一层。

6.1 本章小结

在 lifelong learning 中, 元学习可以学习更好的正则、更新或记忆策略, 以降低 catastrophic forgetting。但元学习本身也会在 task distribution 变化时遗忘, 因此需要更高层的 continual/meta-continual 设计。

7 总结与延伸

P57 展示了元学习的“跨范式嵌入”能力。它不是只服务于 few-shot image classification, 而是可以被放进许多学习流程中, 作为优化“如何学习”的上层机制。

¹⁶ 视频画面时间区间: 00:28:00–00:28:15。

结合对象	原本问题	Meta 化后的问题
Self-supervised	代理目标与下游任务有 gap	用任务级训练调整自监督初始化
Knowledge Distillation	teacher 准确率高但不一定会教	让 teacher 为 student 学成后的表现负责
Domain Generalization	真实目标域训练时未知	用源域构造 pseudo target domain 训练泛化规则
Lifelong Learning	新任务会破坏旧任务能力	学习能兼顾新任务与旧任务的更新规则

这四个例子共同说明：元学习的抽象不是“快速分类”本身，而是二层目标设计。内层完成普通学习、蒸馏、跨域训练或连续学习；外层则评价“这个学习过程是否产生了我们想要的结果”，并据此更新学习规则。

最大的误区

看到“meta”不要自动认为问题被彻底解决。元学习只是把学习目标提升到任务层级；若任务分布、域分布或时间序列本身发生偏移，元学习仍然需要泛化、适应和抗遗忘机制。

后续阅读这些方向时，可以用三个问题快速定位论文贡献：

1. 它把哪个已有学习流程 Meta 化了？
2. 外层目标评价的是谁的最终表现：downstream task、student、target domain，还是旧任务集合？
3. 它是否讨论了 meta-level 的泛化问题，例如 training tasks 与 testing tasks 分布不一致？

7.1 本章小结

P57 的核心是递归视角：元学习可以帮助 self-supervised learning、knowledge distillation、domain generalization 和 lifelong learning，但它自己也会遇到同类问题的高层版本。真正重要的是识别内层学习过程、外层评价信号，以及任务分布是否可靠。